

Documentation de l'outil

Calibrage des paramètres propres à l'entreprise
Moteur de calcul, tests statistiques et application

Règlement délégué (UE) 2015/35, annexe XVII — profondeur d'intérêt $T = 8$

Objet du document

Ce document constitue la documentation de l'**outil de calibrage des paramètres propres à l'entreprise** (USP) au titre des méthodes « risque de prime » et « risque de réserve 1 » de l'annexe XVII du règlement délégué (UE) 2015/35. Il couvre le moteur de calcul `R/engine.R`, les tests statistiques qu'il met en œuvre, et l'application interactive qui l'exploite.

Il est organisé en quatre parties. La **partie I** décrit l'architecture de l'outil, les notations et les contrôles de recevabilité des données. La **partie II** pose le cadre statistique commun : nature des p-values (exactes, asymptotiques, de Monte-Carlo) et séparation de l'erreur numérique liée au nombre B de réplifications d'avec l'erreur d'approximation liée à la taille T de l'échantillon. La **partie III** rassemble les fiches de tests, groupées par hypothèse réglementaire H1 à H4, chacune suivant une structure uniforme en six rubriques : cadre et hypothèses de validité (non testées), hypothèse nulle, statistique de test, loi sous l'hypothèse nulle, p-value, usage et limites. La **partie IV** rassemble la validation empirique de l'implémentation, les références bibliographiques et la synthèse de lecture.

Une attention particulière est portée à la profondeur d'intérêt du projet, $T = 8$, à laquelle plusieurs des tests présentés sont structurellement incapables de rejeter au seuil usuel de 5 %. Le sommaire détaille les sous-sections afin de permettre l'accès direct à chaque test.

Article 218 du règlement délégué (UE) 2015/35

Les entreprises d'assurance et de réassurance peuvent remplacer un sous-ensemble des paramètres standard du module « souscription non-vie », du module « souscription santé » et du module « souscription vie » par des paramètres propres à l'entreprise.

Élément	Référence
Base réglementaire	Directive 2009/138/CE, art. 104(7); règlement délégué (UE) 2015/35, art. 218 à 220 et annexe XVII
Procédure d'agrément	Règlement d'exécution (UE) 2015/498
Transposition	Code des assurances, art. R. 352-5 (V) et R. 356-19 (II)
Moteur de calcul	<code>R/engine.R</code> (R base et stats uniquement)
Interface	<code>app.R</code> , <code>R/display_helpers.R</code> (aucun calcul)
Profondeur d'intérêt	$T = 8$ années de survenance

Sommaire

PARTIE I — Présentation de l'outil	7
1 Architecture du moteur de calcul	7
1.1 Principe de séparation	7
1.2 Chaîne de calcul et flux de données	8
1.3 Inventaire des fonctions	10
1.4 Périmètres couverts et paramètres standard	13
1.5 Reproductibilité et gestion des graines	14
1.6 Index des fonctions de statistique et de p-value	20
2 Notations générales	26
3 Contrôles de qualité des données	29
PARTIE II — Cadre statistique général	33
4 Bootstrap paramétrique et p-values de Monte-Carlo	33
4.1 Procédure générale de p-value de Monte-Carlo	33
4.2 Bootstrap semi-paramétrique de la méthode Merz–Wüthrich	34
5 Nature des p-values et validité à $T = 8$	35
5.1 Quatre statuts épistémiques à ne jamais confondre	35
5.2 Deux sources d'erreur distinctes	36
5.3 Ce que l'on peut et ne peut pas affirmer à $T = 8$	37
5.4 Tableau 1 : disponibilité et choix des p-values	38
5.5 Tableau 2 : nature et vitesse des convergences	45
5.6 Choix de la base de résidus	50
5.7 Variantes principales et secondaires	54
5.8 Tests dont l'usage reste fragile à $T = 8$	54
PARTIE III — Fiches de tests par hypothèse	56
6 Hypothèse H1 — linéarité et proportionnalité	56
6.1 Test de Student sur la constante	56
6.2 Équivalence de la constante à zéro (TOST)	57
6.3 Test de Student sur la pente	58
6.4 Test de Fisher de significativité globale	58
6.5 Coefficient de détermination R^2	59
6.6 Test RESET de Ramsey	59
6.7 Corrélation de rang de Spearman (ratio contre volume, ratio contre temps)	60
6.8 Test de tendance de Mann–Kendall	61
6.9 Test de tendance par signes de Cox–Stuart	61

7	Hypothèse H2 — structure de variance quadratique	63
7.1	Test de Breusch–Pagan, version studentisée de Koenker	63
7.2	Test de Breusch–Pagan, version originale de 1979	63
7.3	Test de White	64
7.4	Test de Goldfeld–Quandt	65
7.5	Test de Brown–Forsythe	65
7.6	Test de Smirnov à deux échantillons	66
7.7	Position de $\hat{\delta}$ dans son domaine (diagnostic)	66
8	Hypothèse H3 — lognormalité des pertes agrégées	68
8.1	Test de Shapiro–Wilk	68
8.2	Test de Shapiro–Francia	69
8.3	Test d’Anderson–Darling	69
8.4	Test de Cramér–von Mises	70
8.5	Test de Kolmogorov–Smirnov contre $\mathcal{N}(0, 1)$	70
8.6	Test de Lilliefors	71
8.7	Shapiro–Wilk sans la normalisation de Royston	72
8.8	Test de Jarque–Bera	72
8.9	Test d’asymétrie de D’Agostino	73
8.10	Test d’aplatissement d’Anscombe–Glynn	73
9	Hypothèse H4 — indépendance et validité du maximum de vraisemblance	75
9.1	Test de Durbin–Watson	75
9.2	Tests portemanteau de Ljung–Box et de Box–Pierce	76
9.3	Test des suites de Wald–Wolfowitz	76
9.4	Condition du premier ordre (gradient projeté, KKT)	78
9.5	Centrage des résidus standardisés (diagnostic)	82
9.6	Variance unitaire des résidus standardisés (diagnostic)	84
9.7	Durbin–Watson sur ratios bruts	86
9.8	Ljung–Box au retard 1 sur ratios bruts	87
9.9	Test des suites sur ratios bruts	87
10	Diagnostics de stabilité, ruptures et points aberrants	89
10.1	Test de rupture sup-F (Quandt / Chow / Andrews)	89
10.2	Test de stabilité OLS-CUSUM	89
10.3	Test de Grubbs	90
10.4	Procédure ESD généralisée de Rosner	91
10.5	Distance de Cook (diagnostic)	91
10.6	Leviers (<i>hat values</i> , diagnostic)	92
10.7	Rupture sup-F sur ratios bruts	92
10.8	Stabilité OLS-CUSUM sur ratios bruts	93
10.9	Grubbs sur ratios bruts	93
11	Diagnostics de robustesse de l’estimation	95
11.1	Test du rapport de vraisemblance sur les cas limites de δ	95
11.2	Jackknife (sensibilité au retrait d’une année)	95
11.3	Intervalle de confiance par bootstrap paramétrique	97
11.4	Convergence multi-démarrages	98

12	Diagnostics graphiques complémentaires	100
12.1	Couverture exhaustive	100
12.2	Fiches détaillées	102
12.3	QQ-plot normal	102
12.4	QQ-plot à deux échantillons (faible volume contre fort volume)	103
12.5	Graphiques d'influence et de levier	103
12.6	Graphique dispersion-niveau (<i>spread-location</i>)	104
12.7	Visualisation de la régression chain-ladder (Merz–Wüthrich)	105
12.8	Influence et leviers du triangle (Merz–Wüthrich)	105
13	Méthode Merz–Wüthrich — cadre et spécification	107
13.1	Positionnement par rapport à la méthode lognormale	107
13.2	Spécification réglementaire	107
13.3	Hypothèses testables et résidus	111
13.4	Réemploi et adaptation des tests	112
14	Hypothèse M1 — proportionnalité des cumulés	114
14.1	M1 — Absence de tendance des facteurs avec le cumulé, à colonne donnée	114
14.2	M1 — Nullité de l'ordonnée à l'origine, colonne par colonne	115
14.3	M1 — Homogénéité de f_j entre années de survénance	115
14.4	M1 — Absence de courbure de la régression	116
14.5	M1 — Stabilité du facteur selon la pondération (famille α)	116
15	Hypothèse M2 — variance proportionnelle au cumulé	118
15.1	M2 — Hétéroscédasticité résiduelle contre le cumulé	118
15.2	M2 — Adéquation de l'exposant de variance, colonne par colonne	118
15.3	M2 — Variance unitaire des résidus de Mack (diagnostic)	119
16	Hypothèse M3 — indépendance	121
16.1	M3 — Effets d'année calendaire (test de Mack)	121
16.2	M3 — Homogénéité des résidus entre années de survénance	121
16.3	M3 — Corrélation entre années de développement adjacentes	122
16.4	M3 — Autocorrélation des résidus de Mack (Durbin–Watson)	122
16.5	M3 — Test des suites sur les résidus de Mack	123
17	Diagnostics M4 — points aberrants du triangle	124
17.1	M4 — Cellule aberrante du triangle (Grubbs)	124
17.2	M4 — Cellules aberrantes multiples (ESD généralisé de Rosner)	124
18	Diagnostics M5 — normalité des résidus de Mack	126
18.1	M5 — Shapiro–Wilk sur les résidus de Mack	126
18.2	M5 — Lilliefors sur les résidus de Mack	126
19	Diagnostics M6 — robustesse de l'estimation	128
19.1	M6 — Extrapolation de $\hat{\sigma}_{j-1}^2$ (diagnostic)	128
19.2	M6 — Concentration de la réserve sur la dernière année	129
	PARTIE IV — Validation, références et synthèse	130

20	Vérification empirique de l'implémentation	130
20.1	Vérification de l'implémentation Merz–Wüthrich	132
20.2	Calibration des p-values asymptotiques (Merz–Wüthrich)	132
20.3	Calibration des p-values de Monte-Carlo (Merz–Wüthrich)	133
21	Compléments bibliographiques	134
21.1	Traçabilité entre la documentation et le code	136
22	Synthèse et lecture des verdicts	140
	ANNEXE — Flux détaillés entre fonctions	142
23	Annexe — flux détaillés entre fonctions	143
23.1	Convention graphique	143
23.2	Graphe chapeau : les deux branches et leurs points de partage	145
23.3	Méthode lognormale : hypothèse H1	146
23.4	Méthode lognormale : hypothèse H2	146
23.5	Méthode lognormale : hypothèses H3 et H4, stabilité	146
23.6	Méthode Merz–Wüthrich : de l'ajustement aux tests M1 à M6	149
23.7	Lecture en termes de revue de code	151

PARTIE I

Présentation de l'outil

Architecture du moteur de calcul

1.1 Principe de séparation

Le projet applique une séparation stricte entre le *moteur quantitatif* et la *couche d'affichage*. La règle appliquée est la suivante : si un résultat peut être calculé indépendamment de l'interface graphique, son calcul figure dans `R/engine.R`.

Fichier	Contenu	Interdit
<code>R/engine.R</code>	Préparation des données, contrôles, estimation, tests, p-values, bootstrap, jackknife, calibration, quantités des graphiques	Toute primitive Shiny (<code>input\$</code> , <code>output\$</code> , <code>reactive()</code> , <code>render*()</code>)
<code>app.R</code>	Saisie, déclenchement, stockage réactif, agencement des onglets	Tout calcul statistique ou actuariel
<code>R/display_helpers.R</code>	Formatage des nombres et des tableaux, tracés à partir de <code>res\$plots_data</code> , rapport HTML figé d'un résultat (<code>rapport_html()</code>) et identité du code qu'il restitue (<code>identite_code()</code>)	Tout calcul de statistique, de p-value ou de paramètre

Cette séparation a été vérifiée automatiquement : aucune primitive Shiny n'est présente dans le moteur, et aucun appel de fonction de calcul (`optim`, `lm`, `*.test`, `rnorm`, `quantile`, `sd`, `var`, `mean`) ne subsiste dans la couche d'affichage. Le moteur s'exécute seul :

```
source("R/engine.R")
res <- run_engine(xt = ..., yt = ..., methode = "premium", segment = 1,
                  T = 8, B = 999, seed = 20260831)
res$parametre_final$sigma_usp ; engine_table_tests(res)
```

Le *rapport figé*, produit par `rapport_html()`, est un fichier HTML unique, sans ressource externe, qui fige l'objet renvoyé par `run_engine()` tel qu'il est en mémoire, et jamais la saisie en cours ; il ne relance aucun calcul et refuse un résultat que le moteur a rejeté (`docs/exigences.md`, § 5.6 ; ADR 0009). Son en-tête porte trois empreintes md5 : celle des données du calcul et celle de l'objet résultat, calculées par `engine_empreinte()` (la seconde est stable sur une même machine et dépend de la plateforme, ADR 0006), et celle des octets de `R/engine.R`, relevée avec la version déclarée dans `DESCRIPTION` par

`identite_code()` au chargement du moteur par l'application. Les tests restitués sont les *tests retenus* selon la règle de l'onglet Tests, appliquée par la même fonction (`filtrer_selection()`), les tests exclus figurant en annexe avec leur verdict, leur p-value retenue et le motif de leur exclusion ; le tableau de robustesse du calibrage reprend, comme l'onglet Calibration, tous les diagnostics de robustesse, indépendamment de cette sélection.

1.2 Chaîne de calcul et flux de données

La figure 1 donne l'enchaînement des fonctions du moteur. Les blocs sont les fonctions, les flèches portent les objets transmis. Les blocs bleus sont les entrées, les blancs les étapes de calcul, les verts les sorties exposées à l'application. Le point d'aiguillage est le paramètre `methode` : il oriente vers l'une des deux chaînes, dont les géométries de données et les jeux de tests diffèrent. L'annexe 23 en donne le détail fonction par fonction.



FIGURE 1 : Architecture du moteur R/engine.R. Le paramètre *methode* aiguille vers l’une des deux chaînes : à gauche les méthodes lognormales (sections B et C de l’annexe XVII), à droite la méthode Merz–Wüthrich (section D). Les deux convergent vers un objet de sortie unique, que la couche d’affichage se contente de lire. `usp_credibilite()` est la seule fonction de calibration commune aux deux branches.

1.3 Inventaire des fonctions

Fonction	Entrées	Sorties
<i>Contrôles et données</i>		
engine_valider_donnees()	xt, yt, T_min	\$ok, \$erreurs, \$avertissements
usp_controle_donnees()	x, y , alpha (0,10)	liste de contrôles de recevabilité
usp_controles_numeriques()	fit (sortie de usp_ajuster())	deux contrôles numériques de l'estimation (famille H, OK / ECHEC, non bloquants), ajoutés à res\$controles
mw_valider_triangle()	tri, T_min	\$ok, \$erreurs, \$avertissements, I, J
mw_valider_ajustement()	aj (sortie de mw_ajuster()), msep (champ \$msep de mw_msep())	\$ok, \$erreurs, \$avertissements, \$reserve, \$msep
usp_lire_vecteur(), usp_charger()	chemins de fichiers CSV, sep, dec; pour la seconde, T et le sens chronologique des données	vecteur lu; liste $\$x, \$y, \$T$ (les T années les plus récentes)
engine_lire_donnees_csv()	data.frame (colonnes t, xt, yt)	\$ok, \$erreurs, \$xt, \$yt, \$n
engine_lire_xlsx(), engine_ecrire_xlsx()	chemin, entete; df, chemin, feuille	data.frame lu; chemin du fichier écrit (§1.5 pour la voie de repli)
<i>Noyau du modèle</i>		
usp_pi()	$\delta, \gamma, x, \text{xbar}$ (moyenne de x)	vecteur π_t
usp_noyau()	$\delta, \gamma, x, y, \text{xbar}$	$\pi_t, \ln \hat{\beta}, \hat{\beta}, v_t, z_t, \sigma$, objectif
usp_objectif()	par = $(\delta, \gamma), x, y, \text{xbar}$	$-2 \ln L$ (à une constante près)
usp_ajuster()	x, y , n_starts_delta (9), verbose, controle (paramètres d'optim(), par défaut factr = 1e5, maxit = 500)	fit complet, gradient projeté, pas de Newton en γ , convergence multi-démarrages (démarrages à l'optimum à TOL_OPTIMUM = 10^{-6} près), décision de Kuhn et Tucker sur ces démarrages (\$kkt_au_moins_un, dernier champ)
usp_gradient()	$\delta, \gamma, x, y, \text{xbar}$	gradient analytique (g_δ, g_γ) de l'objectif profilé
usp_condition_premier_ordre()	$\delta, \gamma, x, y, \text{xbar}$, tol (TOL_DELTA_BORD), h (10^{-4})	\$gradient, \$gradient_projete, \$hessian_gamma, \$pas_newton_gamma
usp_kkt_satisfaite()	sortie de usp_condition_premier_ordre() et γ d'un démarrage, rep_pas (REP_PAS_KKT, 10^{-6}), rep_gd (REP_GD_KKT, 10^{-4})	booléen : condition de Kuhn et Tucker satisfaite en ce point (fiche 9.4)
usp_ajuster_rapide()	x, y , point de départ (δ_0, γ_0)	réajustement à un seul démarrage (factr = 1e7), employé par usp_bootstrap()
usp_regime()	δ, x , tol (constante TOL_DELTA_BORD, 10^{-6})	drapeaux \$delta_au_bord, \$volumes_constants, \$pi_constant, \$pi_constant_exact, \$delta_dans_bande, \$volumes_dans_bande (fiche 7.7, fiche 9.5)
<i>Lois exactes</i>		
mk_p_exacte()	série r_t	p-value exacte (loi mahonienne)

Fonction	Entrées	Sorties
<code>runs_p_exacte()</code>	résidus z_t ou ratios centrés u_t	p-value exacte (Swed & Eisenhart), bilatérale par doublement (fiche 9.3)
<code>usp_runsr_p_exacte()</code>	z_t , u_t , drapeau <code>pi_constant</code>	p-value exacte de <code>runs_p_exacte()</code> sur u_t si $\hat{\pi}_t$ est constant <i>et</i> si les signes de $u_t - \text{med}(u)$ et de $z_t - \text{med}(z)$ coïncident (<code>.signes_mediane_egaux()</code>), NA sinon
<code>sw_loi_nulle()</code>	<code>n</code> , <code>B_null</code> (20 000), <code>seed</code> (20260901)	loi nulle simulée de W (Shapiro–Wilk), triée et mise en cache
<i>Statistiques et tests</i>		
<code>stat_*</code> (<code>test_*</code>)	x, y ou z	statistique et p-value
<code>test_tost_intercept()</code>	x, y, θ ou Δ	p-value d'équivalence (TOST)
<code>.stats_bootstrapables()</code>	x, y, z	vecteur de 34 statistiques, évaluation du catalogue <code>USP_CATALOGUE_MC</code>
<code>USP_CATALOGUE_MC</code> , <code>MW_CATALOGUE_MC</code>	entrées construites par <code>.mc_entree(calc, queue, degenerate)</code>	catalogues des statistiques Monte-Carlo (34 et 13 entrées) : fonction de calcul, sens du rejet (haut, bas, deux) et condition de dégénérescence (NULL pour toutes les entrées, lue par aucun calcul); seule source du calcul observé, du calcul simulé et de la p-value de Monte-Carlo (ADR 0003)
<code>.usp_contexte_mc()</code> , <code>.mw_contexte_mc()</code>	x, y, z ; <code>aj</code>	contexte des fonctions de calcul du catalogue : ratios r_t et ratios centrés u_t ; résidus de Mack
<code>.mc_evaluer()</code>	catalogue, contexte	vecteur nommé dans l'ordre du catalogue; erreur qui nomme la statistique si une entrée ne rend pas une valeur de longueur 1
<code>engine_p_mc()</code>	valeurs simulées, valeur observée, sens du rejet	<code>p_mc</code> , <code>err_mc</code> (formule selon le sens, §5.2), <code>B_effectif</code> , <code>granularite</code> d'une statistique (fiche 4.1); fonction unique des deux méthodes
<code>.mc_p_values()</code>	matrice des simulations, valeurs observées, catalogue	<code>engine_p_mc()</code> colonne par colonne, sens lu au catalogue; erreur si une statistique simulée est absente du catalogue
<code>engine_registre_tests()</code>	<code>boot</code> , catalogue, <code>alpha</code> , libellé de nature Monte-Carlo	fonction <code>add()</code> d'enregistrement d'une ligne de test, unique et partagée par <code>usp_tests()</code> et <code>mw_tests()</code> : hiérarchie des p-values, règle de verdict, refus d'une clé Monte-Carlo absente du catalogue ou du bootstrap
<code>usp_simuler()</code> <code>usp_bootstrap()</code>	<code>fit</code> <code>fit</code> , <code>B</code> (999), <code>seed</code> (20260831), <code>refit</code> (vrai), <code>progres</code>	T pertes y_t simulées sous le modèle ajusté <code>stats_obs</code> , <code>p_mc</code> , <code>err_mc</code> , <code>B_effectif</code> , <code>granularite</code> , <code>sigma_boot</code> , <code>delta_boot</code> , <code>gamma_boot</code> , <code>B</code> , <code>granularite_stat</code>
<code>mw_bootstrap()</code>	<code>aj</code> , <code>B</code> (999), <code>seed</code> (20260831)	<code>stats_obs</code> , <code>p_mc</code> , <code>err_mc</code> , <code>B_effectif</code> , <code>granularite</code> , <code>sigma_boot</code> , <code>B</code> , <code>granularite_stat</code>

Fonction	Entrées	Sorties
usp_tests()	fit, boot, alpha (0,10), theta_equiv (0,10), delta_equiv, robustesse (NULL)	liste des tests (H0, H1, statistique, 3 p-values, nature), enregistrés par l'add() d'engine_registre_tests(); robustesse, calculé par run_engine() et non stocké, alimente le seul commentaire de la ligne jackknife (année d'écart maximal et sens de l'écart sur σ_{USP} ; fiche 11.2); celui de la ligne de l'intervalle bootstrap n'en dépend pas (fiche 11.3)
<i>Robustesse et calibration</i>		
usp_jackknife()	fit, σ_{std} , barème	table des $\hat{\sigma}^{(-t)}$, $\sigma_{\text{USP}}^{(-t)}$, $\hat{\delta}^{(-t)}$, $\hat{\gamma}^{(-t)}$
usp_profil()	fit, n (41 points)	profils en δ et γ , tests LR
usp_segment_infos(), usp_bareme_segment()	segment, annexe	libellé, σ standard, barème; barème seul
usp_credibilite()	T, barème	facteur c
usp_parametre()	fit, σ_{std} , barème	σ_{USP} et ses composantes
<i>Chaîne Merz-Wüthrich (section D, §13)</i>		
mw_ajuster()	tri	$I, J, \hat{f}_j, \hat{\sigma}_j^2, Q_j, S_j, S'_j, \hat{C}(i, j)$, réserve par année et totale
mw_extrapolation_sigma2()	aj, tol (10^{-12})	valeur de $\hat{\sigma}_{j-1}^2$, trois arguments du minimum et \$revenu (argument qui l'atteint, au sens littéral); critère de dégénérescence par colonne, \$degeneree_Jm3 (champs historiques \$colonne, \$nb_facteurs, \$ecart_relatif, \$f_colonne) et \$degeneree_Jm2 (\$nb_facteurs_Jm2, \$ecart_relatif_Jm2, \$f_colonne_Jm2), et leur union \$degeneree
mw_msep()	aj	\$msep, \$terme_variance, \$terme_covariance
mw_residus()	aj	data.frame des résidus de Mack $r(i, j)$
mw_simuler_triangle(), .mw_stats()	aj, vivier de résidus; aj	triangle simulé; vecteur de 13 statistiques
mw_test_*(mw_famille_alpha(mw_stat_correlation_dev(mw_tests()	aj	statistiques des tests M1 à M6 (détail : §1.6)
mw_tests()	aj, boot, alpha (0,10)	liste des tests M1 à M6 (même structure que usp_tests(), même fonction d'enregistrement engine_registre_tests())
mw_parametre()	aj, msep (champ \$msep), σ_{std} , barème	σ_{USP} et ses composantes
mw_influence()	aj	levier, facteur sans la cellule, écart relatif de $\hat{f}_j$, par cellule
mw_contributions()	aj, msep (sortie de mw_msep())	parts de chaque année de survenance dans la réserve et dans le terme de variance de processus
<i>Sorties</i>		
engine_plots_data()	fit, boot, profil, jackknife, sigma_esp	toutes les quantités tracées (branche lognormale)
engine_surface_objectif() engine_influence() engine_contours_cook()	fit; fit, jackknife, sigma_esp; T	surface de l'objectif en (δ, γ) ; leviers, distances de Cook; courbes d'iso-Cook (appelées par engine_plots_data())

Fonction	Entrées	Sorties
<code>mw_plots_data()</code>	aj, résidus, boot, msep	toutes les quantités tracées (branche Merz–Wüthrich)
<code>engine_table_tests()</code>	res	<code>data.frame</code> auditable
<code>run_engine()</code>	entrées utilisateur	objet <code>usp_engine</code> complet
<code>.run_engine_mw()</code>	entrées de <code>run_engine()</code> pour <code>methode = "reserve2"</code>	objet <code>usp_engine</code> de la branche Merz–Wüthrich

1.4 Périmètres couverts et paramètres standard

L'outil couvre les deux segmentations pour lesquelles l'annexe XVII autorise des paramètres propres au titre du risque de primes et de réserve : l'annexe II (engagements non-vie) et l'annexe XIV (engagements de santé non similaires à la vie, dits « non-SLT »). Les écarts-types standard ci-dessous sont ceux du règlement délégué (UE) 2015/35 dans sa *version consolidée du 14 novembre 2024*, qui fait foi pour l'outil. Les annexes II et XIV y portent le marqueur ▼ M6 : elles ont été remplacées par le règlement délégué (UE) 2019/981 de la Commission du 8 mars 2019, *Journal officiel de l'Union européenne*, L 161 du 18 juin 2019, p. 1. Ils sont codés dans les tables `ANNEXE_II` et `ANNEXE_XIV` de `R/engine.R`, qui ne conservent pas les valeurs antérieures. **Limite de périmètre** : l'outil ne vaut que pour un calcul dont la date de référence est postérieure ou égale à la date d'application du règlement délégué (UE) 2019/981, l'écart-type standard qui entre dans le mélange de l'annexe XVII étant celui en vigueur à la date de référence du calcul ; il ne permet pas de reproduire un calcul selon les valeurs de la version d'origine (*Journal officiel de l'Union européenne*, L 12 du 17 janvier 2015, p. 230 pour l'annexe II et p. 269 pour l'annexe XIV), citée ici pour l'historique seulement.

Seg.	Annexe II — non-vie	LoB	σ prime brut	σ réserve
1	Assurance de responsabilité civile automobile et réassurance proportionnelle y afférente	4 et 16	10 %	9 %
2	Autre assurance des véhicules à moteur et réassurance proportionnelle y afférente	5 et 17	8 %	8 %
3	Assurance maritime, aérienne et transport et réassurance proportionnelle y afférente	6 et 18	15 %	11 %
4	Assurance incendie et autres dommages aux biens et réassurance proportionnelle y afférente	7 et 19	8 %	10 %
5	Assurance de responsabilité civile générale et réassurance proportionnelle y afférente	8 et 20	14 %	11 %
6	Assurance crédit et cautionnement et réassurance proportionnelle y afférente	9 et 21	19 %	17,2 %
7	Assurance de protection juridique et réassurance proportionnelle y afférente	10 et 22	8,3 %	5,5 %
8	Assurance assistance et réassurance proportionnelle y afférente	11 et 23	6,4 %	22 %
9	Assurance pertes pécuniaires diverses et réassurance proportionnelle y afférente	12 et 24	13 %	20 %
10	Réassurance accidents non proportionnelle	26	17 %	20 %
11	Réassurance maritime, aérienne et transport non proportionnelle	27	17 %	20 %
12	Réassurance dommages non proportionnelle	28	17 %	20 %

Seg.	Annexe XIV — santé non-SLT	LoB	σ prime brut	σ réserve
1	Assurance frais médicaux et réassurance proportionnelle y afférente	1 et 13	5 %	5,7 %
2	Assurance de protection du revenu, y compris réassurance proportionnelle y afférente	2 et 14	8,5 %	14 %
3	Assurance indemnisation des travailleurs et réassurance proportionnelle y afférente	3 et 15	9,6 %	11 %
4	Réassurance santé non proportionnelle	25	17 %	17 %

Libellés, lignes d'activité de l'annexe I et valeurs sont ceux de la version consolidée. Neuf des trente-deux valeurs diffèrent de la version d'origine de 2015 (entre parenthèses) : segment 6 de l'annexe II, 19 % (12 %) et 17,2 % (19 %); segment 7, 8,3 % (7 %) et 5,5 % (12 %); segment 8, 6,4 % (9 %) et 22 % (20 %); segment 1 de l'annexe XIV, réserve 5,7 % (5 %); segment 3, primes 9,6 % (8 %); segment 4, réserve 17 % (20 %). Les vingt-trois autres sont inchangées.

Le facteur de crédibilité applicable est déterminé par la section G de l'annexe XVII, dont le paragraphe 2 range explicitement *tous* les segments de l'annexe XIV sous le barème court, aux côtés des segments 2 à 4 et 7 à 12 de l'annexe II. Le barème long du paragraphe 1 est réservé aux seuls segments 1, 5 et 6 de l'annexe II. L'annexe d'appartenance fait donc partie de la clé : à $T = 8$, le segment 1 de l'annexe XIV (frais médicaux) reçoit $c = 81$ %, alors que le segment 1 de l'annexe II (responsabilité civile automobile) reçoit $c = 59$ %. La fonction `usp_bareme_segment(segment, annexe)` implémente cette distinction, et `usp_segment_infos()` renvoie l'ensemble des caractéristiques réglementaires d'un segment.

Portée. L'outil ne couvre pas les autres paramètres remplaçables de l'article 218, paragraphe 1 (version consolidée) :

- le *facteur d'ajustement pour la réassurance non proportionnelle*, remplaçable pour chaque segment de l'annexe II (point a) iii), sous ▼ M6) et pour chaque segment de l'annexe XIV (point c) iii), sous ▼ M6), à condition qu'il existe pour ce segment un contrat de réassurance en excédent de sinistres ou en excédent de pertes reconnaissable au sens du paragraphe 2. Il ne faut pas le confondre avec sa valeur standard : 80 % pour les segments 1, 4 et 5 de l'annexe II et 100 % pour les autres (article 117, paragraphe 3), 100 % par défaut pour tous les segments de l'annexe XIV (article 148, paragraphe 3);
- l'*écart-type du risque de primes* (net) visé aux points a) i) et c) i), égal au produit de l'écart-type brut et de ce facteur (articles 117 et 148, paragraphe 3); l'outil prend pour paramètre standard du mélange l'écart-type brut des annexes II et XIV quelle que soit la nature des données, et le choix entre les deux lectures, nette ou brute, est ouvert (issue #55 du dépôt);
- l'augmentation du montant des prestations de rente des sous-modules « risque de révision en vie » (point b) et « risque de révision en santé » (point d).

Il met en revanche en œuvre trois des méthodes de calibrage de l'annexe XVII : risque de primes (section B), risque de réserve n° 1 (section C) et risque de réserve n° 2 (section D : chaîne d'échelle et erreur de prédiction à un an, §13).

1.5 Reproductibilité et gestion des graines

Le moteur comporte cinq sources de tirages aléatoires, et cinq seulement : une recherche dans `R/engine.R` de `set.seed()`, `RNGkind()`, `.Random.seed`, `sample()` et des générateurs `r*( )` de `stats` ne renvoie aucun appel qui n'appartienne à l'une d'elles. Pour chacune, on indique la fonction qui tire, la graine, la portée du tirage et le sort de l'état du générateur (l'objet `.Random.seed` de l'environnement global) après l'appel.

- `usp_bootstrap()` (méthodes de primes et de réserve n° 1). *Graine* : le paramètre `seed` de `run_engine()` (défaut 20260831), posé par `set.seed(seed)` une seule fois, avant la boucle des B réplifications ; à chaque réplification, `usp_simuler()` tire par `stats::rnorm()` les logarithmes des T pertes simulées sous le modèle ajusté. *Portée* : tous les résultats de Monte-Carlo de la branche lognormale (p-values Monte-Carlo, erreurs `err_mc`, `sigma_boot` et les grandeurs qui en sont tirées). *État* : non restauré.
- `mw_bootstrap()` (méthode de réserve n° 2). *Graine* : le même paramètre `seed`, posé par `set.seed(seed)` une seule fois avant la boucle ; à chaque réplification, `mw_simuler_triangle()` tire avec remise, par `sample()`, les résidus du vivier recentré. *Portée* : tous les résultats de Monte-Carlo de la branche Merz–Wüthrich (p-values Monte-Carlo, `sigma_boot` et l'intervalle qui en est tiré). *État* : non restauré.
- `sw_loi_nulle()`, appelée par `sw_p_loi_nulle()` dans les deux branches. *Graine* : fixe, 20260901, indépendante de `seed` ; `set.seed()` est suivi de 20 000 échantillons $\mathcal{N}(0, 1)$ de taille n tirés par `stats::rnorm()`, où n vaut T dans la branche lognormale et le nombre de résidus dans la branche Merz–Wüthrich. La loi simulée est mise en cache, pour la durée de la session R, sous une clé formée de n , du nombre de tirages et de la graine : un second appel à la même taille ne tire plus rien et renvoie la même loi. *Portée* : la p-value exacte simulée du test de Shapiro–Wilk sans la normalisation de Royston (fiche 8.7) et du test de Shapiro–Wilk sur les résidus de Mack (fiche 18.1). *État* : sauvegardé avant le tirage et restauré après. Exception : si aucun état n'existait avant l'appel, la fonction laisse celui qu'elle a produit ; le cas ne se présente pas dans `run_engine()`, où le bootstrap a déjà initialisé le générateur.
- `engine_plots_data()` (branche lognormale). *Graine* : fixe, 20260831, indépendante de `seed` bien qu'elle en égale la valeur par défaut ; `set.seed()` est suivi de 499 échantillons $\mathcal{N}(0, 1)$ de taille T tirés par `stats::rnorm()`, dont les statistiques d'ordre fournissent, point par point, les quantiles à 5 % et 95 % de l'enveloppe du QQ-plot. *Portée* : ce seul graphique (champs `env_bas` et `env_haut` de `plots_data$qqnorm`) ; aucun test ni aucun paramètre n'en dépend. *État* : non restauré.
- `engine_ecrire_xlsx()` et `engine_lire_xlsx()`, dans leur seule voie de repli, empruntée quand le paquet `openxlsx` n'est pas installé. *Graine* : aucune ; chacune tire une valeur par `runif()` sur l'état courant du générateur. *Portée* : le nom d'un dossier temporaire créé sous `tempdir()`, rien d'autre. *État* : avancé d'un tirage, non restauré.

Sur les cas de contrôle de `tests/test_reproductibilite.R`, on a vérifié par exécution les trois propriétés qui en découlent. *Indépendance à l'égard de l'état antérieur* : tout tirage qui alimente un résultat numérique est précédé d'un `set.seed()` dans la fonction même qui l'effectue ; les résultats de `run_engine()` ne dépendent donc pas de l'état du générateur avant l'appel (trois états de départ différents, dont un générateur non initialisé, donnent pour chacune des trois méthodes des objets identiques, aux champs d'exécution de `$metadata` près). Les tirages des fonctions de lecture et d'écriture `xlsx`, appelées par l'application hors de `run_engine()`, n'atteignent pour cette raison aucun résultat. *Dépendance au type de générateur* : le moteur ne fixe pas `RNGkind()` et suppose le générateur par défaut de R (Mersenne-Twister, inversion pour la loi normale, rejet pour `sample()`), et `$metadata` ne consigne pas le générateur employé (issue #37). Sous un autre générateur, les tirages et donc les résultats de Monte-Carlo changent, mais ni le paramètre final ni aucune grandeur issue de l'estimation : σ_{USP} est identique sous les trois réglages testés (branche lognormale : 0,1114524359 ; Merz–Wüthrich : 0,0497764613), parce qu'il ne dépend d'aucun tirage. Mesuré sur les cas de contrôle : sous `RNGkind("L'Ecuyer-CMRG")`, 33 des 34 p-values de Monte-Carlo de la méthode de primes changent, d'au plus 0,043 ($\text{sup-F} : 0,840 \rightarrow 0,883$), sans qu'aucun verdict change, et la médiane de `sigma_boot` passe de 0,092079 à 0,092274 ; sous `RNGkind(sample.kind = "Rounding")`, 12 des 13 p-values de Monte-Carlo de la méthode de réserve n° 2 changent, d'au plus 0,046 (test des suites : 0,374 $\rightarrow$ 0,328), sans changement de verdict, la médiane de `sigma_boot` passant de

0,016359 à 0,016752. Les deux croisements complètent le tableau : sous `RNGkind("L'Ecuyer-CMRG")`, la méthode de réserve n° 2 voit elle aussi 12 de ses 13 p-values de Monte-Carlo changer, d'au plus 0,062, sans changement de verdict ; sous `RNGkind(sample.kind = "Rounding")`, la méthode de primes est inchangée, la branche lognormale ne tirant rien par `sample()`. Parmi les champs du résultat, seuls changent ceux qui dérivent des tirages : p-values et erreurs de Monte-Carlo, et avec elles les p-values retenues qui en sont issues, les répliques `sigma_boot` (ainsi que `delta_boot` et `gamma_boot` dans la branche lognormale) et l'intervalle bootstrap (y compris le champ `largeur_ic` rangé dans `$ajustement`), et, pour le seul générateur L'Ecuyer, l'enveloppe du QQ-plot ainsi que les deux p-values exactes simulées de Shapiro–Wilk, qui reposent sur la loi nulle de `sw_loi_nulle()` : mesuré dans une session R neuve, $0,596370 \rightarrow 0,595220$ (fiche 8.7) et $0,0713964 \rightarrow 0,0712964$ (résidus de Mack, fiche 18.1), sans changement de verdict. Ces deux dernières ne changent toutefois que si la loi nulle n'a pas déjà été simulée dans la session : la clé du cache (taille, nombre de tirages, graine) ne comporte pas le générateur, de sorte qu'une loi simulée sous un générateur reste servie après un changement de `RNGkind()`. L'ordre de grandeur des écarts sur les p-values de Monte-Carlo est celui de leur erreur de Monte-Carlo à $B = 999$ (§5.2) : pour une p-value unilatérale estimée par une proportion, l'écart-type de la différence entre deux estimations indépendantes d'une même p-value p vaut $\sqrt{2p(1-p)/B}$ à la correction $1/(B+1)$ près, soit 0,016 pour $p = 0,84$ (sup-F) ; pour une p-value bilatérale $2 \min(\hat{p}^+, \hat{p}^-)$, la queue retenue $q = p/2$ est doublée et l'écart-type devient $\sqrt{2p(2-p)/B}$, soit 0,035 pour $p = 0,37$ (test des suites). Les écarts maximaux observés, 0,043, 0,046 et 0,062, valent entre 1,3 et 2,6 fois ces écarts-types, ce qui est attendu pour le maximum sur 34 et 13 statistiques. *État laissé à l'appelant* : seule `sw_loi_nulle()` restaure l'état du générateur. Après `run_engine()`, cet état est donc modifié : dans la branche lognormale, c'est celui que laisse `engine_plots_data()`, le même quels que soient `seed` et l'état de départ ; dans la branche Merz–Wüthrich, celui que laisse `mw_bootstrap()`. Un code appelant qui tire ses propres nombres après `run_engine()` sans reposer sa graine hérite de cet état.

Le script `tests/test_reproductibilite.R` vérifie, pour chacune des trois méthodes, deux propriétés qu'il ne faut pas confondre.

La reproductibilité. Deux appels de `run_engine()` avec les mêmes données, les mêmes paramètres et la même graine, **sur une même machine**, produisent des objets identiques au bit près, hors les trois champs de `$metadata` qui décrivent l'exécution et non le calcul (horodatage, durée, version de R), que le script retire avant de comparer. C'est ce que contrôle la comparaison de deux appels successifs par `identical()`, et cette propriété tient (vérification exécutée).

La non-régression. Le résultat est en outre confronté à des valeurs de référence enregistrées (`tests/reference/`) et versionnées avec le code. Leurs valeurs *numériques* sont produites sur une plateforme unique désignée : la CI du dépôt, par le workflow `.github/workflows/references.yml`, déclenché manuellement, sous Linux avec R 4.3.1, le libellé d'image `ubuntu-22.04` et, depuis la décision M34 du mainteneur (24 septembre 2026 au soir, ADR 0011 amendé), les bibliothèques BLAS et LAPACK de référence, `monothread` ; c'est aussi la plateforme du job « Tests du moteur » qui compare les résultats aux références. Il en est ainsi depuis la bascule du 24 septembre 2026 (ADR 0011, qui remplace le point 1 de l'ADR 0006) ; jusque-là, les références étaient produites sur le poste du mainteneur (Windows, R 4.3.1). Le libellé `ubuntu-22.04` fixe la version du système, non l'image exacte, que GitHub met à jour : l'image réelle, la version de R et les bibliothèques d'algèbre linéaire (BLAS, LAPACK) sont consignées dans le message de chaque commit de référence. Le workflow ne fait que calculer et publier les références ; leur commit reste un geste distinct, après visa du mainteneur sur le tableau avant / après, et aucune valeur numérique de référence n'est plus produite sur un poste ni dans une session de travail. Leurs grandeurs *non numériques* (libellés, verdicts, valeurs manquantes, entrées retirées) peuvent en outre être mises à jour par un *patch chirurgical*, qui recalcule le cas mais ne reprend que ces grandeurs et refuse d'écrire la moindre valeur numérique finie (ADR 0006, amendement du 22 septembre 2026). Une référence peut donc contenir des grandeurs non numériques calculées sur

une autre machine, mais aucune valeur numérique. Cette seconde comparaison n'est **pas** au bit près. Elle passe par un comparateur unique, `comparer_objets()` de `tests/outils_tests.R`, que partagent `tests/test_reproductibilite.R`, le tableau avant / après (`tests/comparer_references.R`) et le patch chirurgical (`tests/patcher_reference.R`) : l'objet est aplati en valeurs élémentaires nommées par leur chemin, les deux objets doivent porter les mêmes chemins, et **chaque valeur est jugée isolément**, sans moyenne ni agrégat. Une valeur non numérique, ou non finie (NA, NaN, $\pm\infty$) d'un côté, doit être identique à sa référence; une valeur numérique finie doit s'en écarter d'au plus 10^{-6} en relatif si la référence dépasse 10^{-6} en valeur absolue, d'au plus 10^{-6} en absolu sinon (une grandeur nulle par construction, de l'ordre de 10^{-16} par arrondi, aurait sans cela un écart relatif d'ordre 1). Le type d'une valeur fait partie de la valeur, et la structure de l'objet (type et attributs de chaque nœud) est comparée à part, à l'identique. Avant comparaison, `neutraliser_instables()` remplace par NA, dans le résultat comme dans la référence, deux catégories de grandeurs dont la structure reste comparée : les résultats connus pour s'écarter d'une plateforme à l'autre au-delà du seuil ci-dessous (liste `INSTABLES`, où chaque entrée renvoie à l'issue qui la justifie; vide à ce jour), et les champs *exclus par conception* de `res$ajustement` (liste `EXCLUS_AJUSTEMENT`, décisions du mainteneur, issue #22) : `$gradient` et `$gradient_projete`, `$n_starts_optimum_code0` et `$convergence`. Cette seconde exclusion ne repose pas sur un écart constaté entre plateformes mais sur la nature de la grandeur, établie sur une même machine : pour les deux premiers, un résidu d'optimiseur voisin de zéro, dont la valeur dépend du démarrage retenu et non des données (fiche 9.4); pour le troisième, un décompte de démarrages dont l'un au moins bascule entre les codes de retour 0 et 52 d'`optim()` sous une perturbation des données de 10^{-12} (sur le jeu de contrôle, 52, 53 ou 54 selon la perturbation; fiche 11.4); pour le quatrième, le code de retour du démarrage retenu, premier de la grille parmi des démarrages équivalents, qui dépend du même chemin d'optimisation (décision M23 du mainteneur, issue #22; fiche 11.4). Le pas de Newton, la courbure, les verdicts des contrôles, le nombre de démarrages à l'optimum et de démarrages sans résultat, la décision de Kuhn et Tucker `$kkt_au_moins_un` et $(\hat{\delta}, \hat{\gamma})$ restent comparés, et la reproductibilité à graine égale (`identical()`) porte sur l'objet entier. Ce critère a remplacé, le 23 septembre 2026, une comparaison par `all.equal()` à la tolérance relative de 10^{-8} , qui portait sur une différence relative *moyenne* et pouvait diluer un écart localisé dans un vecteur dont les autres valeurs dérivent — les tirages bootstrap en sont le cas réel (décision M9 du mainteneur, ADR 0006, second amendement). Le seuil 10^{-6} est *empirique*, non théorique : il vaut environ trois fois la dérive maximale mesurée entre plateformes, décrite ci-après ($3,508 \cdot 10^{-7}$), qu'il absorbe avec une marge. Il a été maintenu lors de la bascule vers la CI (ADR 0011, point 6) : sur la CI, les résultats sont désormais comparés à des références produites sur la même plateforme, mais le poste du mainteneur exécute lui aussi les tests, contre ces mêmes références, et la dérive y joue alors dans l'autre sens; l'écart entre le poste et les références de la CI, mesuré depuis (ci-après), vaut encore $3,508 \cdot 10^{-7}$, et le seuil garde sa marge. Une telle dérive existe entre plateformes et a été mesurée lors de l'audit consigné dans l'ADR 0006 (22 septembre 2026), en confrontant le code alors en vigueur, exécuté sous Linux avec R 4.3.3, aux références produites sur le poste du mainteneur : sur le cas de contrôle de la méthode prime, 5 515 valeurs élémentaires de l'objet, soit 44 % d'entre elles, différaient au sens strict, pour une différence relative moyenne de $6,2 \cdot 10^{-10}$ et un écart relatif maximal de $3,5 \cdot 10^{-7}$ sur les tirages bootstrap; l'écart sur σ_{USP} lui-même est de l'ordre de 10^{-14} en relatif, très en deçà de la précision à laquelle le paramètre est lu. La branche Merz–Wüthrich était, elle, indemne sous R 4.3.3 (aucun écart sur le triangle de contrôle); ce n'est plus vrai sous R 4.3.1 (voir ci-dessous). Ces décomptes sont datés : l'objet a changé depuis l'audit (il comptait 12 393 valeurs élémentaires sur le cas de la méthode prime lors de la mesure du 23 septembre 2026 rapportée ci-dessous, 12 369 après l'issue #22, 12 370 depuis l'ajout de `$kkt_au_moins_un`, décision M25, et en compte 12 419 le 25 septembre 2026, après les issues #40, #55 et #37), et la mesure ne peut se refaire qu'en confrontant deux plateformes. Tant que les références étaient produites sur le poste du mainteneur (Windows, R 4.3.1), le résultat courant des trois cas de contrôle y était identique au bit près

à sa référence, hors les trois champs d'exécution de `$metadata(identical())`, mesuré le 22 septembre 2026, puis de nouveau le 23 septembre 2026 sur les références régénérées pour l'issue #22). Refaite le 23 septembre 2026 sous Linux avec R 4.3.3, au critère ci-dessus, la comparaison donne, sur les cas prime et réserve n° 1, 5 504 valeurs sur 12 393 non strictement identiques à leur référence, d'écart relatif maximal $3,508 \cdot 10^{-7}$ (sur `bootstrap$sigma_boot`), aucune au-delà du seuil ; sur le cas Merz-Wüthrich, 4 211 valeurs toutes identiques. La même comparaison, exécutée le même jour par la CI du dépôt (Linux, R 4.3.1, job « Tests du moteur » de GitHub Actions ; ADR 0006, second amendement), donne pour les cas prime et réserve n° 1 exactement le même résultat — 5 504 valeurs non strictement identiques sur 12 393, écart maximal $3,508 \cdot 10^{-7}$ sur la même valeur de `bootstrap$sigma_boot` —, et pour le cas Merz-Wüthrich 8 valeurs non strictement identiques sur 4 211, d'écart relatif maximal $1,339 \cdot 10^{-13}$ (statistique de la première ligne de la table des tests). Deux enseignements, constatés et non démontrés : sur la branche lognormale, la dérive entre le poste et Linux ne dépend pas de la version mineure de R, et le seuil 10^{-6} garde sa marge d'environ trois ; la branche Merz-Wüthrich, qui n'emploie pas d'optimiseur, n'est pas strictement indemne de toute dérive de plateforme, mais son écart, d'ordre 10^{-13} , relève de l'arrondi du dernier bit et se situe six ordres de grandeur sous la dérive lognormale et sept sous le seuil. La bascule du 24 septembre 2026 a refait la mesure sur l'état courant de l'objet, avant de produire les nouvelles références : exécuté sur la CI (image `ubuntu22_20260920.303.1`, R 4.3.1, OpenBLAS 0.3.20), le workflow a comparé ses résultats aux références du poste en deux parts. Dans la part numérique, les cas prime et réserve n° 1 comptent chacun 5 505 valeurs non strictement identiques sur 12 370, d'écart relatif maximal $3,508 \cdot 10^{-7}$ sur la même valeur de `bootstrap$sigma_boot`, et le cas Merz-Wüthrich 8 sur 4 211, d'écart maximal $1,339 \cdot 10^{-13}$, aucune au-delà du seuil ; la part non numérique (chaînes, verdicts, booléens dont `$kkt_au_moins_un`, valeurs non finies, structure) est vide dans les trois cas, ce qui confirme entre deux machines la règle d'écriture des libellés exposée ci-après. Comparées aux références issues de cette exécution sous Linux avec R 4.3.3 (session de travail), les cas prime et réserve n° 1 ne présentaient plus qu'une valeur non strictement identique, à $1,6 \cdot 10^{-16}$, et le cas Merz-Wüthrich les mêmes 8 valeurs à $1,339 \cdot 10^{-13}$ au plus.

Ces références n'ont servi que jusqu'au soir du même jour. La première régénération demandée à la CI (issue #40) a été refusée : à image, version de R et BLAS identiques, son résultat différait de celui de la bascule, hors des seules valeurs que le code de l'issue devait changer, sur 5 526 valeurs de chaque cas lognormal, jusqu'à $3,508 \cdot 10^{-7}$ sur la même valeur de `bootstrap$sigma_boot`, et sur 45 valeurs du cas Merz-Wüthrich, jusqu'à $6,5 \cdot 10^{-14}$: deux exécutions de la CI sous OpenBLAS n'étaient pas strictement identiques. OpenBLAS choisit ses noyaux de calcul selon le processeur, qui varie d'un runner à l'autre ; c'est la cause probable, non démontrée, retenue par l'ADR 0011 amendé. Depuis la décision M34, les deux workflows calculent avec le BLAS et le LAPACK de référence (LAPACK 3.10.0), monothread, qu'une étape de contrôle bloquante (`.github/actions/blas-reference/controle_blas.R`) vérifie avant tout calcul ; le modèle de processeur est consigné. Les références ont été reproduites sous cette plateforme par deux exécutions successives, sur deux runners distincts, aux empreintes md5 identiques pour les quatre fichiers ; par rapport aux références sous OpenBLAS, les trois cas lognormaux étaient identiques au bit près, et le cas Merz-Wüthrich différait sur 8 valeurs, d'au plus $1,339 \cdot 10^{-13}$. Deux exécutions identiques ne démontrent pas le déterminisme de la plateforme, elles ne le réfutent pas ; chaque régénération ultérieure en est une épreuve de plus, et celles des issues #40 et #37 ont été acceptées sans aucune valeur modifiée hors des changements attendus.

Mesure à la date du 25 septembre 2026 (`tests/comparer_references.R -deux-parts`, session de travail Linux, R 4.3.3, BLAS et LAPACK de référence 3.12.0) : comparés aux références versionnées, les quatre cas lognormaux ne présentent qu'une valeur non strictement identique, à $1,577 \cdot 10^{-16}$ (`plots_data$surface$objectif`), et le cas Merz-Wüthrich aucune ; la part non numérique est vide pour les cinq cas. Sur le poste du mainteneur (Windows, R 4.3.1, BLAS interne de R, LAPACK 3.11.0), la comparaison aux références produites sous le BLAS de référence, mesurée le 24 septembre 2026 et

consignée dans le message du commit de ces références, donne 5 505 valeurs non strictement identiques par cas lognormal, d'écart maximal $3,508 \cdot 10^{-7}$, et le cas Merz–Wüthrich identique au bit près : le poste ne coïncide pas avec la CI sur la branche lognormale, et le seuil 10^{-6} garde sa marge d'environ trois. L'origine vraisemblable de cette dérive est l'optimiseur employé par la branche lognormale sur une vraisemblance quasi plate en δ , dont le chemin dépend de l'ordre des opérations en virgule flottante ; cette explication est cohérente avec la répartition observée des écarts. L'expérience de M34 en isole une partie — à version de R, image et système fixés, deux exécutions sous OpenBLAS ont différé, deux sous le BLAS de référence non —, mais elle ne démontre pas que la bibliothèque d'algèbre linéaire en soit la seule cause, les compilateurs et bibliothèques mathématiques différant aussi entre le poste et la CI. Ce qui précède ne remet en cause aucun résultat publié : c'est la portée de la garantie qui doit être énoncée exactement.

Les libellés. Les chaînes de caractères de l'objet (commentaires des tests et des contrôles, notamment) sont comparées à l'identique, sans tolérance. D'où une règle d'écriture du moteur : **aucune chaîne ne porte un nombre dont la valeur imprimée dépend de la plateforme** ; un résidu d'optimiseur ou une valeur voisine d'un point de bascule d'arrondi va dans un champ numérique, jugé au seuil ci-dessus, et le libellé y renvoie. La règle est née d'un constat de la CI (issue #22) : le commentaire de l'ancienne ligne « condition du premier ordre » imprimait un résidu au bruit machine, $1,1 \cdot 10^{-17}$ sous Windows contre $2,5 \cdot 10^{-17}$ sous Linux, et cette seule chaîne faisait échouer la comparaison. Le test *anti-bruit* (tests/unitaires/test_anti_bruit.R) la protège sur une même machine, sans attendre la CI : pour les trois méthodes, les données sont multipliées par 1 ± 10^{-12} selon huit motifs de signes déterministes, sans tirage (motifs de Walsh–Hadamard $s_i = (-1)^{\text{popcount}((i-1) \& k)}$, $k = 1, \dots, 7$: un couple (k_x, k_y) applique le motif k_x aux x_t et le motif k_y aux y_t , et le motif k_x au triangle, cellule par cellule dans l'ordre de stockage (par colonnes) ; le premier couple, $(1, 1)$, est celui des signes alternés, seul employé jusqu'à la revue finale d'audit de l'issue #22), et toutes les chaînes de l'objet, hors les trois champs d'exécution de \$metadata, doivent rester identiques (identical()), toutes les valeurs numériques sous le seuil du comparateur après la même neutralisation. Il a révélé un second cas, corrigé : le commentaire du TOST imprimait la marge $\Delta = 0,1 \bar{y} = 8,5005$ à quatre chiffres significatifs, soit « 8.501 », devenu « 8.5 » sous la perturbation ; la valeur de Δ est désormais restituée dans le champ estim de la ligne (fiche 6.2), et le commentaire n'en donne que la définition. Un troisième cas est apparu sur la CI Linux : le commentaire du contrôle de convergence multi-démarrages imprimait le nombre de démarrages à l'optimum rendant le code 0 (« dont 54 » sur le poste, « dont 53 » sous Linux) ; il dit désormais seulement si au moins un tel démarrage existe (« oui » ou « non »), et le décompte, conservé dans res\$ajustement, est exclu par conception de la comparaison (ci-dessus). Le motif alterné seul ne l'aurait pas détecté sur une même machine : sur le jeu de contrôle, le décompte reste égal à 54 sous ce motif et ne change que pour 13 des 49 couples de motifs de Walsh–Hadamard (52 pour deux d'entre eux, 53 pour onze ; mesure sous Linux, R 4.3.3), d'où les huit couples du test, dont cinq le font changer sur la machine de mesure (sur une autre plateforme, ce peuvent être d'autres couples). Pour la même raison, le commentaire n'imprime plus le code de retour du démarrage retenu (décision M23 du mainteneur, issue #22), qui ne décide pas du verdict et reste dans res\$ajustement\$convergence, exclu lui aussi de la comparaison (fiche 11.4).

La décision M24 du mainteneur (issue #24) a étendu la règle à tout nombre d'un commentaire de usp_tests() qui provient de l'optimiseur, du bootstrap ou des réajustements du jackknife et dont la valeur est restituée ailleurs dans l'objet : les bornes de l'intervalle bootstrap à 90 % et sa largeur rapportée à σ_{USP} (fiche 11.3), l'écart du jackknife sur σ_{USP} , dont seul le sens reste écrit (fiche 11.2), l'asymétrie et l'aplatissement que la ligne de Jarque–Bera imprimait et pour lesquels elle renvoie désormais aux champs estim des lignes de D'Agostino et d'Anscombe–Glynn (fiche 8.8). Le motif est celui du Δ du TOST : sur le jeu de contrôle de la méthode prime, le quantile à 95 % de σ_{USP} bootstrap, 0,136955, est à $3,4 \cdot 10^{-5}$ en relatif de la frontière d'arrondi de son impression à quatre décimales, soit environ cent fois seulement la dérive de plateforme mesurée ($3,5 \cdot 10^{-7}$). Deux nombres étaient restés imprimés parce qu'ils n'étaient

stockés nulle part ailleurs : l'écart du jackknife et la largeur de l'intervalle rapportés à la part estimée, affichés $-14,8\%$ et $87,6\%$ sur ce jeu (valeurs $-14,833\%$ et $87,626\%$, à $1,1 \cdot 10^{-3}$ et $2,8 \cdot 10^{-4}$ en relatif de leur frontière d'arrondi, soit au moins huit cents fois la dérive mesurée) ; le mainteneur en avait accepté le risque. La décision M27 du mainteneur (issue #76), prise avant la production des références par la CI, les a retirés : les commentaires des lignes jackknife et intervalle bootstrap, et ceux des deux contrôles numériques de la famille H, sont ramenés à une phrase ; la règle, les repères et leur justification figurent dans les fiches (9.4, 11.4, 11.2 et 11.3), les valeurs dans `res$ajustement`, les champs `stat` et `estim` et `res$ic_bootstrap`. Ces quatre commentaires ne portent plus aucune valeur réelle issue de l'optimiseur, du bootstrap ou du jackknife, seulement des entiers (année la plus influente, nombres de démarrages à l'optimum et sans résultat) ; les deux grandeurs sur la part estimée ne sont plus restituées et se recalculent à partir de `res$jackknife` et `res$bootstrap$sigma_boot` (fiches 11.2 et 11.3). Reste aussi imprimée, hors du cas de contrôle ($\hat{\delta} = 1$), la valeur de $1 - \hat{\delta}$ que les commentaires des lignes de centrage et de variance donnent à deux chiffres significatifs dans la bande de tolérance (fiche 9.5) : issue de l'optimiseur et non stockée en tant que telle ($\hat{\delta}$ l'est), elle a été signalée et conservée lors de la même revue.

Point de revue. L'objet retourné contient un champ `$metadata` consignait la méthode, le segment, σ_{standard} , le barème de crédibilité, T , B (dont se déduit la granularité $1/(B + 1)$), le seuil α , la graine, l'horodatage, la durée et la version de R. Ce champ suffit, avec les données, à rejouer un calcul à l'identique sur une même machine, sous le générateur par défaut de R, que `$metadata` ne consigne pas.

1.6 Index des fonctions de statistique et de p-value

L'inventaire de la section 1.3 regroupe les fonctions par catégorie (`stat_*`(), `test_*`()). Le tableau ci-dessous descend d'un niveau : il relie **chaque test documenté** — méthode lognormale en partie III, méthode Merz–Wüthrich en sections 14 à 19 — à la ou aux fonctions R qui calculent sa statistique, et à celle(s) qui calculent chacune des p-values disponibles. Les entrées sont groupées par hypothèse : H1 à H4 pour la méthode lognormale, M1 à M6 pour la méthode Merz–Wüthrich. La colonne « Réf. » renvoie à la fiche correspondante. La méthode générale de p-value de Monte-Carlo est décrite à part (fiche 4.1, page 33) : la colonne « Clé MC » indique, pour chaque test, le nom de l'entrée du catalogue des statistiques Monte-Carlo de la méthode (`USP_CATALOGUE_MC` pour la méthode lognormale, évalué par `.stats_bootstrapables()` ; `MW_CATALOGUE_MC` pour la méthode Merz–Wüthrich, évalué par `.mw_stats()`) qui lui correspond, lorsqu'une p-value de Monte-Carlo est calculée.

Certains tests s'appuient sur un appel direct à une fonction de `stats` plutôt que sur une fonction dédiée du moteur : cela est indiqué explicitement, la fonction `stats:... restant néanmoins un élément identifiable et auditable du code de usp_tests().`

Test (fiche)	Réf.	Fonction(s) — statistique	Fonction(s) / méthode — p-value non simulée	Clé MC
Hypothèse H1 — linéarité et proportionnalité				
Student, constante	6.1	<code>test_intercept()</code>	<code>test_intercept()</code> (p exacte, loi t)	Intercept
Équivalence (TOST)	6.2	<code>test_tost_intercept()</code>	<code>test_tost_intercept()</code> (p exacte si Δ a priori)	—
Student, pente	6.3	<code>test_lm_complet()</code>	<code>test_lm_complet()</code> (p exacte, loi t)	—
Fisher global	6.4	<code>test_lm_complet()</code>	<code>test_lm_complet()</code> (p exacte, loi F)	—
Coefficient R^2	6.5	<code>test_lm_complet()</code>	diagnostic, aucune p-value	—
RESET	6.6	<code>test_reset()</code>	<code>test_reset()</code> (p asymptotique, loi F approchée)	RESET
Spearman ($\times 2$)	6.7	<code>stats::cor.test()</code> (appel direct)	<code>stats::cor.test(..., exact = TRUE)</code> (p exacte, permutation)	SpearVol / SpearTps
Mann–Kendall	6.8	<code>test_mann_kendall()</code>	<code>mk_p_exacte()</code> (p exacte, loi mahonienne, via <code>.mk_loi_exacte()</code> , <code>.poly_mult()</code>)	MK
Cox–Stuart	6.9	<code>test_cox_stuart()</code>	<code>test_cox_stuart()</code> (p exacte, loi binomiale)	CoxStuart
Hypothèse H2 — structure de variance quadratique				
Breusch–Pagan (Koenker)	7.1	<code>test_breusch_pagan()</code>	<code>test_breusch_pagan()</code> (p asymptotique, χ^2)	BP
Breusch–Pagan (1979)	7.2	<code>test_breusch_pagan_original()</code>	idem (p asymptotique, χ^2 sous normalité)	BP79
White	7.3	<code>test_white()</code>	<code>test_white()</code> (p asymptotique, χ^2)	White
Goldfeld–Quandt	7.4	<code>test_goldfeld_quandt()</code>	<code>test_goldfeld_quandt()</code> (p asymptotique, loi F approchée)	GQ
Brown–Forsythe	7.5	<code>test_brown_forsythe()</code>	<code>test_brown_forsythe()</code> (p asymptotique, loi F approchée)	BF
Smirnov (2 éch.)	7.6	<code>stats::ks.test()</code> (appel direct)	<code>stats::ks.test()</code> (p exacte combinatoire, sans ex æquo)	Smirnov
Position de $\hat{\delta}$	7.7	<code>usp_ajuster()</code> (champ <code>\$delta</code>); drapeau <code>\$delta_au_bord</code> par <code>usp_regime()</code> , tolérance <code>TOL_DELTA_BORD</code>	diagnostic, aucune p-value	—
Hypothèse H3 — lognormalité des pertes agrégées				
Shapiro–Wilk	8.1	<code>.shapiro_sur()</code> (encapsule <code>stats::shapiro.test()</code>)	<code>.shapiro_sur()</code> (p approx. Royston 1992)	SW
Shapiro–Francia	8.2	<code>test_shapiro_francia()</code>	<code>test_shapiro_francia()</code> (p approx. Royston 1993)	SF
Anderson–Darling	8.3	<code>stat_ad()</code>	<code>ad_p_stephens()</code> (p approx. D'Agostino & Stephens)	AD
Cramér–von Mises	8.4	<code>stat_cvm()</code>	<code>cvm_p_stephens()</code> (p approx. D'Agostino & Stephens)	CvM
KS contre $\mathcal{N}(0, 1)$	8.5	<code>stat_ks()</code>	formule de Kolmogorov, calculée en ligne dans <code>usp_tests()</code>	KS
Lilliefors	8.6	<code>stat_lilliefors()</code>	<code>lillie_p()</code> (p approx. Dallal & Wilkinson)	Lillie
Shapiro–Wilk sans Royston	8.7	<code>.shapiro_sur()</code> (statistique W réutilisée)	<code>sw_p_loi_nulle()</code> (p exacte simulée, via <code>sw_loi_nulle()</code> , mise en cache)	—

Suite page suivante

Test (fiche)	Réf.	Fonction(s) — statistique	Fonction(s) / méthode — p-value non simulée	Clé MC
Jarque–Bera	8.8	<code>test_jarque_bera()</code>	<code>test_jarque_bera()</code> (p asymptotique, χ_2^2)	JB
D’Agostino (asymétrie)	8.9	<code>test_dagostino_skew()</code>	<code>test_dagostino_skew()</code> (p asymptotique, transf. S_{U^r})	DAgo
Anscombe–Glynn (aplat.)	8.10	<code>test_anscombe_kurt()</code>	<code>test_anscombe_kurt()</code> (p asymptotique, Wilson–Hilferty)	—
Hypothèse H4 — indépendance et validité du maximum de vraisemblance				
Durbin–Watson	9.1	<code>stat_dw()</code>	<code>dw_p_exacte()</code> (p exacte, méthode d’Imhof via <code>.imhof_p_sup0()</code>)	DW
Ljung–Box / Box–Pierce	9.2	<code>stats::Box.test()</code> (appel direct, 2 retards)	<code>stats::Box.test()</code> (p asymptotique, χ^2)	LB1, LB2, BP2
Suites (Wald–Wolfowitz)	9.3	<code>test_runs()</code>	<code>runs_p_exacte()</code> (p exacte combinatoire, via <code>.runs_dens()</code>)	Runs
Durbin–Watson sur ratios bruts	9.7	<code>stat_dw()</code> sur u_t	aucune hors Monte-Carlo	DW _r
Ljung–Box (retard 1) sur ratios bruts	9.8	<code>stats::Box.test()</code> sur u_t	aucune hors Monte-Carlo	LB1 _r
Suites sur ratios bruts	9.9	<code>test_runs()</code> sur u_t	<code>usp_runsr_p_exacte()</code> (p exacte de <code>runs_p_exacte()</code> sous double condition)	Runs _r
Condition du premier ordre (contrôle numérique, hors table des tests)	9.4	<code>usp_condition_premier_ordre()</code> , <code>usp_kkt_satisfaite()</code> , <code>usp_ajuster()</code> (champ <code>\$kkt_au_moins_un</code>), <code>usp_controles_numeriques()</code>	contrôle OK / ECHEC, aucune p-value	—
Centrage des résidus (diagnostic)	9.5	<code>mean()</code> sur z (appel direct dans <code>usp_tests()</code>)	diagnostic, aucune p-value	—
Variance unitaire (diagnostic)	9.6	<code>stats::var()</code> sur z (appel direct dans <code>usp_tests()</code>)	diagnostic, aucune p-value	—
Stabilité, ruptures et points aberrants				
Rupture sup-F	10.1	<code>stat_supF()</code>	aucune (théorique seulement, Andrews 1993)	supF
OLS-CUSUM	10.2	<code>stat_cusum()</code>	formule de Kolmogorov, calculée en ligne dans <code>usp_tests()</code>	CUSUM
Grubbs	10.3	<code>test_grubbs()</code>	<code>test_grubbs()</code> (p asymptotique, borne de Bonferroni)	Grubbs
Rosner (ESD)	10.4	<code>test_rosner()</code>	procédure de décision, aucune p-value	—
Distance de Cook	10.5	<code>stats::cooks.distance()</code> (appel direct)	diagnostic, aucune p-value	—
Leviers	10.6	<code>stats::hatvalues()</code> (appel direct)	diagnostic, aucune p-value	—
Rupture sup-F sur ratios bruts	10.7	<code>stat_supF()</code> sur u_t	aucune hors Monte-Carlo	supF _r
OLS-CUSUM sur ratios bruts	10.8	<code>stat_cusum()</code> sur u_t	aucune hors Monte-Carlo	CUSUM _r
Grubbs sur ratios bruts	10.9	<code>test_grubbs()</code> sur u_t	aucune hors Monte-Carlo	Grubbs _r

Suite page suivante

Test (fiche)	Réf.	Fonction(s) — statistique	Fonction(s) / méthode — p-value non simulée	Clé MC
Robustesse de l'estimation (méthode lognormale)				
Rapport de vraisemblance sur δ	11.1	fonction interne <code>lr()</code> dans <code>usp_profil()</code>	calcul direct <code>stats::pchisq()</code> (p asymptotique, correction de Chernoff non appliquée)	—
Jackknife	11.2	<code>usp_jackknife()</code>	diagnostic, aucune p-value	—
IC bootstrap	11.3	<code>usp_bootstrap()</code> (champ <code>\$sigma_boot</code>)	diagnostic, aucune p-value	—
Convergence multi-démarrages (contrôle numérique, hors table des tests)	11.4	<code>usp_ajuster()</code> (champs <code>\$n_starts_optimum</code> , <code>\$n_starts_optimum_code0</code> , <code>\$n_starts_echec</code> , <code>\$part_starts_convergensts</code> , <code>usp_controles_numeriques()</code>)	contrôle OK / ECHEC, aucune p-value	—
Méthode Merz-Wüthrich — M1 : proportionnalité des cumulés (annexe XVII, D(2)(h)(iii))				
Tendance avec le cumulé, à colonne donnée	14.1	<code>.mw_lm_intra()</code> (via <code>.mw_pente_intra()</code>)	idem (p de Student, approchée)	PenteIntra
Ordonnée à l'origine par colonne	14.2	<code>mw_test_ordonnee_origine()</code>	idem (p de Fisher, via <code>.fisher_combine()</code>)	Origine
Homogénéité de f_j	14.3	<code>mw_test_homogeneite_f()</code>	idem (p de Fisher)	HomogF
Absence de courbure	14.4	<code>mw_test_courbure()</code>	idem (p de Fisher)	Courbure
Famille α	14.5	<code>mw_famille_alpha()</code>	aucune (pas de loi analytique)	Alpha
Méthode Merz-Wüthrich — M2 : variance proportionnelle au cumulé (annexe XVII, D(2)(h)(iv))				
Breusch-Pagan sur résidus de Mack	15.1	<code>stats::lm(r^2 ~ C)</code> dans <code>mw_tests()</code>	<code>stats::pchisq()</code> (p asymptotique)	BP
Exposant de variance par colonne	15.2	<code>mw_test_exposant_variance()</code>	idem (p de Fisher)	ExpVar
Variance unitaire des résidus	15.3	<code>stats::var()</code> sur <code>mw_residus()</code>	diagnostic, aucune p-value	—
Méthode Merz-Wüthrich — M3 : indépendance (annexe XVII, D(2)(h)(i) et (ii))				
Homogénéité entre années de surveillance	16.2	<code>mw_test_homogeneite_accident()</code>	<code>stats::kruskal.test()</code> (p asymptotique)	KruskalAcc
Effets d'année calendaire	16.1	<code>mw_test_annees_calendaires()</code> (via <code>.mack_moments_Z()</code>)	idem (p asymptotique ; moments <i>exacts</i>)	Calendrier
Corrélation entre années de développement	16.3	<code>mw_stat_correlation_dev()</code>	aucune (pas de loi analytique)	CorrDev
Autocorrélation (Durbin-Watson)	16.4	<code>stat_dw()</code>	aucune (loi d'Imhof inapplicable aux résidus de Mack)	DW
Test des suites	16.5	<code>test_runs()</code>	<code>test_runs()</code> (approximation normale)	Runs
Méthode Merz-Wüthrich — M4 : points aberrants				

Suite page suivante

Test (fiche)	Réf.	Fonction(s) — statistique	Fonction(s) / méthode — p-value non simulée	Clé MC
Cellule aberrante (Grubbs)	17.1	<code>test_grubbs()</code>	<code>test_grubbs()</code> (borne de Bonferroni)	Grubbs
Cellules aberrantes multiples (Rosner)	17.2	<code>test_rosner()</code>	procédure de décision, aucune p-value	—
Méthode Merz-Wüthrich — M5 : normalité (diagnostic, non exigée par le modèle)				
Shapiro–Wilk sur résidus de Mack	18.1	<code>.shapiro_sur()</code>	<code>sw_p_loi_nulle()</code> (p exacte simulée, via <code>sw_loi_nulle()</code>)	—
Lilliefors sur résidus de Mack	18.2	<code>stat_lilliefors()</code>	<code>lillie_p()</code> (approx. Dallal & Wilkinson)	—
Méthode Merz-Wüthrich — M6 : robustesse de l'estimation				
Extrapolation de $\hat{\sigma}_{J-1}^2$	19.1	<code>mw_ajuster()</code> (champ <code>\$sigma2</code>); res- titution des trois arguments du minimum par <code>mw_extrapolation_sigma2()</code> et <code>.mw_detail_extrapolation()</code>	diagnostic, aucune p-value	—
Concentration de la réserve	19.2	<code>mw_ajuster()</code> (champ <code>\$reserve_par_annee</code>)	diagnostic, aucune p-value	—
Méthode Merz-Wüthrich — chaîne de calcul (hors tests)				
Recevabilité du triangle (avant ajuste- ment)	§3	<code>mw_valider_triangle()</code>	sans objet	—
Applicabilité de D(4) — réserve $\hat{R}$ et MSEP (après ajustement)	§3	<code>mw_valider_ajustement()</code>	sans objet	—
Facteurs et variances de développement	§13	<code>mw_ajuster()</code>	sans objet	—
Erreur de prédiction à un an	§13	<code>mw_msep()</code>	sans objet	—
Paramètre propre $\sigma_{(res,s,USP)}$	§13	<code>mw_parametre()</code> <code>usp_credibilite()</code>	× sans objet	—
Résidus standardisés de Mack	§13	<code>mw_residus()</code>	sans objet	—
Bootstrap semi-paramétrique	§13	<code>mw_bootstrap()</code> <code>mw_simuler_triangle()</code> <code>.mw_stats()</code>	(via sans objet et	toutes les clés ci- dessus
Leviers et DFBETA du triangle	12.8	<code>mw_influence()</code>	diagnostic, aucune p-value	—
Contributions par année de survenance	12.8	<code>mw_contributions()</code>	diagnostic, aucune p-value	—

Fonctions internes de support. Quatre fonctions préfixées d'un point ne sont jamais appelées directement par `usp_tests()` mais seulement par les fonctions de p-value ci-dessus, directement ou l'une par l'intermédiaire de l'autre : `.imhof_p_sup0()` (intégrale d'Imhof, utilisée par `dw_p_exacte()`), `.mk_loi_exacte()` et `.poly_mult()` (distribution exacte du S de Kendall par produit de polynômes, utilisées par `mk_p_exacte()`), et `.runs_dens()` (densité exacte du nombre de suites, utilisée par `runs_p_exacte()`). `.shapiro_sur()` et `sw_loi_nulle()` sont deux autres fonctions internes : la première encapsule `stats::shapiro.test()` pour éviter qu'un échantillon dégénéré n'interrompe la boucle de bootstrap, la seconde met en cache la loi nulle simulée de W par taille d'échantillon (T dans la branche lognormale, nombre de résidus de Mack dans la branche Merz–Wüthrich ; §1.5).

Lecture de la colonne « Clé MC ». Un tiret signifie qu'aucune p-value de Monte-Carlo n'est calculée pour ce test : soit parce que l'hypothèse nulle n'appartient pas au modèle simulé (Student sur la pente, Fisher) ; soit parce que le test n'est pas de nature à produire de p-value (diagnostics, procédures de décision) ; soit, troisième motif, parce que la grandeur est *rivée par l'estimation* : contrainte par une condition du premier ordre, sa dispersion sous le modèle est gouvernée par celle des poids $\hat{\pi}_t$, non par les données, de sorte qu'elle ne peut pas contredire le modèle ; à $\hat{\pi}_t$ constant, sa loi simulée porte en outre un atome en la valeur observée (centrage et variance unitaire des résidus standardisés, fiches 9.5 et 9.6). Dans tous les autres cas, la clé est le nom d'une entrée du catalogue de la méthode, qui est aussi le nom de colonne retourné par `.stats_bootstrapables()` (ou `.mw_stats()`) et consommé par `usp_bootstrap()` (ou `mw_bootstrap()`). La fonction d'enregistrement `add()` d'`engine_registre_tests()` refuse, par une erreur, une clé absente du catalogue ou de l'objet bootstrap : une p-value asymptotique ne peut donc pas être retenue à la place d'une p-value de Monte-Carlo prévue par suite d'une clé mal écrite (ADR 0003, point 3).

Notations générales

L'outil couvre deux familles de méthodes, aux géométries de données distinctes. Les notations sont donc présentées séparément : la sous-section suivante concerne les méthodes lognormales (sections B et C de l'annexe XVII), la section 2 la méthode Merz–Wüthrich (section D). Les conventions communes — lois, fonctions de répartition, convention de restitution — valent pour les deux.

Méthodes lognormales : données et modèle

Pour un segment donné et une profondeur T :

- $x_1, \dots, x_T$: primes acquises par année de survenance (méthode risque de prime) ou meilleure estimation de la provision en début d'exercice (méthode risque de réserve 1) ;
- $y_1, \dots, y_T$: pertes agrégées (méthode prime) ou paiements de l'exercice augmentés de la meilleure estimation de clôture sur les mêmes sinistres (méthode réserve 1) ;
- $r_t = y_t/x_t$: ratio observé (ratio S/P, ou ratio de liquidation) ;
- $\bar{x} = T^{-1} \sum_t x_t$.

Le modèle de l'annexe XVII postule $Y_t \mid x_t \sim \mathcal{LN}(\mu_t, \psi_t)$ avec

$$\mathbb{E}[Y_t] = \beta x_t, \quad \text{Var}(Y_t) = \sigma^2 [(1 - \delta) \bar{x} x_t + \delta x_t^2], \quad \delta \in [0, 1], \quad \sigma = \beta e^\gamma.$$

On en déduit la précision logarithmique et l'estimateur du niveau :

$$\pi_t(\delta, \gamma) = \left[\ln(1 + e^{2\gamma}(\delta + (1 - \delta)\bar{x}/x_t)) \right]^{-1}, \quad \ln \hat{\beta} = \frac{\frac{T}{2} + \sum_t \pi_t \ln r_t}{\sum_t \pi_t}.$$

Résidus

Les tests des sections 7 à 10 portent sur les *résidus standardisés*

$$z_t = \sqrt{\hat{\pi}_t} \left(\ln r_t + \frac{1}{2\hat{\pi}_t} - \ln \hat{\beta} \right), \quad t = 1, \dots, T,$$

qui, si le modèle est correctement spécifié, sont *approximativement* indépendants et de loi $\mathcal{N}(0, 1)$. On note $z_{(1)} \leq \dots \leq z_{(T)}$ la statistique d'ordre associée, $\bar{z}$ la moyenne empirique, $s_z^2 = (T - 1)^{-1} \sum_t (z_t - \bar{z})^2$ la variance empirique corrigée, et $p_{(i)} = \Phi(z_{(i)})$.

Lois et fonctions de répartition

Φ et φ désignent la fonction de répartition et la densité de $\mathcal{N}(0, 1)$; $F_{t,\nu}$, $F_{\chi_\nu^2}$, $F_{\mathcal{F},\nu_1,\nu_2}$ celles des lois de Student, du khi-deux et de Fisher. Les moments empiriques centrés d'ordre k sont notés $m_k = T^{-1} \sum_t (z_t - \bar{z})^k$, l'asymétrie $\sqrt{b_1} = m_3/m_2^{3/2}$ et l'aplatissement $b_2 = m_4/m_2^2$.

Régression auxiliaire

Plusieurs tests de la section 6 s'appuient sur la régression auxiliaire non contrainte $y_t = a + b x_t + \varepsilon_t$, dont on note $S_{xx} = \sum_t (x_t - \bar{x})^2$, $S_{xy} = \sum_t (x_t - \bar{x})(y_t - \bar{y})$, $\hat{b} = S_{xy}/S_{xx}$, $\hat{a} = \bar{y} - \hat{b}\bar{x}$, les résidus $e_t = y_t - \hat{a} - \hat{b}x_t$, ainsi que $\text{SCR} = \sum_t e_t^2$, $\text{SCT} = \sum_t (y_t - \bar{y})^2$ et $\hat{s}^2 = \text{SCR}/(T - 2)$.

Attention. Cette régression auxiliaire n'est pas le modèle réglementaire, qui impose $\mathbb{E}[Y_t] = \beta x_t$ sans constante. Elle sert uniquement de support aux tests de la section 6 et à son coefficient R^2 .

Méthode Merz–Wüthrich : données et modèle

La donnée d'entrée n'est plus un couple de vecteurs mais un *triangle* de paiements cumulés. Les notations sont celles de l'annexe XVII, section D, paragraphe 3 :

- $i = 0, \dots, I$: années de survénance, la plus ancienne portant l'indice 0 ;
- $j = 0, \dots, J$: années de développement ;
- $C(i, j)$: sinistres cumulés de l'année de survénance i à l'année de développement j , observés pour $i + j \leq I$;
- $F(i, j) = C(i, j + 1)/C(i, j)$: facteur de développement individuel ;
- $n_j = I - j$: nombre d'observations disponibles dans la colonne j .

Le modèle de chaîne d'échelle postule, pour tout i et tout j :

$$\mathbb{E}[C(i, j + 1) \mid C(i, j)] = f_j C(i, j), \quad \text{Var}[C(i, j + 1) \mid C(i, j)] = \sigma_j^2 C(i, j),$$

les années de survénance étant mutuellement indépendantes. **Aucune loi n'est spécifiée** : seuls les deux premiers moments conditionnels le sont, ce qui constitue la différence de nature la plus importante avec les méthodes lognormales et commande l'ensemble des choix de p-values.

Les estimateurs sont

$$\hat{f}_j = \frac{\sum_{i=0}^{I-j-1} C(i, j + 1)}{\sum_{i=0}^{I-j-1} C(i, j)}, \quad \hat{\sigma}_j^2 = \frac{1}{I - j - 1} \sum_{i=0}^{I-j-1} C(i, j) (F(i, j) - \hat{f}_j)^2,$$

la variance de la dernière année de développement étant *extrapolée* et non estimée (section 13).

Résidus des deux méthodes

Chaque méthode a son résidu de référence, support de ses tests :

Méthode	Résidu	Loi sous le modèle
Lognormale	$z_t = \sqrt{\hat{\pi}_t} \left(\ln r_t + \frac{1}{2\hat{\pi}_t} - \ln \hat{\beta} \right)$	i.i.d. $\mathcal{N}(0, 1)$: la loi est entièrement spécifiée
Merz–Wüthrich	$r(i, j) = \frac{\sqrt{C(i, j)}}{\hat{\sigma}_j} (F(i, j) - \hat{f}_j)$	centré, d'échelle approximativement unitaire, non corrélé ; aucune loi n'est spécifiée

Cette asymétrie est déterminante : pour la méthode lognormale, la normalité des résidus est une *hypothèse à tester* (H3) ; pour la méthode Merz–Wüthrich, elle n'est qu'un *diagnostic facultatif* (M5).

Convention de restitution : statistique, estimation, p-value

Les sorties du script distinguent explicitement trois grandeurs, qui ne doivent jamais être confondues et figurent dans des champs séparés :

stat	Statistique de test : la quantité dont la loi sous H_0 est connue (ou simulée). C'est elle, et elle seule, qui est comparée à une loi de référence pour produire une p-value. Le champ <code>loi</code> rappelle cette loi. Quand une p-value de Monte-Carlo est calculée, la statistique affichée est celle que simule le catalogue de la méthode, à une transformation près qui conserve la région de rejet et que le champ <code>loi</code> énonce alors ; un seul cas, Cox–Stuart (fiche 6.9 ; ADR 0003).
estim	Estimation ou grandeur descriptive : pente, constante, $\hat{\rho}_s$, $\hat{\delta}$, R^2 , nombre de valeurs aberrantes, distance de Cook maximale. . . Ces quantités n'ont <i>aucune</i> loi de référence dans ce dispositif et ne doivent pas être lues comme des statistiques de test.
p_exacte, p_ asymptotique, p_mc	p-values : respectivement exacte, asymptotique et de Monte-Carlo (bootstrap paramétrique, ou de résidus pour la méthode Merz–Wüthrich), chacune NA quand elle n'est pas calculée ; <code>err_mc</code> porte l'erreur de Monte-Carlo de <code>p_mc</code> . La p-value qui fonde le verdict est <code>p_retenue</code> , choisie dans l'ordre exacte, Monte-Carlo, asymptotique par la fonction <code>add()</code> d' <code>engine_registre_tests()</code> , commune aux deux méthodes ; <code>nature_p</code> dit laquelle.

Le champ `type` classe chaque ligne en *test* (hypothèse nulle et loi de référence), *diagnostic* (grandeur descriptive comme R^2 , grandeur rivée par l'estimation, diagnostic d'influence ou de robustesse ; les contrôles numériques de l'estimation n'y figurent pas, voir la section 3), *procédure de décision* (Rosner, qui ne produit pas de p-value) ou *non applicable*. Le champ `sens` indique enfin si l'on souhaite rejeter ou ne pas rejeter H_0 : pour les tests de Student sur la pente et de Fisher, un p faible est un *bon* résultat, et le verdict du script est inversé en conséquence.

Contrôles de qualité des données

Les contrôles de recevabilité ne sont **pas** des tests statistiques : ils ne comportent ni hypothèse nulle, ni statistique, ni loi de référence. Ce sont des vérifications déterministes au titre des articles 19 et 219 du règlement délégué et des exigences de données propres à chaque méthode — à une exception près, signalée plus bas. Chaque méthode a ses fonctions de contrôle dans le moteur, exécutables indépendamment de l'interface : `engine_valider_donnees()` et `usp_controle_donnees()` pour les méthodes lognormales ; `mw_valider_triangle()` et `mw_valider_ajustement()` pour la méthode Merz–Wüthrich.

La section décrit en outre, dans une sous-section propre placée à sa fin, les deux *contrôles numériques de l'estimation* des méthodes lognormales (famille « H. Controles numeriques de l'estimation » de `res$controles`, produite par `usp_controles_numeriques()`, issue #22). Ils ne sont pas des contrôles de données : exécutés après `usp_ajuster()`, ils jugent l'exécution de l'optimisation et ne relèvent ni des articles 19 et 219 ni de l'article 220. Ils ne sont pas davantage des tests : leur verdict OK / ECHEC n'a ni p-value ni loi de référence, et il est **non bloquant**.

La méthode Merz–Wüthrich en compte donc **deux**, appelées à deux moments distincts de la chaîne. `mw_valider_triangle()` s'exécute *avant* l'ajustement et ne porte que sur les données fournies : dimensions, complétude de la partie observée, positivité des cumulés. `mw_valider_ajustement()` s'exécute *après* `mw_ajuster()` et `mw_msep()`, parce que les deux grandeurs dont elle contrôle le domaine — la réserve chain-ladder totale $\hat{R} = \sum_{i=0}^J (\hat{C}(i, J) - C(i, I - i))$ et la MSEF — ne sont pas connues avant lui ; elle précède en revanche le calcul du paramètre propre et le bootstrap. Elle émet en outre, sans refuser le calcul, l'avertissement relatif à une colonne $J - 3$ ou $J - 2$ à facteurs individuels tous égaux, décrit dans le tableau ci-dessous et justifié au §13.

Son fondement n'est pas le même que celui des autres contrôles, et c'est l'exception annoncée ci-dessus. Tous les autres relèvent des exigences de données des articles 19 et 219 — exhaustivité, exactitude, caractère approprié. Une réserve chain-ladder totale $\hat{R} \leq 0$ n'est pas un défaut de données : le triangle peut satisfaire intégralement le paragraphe 2 de la section D, et c'est l'*estimation* qui place le paramètre hors de ce que la méthode peut produire. Le refus se fonde donc sur l'article 220, dont la justification détaillée figure au §13.

Dans les deux cas, un refus conduit `run_engine()` à retourner un objet portant `ok = FALSE` et le champ `validation` détaillant les motifs : aucune erreur R n'est levée. `mw_parametre()` porte en outre une garde défensive sur le même diagnostic, destinée à un appel direct de la fonction hors de la chaîne ; elle est inatteignable depuis `run_engine()`.

Un refus n'est pas un avertissement que l'on peut laisser passer : l'interface le restitue par un bandeau persistant portant les motifs renvoyés par le moteur, vide les onglets de résultat et rend indisponible l'export du calcul précédent, de sorte qu'un paramètre calculé sur d'autres données ne puisse être ni lu ni exporté à côté d'un triangle refusé.

Méthodes lognormales (annexe XVII, section B/C, paragraphe 2)

Contrôle	Critère	Justification
Profondeur minimale	$T \geq 5$	Annexe XVII, B/C(2)(b). Bloquant.
Valeurs manquantes	aucun NA	Art. 19 : exhaustivité. Bloquant.
Positivité de x_t	$\min_t x_t > 0$	$r_t = y_t/x_t$ doit être défini. Bloquant.
Positivité de y_t	$\min_t y_t > 0$	Support de la loi lognormale. Bloquant.
Doublons	aucun couple (x_t, y_t) répété	Signale une duplication de ligne.
Plausibilité du ratio	$r_t \in]0 ; 5[$	Erreurs d'unité ou de saisie.
Amplitude du volume	$\max_t x_t / \min_t x_t < 10$	Rupture de périmètre probable.
Crédibilité pleine	$T \geq 10$ (barème court)	Informatif, section G annexe XVII.

Les contrôles non bloquants ci-dessus sont restitués dans `res$controles` (famille « A. Qualite des donnees ») et signalés par `engine_valider_donnees()` comme avertissements : `run_engine()` produit le calcul (vérifié par exécution : un ratio hors de $]0 ; 5[$, une amplitude de volume de 10 ou plus, un couple dupliqué ou $T = 5$ laissent `ok = TRUE` ; une valeur manquante, un y_t négatif ou $T = 4$ donnent `ok = FALSE`).

Méthode Merz–Wüthrich (annexe XVII, section D, paragraphes 2, 4 et 5)

Contrôle	Critère	Justification
Années de survénance	$I + 1 \geq 5$	D(2)(b). Bloquant.
Années de développement	$J + 1 \geq 5$	D(2)(c). Bloquant.
Forme du triangle	$I + 1 \geq J + 1$	D(2)(e). Bloquant.
Géométrie carrée	$I = J$	Restriction d'implémentation : la formule du paragraphe 4 fait intervenir $C(i, I - i)$, indéfinie si $I - i > J$. Bloquant.
Cellules observées	aucune valeur manquante pour $i + j \leq I$	Le chain-ladder exige la partie supérieure gauche complète.
Positivité des cumulés	$C(i, j) > 0$	Les facteurs $F(i, j)$ et la pondération en $C(i, j)$ doivent être définis.
Monotonie des cumulés	$C(i, j + 1) \geq C(i, j)$	Avertissement <i>actuariel</i> , sans fondement réglementaire : le paragraphe 2(h)(iii) ne pose qu'une proportionnalité en espérance et ne contraint pas $f_j \geq 1$. Un recul traduit un recouvrement ou un boni de liquidation, licite mais à signaler. Ce n'est pas un motif de refus , pas plus qu'une réserve négative sur certaines années de survénance ou qu'un $\hat{f}_j < 1$ isolé.
Applicabilité de D(4) (<i>post-ajustement</i>)	$\hat{R} > 0$ et $0 \leq \text{MSEP} < \infty$	Le paragraphe 4 définit l'écart type $\sigma_{(\text{res}, s, \text{USP})}$ à partir de $\sqrt{\text{MSEP}}/\hat{R}$ (MSEP : paragraphe 5), coefficient de variation à horizon un an de la réserve — le paragraphe ne le nomme pas ainsi. Non défini pour $\hat{R} = 0$; négatif, donc pas un écart type, pour $\hat{R} < 0$ (article 220, §13). Bloquant.
Colonne $J - 3$ ou $J - 2$ dégénérée (<i>post-ajustement</i>)	$\max_i F(i, j)/\hat{f}_j - 1 \leq 10^{-12}$ pour $j = J - 3$ ou $j = J - 2$	Avertissement , non bloquant, jamais un refus : les facteurs individuels de la colonne sont tous égaux, donc $\hat{\sigma}_{J-3}^2 = 0$ ou $\hat{\sigma}_{J-2}^2 = 0$ et, par application littérale de D(5)(d)(ii), $\hat{\sigma}_{J-1}^2 = 0$ — la MSEP ne porte alors aucune variance sur la dernière année de développement (§13). Un seul avertissement par triangle, de même structure pour les trois chemins (colonne $J - 3$, colonne $J - 2$, les deux), seule la cause nommée variant. Le critère porte sur les facteurs, non sur une égalité à zéro en virgule flottante, que l'arrondi rend inopérante.
Crédibilité pleine	$I + 1 \geq 10$ (barème court)	Informatif; à défaut, $\hat{\sigma}_j^2$ repose sur deux ou trois observations en fin de triangle.

Différence de nature. Les contrôles lognormaux portent sur la *plausibilité économique* des séries (ratio dans une plage admissible, amplitude des volumes). Ceux de la méthode Merz–Wüthrich

portent d'abord sur la *géométrie* du triangle, dont dépend la simple définition des estimateurs : un triangle non carré ou incomplet ne permet pas d'appliquer la formule du paragraphe 4. C'est pourquoi la plupart sont bloquants et non de simples avertissements.

Le contrôle d'applicabilité de D(4) fait cependant exception à cette description : exécuté après l'ajustement, il ne porte pas sur les données mais sur des *grandeurs estimées* — la réserve chain-ladder totale $\hat{R}$ et la MSE, issues du même ajustement. Il n'énonce donc pas un défaut du triangle — un triangle parfaitement recevable au titre du paragraphe 2 peut conduire à $\hat{R} \leq 0$ — mais une condition d'*applicabilité de la méthode* : hors de ce domaine, ce que la formule du paragraphe 4 produit — quand elle produit quelque chose — n'est pas l'écart type qu'elle prétend définir (§13). C'est aussi pourquoi il est le seul à ne pas pouvoir être anticipé à la saisie. Cohérence interne : `mw_bootstrap()` écarte depuis l'origine toute réplication dont la réserve simulée est ≤ 0 ; la règle appliquée à l'estimation ponctuelle ne pouvait pas rester plus permissive que celle appliquée à chacune de ses répliques.

Contrôles numériques de l'estimation (méthodes lognormales, famille H)

Décision M11 du mainteneur (issue #22) : la condition du premier ordre et la convergence multi-démarrages ont quitté la table des tests, où elles figuraient comme diagnostics, pour `res$controles`. Elles y suivent les huit contrôles de la famille A, au même format (`usp_controle_donnees()`), ce qui porte `res$controles` à dix entrées pour les méthodes lognormales (la méthode Merz–Wüthrich n'a pas de famille H). Un ECHEC est restitué sans que `run_engine()` refuse le calcul, comme pour la crédibilité pleine ; il doit néanmoins être traité avant toute lecture des tests (section 22). Les critères sont justifiés dans les fiches, que le document conserve en partie III, à la place qu'occupaient les diagnostics correspondants.

Contrôle	Critère	Justification
Condition du premier ordre (<i>post-ajustement</i>)	au moins un démarrage à l'optimum (objectif à $\text{TOL_OPTIMUM} = 10^{-6}$ près) satisfait, en un même point : gradient et courbure finis, γ hors des bornes numériques <code>BORNES_GAMMA</code> , $H_{\gamma\gamma} > 0$, $ \Delta\gamma \leq \text{REP_PAS_KKT} = 10^{-6}$, $ \text{pg}_\delta \leq \text{REP_GD_KKT} = 10^{-4}$ (fiche 9.4)	Contrôle numérique de l'estimation (<code>usp_controles_numeriques()</code>) ; règle « au moins un démarrage », décision M25 du mainteneur. Repère 10^{-6} ancré sur la décision M9, repère 10^{-4} fixé d'après des mesures. Non bloquant.
Convergence multi-démarrages (<i>post-ajustement</i>)	au moins un démarrage à l'optimum (objectif à TOL_OPTIMUM près) au code de retour 0, et au moins deux démarrages à l'optimum (fiche 11.4)	Contrôle numérique de l'estimation ; convention minimale, sans référence. Non bloquant.

PARTIE II

Cadre statistique général

Bootstrap paramétrique et p-values de Monte-Carlo

La profondeur exigée par l'annexe XVII (cinq années au minimum) rend inutilisables, en toute rigueur, les lois asymptotiques de la majorité des tests documentés ci-après. Le script recalcule donc, pour les statistiques les plus sensibles, une p-value de Monte-Carlo par bootstrap paramétrique.

4.1 Procédure générale de p-value de Monte-Carlo

Référence. B. Efron, *Bootstrap methods : another look at the jackknife*, *Annals of Statistics*, 7(1), 1979, p. 1–26 ; G. A. Barnard, discussion, *JRSS B*, 25, 1963, p. 294 ; J. G. MacKinnon, *Bootstrap hypothesis testing*, in *Handbook of Computational Econometrics*, Wiley, 2009.

1. Cadre, notations et hypothèses de validité (non testées). On dispose d'un modèle paramétrique entièrement estimé $\widehat{M} = (\hat{\delta}, \hat{\gamma}, \hat{\beta})$ et d'une statistique S dont la loi exacte sous H_0 est inconnue ou mal approchée. L'hypothèse de validité, non testée, est que $\widehat{M}$ constitue une approximation suffisante du vrai modèle sous H_0 (bootstrap *paramétrique*, par opposition au rééchantillonnage non paramétrique).

2. Hypothèse nulle. Celle du test sous-jacent, inchangée : la statistique S a été calculée sur des données conformes au modèle.

3. Statistique de test. S_{obs} , calculée sur l'échantillon réel. Pour $b = 1, \dots, B$, on simule $y_t^{(b)} \sim \mathcal{LN}(\ln(\hat{\beta}x_t) - \frac{1}{2\hat{\pi}_t}, \hat{\pi}_t^{-1})$, on **réestime intégralement** (δ, γ) sur $(x_t, y_t^{(b)})$, et l'on recalcule $S^{(b)}$.

4. Loi sous H_0 . La loi empirique de $\{S^{(1)}, \dots, S^{(B)}\}$ est, par construction, un échantillon de la loi exacte de S sous H_0 conditionnellement au modèle ajusté – y compris l'effet de l'estimation des paramètres, source principale du biais des lois asymptotiques à petit T .

5. p-value. Pour un test unilatéral à droite,

$$\hat{p}_{\text{MC}} = \frac{1 + \#\{b : S^{(b)} \geq S_{\text{obs}}\}}{B + 1},$$

avec l'adaptation évidente à gauche, et $\hat{p} = 2 \min(\hat{p}_{\text{gauche}}, \hat{p}_{\text{droite}})$ au bilatéral, borné à 1. Dans le moteur, le sens du rejet de chaque statistique (haut, bas ou deux) est déclaré une seule fois, dans le catalogue de la méthode (USP_CATALOGUE_MC, MW_CATALOGUE_MC ; ADR 0003), et la p-value est calculée par une seule fonction, `engine_p_mc()`, commune aux deux méthodes. B y est remplacé par B_{eff} (champ `B_effectif`), nombre de réplifications où la statistique est finie : une réplification dont le réajustement ou le calcul des statistiques échoue est écartée.

La portée de l'ajout de 1 au numérateur et au dénominateur mérite d'être énoncée avec précision, car elle est souvent surestimée. Deux situations doivent être distinguées.

Lorsque la loi de S sous H_0 est exactement simulable — cas des tests de permutation et de randomisation — les B valeurs simulées et la valeur observée sont échangeables sous H_0 . Le rang de S_{obs} est alors uniforme sur $\{1, \dots, B+1\}$ et la règle ci-dessus fournit un test **exactement** de niveau α dès que $\alpha(B+1)$ est entier (Dwass, 1957 ; Hope, 1968). Vérification numérique sur 200 000 répliques avec $B = 99$: la fréquence de rejet vaut 0,0506 pour $\alpha = 0,05$ et 0,1003 pour $\alpha = 0,10$.

Dans le cas présent, la loi de référence n'est pas connue : elle est celle du *modèle estimé* $\widehat{M}$. Les $S^{(b)}$ sont tirés sous $\widehat{M}$ et non sous le vrai modèle, de sorte que l'échangeabilité avec S_{obs} n'est pas acquise. Le résultat d'exactitude ci-dessus **ne se transporte donc pas** au bootstrap paramétrique. L'ajout de 1 corrige la seule discrétisation liée à un B fini ; il ne corrige pas l'écart entre la loi sous $\widehat{M}$ et la loi sous le vrai modèle, dont la disparition est un résultat *asymptotique en T* (Bickel & Freedman, 1981 ; Singh, 1981 ; Hall, 1992). La validité du dispositif reste par conséquent asymptotique, et l'étude de simulation de la section 20 en constitue la seule mesure disponible à $T = 8$.

6. Usage et limites. C'est la seule p-value réellement calibrée aux tailles d'échantillon du régime USP. Sa granularité est bornée par $1/(B+1)$: avec $B = 999$, la plus petite p-value atteignable vaut 0,001 en queue haute ou basse, et $2/(B+1) = 0,002$ au bilatéral, du fait du doublement. Le moteur restitue ce pas par statistique, sur B_{eff} , dans le champ `granularite_stat` de l'objet bootstrap : $1/(B_{\text{eff}}+1)$ en queue haute ou basse, $2/(B_{\text{eff}}+1)$ au bilatéral (issue #40) ; le champ `granularite`, lu par l'application, reste le pas unilatéral nominal $1/(B+1)$. Sa limite est qu'elle teste la conformité au *modèle ajusté* : si le modèle est mal spécifié dans une direction que S ne détecte pas, la p-value sera élevée à tort. Dans les sorties du script, elle figure en colonne `p_mc` et prime sur la p-value asymptotique lorsque les deux sont disponibles.

4.2 Bootstrap semi-paramétrique de la méthode Merz–Wüthrich

Le modèle de Mack ne spécifiant aucune loi, aucun bootstrap *paramétrique* n'est possible. Le moteur emploie un rééchantillonnage des résidus standardisés (England & Verrall, 2002, *British Actuarial Journal* 8(3), 443–518), qui ne suppose que leur échangeabilité : les p-values correspondantes sont donc *semi-paramétriques* et non paramétriques.

Limite structurelle du rééchantillonnage de résidus. Cette procédure tire dans la loi *empirique* des résidus observés. Son hypothèse nulle est « les résidus suivent leur propre loi empirique », et non « les résidus sont normaux ». Une p-value de Monte-Carlo pour un test de normalité y serait donc vide de sens ; la vérification par simulation le confirme, la fréquence de rejet tombant à zéro au lieu de 5 %. Les tests de normalité de la famille M5 sont en conséquence exclus du bootstrap et rapportés avec leur propre loi nulle : loi exacte de W évaluée par simulation directe pour Shapiro–Wilk, approximation de Dallal & Wilkinson pour Lilliefors.

Nature des p-values et validité à $T = 8$

5.1 Quatre statuts épistémiques à ne jamais confondre

Toute conclusion du dispositif relève de l'un des quatre statuts suivants. La distinction est reprise systématiquement dans les tableaux 5.4 et 5.5.

Statut	Signification et portée
Exact	La loi de la statistique sous H_0 est connue pour la taille d'échantillon considérée, sans approximation (loi combinatoire, de permutation, binomiale, ou loi de Student/Fisher sous normalité exacte des erreurs). La p-value est alors valide à $T = 8$ comme à $T = 1000$.
Asymptotique	La loi n'est connue qu'à la limite $T \rightarrow \infty$. L'existence du résultat limite ne dit <i>rien</i> de la qualité de l'approximation à T fini : il faut disposer, séparément, d'un résultat sur la <i>vitesse</i> de convergence ou d'une étude de simulation.
Approximation numérique	La loi exacte existe mais n'est pas calculable analytiquement, et l'on emploie une formule d'ajustement (Royston pour Shapiro–Wilk, Stephens pour Anderson–Darling). La qualité de l'approximation dépend du domaine de validité annoncé par ses auteurs, qui doit être vérifié pour $T = 8$.
Comportement empirique	Résultat d'une étude de simulation. Il documente le niveau effectif observé, mais ne transforme jamais une approximation en résultat exact et ne vaut que pour le modèle sous lequel la simulation a été conduite.

Principe de sélection retenu dans le moteur. Pour chaque test, la p-value effectivement utilisée pour le verdict suit la hiérarchie *exacte* $\succ$ *Monte-Carlo* $\succ$ *asymptotique*. Le champ `nature_p` de la sortie indique laquelle a été retenue, et les trois valeurs (`p_exacte`, `p_asymptotique`, `p_monte_carlo`) restent affichées séparément pour permettre la revue. Aucune p-value asymptotique n'est retenue lorsqu'une p-value exacte ou de Monte-Carlo est disponible.

Ce que cette hiérarchie ne dit pas : la règle de sortie. La hiérarchie *ordonne des p-values qui existent*. Elle ne se lit pas à l'envers : l'absence de p-value exacte et de p-value de Monte-Carlo n'autorise pas un repli sur l'asymptotique, ni, plus généralement, sur la loi *nominale* — celle que la statistique suivrait si les paramètres n'avaient pas été estimés. Lorsqu'une grandeur est **rivée par l'estimation**, c'est-à-dire contrainte par une condition du premier ordre du maximum de vraisemblance plutôt que librement observée — le centrage des résidus standardisés par la condition en $\ln \beta$, identité algébrique $\sum_t \sqrt{\hat{\pi}_t} z_t = 0$ vraie dans tous les cas, leur variance par la condition en γ , relation pondérée distincte qui ne tient qu'à un optimum intérieur en γ —, aucune des trois voies n'est ouverte, et il faut le dire des trois et non de la seule qui a échoué en premier : (i) il n'existe pas de loi exacte sous H_0 pour une quantité que H_0 ne laisse pas varier ; (ii) la dispersion simulée de la grandeur sous le modèle ajusté est gouvernée par celle des poids $\hat{\pi}_t^*$, non par les données, et, à $\hat{\pi}_t$ constant, la loi simulée porte un atome en la valeur observée, de sorte que la p-value de Monte-Carlo se décide au signe d'un bruit numérique ; (iii) la loi nominale ne décrit pas la grandeur restituée, puisque la valeur observée n'est pas une observation. Le point (iii) est le plus important pour le relecteur, car c'est le repli le plus tentant : à $\hat{\pi}_t$ constant, la p-value

nominale de ces grandeurs est une *constante de T* qui ne dépend plus des données, identique pour deux jeux étrangers l'un à l'autre. Le « OK » qu'elle produirait ne pourrait être perdu par aucune donnée ; c'est exactement la fausse assurance que la restitution en diagnostic vise à éviter. Le calcul et les mesures figurent aux fiches 9.5 et 9.6. Ces lignes sont donc restituées comme *diagnostics*, sans p-value retenue et avec le motif. Cette règle de sortie ne concerne ni le test de Student sur la pente ni le test de Fisher global : leur statistique est librement observée et leur loi est exacte sous normalité des erreurs ; ils conservent leur p-value, pour la raison exposée à la sous-section 5.3.

5.2 Deux sources d'erreur distinctes

Lorsqu'une p-value est estimée par B simulations, deux erreurs se superposent ; elles ont des causes, des ordres de grandeur et des remèdes différents, et ne doivent en aucun cas être confondues.

	Erreur de Monte-Carlo	Erreur d'approximation statistique
Source	Nombre fini B de réplifications	Taille finie T de l'échantillon
Grandeur affectée	L'estimateur $\hat{p}_{MC}$ de la p-value bootstrap	L'écart entre la loi bootstrap et la vraie loi sous H_0
Ordre de grandeur	$\sqrt{p(1-p)/B}$ en queue haute ou basse, $\sqrt{p(2-p)/B}$ au bilatéral, soit $\mathcal{O}(B^{-1/2})$	Dépend du test ; typiquement $\mathcal{O}(T^{-1/2})$ ou $\mathcal{O}(T^{-1})$
Réduction	Augmenter B (gratuit, purement numérique)	Impossible : $T = 8$ est une donnée du problème
Mesure dans le moteur	champ <code>err_mc</code> (colonne <code>erreur_MC</code> de la table auditable)	non mesurable directement ; approchée par l'étude de simulation de la section 20

Avec $B = 999$ et $\hat{p} \approx 0,10$, l'erreur de Monte-Carlo vaut environ 0,009 pour une p-value unilatérale et 0,014 pour une p-value bilatérale. Il serait erroné d'en conclure que la p-value est « précise à $\pm 0,01$ » : cette précision porte sur l'estimation de la p-value *bootstrap*, pas sur son écart à la vraie p-value sous H_0 . La granularité de $\hat{p}_{MC}$ est en outre bornée inférieurement par $1/(B+1)$ (Dwass, 1957 ; Hope, 1968 ; voir la bibliographie complémentaire, section 21), et par $2/(B+1)$ au bilatéral (champ `granularite_stat`, fiche 4.1).

Formule de l'erreur de Monte-Carlo (`engine_p_mc()`, issue #40). Sous le modèle de la simulation — réplifications indépendantes et de même loi sous le modèle ajusté, conditionnellement aux données —, le nombre N^+ de réplifications au moins égales à la valeur observée suit **exactement** une loi binomiale $B(B_{\text{eff}}, q^+)$, où q^+ est la p-value bootstrap que donnerait un B infini. En queue haute (symétriquement en queue basse), $\text{Var}(\hat{p}) = B_{\text{eff}} q^+ (1 - q^+) / (B_{\text{eff}} + 1)^2$: la formule du moteur, $\sqrt{\hat{p}(1 - \hat{p}) / B_{\text{eff}}}$, en est l'écart-type au facteur $B_{\text{eff}} / (B_{\text{eff}} + 1)$ près et au remplacement de q^+ par son estimateur $\hat{p}$ près ; c'est une approximation numérique d'un écart-type exact, sans lien avec T . Au bilatéral, $\hat{p} = 2 \min(\hat{p}^+, \hat{p}^-)$: tant que le minimum ne change pas de côté d'une réalisation à l'autre, $\hat{p}$ est le double d'une proportion de queue d'espérance $q = p/2$, de variance $4q(1-q)/B = p(2-p)/B$, et le moteur retient $\sqrt{\hat{p}(2 - \hat{p}) / B_{\text{eff}}}$, $\hat{p}$ étant pris après la borne à 1. L'énumération exacte de la loi binomiale à $B = 999$ — constat numérique, non théorème — montre que l'écart-type exact de $\hat{p}$ et la formule bilatérale coïncident à moins de 0,5 % pour $p \leq 0,90$ (0,0138 à $p = 0,10$, 0,0247 à $p = 0,374$, 0,0310 à $p = 0,80$). Au-delà, le minimum change de côté avec une probabilité non négligeable et la formule **maïore** l'écart-type exact : 0,0316 contre 0,0290 à $p = 0,95$, 0,0222 à $p = 0,98$ et 0,0190 à $p = 1$, soit jusqu'à 1,66 fois l'écart-type exact en $p = 1$ ($1/\sqrt{B}$ contre $\sqrt{(1 - 2/\pi)/B}$ sous l'approximation normale). Le moteur garde une seule formule, sans cas particulier au bord : une borne supérieure est préférable, dans une table auditable, à une valeur exacte en un seul point et fausse à côté. La formule unilatérale, appliquée jusqu'à l'issue #40 aux p-values bilatérales, sous-estimait leur erreur d'un facteur $\sqrt{(1-p)/(2-p)}$ (0,62 à $p = 0,374$) ; aucune p-value ni aucun verdict n'en dépendait.

À $\hat{p} = 1$ en queue haute ou basse — toutes les répliques au-delà de la valeur observée, cas de la p-value de Monte-Carlo de Cox–Stuart sur le jeu de contrôle (fiche 6.9) —, la formule donne une erreur nulle. Cela ne signifie pas l’absence d’erreur, mais une erreur inférieure à la granularité : $N^+ = B_{\text{eff}}$ implique, au niveau de confiance de 95 %, $q^+ \geq 0,05^{1/B}$, soit $1 - q^+ \leq 0,003$ à $B = 999$.

Au bilatéral s’ajoutent deux biais de signes opposés, d’ordre $1/B$ à $1/\sqrt{B}$ et sans lien avec T (énumération à $B = 999$) : la convention $(1 + N)/(B + 1)$ relève chaque queue de $1/(B + 1)$, soit environ $+0,002$ après doublement ; le minimum biaise vers le bas, de façon négligeable tant que $1 - p$ dépasse $3/\sqrt{B} \approx 0,10$, puis jusqu’à $-0,024$ en $p = 1$, voisin de $-\sqrt{2/(\pi B)} = -0,025$. Le biais total reste au plus égal à $0,8/\sqrt{B}$ en valeur absolue ; son maximum, atteint en $p = 1$, est loin des seuils de verdict (0,05, 0,10 et 0,30 au seuil $\alpha = 0,10$) et sans conséquence sur un verdict, tandis qu’au voisinage de ces seuils il se réduit au relèvement de la convention, de l’ordre de la granularité.

5.3 Ce que l’on peut et ne peut pas affirmer à $T = 8$

- **Résultats exacts disponibles à $T = 8$.** Loi binomiale (Cox–Stuart), loi de permutation de Spearman, loi mahonienne du S de Kendall, loi combinatoire du nombre de suites, loi exacte de Smirnov à deux échantillons, et les lois de Student et de Fisher de la régression auxiliaire *sous l’hypothèse de normalité exacte des erreurs*. Ces p-values sont valides sans réserve de taille d’échantillon.
- **Résultats asymptotiques sans justification suffisante à $T = 8$.** Les statistiques de type multiplicateur de Lagrange (Breusch–Pagan, White), portmanteau (Ljung–Box, Box–Pierce), Jarque–Bera, et les approximations normales de Mann–Kendall, Wald–Wolfowitz et D’Agostino. La littérature disponible ne fournit, pour aucune d’entre elles, de borne d’erreur exploitable à $T = 8$.
- **Deux cas où aucune p-value de Monte-Carlo n’est possible.** Les tests de Student sur la pente et de Fisher global ont pour hypothèse nulle $b = 0$. Or le bootstrap paramétrique simule sous le *modèle ajusté*, pour lequel $\hat{b} \neq 0$: le modèle de simulation appartient à H_1 et non à H_0 . Une p-value de Monte-Carlo y serait dépourvue de sens. Ces deux tests conservent donc leur loi de Fisher/Student, qui est *exacte* sous normalité des erreurs : la limitation porte sur l’hypothèse de normalité, non sur la taille d’échantillon.
- **Un troisième cas, de nature différente : la grandeur rivée par l’estimation.** Le centrage et la variance unitaire des résidus standardisés (fiches 9.5 et 9.6) sont contraints par les conditions du premier ordre du maximum de vraisemblance, le premier par la condition en $\ln \beta$, la seconde par la condition en γ . La loi simulée sous le modèle ajusté existe bien, mais, à $\hat{\pi}_t$ constant, elle porte un *atome* en la valeur observée : la p-value de Monte-Carlo s’y décide au signe d’un bruit numérique. À la différence des deux cas précédents, il n’y a ici aucun repli possible : ni loi exacte, ni loi nominale utilisable, cette dernière produisant à $\hat{\pi}_t$ constant une p-value qui ne dépend plus des données. Ces deux lignes sont restituées comme *diagnostics*, sans p-value retenue et avec le motif.
- **Ce qu’aucune méthode ne restitue.** Ni le bootstrap ni les lois exactes n’augmentent la *puissance*. À $T = 8$, l’ensemble du dispositif reste très peu puissant : une p-value élevée n’est pas une validation d’hypothèse. Les diagnostics de robustesse de la section 11 conservent la priorité sur les tests d’hypothèse.

5.4 Tableau 1 : disponibilité et choix des p-values

Ce tableau recense les tests *effectivement présents* dans le moteur (R/engine.R). La colonne « Asympt. utilisable à $T = 8$? » ne répond pas mécaniquement : elle distingue l’existence théorique d’une loi limite de la qualité de son approximation à $T = 8$.

La colonne « Méthode » indique le périmètre d’emploi : **LN** pour les méthodes lognormales (risque de prime, section B, et risque de réserve n° 1, section C), **MW** pour la méthode du risque de réserve n° 2 (Merz–Wüthrich, section D), et **Les deux** lorsque le test est employé dans les deux dispositifs. Dans ce dernier cas la statistique est identique, mais son support diffère : résidus standardisés z_t du modèle lognormal d’un côté, résidus standardisés de Mack $r(i, j)$ de l’autre (voir la section 13).

La mention « exacte si $\hat{\pi}_t$ constant » de la colonne « Voie retenue » (issue #25) porte sur les tests dont la loi de référence suppose un vecteur échangeable ou un échantillon i.i.d. : sous le modèle ajusté, les résidus standardisés suivent $\mathcal{N}(0, P)$ et les ratios r_t ne sont identiquement distribués qu’à $\hat{\pi}_t$ constant ($\hat{\delta} = 1$ ou volumes constants, au sens de `usp_regime()` ; section 5.6). Dans ce régime la p-value est exacte au sens de l’ADR 0002 ; hors de lui, c’est une approximation sans borne d’erreur connue à $T = 8$. Le moteur étiquette ces p-values exacte et les retient dans les deux régimes.

Test	Méthode	Stat.	Exacte ?	Asympt. ?	MC ?	Voie retenue	Asympt. utilisable à $T = 8$?	Recommandation ACPR
Student, constante	LN	t_a	Oui (sous normalité)	—	Oui	Exacte (MC en recouplement)	Sans objet : loi exacte	Distribution exacte à privilégier. <i>Mais</i> le non-rejet ne prouve rien : compléter par le TOST
Équivalence (TOST)	LN	max des 2 unilatéraux	Oui si Δ fixée a priori	—	Sans objet	Exacte (Δ a priori) ou quasi-exacte ($\Delta = \theta\bar{y}$)	Sans objet : loi exacte	Seul test fournissant une preuve positive de proportionnalité ; fixer Δ a priori. Puissance de 46 % seulement à $T = 8$
Student, pente	LN	t_b	Oui (sous normalité)	—	Non (voir texte)	Exacte (loi t)	Sans objet : loi exacte	Distribution exacte à privilégier ; vérifier la normalité
Fisher global	LN	F	Oui (sous normalité)	—	Non (voir texte)	Exacte (loi F)	Sans objet : loi exacte	Idem ; redondant avec t_b
RESET	LN	F	Non	Oui	Oui	Monte-Carlo	Déconseillée : $\hat{y}^2, \hat{y}^3$ dépendent de y , la loi F n'est pas exacte	Bootstrap recommandé
Spearman ($\times 2$)	LN	S	Oui ($T \leq 9$)	Oui	Oui	Exacte si $\hat{\pi}_t$ constant, approximation sinon	Inutile : l'exacte est calculable	Distribution exacte à privilégier
Mann–Kendall	LN	Z / S	Oui (loi mahonnienne)	Oui	Oui	Exacte si $\hat{\pi}_t$ constant, approximation sinon	Déconseillée : approx. normale usuellement requise à $T \geq 10$	Distribution exacte à privilégier
Cox–Stuart	LN	K	Oui (binomiale)	—	Oui	Exacte si $\hat{\pi}_t$ constant, approximation sinon	Sans objet	Exacte ; mais $p_{\min} = 0,125$ à $T = 8$: test inopérant
Breusch–Pagan studentisé (Koenker)	LN	LM	Non	Oui	Oui	Monte-Carlo	Déconseillée : convergence χ^2 lente, aucune borne à $T = 8$	Bootstrap recommandé ; version de référence pour conclure
Breusch–Pagan original (1979)	LN	LM	Non	Oui, sous normalité	Oui	Monte-Carlo	Déconseillée : convergence lente <i>et</i> hypothèse de normalité non acquise	À lire en regard de la version studentisée ; un écart signale H3, pas H2
White	LN	LM	Non	Oui	Oui	Monte-Carlo	Déconseillée : 3 coefficients auxiliaires pour 8 points	Bootstrap ; puissance quasi nulle
Goldfeld–Quandt	LN	F	Approx. seulement	Oui	Oui	Monte-Carlo	Sous conditions : exacte si régressions séparées, ici résidus globaux	Bootstrap recommandé
Brown–Forsythe	LN	W	Non	Oui	Oui	Monte-Carlo	Déconseillée : loi F approchée, 4 points par groupe	Bootstrap recommandé
Smirnov 2 éch.	LN	D	Oui (combinatoire)	Oui	Oui	Exacte si $\hat{\pi}_t$ constant ($\hat{\delta} = 1$), approximation sinon	Inutile	Exacte ; $n_1 = n_2 = 4$: $p_{\min} = 0,029$

Suite page suivante

Test	Méthode	Stat.	Exacte ?	Asympt. ?	MC ?	Voie retenue	Asympt. utilisable à $T = 8$?	Recommandation ACPR
Shapiro–Wilk	LN	W	Oui si $\hat{\pi}_t$ constant, loi de W évaluée par simulation directe (sans Royston); approximation sinon	Approx. Royston	Oui	Monte-Carlo, avec p Royston <i>et</i> p de loi nulle simulée	Sous conditions pour Royston; la loi nulle simulée s'en affranchit	Loi nulle simulée à privilégier; les deux concordent à $T = 8$
Shapiro–Francia	LN	W'	Non	Approx. Royston	Oui	Monte-Carlo	Sous conditions : validité annoncée $5 \leq T \leq 5000$	Bootstrap recommandé
Anderson–Darling	LN	A^2	Non (param. estimés)	Oui (Stephens, cas 3)	Oui	Monte-Carlo, p de Stephens en complément	Sous conditions : ajustement empirique, calibration vérifiée à $T = 8$	Bootstrap retenu; p de Stephens disponible
Cramér–von Mises	LN	W^2	Non	Oui (Stephens, cas 3)	Oui	Monte-Carlo, p de Stephens en complément	Idem A^2	Bootstrap retenu; p de Stephens disponible
KS contre $\mathcal{N}(0, 1)$	LN	D	Non	Oui (Kolmogorov)	Oui	Monte-Carlo	Déconseillée : 0 rejet sur 3 000 simulations à 5 %, test vidé de sa puissance	Utiliser Lilliefors à la place
Lilliefors	LN	D_L	Non	Oui (Dallal–Wilkinson)	Oui	p de Dallal–Wilkinson	Oui : calibration vérifiée à $T = 8$ (5,2 % à 5 %)	Version correcte du KS à paramètres estimés
Jarque–Bera	LN	JB	Non	Oui	Oui	Monte-Carlo	Déconseillée : convergence χ^2_2 très lente; b_2 borné par $\sim T$	Bootstrap; test peu informatif à $T = 8$
D’Agostino (asym.)	LN	Z	Non	Oui (transf. S_U)	Oui	Monte-Carlo	Sous conditions : défini dès $T \geq 8$, à la limite du domaine	Bootstrap; à interpréter avec prudence
Anscombe–Glynn	LN	Z	Non	Oui	—	Non applicable ($T < 20$)	Sans objet	Non utilisable à $T = 8$
Durbin–Watson	LN	DW	Oui : forme quadratique, méthode d’Imhof	—	Oui	Exacte (Imhof) si $\hat{\pi}_t$ constant, approximation sinon	Sans objet : loi exacte à $\hat{\pi}_t$ constant	Distribution exacte à privilégier; statistique calculée sur résidus centrés
Ljung–Box (1, 2)	LN	Q	Non	Oui	Oui	Monte-Carlo	Déconseillée : approx. χ^2 mal calibrée en petit échantillon	Bootstrap recommandé
Box–Pierce	LN	Q	Non	Oui	Oui	Monte-Carlo	Déconseillée : encore moins bonne que Ljung–Box	Bootstrap; préférer Ljung–Box

Suite page suivante

Test	Méthode	Stat.	Exacte ?	Asympt. ?	MC ?	Voie retenue	Asympt. utilisable à $T = 8$?	Recommandation ACPR
Suites (W.-W.)	LN	Z / R	Oui (combinatoire)	Oui	Oui	Exacte (doublement) si $\hat{\pi}_t$ constant, approximation sinon	Déconseillée : approx. normale requiert $n_1, n_2 \geq 10$	Distribution exacte à privilégier ; $p_{\min} = 0,057$ à $T = 8$
Durbin-Watson sur ratios bruts	LN	DW	Non : u_t non gaussiens, Imhof inapplicable	—	Oui	Monte-Carlo	Sans objet (aucune loi limite employée)	Quasi-doublon de la ligne sur z_t à $\hat{\pi}_t$ constant
Ljung-Box (1) sur ratios bruts	LN	Q	Non	—	Oui	Monte-Carlo	Sans objet (χ^2 non calculée)	Quasi-doublon de la ligne sur z_t à $\hat{\pi}_t$ constant
Suites sur ratios bruts	LN	Z / R	Oui si $\hat{\pi}_t$ constant (combinatoire)	—	Oui	Exacte (doublement) si $\hat{\pi}_t$ constant <i>et</i> signes de u_t et z_t identiques, Monte-Carlo sinon	Sans objet (approx. normale non calculée)	Doublon exact de la ligne sur z_t à $\hat{\pi}_t$ constant
Centrage des résidus	LN	—	—	—	—	Diagnostic	Sans objet	Aucune p-value : $\bar{z}$ est rivé par une identité de l'estimation. La p-value nominale du t ne dépendrait pas des données (= 1 à $\hat{\pi}_t$ constant). Restitué sans verdict
Variance unitaire	LN	—	—	—	—	Diagnostic	Sans objet	Aucune p-value : $\text{Var}(z)$ est rivée par la condition en γ (optimum intérieur) ; à $\hat{\pi}_t$ constant, la loi simulée porte un atome en la valeur observée et la p-value nominale du χ^2 ne dépendrait pas des données (0,6651878 à $T = 8$). Restituée sans verdict
sup-F (rupture)	LN	$\sup F$	Non	Théorique seulement (Andrews)	Oui	Monte-Carlo	Absence de justification : loi de sup. de processus, convergence fonctionnelle	Seul test sur z_t sans p-value non simulée : bootstrap indispensable
OLS-CUSUM	LN	$\sup S $	Non	Oui (Kolmogorov asympt.)	Oui	Monte-Carlo	Absence de justification : 8 points ne forment pas une trajectoire brownienne	Bootstrap indispensable ; p asympt. fournie pour mémoire
Grubbs	LN	G	Borne de Bonferroni	—	Oui	Monte-Carlo	Sous conditions : borne conservatrice, non exacte	Bootstrap ; borne utilisable comme majorant
sup-F sur ratios bruts	LN	$\sup F$	Non	—	Oui	Monte-Carlo	Sans objet (aucune loi limite employée)	Quasi-doublon de la ligne sur z_t à $\hat{\pi}_t$ constant
OLS-CUSUM sur ratios bruts	LN	$\sup S $	Non	—	Oui	Monte-Carlo	Sans objet (Kolmogorov non calculée)	Quasi-doublon de la ligne sur z_t à $\hat{\pi}_t$ constant

Suite page suivante

Test	Méthode	Stat.	Exacte ?	Asympt. ?	MC ?	Voie retenue	Asympt. utilisable à $T = 8$?	Recommandation ACPR
Grubbs sur ratios bruts	LN	G	Non	—	Oui	Monte-Carlo	Sans objet (Bonferroni non calculée)	Quasi-doublon de la ligne sur z_t à $\hat{\pi}_t$ constant
Rosner (ESD)	LN	R_i	Valeurs critiques tabulées	—	—	Procédure de décision	Sans objet (pas de p-value)	Indicatif seulement ; fiabilité annoncée pour $T \geq 25$
Méthode Merz-Wüthrich — M1 : proportionnalité des cumulés								
Tendance avec le cumulé, à colonne donnée	MW	t pondéré (GLS, effet fixe de colonne)	Non	Oui	Oui	Monte-Carlo	Déconseillée : les cellules d'une colonne partagent $\hat{f}_j$ et $\hat{\sigma}_j$	Version agrégée puissante (100 % sous l'alternative testée) ; les tests par colonne localisent
Ordonnée à l'origine par colonne	MW	X de Fisher	Non	Oui, $\chi^2(2K)$	Oui	Monte-Carlo	Déconseillée : colonnes adjacentes non indépendantes	Test central de M1 ; calibration MC vérifiée (10,7 % et 4,7 %)
Homogénéité de f_j entre années de survéance	MW	X de Fisher	Non	Oui, $\chi^2(2K)$	Oui	Monte-Carlo	Idem	Seconde exigence du texte : « pour toutes les années d'accident »
Absence de courbure	MW	X de Fisher	Non	Oui, $\chi^2(2K)$	Oui	Monte-Carlo	Idem	Puissance faible : 3 paramètres pour 4 à 6 observations
Famille α (pondération)	MW	amplitude relative	Non	Non	Oui	Monte-Carlo	Sans objet : aucune loi analytique	Diagnostic de robustesse ; chiffrer l'enjeu du choix de pondération
Méthode Merz-Wüthrich — M2 : variance proportionnelle au cumulé								
Breusch-Pagan sur résidus de Mack	MW	LM	Non	Oui	Oui	Monte-Carlo	Déconseillée : convergence χ^2 lente <i>et</i> dépendance intra-colonne	Bootstrap recommandé ; teste l'exposant 1 imposé par le règlement
Exposant de variance par colonne	MW	X de Fisher	Non	Oui, $\chi^2(2K)$	Oui	Monte-Carlo	Déconseillée : colonnes non indépendantes	Localise ce que Breusch-Pagan agrège ; un rejet est une limite du modèle, pas un motif de changement de méthode
Variance unitaire des résidus de Mack	MW	—	—	—	—	Diagnostic	Sans objet	Valeur contrainte par construction à $(N - k)/(N - 1)$ — N résidus, k colonnes retenues —, et non à 1 : identité exacte, fiche 15.3. Contrôle de cohérence de la standardisation, sans pouvoir de détection sur σ_j
Méthode Merz-Wüthrich — M3 : indépendance								
Homogénéité des résidus entre années de survéance	MW	H de Kruskal-Wallis	Non	Oui, $\chi^2(k - 1)$	Oui	Monte-Carlo	Déconseillée : groupes très déséquilibrés (de J à 1 résidu)	Traduction testable de D(2)(h)(i) ; complète le test calendaire

Suite page suivante

Test	Méthode	Stat.	Exacte ?	Asympt. ?	MC ?	Voie retenue	Asympt. utilisable à $T = 8$?	Recommandation ACPR
Effets d'année calendaire	MW	Z	Non	Oui (moments <i>exacts</i> de Z)	Oui	Monte-Carlo	Sous conditions : les moments sont exacts, l'approximation normale de leur somme ne l'est pas	Bootstrap de résidus ; test le plus informatif sur un triangle
Corrélation entre années de développement	MW	ρ agrégé	Non	Non	Oui	Monte-Carlo	Sans objet : aucune loi analytique	Bootstrap indispensable
Autocorrélation (Durbin-Watson) sur résidus de Mack	MW	DW	Non	Non : loi d'Imhof in-applicable	Oui	Monte-Carlo	Sans objet : aucune loi analytique	Bootstrap indispensable
Test des suites sur résidus de Mack	MW	Z	Non (échangeabilité en défaut)	Oui	Oui	Monte-Carlo	Déconseillée : dépendance intra-colonne	Bootstrap recommandé
Méthode Merz-Wüthrich — M4 : points aberrants								
Grubbs sur résidus de Mack	MW	G	Borne de Bonferroni	—	Oui	Monte-Carlo	Sous conditions : suppose la normalité, non exigée par le modèle	Bootstrap ; borne utilisable comme majorant
Rosner (ESD) sur résidus de Mack	MW	R_i	Valeurs critiques tabulées	—	—	Procédure de décision	Sans objet (pas de p-value)	Indicatif ; $n = 28$ à $T = 8$, sous le seuil de fiabilité
Méthode Merz-Wüthrich — M5 : normalité (diagnostic, non exigée)								
Shapiro-Wilk sur résidus de Mack	MW	W	Oui , loi nulle simulée	Approx. Royston	Non (voir texte)	Loi nulle simulée	Sans objet : loi propre	Diagnostic seulement : normalité non exigée par D(2)(h)
Lilliefors sur résidus de Mack	MW	D_L	Non	Oui (Dallal-Wilkinson)	Non	p de Dallal-Wilkinson	Sous conditions	Variante secondaire ; diagnostic seulement
Méthode Merz-Wüthrich — M6 : robustesse de l'estimation								
Concentration de la ré-serve sur la dernière année	MW	—	—	—	—	Diagnostic	Sans objet	Équivalent du jackknife : mesure la concentration du résultat sur la ligne la moins informative
Extrapolation de $\hat{\sigma}_{J-1}^2$	MW	—	—	—	—	Diagnostic	Sans objet	Valeur imposée par le règlement, non estimée : à signaler dans le dossier, avec les cas $\hat{\sigma}_{J-3}^2 = 0$ ou $\hat{\sigma}_{J-2}^2 = 0$ où la lettre du texte l'annule

Lecture. « Sans objet : loi exacte » signifie que la question de la qualité de l'approximation asymptotique ne se pose pas, une loi exacte étant employée. « Absence de justification suffisante » signifie que la littérature consultée n'établit pas, pour $T = 8$, de borne d'erreur ni d'étude de simulation permettant de conclure : la p-value asymptotique n'est alors pas retenue.

5.5 Tableau 2 : nature et vitesse des convergences

Ce tableau sépare strictement les deux phénomènes : la convergence en T de la loi de la statistique, et la convergence en B de l'estimateur de la p-value. Lorsque les deux coexistent, ils sont documentés sur deux lignes distinctes. Les blocs (A), (B) et (D) concernent la méthode lognormale ; le bloc (C) est propre à la méthode Merz–Wüthrich, où la profondeur pertinente n'est plus T mais le nombre d'observations $n_j = I - j$ de chaque colonne du triangle, qui décroît jusqu'à 2 ou 3 sur les dernières années de développement.

Test	Objet qui converge	Limite	Nature	Vitesse	Hypothèses	Conséquence à $T = 8$
(A) Convergence en T de la loi de la statistique — non contrôlable, T est une donnée						
Student / Fisher	Aucune : loi exacte à T fini	—	—	—	Erreurs i.i.d. $\mathcal{N}(0, \sigma^2)$, régresseurs fixes	Valide, sous réserve de la normalité
Breusch–Pagan (Koenker), White	$LM = TR_{\text{aux}}^2$	$\chi^2(q)$	Convergence en loi	Non établie de façon exploitable; TCL sous-jacent en $\mathcal{O}(T^{-1/2})$	Moments d'ordre 4 finis, indépendance	Non exploitable; bootstrap requis
Breusch–Pagan (1979)	$LM = \frac{1}{2} \text{SCE}$	$\chi^2(q)$	Convergence en loi	Idem, <i>mais</i> la limite n'est atteinte que si $\text{Var}(u^2) = 2\sigma^4$	Normalité des erreurs , en sus des précédentes	Non exploitable; sur-rejet si queues lourdes
Ljung–Box, Box–Pierce	Q	$\chi^2(h)$	Convergence en loi	Non établie; niveau effectif connu comme dégradé en petit échantillon	Stationnarité, moments d'ordre 2	Non exploitable; bootstrap requis
Jarque–Bera	$(\sqrt{b_1}, b_2)$ puis JB	$\chi^2(2)$	Convergence en loi	Réputée <i>très</i> lente	Moments d'ordre 8 finis pour la normalité asymptotique de b_2	Non exploitable; b_2 borné par $\sim T$
Mann–Kendall	S (U -statistique)	$\mathcal{N}(0, 1)$ après normalisation	Convergence en loi	Berry–Esseen pour U -statistiques : $\mathcal{O}(T^{-1/2})$	Variance de la projection non nulle, moment d'ordre 3	Borne $\mathcal{O}(8^{-1/2}) \approx 0,35$: inexploitable. Loi exacte employée (exacte à $\hat{\pi}_t$ constant)
Wald–Wolfowitz	R	$\mathcal{N}(0, 1)$	Convergence en loi	Vitesse non documentée dans la littérature consultée; loi exacte employée, la question est sans objet; recommandation d'usage $n_1, n_2 \geq 10$	Continuité, indépendance	Loi exacte employée (exacte à $\hat{\pi}_t$ constant)
Spearman	$\hat{\rho}_s$	$\mathcal{N} / t(T - 2)$	Convergence en loi	$\mathcal{O}(T^{-1/2})$	Indépendance, absence d'ex aequo	Loi de permutation exacte employée (exacte à $\hat{\pi}_t$ constant)
D'Agostino	$\sqrt{b_1}$ transformé	$\mathcal{N}(0, 1)$	Convergence en loi	Transformation S_U conçue pour corriger l'ordre T^{-1} ; validité annoncée $T \geq 8$	Moments d'ordre 6 finis	Limite du domaine; bootstrap en complément
Anderson–Darling, CvM, KS	Processus empirique $\sqrt{T}(\hat{F} - F_0)$	Pont brownien (transformé)	Convergence faible dans $D[0, 1]$	$\mathcal{O}(T^{-1/2})$ pour les fonctionnelles régulières	F_0 continue, paramètres connus	Hypothèse violée (paramètres estimés); bootstrap requis
sup-F	$\{F(k)\}_k$	Sup. d'un processus de Bessel	Convergence faible	Fonctionnelle : lente, non quantifiée à T petit	Erreurs i.i.d., écrêtement τ fixé	Non exploitable; bootstrap requis
OLS-CUSUM	$S(\lfloor uT \rfloor)$	Pont brownien B°	Convergence faible (principe d'invariance)	$\mathcal{O}(T^{-1/2})$	Erreurs i.i.d., variance finie	8 points : non exploitable
Shapiro–Wilk / Francia	W, W'	Approx. normalisée de Royston	Approximation numérique, non asymptotique	Sans objet (ajustement empirique)	Domaine de validité annoncé par l'auteur	Domaine couvert mais transformation distincte à $T \leq 11$; bootstrap en complément

Suite page suivante

Test	Objet qui converge	Limite	Nature	Vitesse	Hypothèses	Conséquence à $T = 8$
Centrage, variance unitaire (diagnostics)	<i>Aucun</i> : $\bar{z}$ et $\text{Var}(z)$ sont riviés par les conditions du premier ordre (en $\ln \beta$ pour $\bar{z}$, en γ pour $\text{Var}(z)$)	—	—	Sans objet	Optimum intérieur en γ ; $\hat{\pi}_t$ constant pour la forme simple $\sum_t z_t = 0$, $\sum_t z_t^2 = T$	Aucune p-value : à $\hat{\pi}_t$ constant, la loi simulée sous le modèle ajusté porte un atome en la valeur observée, et la loi nominale, qui ignore l'estimation, produit à $\hat{\pi}_t$ constant une p-value qui ne dépend plus des données du tout : 1 pour le t de Student et 0,6651878 pour le χ^2 , à $T = 8$. Restitués sans verdict
(B) Convergence en B de l'estimateur Monte-Carlo — entièrement contrôlable						
Toutes statistiques bootstrapées	$\hat{p}_{MC} = \frac{1 + \#\{S^{(b)} \geq S_{\text{obs}}\}}{B+1}$	p^* , p-value bootstrap exacte	Convergence presque sûre (LFGN) et en loi (TCL)	Écart-type $\sqrt{p(1-p)/B} = \mathcal{O}(B^{-1/2})$, $\sqrt{p(2-p)/B}$ au bilatéral (majorant au-delà de $p = 0,9$); granularité $1/(B+1)$, $2/(B+1)$ au bilatéral	Réplications i.i.d. sous le modèle ajusté	$B = 999 \Rightarrow \pm 0,009$ à $p = 0,10$ ($\pm 0,014$ au bilatéral). Sans lien avec T
Idem	Loi bootstrap p^*	Vraie p-value sous H_0	Convergence bootstrap en T	Consistance établie asymptotiquement; raffinement d'ordre supérieur pour statistiques pivotales	Modèle correctement spécifié, estimateur consistant	Non quantifiable à $T = 8$. C'est ici, et non dans le choix de B , que réside la limite du dispositif : la correction en $1/(B+1)$ ne rend pas le test exact
Durbin–Watson sur ratios bruts	$\hat{p}_{MC}$ (loi limite de DW non employée)	$p_{MC}(\hat{\theta})$, p-value sous le modèle ajusté de paramètres $\hat{\theta} = (\hat{\beta}, \hat{\delta}, \hat{\gamma})$	Convergence en B	$\mathcal{O}(B^{-1/2})$	Modèle ajusté pris pour vrai	Erreur de Monte-Carlo seule contrôlée; validité en T non quantifiable (fiche 9.7)
Ljung–Box (1) sur ratios bruts	$\hat{p}_{MC}$ ($\chi^2(1)$ non employée)	$p_{MC}(\hat{\theta})$	Convergence en B	$\mathcal{O}(B^{-1/2})$	Modèle ajusté pris pour vrai	Idem (fiche 9.8)
Suites sur ratios bruts	<i>Aucun</i> à $\hat{\pi}_t$ constant et signes identiques : loi exacte de R ; sinon $\hat{p}_{MC}$	Loi exacte; sinon $p_{MC}(\hat{\theta})$	— ; sinon convergence en B	—; sinon $\mathcal{O}(B^{-1/2})$	r_t i.i.d. ($\hat{\pi}_t$ constant); sinon modèle ajusté pris pour vrai	Exacte dans ce régime, régime estimé sur les données; sinon comme ci-dessus (fiche 9.9)
sup-F sur ratios bruts	$\hat{p}_{MC}$ (loi d'Andrews non employée)	$p_{MC}(\hat{\theta})$	Convergence en B	$\mathcal{O}(B^{-1/2})$	Modèle ajusté pris pour vrai	Idem (fiche 10.7)
OLS-CUSUM sur ratios bruts	$\hat{p}_{MC}$ (loi de Kolmogorov non employée)	$p_{MC}(\hat{\theta})$	Convergence en B	$\mathcal{O}(B^{-1/2})$	Modèle ajusté pris pour vrai	Idem (fiche 10.8)
Grubbs sur ratios bruts	$\hat{p}_{MC}$ (borne de Bonferroni non employée)	$p_{MC}(\hat{\theta})$	Convergence en B	$\mathcal{O}(B^{-1/2})$	Modèle ajusté pris pour vrai	Idem (fiche 10.9)
(C) Convergence propre à la méthode Merz–Wüthrich						

Suite page suivante

Test	Objet qui converge	Limite	Nature	Vitesse	Hypothèses	Conséquence à $T = 8$
Effets d'année calendaire	$Z = \sum_k \min(L_k, S_k)$	$\mathcal{N}(0, 1)$ après centrage-réduction	Convergence en loi	Non quantifiée; les moments de chaque Z_k sont en revanche <i>exacts</i>	Indépendance des diagonales, absence d'ex æquo dans les colonnes	Le nombre de diagonales exploitables est $I - 1$: la somme porte sur peu de termes, d'où le recours au bootstrap
Facteurs $\hat{f}_j$	Estimateur des moindres carrés pondérés	f_j	Convergence en probabilité; sans biais sous M1	$\mathcal{O}_P(n_j^{-1/2})$ avec $n_j = I - j$ observations	M1 et M3	Les colonnes de droite ne reposent que sur 2 ou 3 observations
Variances $\hat{\sigma}_j^2$	Estimateur pondéré de la variance	σ_j^2	Convergence en probabilité	$\mathcal{O}_P(n_j^{-1/2})$, avec $n_j - 1$ degrés de liberté	M2, moments d'ordre 4 finis	$\hat{\sigma}_{j-1}^2$ n'est pas estimée mais extrapolée par la règle du règlement, et nulle lorsque $\hat{\sigma}_{j-3}^2 = 0$ ou $\hat{\sigma}_{j-2}^2 = 0$
Variance des résidus de Mack (diagnostic)	<i>Aucune</i> : identité exacte à I fini, $\sum_{i,j} r(i, j)^2 = N - k$ pour N résidus répartis sur k colonnes	—	—	—	Aucune : l'identité découle de la seule définition de $\hat{\sigma}_j^2$	La valeur est fixée à $(N - k)/(N - 1) = 0,8077$ sur un triangle 8×8 , et non à 1 : rien ne converge et rien ne se teste (fiche 15.3)
$\sqrt{\text{MSEP}}$	Erreur de prédiction à un an	Erreur vraie	Convergence en probabilité	Non établie à I fini	M1 à M3, modèle correctement spécifié	Non quantifiable; la MSEF hétérite de l'incertitude sur $\hat{\sigma}_{j-1}^2$
Combinaisons de Fisher (ordonnée à l'origine, homogénéité, courbure, exposant de variance)	$X = -2 \sum \ln p_k$	$\chi^2(2K)$	Convergence en loi	Sans objet en toute rigueur : la loi $\chi^2(2K)$ suppose l'indépendance des K p-values, mise en défaut car les colonnes j et $j + 1$ partagent $C(\cdot, j + 1)$	Indépendance des colonnes	p-value du χ^2 indicative seulement; bootstrap retenu
Corrélation entre colonnes	$\hat{\rho}$ agrégé	<i>aucune limite tabulable</i>	—	Sans objet : la géométrie du triangle interdit toute normalisation	Continuité, absence d'ex æquo	Bootstrap seul recours; 5 à 6 paires exploitables à $T = 8$
Durbin-Watson et suites sur résidus de Mack	DW, Z	$\mathcal{N}(0, 1)$ / loi combinatoire	Convergence en loi	Non établie : les résidus d'une colonne partagent $\hat{f}_j$ et $\hat{\sigma}_j$	Échangeabilité, mise en défaut ici	Lois classiques écartées; bootstrap retenu
Bootstrap de résidus	$\hat{p}_{MC}$	p-value paramétrique	Convergence en B (Monte-Carlo) et en I (validité bootstrap)	$\mathcal{O}(B^{-1/2})$ pour la première; non établie pour la seconde	Échangeabilité des résidus standardisés	Ne permet pas de tester la normalité : la loi nulle simulée est la loi empirique des résidus
(D) Convergence de l'estimateur du paramètre (méthode lognormale)						
$(\hat{\delta}, \hat{\gamma})$ (MV)	Estimateur du maximum de vraisemblance	(δ_0, γ_0)	Convergence en probabilité; normalité asymptotique	$\mathcal{O}_P(T^{-1/2})$ sous conditions de régularité	Modèle correct, identifiabilité, intérieur du domaine	$\hat{\delta}$ souvent au bord : régularité en défaut, normalité asymptotique non applicable
Test du rapport de vraisemblance sur δ	LR	$\frac{1}{2}\chi^2(0) + \frac{1}{2}\chi^2(1)$	Convergence en loi	Non quantifiée à T petit	Frontière du domaine (résultat de Chernoff)	p-value $\chi^2(1)$ conservatrice d'un facteur 2

Point de méthode central. Les deux blocs (A) et (B) répondent à des questions différentes. Le bloc (B) montre que l'erreur numérique sur $\hat{p}_{MC}$ est maîtrisée et réductible à volonté en augmentant B . Le bloc (A) montre qu'à $T = 8$, aucune des lois asymptotiques mobilisées ne dispose d'une justification exploitable. Le bootstrap paramétrique déplace le problème sans le supprimer : il remplace une approximation asymptotique par une approximation *de plug-in*, dont la validité reste asymptotique en T et n'est pas quantifiable à $T = 8$. C'est la raison pour laquelle la section 11 (jackknife, largeur de l'intervalle bootstrap, position de $\hat{\delta}$) doit primer sur la lecture des p-values dans le dossier remis au superviseur.

5.6 Choix de la base de résidus

Plusieurs séries peuvent servir de support aux tests. Le choix n'est pas neutre : il détermine à la fois l'hypothèse effectivement testée et la validité des p-values classiques.

Les trois séries candidates

Série	Définition	Loi sous le modèle
Résidus standardisés	$z_t = \sqrt{\hat{\pi}_t} v_t$	$z \sim \mathcal{N}(0, P)$, P projecteur de rang $T - 1$ (ci-dessous) et non $\mathcal{N}(0, I_T)$; échangeables si et seulement si $\hat{\pi}_t$ est constant, P étant alors la matrice de centrage
Résidus logarithmiques	$v_t = \ln r_t + \frac{1}{2\hat{\pi}_t} - \ln \hat{\beta}$	normaux, liés par le terme commun $\ln \hat{\beta}$, de variances inégales dès que $\hat{\pi}_t$ varie avec x_t
Ratios centrés	$u_t = r_t - \bar{r}$, avec $r_t = y_t/x_t$	issus de r_t indépendants, mais liés par le centrage, ni normaux ni de même variance

La différence $y_t - x_t$ n'est pas un résidu mais le *résultat technique* de l'exercice : elle mélange le niveau de marge et l'erreur de prévision. Le résidu correspondant sur l'échelle monétaire est $e_t = y_t - \hat{\beta}x_t$, égal à $x_t(r_t - \hat{\beta})$: à un facteur de volume près, il coïncide avec u_t . C'est donc u_t qui est retenu comme base « brute », le passage au ratio neutralisant l'effet de taille au premier ordre.

Loi des résidus standardisés et portée des p-values exactes

Sous le modèle ajusté pris pour vrai, les $\hat{\pi}_t$ étant tenus pour connus et notés π_t , $\ln r_t = \ln \beta - 1/(2\pi_t) + \varepsilon_t/\sqrt{\pi_t}$, avec ε_t i.i.d. $\mathcal{N}(0, 1)$. En reportant cette écriture dans la forme fermée de $\ln \hat{\beta}$ calculée par `usp_noyau()`, $\ln \hat{\beta} = (T/2 + \sum_t \pi_t \ln r_t) / \sum_t \pi_t = \ln \beta + \sum_s \sqrt{\pi_s} \varepsilon_s / \sum_s \pi_s$, on obtient (issue #25)

$$z = P\varepsilon, \quad P = I_T - \frac{\sqrt{\pi} \sqrt{\pi}'}{\sum_t \pi_t}, \quad \sqrt{\pi} = (\sqrt{\pi_1}, \dots, \sqrt{\pi_T})'.$$

P est la projection orthogonale, de rang $T - 1$, sur l'orthogonal de $\sqrt{\pi}$: z suit $\mathcal{N}(0, P)$ et **non** $\mathcal{N}(0, I_T)$ (résultat exact, algébrique ; vérifié numériquement, z calculé par `usp_noyau()` et $P\varepsilon$ coïncidant à $9 \cdot 10^{-16}$ près). Les z_t sont corrélés, de variances $1 - \pi_t / \sum_s \pi_s$; ils sont échangeables si et seulement si les π_t sont égaux, et P est alors la matrice de centrage $M = I_T - \mathbf{1}\mathbf{1}'/T$. Ce calcul tient $\hat{\pi}_t$ pour connu : il ne rend pas compte de ce que $\hat{\delta}$ et $\hat{\gamma}$ sont estimés sur les mêmes données.

Conséquence sur les p-values dites exactes. Huit lignes de la table auditable retiennent une p-value exacte dont la loi de référence est construite pour un vecteur échangeable ou un échantillon i.i.d. : quatre sur z_t — Durbin–Watson (loi d'Imhof de *MAM*), suites (loi combinatoire), Shapiro–Wilk à loi nulle simulée (échantillons $\mathcal{N}(0, 1)$ i.i.d.) et Smirnov (loi combinatoire) —, et quatre sur les ratios r_t — Spearman ratio contre volume et ratio contre temps, Mann–Kendall et Cox–Stuart, qui supposent les r_t identiquement distribués. À $\hat{\pi}_t$ **constant**, ces lois sont exactes au sens de l'ADR 0002 : z est proportionnel à $M\varepsilon$ et les r_t sont i.i.d. À $\hat{\pi}_t$ **variable**, ce ne sont que des approximations ; aucune borne d'erreur n'a été

trouvée dans la littérature consultée pour un projecteur P non uniforme, et le document n'affirme rien sur l'ampleur de l'écart. Le moteur, lui, étiquette ces huit p-values exacte et les retient dans tous les régimes ; seule la ligne des suites sur ratios bruts conditionne son étiquette au régime (issue #29, fiche 9.3). Dans la bande de tolérance de `usp_regime()`, $\hat{\pi}_t$ n'est constant qu'à un écart d'ordre $1 - \hat{\delta}$ près, et l'exactitude ne vaut qu'à cet ordre près.

Calibration mesurée par régime (constat de simulation, non une borne). Deux scénarios à $T = 8$, $\beta = 0,7$, $\sigma = 0,15$, 10 000 jeux chacun : (A) $\delta = 1$, volumes du jeu de contrôle (graine 2501) ; (B) $\delta = 0$, volumes équidistants et croissants de 50 à 200, soit des π_t du modèle d'étendue relative 2,9 (graine 2502). Chaque jeu est réajusté par `usp_ajuster()`, le régime est celui que déclare `usp_regime()` sur $\hat{\delta}$, et les p-values sont celles des fonctions du moteur (`dw_p_exacte()`, `sw_p_loi_nulle()`, `runs_p_exacte()`, `ks.test()` sur la partition en volumes). Le tableau donne la fréquence de $p \leq \text{seuil}$, à comparer à la probabilité exacte sous échangeabilité, qui vaut le seuil pour les lois continues et 4/70, 16/70, 2/70 ou 16/70 pour les lois discrètes des suites et de Smirnov ($n_1 = n_2 = 4$) ; en gras, un écart supérieur à la demi-largeur de l'intervalle de fluctuation à 95 % (de 0,003 à 0,015 selon la case).

Fréquence	Exacte	A, tous	A, $\hat{\pi}$ cst	A, $\hat{\pi}$ var.	B, $\hat{\pi}$ cst	B, $\hat{\pi}$ var.
Effectif	—	10 000	4 971	5 029	2 929	7 071
Durbin–Watson, $p \leq 0,10$	0,100	0,099	0,097	0,101	0,101	0,090
Durbin–Watson, $p \leq 0,05$	0,050	0,047	0,048	0,046	0,052	0,043
Shapiro–Wilk (loi nulle simulée), $p \leq 0,10$	0,100	0,105	0,111	0,100	0,096	0,089
Shapiro–Wilk (loi nulle simulée), $p \leq 0,05$	0,050	0,053	0,057	0,050	0,049	0,039
Suites, $p \leq 0,057$	0,057	0,055	0,050	0,060	0,064	0,056
Suites, $p \leq 0,229$	0,229	0,229	0,222	0,235	0,226	0,229
Smirnov, $p \leq 0,029$	0,029	0,027	0,024	0,031	0,037	0,028
Smirnov, $p \leq 0,229$	0,229	0,230	0,233	0,226	0,227	0,216

Trois constats, propres à ces deux configurations. Sur l'ensemble des jeux du scénario A, où π_t est constant dans le modèle générateur, les huit fréquences sont compatibles avec la probabilité exacte. Dans le scénario B à $\hat{\pi}_t$ variable, Durbin–Watson et Shapiro–Wilk rejettent *moins* que le niveau nominal (0,090 et 0,089 au seuil de 10 %) : l'approximation y est conservatrice, sans que rien permette d'étendre ce sens à d'autres volumes ou à d'autres δ . Enfin, des écarts apparaissent aussi à $\hat{\pi}_t$ constant (scénario A, Shapiro–Wilk à 0,111) : l'exactitude énoncée plus haut vaut sous le modèle ajusté pris pour vrai, et non conditionnellement au régime, qui est lui-même estimé sur les mêmes données ; cet effet de sélection n'est pas quantifié au-delà de ce constat. Les mesures antérieures consignées dans les fiches, qui ne précisent pas le régime de $\hat{\delta}$, sont conservées comme telles (fiches 9.1 et 8.7).

Amplitude effective de l'hétéroscédasticité résiduelle

Sous le modèle, $\text{Var}(r_t) = \sigma^2[\delta + (1 - \delta)\bar{x}/x_t]$. Sur un jeu de volumes allant de 50 à 200 avec $\delta = 0,35$, l'écart-type théorique des r_t varie de 0,120 à 0,076, soit un facteur 1,6 entre la première et la dernière année. Les u_t ne sont donc pas identiquement distribués : toute loi de référence supposant l'échangeabilité (permutation, combinatoire, ou normale i.i.d.) est invalide sur cette base. Cette invalidité disparaît lorsque $\hat{\pi}_t$ est constant — c'est-à-dire lorsque $\hat{\delta} = 1$, ou lorsque les volumes x_t le sont — puisque les r_t sont alors identiquement distribués. Les trois séries ne deviennent pas pour autant proportionnelles : $z_t = \sqrt{\hat{\pi}} v_t$ l'est bien de v_t , à facteur constant, mais u_t vit sur l'échelle linéaire quand v_t vit sur l'échelle logarithmique, et l'on ne passe de l'une à l'autre que par une transformation monotone non linéaire. Ce point est repris plus bas : à $\hat{\pi}_t$ constant, cette transformation est tout ce qui sépare encore les deux bases, ce qui prive la base u_t de son objet.

Où la bascule est légitime, et où elle ne l'est pas

Famille	Bascule	Justification
H1 — linéarité	sans objet	Les tests de tendance (Spearman, Mann–Kendall, Cox–Stuart) portent <i>déjà</i> sur r_t . Il n'existe pas de version sur z_t qui aurait un sens : la tendance recherchée est celle du ratio lui-même.
H2 — variance	non	Changer de base changerait l'hypothèse nulle. Sur z_t , on teste s'il subsiste une hétéroscédasticité <i>après</i> pondération, ce qui doit être rejeté par les données si le modèle est correct. Sur u_t , on testerait l'hétéroscédasticité <i>brute</i> , dont la présence est précisément ce que le modèle postule : le test serait attendu significatif et ne dirait rien de la qualité du calibrage.
H3 — lognormalité	non	Le modèle prédit que z_t est normal, non que r_t l'est (r_t est approximativement lognormal). Tester la normalité de u_t reviendrait à tester une hypothèse que le modèle ne formule pas. Sur v_t , la normalité est bien prédite mais la variance $1/\hat{\pi}_t$ n'est pas constante, ce qui invalide les tests de normalité usuels dès que $\hat{\pi}_t$ varie, c'est-à-dire dès que $\hat{\delta} < 1$ et que les volumes x_t ne sont pas constants.
H4 — indépendance	oui	L'indépendance est une propriété que le modèle attribue aux Y_t <i>conditionnellement</i> aux x_t : elle se transmet aux trois séries. Les deux bases testent donc la même hypothèse.
Stabilité et valeurs aberrantes	oui	Idem. Sur u_t , une valeur aberrante s'interprète directement comme un boni/mali exceptionnel et une rupture comme un changement de régime du ratio, sans dépendre de la qualité de l'ajustement.

Statut des p-values selon la base

Sur la base u_t , les p-values exactes et asymptotiques sont **indicatives seulement** : elles supposent l'échangeabilité, mise en défaut par l'hétéroscédasticité résiduelle. En revanche, la p-value de Monte-Carlo garde sur cette base la validité qu'elle a partout ailleurs : le bootstrap paramétrique simule Y_t sous le modèle ajusté, donc la loi de référence d'une statistique quelconque — y compris calculée sur u_t — est reproduite hétéroscédasticité comprise, à l'erreur de Monte-Carlo près et sous le modèle ajusté pris pour vrai (section 4) ; elle n'est exacte ni au sens de l'ADR 0002 ni à T fini. C'est cette p-value que le moteur retient sur cette base, avec une seule exception : le test des suites sur ratios bruts retient la p-value exacte de la loi combinatoire de R lorsque $\hat{\pi}_t$ est constant et que les signes de u_t coïncident avec ceux de z_t , les r_t étant alors i.i.d. sous le modèle ajusté (issue #29 ; condition détaillée à la fiche 9.3, rubrique 5).

Vérification par simulation à $T = 8$, sous H_0 , statistiques calculées sur u_t et p-values de Monte-Carlo (400 répliquations, $B = 199$) :

Statistique sur u_t	rejets à 10 %	rejets à 5 %
Durbin–Watson	0,107	0,050
Grubbs	0,115	0,055

Les deux valeurs sont compatibles avec les niveaux nominaux à l'intérieur de l'intervalle de confiance à 95 % ($\pm 0,029$ et $\pm 0,021$).

Ce contrôle est sans objet lorsque $\hat{\pi}_t$ est constant

Six lignes de la table auditable sont calculées sur la base u_t : Durbin–Watson, Ljung–Box au retard 1, test des suites, rupture de niveau (sup-F), stabilité cumulée (OLS-CUSUM) et Grubbs, chacune ayant son homologue sur z_t et sa fiche (fiches 9.7, 9.8, 9.9, 10.7, 10.8 et 10.9). Le contrôle qu'elles portent consiste à vérifier que les conclusions d'indépendance et de stabilité ne sont pas un artefact de la pondération $\hat{\pi}_t$. **Là où il n'y a pas de pondération, il n'y a pas d'artefact de pondération à détecter**, et ce contrôle perd son objet. C'est le cas dès que $\hat{\pi}_t$ est constant, donc à $\hat{\delta} = 1$ ou à volumes x_t constants — soit

le cas courant à $T = 8$. Le moteur en décide sur cette cause, et non sur l'étendue observée des $\hat{\pi}_t$: `usp_regime()` déclare $\hat{\pi}_t$ constant lorsque $\hat{\delta} \geq 1 - 10^{-6}$ ou que les volumes sont égaux à 10^{-6} près en relatif, avec la tolérance `TOL_DELTA_BORD` justifiée à la fiche 9.5.

Conséquence algébrique exacte. Lorsque $\hat{\pi}_t \equiv \hat{\pi}$, la forme fermée de $\ln \hat{\beta}$ se réduit à $\ln \hat{\beta} = \frac{1}{2\hat{\pi}} + \overline{\ln r}$, d'où $v_t = \ln r_t - \overline{\ln r}$ et

$$z_t = \sqrt{\hat{\pi}} (\ln r_t - \overline{\ln r}).$$

Les deux bases ne diffèrent alors plus que par la transformation logarithmique $r \mapsto \ln r$, à un facteur d'échelle et un recentrage près. Cette transformation est *monotone*.

Conséquence exacte pour le test des suites. La statistique des suites ne dépend que des signes des écarts à la médiane, qu'une transformation monotone préserve : elle prend donc la **même valeur** sur les deux bases. Mesuré sur le jeu de contrôle ($T = 8$, $\hat{\delta} = 1$) : $Z = -0,7637626$ sur z_t comme sur u_t , et les huit signes de $r_t - \text{med}(r)$ et de $z_t - \text{med}(z)$ coïncident un à un. Jusqu'à l'issue #29, les deux lignes affichaient néanmoins des p-values différentes (1,000 contre 0,768). Cet écart de 0,232 ne tenait qu'en partie à la méthode retenue (p-value exacte sur z_t , de Monte-Carlo sur u_t) : il se décomposait en +0,257 de *convention bilatérale* et -0,025 d'*erreur de Monte-Carlo*. La p-value exacte valait alors 1,000 parce que `runs_p_exacte()` sommait les probabilités des issues au plus aussi probables que l'issue observée : $R = 4$ étant observé et $R = 4, 5, 6$ ayant la même probabilité modale 18/70, toutes les issues étaient comptées. Le bootstrap applique au contraire le doublement, $2 \min(P(R \leq R_{\text{obs}}), P(R \geq R_{\text{obs}}))$, dont la valeur exacte est ici $2 \cdot 26/70 = 52/70 = 0,743$; les p-values de Monte-Carlo, 0,762 sur z_t et 0,768 sur u_t (erreur de Monte-Carlo 0,031), estiment cette quantité, d'où $1,000 - 0,743 = 0,257$ et $0,743 - 0,768 = -0,025$. Depuis l'issue #29, `runs_p_exacte()` applique le doublement et la ligne sur u_t reçoit la p-value exacte dans ce régime (fiche 9.3, rubrique 5) : les deux lignes portent désormais la même p-value exacte, $52/70 = 0,743$, et la colonne `p_mc` de chacune l'estime, à l'erreur de Monte-Carlo près.

Pour les cinq autres, un écart du second ordre. En écrivant $r_t = \bar{r}(1 + \varepsilon_t)$, le développement de $\ln$ donne $\ln r_t - \overline{\ln r} = \varepsilon_t + \mathcal{O}(\varepsilon^2)$: les deux séries centrées coïncident au premier ordre, et leur différence est d'ordre ε^2 , soit du *second* ordre en coefficient de variation des r_t (approximation numérique, développement limité). L'écart tient donc à l'opposition *logarithmique contre linéaire*, et non à $\hat{\pi}_t$. Mesuré sur le jeu de contrôle, où le coefficient de variation vaut $\text{CV}(r) = 0,151$: l'écart maximal entre $\ln r_t - \overline{\ln r}$ et $(r_t - \bar{r})/\bar{r}$ vaut 0,0143, à comparer à $\text{CV}(r)^2 = 0,0228$; $\text{cor}(z, u) = 0,998$ et $\text{cor}(z, \ln r) = 1$ à la précision machine. Les six lignes sur base u_t et leurs six homologues sur z_t y portent le même verdict OK ; pour les cinq paires autres que le test des suites, les p-values retenues diffèrent d'au plus 0,091 (sup-F, 0,840 contre 0,931), l'écart le plus faible étant celui de Durbin-Watson (0,0011). Le second ordre vaut pour la série ; sa propagation à la statistique dépend de la régularité de celle-ci, faible pour Durbin-Watson, sensible pour sup-F, dont le maximum porte à $T = 8$ sur des segments de deux ou trois points au plus court. Une statistique qui repose sur une quasi-annulation garde en revanche un écart relatif important sur la valeur elle-même — Ljung-Box au retard 1 vaut $9,2 \cdot 10^{-3}$ sur z_t et $1,3 \cdot 10^{-4}$ sur u_t — sans que le verdict en dépende à ce niveau de p-value.

Ce que cela change pour le dossier, et ce que cela ne change pas. Les six lignes restent exactes : leur statistique, leur p-value retenue — de Monte-Carlo, sauf pour le test des suites, qui retient dans ce régime la p-value exacte — et leur verdict sont justes, et elles gardent tout leur sens *lorsque $\hat{\pi}_t$ varie*, cas pour lequel elles ont été prévues. Ce qui était faux est la promesse formulée sans condition : présentées comme six vérifications indépendantes, elles sont, à $\hat{\pi}_t$ constant, des **quasi-doublons** de leurs homologues sur z_t — et un doublon exact pour le test des suites. Six verdicts OK de la table auditable n'y apportent donc pas six informations. Le moteur porte lui-même cette réserve : dans ce cas, le champ `detai1` de chacune des six lignes commence par « CONTROLE SANS OBJET ICI » et indique que la ligne est un quasi-doublon de son homologue sur résidus standardisés. La situation n'a rien d'exceptionnel : sur les 999 répliquions

du bootstrap paramétrique du jeu de contrôle, 493 — soit 49,3 % — ont un $\hat{\pi}_t^*$ constant (constat de simulation, graine 20260831).

Usage recommandé. La base z_t reste celle du dossier : c'est la seule sur laquelle les p-values exactes et asymptotiques sont valides (à l'exception de la p-value exacte des suites sur u_t , attribuée seulement lorsque $\hat{\pi}_t$ est constant, où la ligne n'apporte rien de plus que son homologue sur z_t), et c'est elle qui teste les hypothèses telles que l'annexe XVII les formule. La base u_t est un *contrôle de cohérence de la pondération*, **sous la condition que cette pondération existe** : elle vérifie que les conclusions d'indépendance et de stabilité ne sont pas un artefact des poids $\hat{\pi}_t$. Une divergence marquée entre les deux bases sur un même test signale que le résultat dépend du modèle plutôt que des données, et doit être documentée. **Lorsque $\hat{\pi}_t$ est constant, ce contrôle est sans objet** et les six lignes correspondantes sont des quasi-doublons de leurs homologues sur z_t : elles ne doivent pas être lues comme six vérifications supplémentaires (voir « Ce contrôle est sans objet lorsque $\hat{\pi}_t$ est constant », plus haut dans cette sous-section, et le champ détail de ces lignes, qui porte la réserve). Les deux bases sont calculées systématiquement par le moteur et figurent toutes deux dans l'export ; la bascule de l'application ne fait que filtrer l'affichage.

5.7 Variantes principales et secondaires

Quatre tests existent dans le dispositif sous deux formes concurrentes. Pour alléger la lecture, l'application n'affiche par défaut que la forme retenue comme référence, les autres restant accessibles par une case à cocher et présentes dans l'export.

Forme de référence	Forme secondaire	Motif du choix
Breusch–Pagan studentisé (Koenker)	Breusch–Pagan original (1979)	La forme originale suppose la normalité des erreurs, hypothèse non acquise à $T = 8$; elle sur-rejette fortement sur queues lourdes.
Shapiro–Wilk (Royston)	Shapiro–Wilk à loi nulle simulée	Les deux concordent à $T = 8$ (4,95 % contre 5,05 %). La forme de Royston est retenue comme référence parce qu'elle est celle de <code>shapiro.test()</code> , donc la plus immédiatement vérifiable.
Lilliefors	Kolmogorov–Smirnov contre $\mathcal{N}(0, 1)$	La seconde applique une loi de référence valable à paramètres connus ; à paramètres estimés elle est vidée de sa puissance.
Ljung–Box	Box–Pierce	La pondération $(T+2)/(T-k)$ de Ljung–Box corrige le biais de petit échantillon que Box–Pierce ignore.

Le classement en forme de référence et forme secondaire est une convention d'*affichage*, consignée dans le champ variante de la table des tests. Il ne modifie ni les calculs, ni les verdicts, ni le contenu de l'export.

5.8 Tests dont l'usage reste fragile à $T = 8$

Les tests suivants figurent dans le dispositif mais leur interprétation doit être explicitement réservée à $T = 8$. Chacun est accompagné d'un complément méthodologique, indiqué en troisième colonne.

Test	Fragilité à $T = 8$	Complément méthodologique
Méthode lognormale		
Cox–Stuart	$m = 4$ paires $\Rightarrow p_{\min} = 2 \cdot 2^{-4} = 0,125$: le rejet est <i>impossible</i> à tout seuil usuel	Conservé (loi exacte), mais signalé comme inopérant ; la détection de tendance repose sur Mann–Kendall exact
Jarque–Bera	b_2 borné par $\sim T$; convergence χ^2_2 très lente	p-value de Monte-Carlo ajoutée ; test à lire comme purement indicatif
White	3 coefficients auxiliaires estimés sur 8 points	p-value de Monte-Carlo ajoutée ; Breusch–Pagan à privilégier
Anscombe–Glynn	Non défini pour $T < 20$	Marqué <i>non applicable</i> ; l’analyse de queue repose sur A^2 , dont la p-value de Monte-Carlo est simulée sous le modèle réajusté ; le QQ-plot à enveloppe n’est qu’une aide de lecture, sa bande $\mathcal{N}(0, 1)$ iid étant conservatrice pour des résidus ré-estimés (fiche 12.3)
Rosner (ESD)	Fiabilité des valeurs critiques annoncée pour $T \geq 25$	Conservé comme signal d’attention ; aucune exclusion de donnée ne doit en découler sans justification métier
sup-F, OLS-CUSUM	Convergence fonctionnelle ; 8 points ne forment pas une trajectoire limite	p-value de Monte-Carlo seule retenue ; à lire conjointement avec la distance de Cook
Student / Fisher (pente)	Loi exacte, mais <i>conditionnelle</i> à la normalité des erreurs, non testable indépendamment à $T = 8$	Aucune p-value de Monte-Carlo possible (voir texte) ; la normalité est examinée séparément en section 8
Méthode Merz–Wüthrich		
Corrélation entre années de développement	Cinq à six paires de colonnes seulement comptent au moins trois observations à $T = 8$	Aucune loi analytique n’existe ; bootstrap seul recours, puissance très faible
Rosner (ESD) sur résidus de Mack	Fiabilité annoncée pour $n \geq 25$; un triangle 8×8 fournit 27 résidus — la colonne $j = J - 1$ n’ayant qu’un seul facteur individuel n’en produit aucun —, soit la limite du domaine	Conservé comme signal d’attention ; aucune exclusion de cellule sur ce fondement
Extrapolation de $\hat{\sigma}_{j-1}^2$	La quantité n’est pas estimée mais imposée par une règle du règlement, appuyée sur deux colonnes, qui l’annule lorsque $\hat{\sigma}_{j-3}^2 = 0$ ou $\hat{\sigma}_{j-2}^2 = 0$	Diagnostic dédié ; à mentionner explicitement dans le dossier, avertissement de validation dans le cas dégénéré
Tests de normalité (M5)	Non exigés par le modèle, et exclus du bootstrap de résidus dont la nulle est la loi empirique observée	Loi nulle propre pour Shapiro–Wilk ; lecture comme diagnostic seulement

PARTIE III

Fiches de tests par hypothèse

Hypothèse H1 — linéarité et proportionnalité

Énoncé réglementaire (annexe XVII, B/C(2)(f)(i)). L'espérance des pertes agrégées est *linéairement proportionnelle* aux primes acquises (ou à la provision d'ouverture) : $\mathbb{E}[Y_t] = \beta x_t$, sans terme constant, avec β constant dans le temps.

6.1 Test de Student sur la constante

Référence. W. S. Gosset (« Student »), *The probable error of a mean*, *Biometrika*, 6(1), 1908, p. 1–25.

1. Cadre, notations et hypothèses de validité (non testées). Régression auxiliaire $y_t = a + bx_t + \varepsilon_t$. Hypothèses non testées : les ε_t sont indépendants, de variance constante σ_ε^2 , de loi $\mathcal{N}(0, \sigma_\varepsilon^2)$, et les x_t sont exogènes et non aléatoires. Nécessite $T \geq 3$ et $S_{xx} > 0$.

2. Hypothèse nulle. $H_0 : a = 0$, absence de composante de sinistralité indépendante du volume. C'est la traduction testable de la *proportionnalité stricte* exigée par le règlement.

3. Statistique de test.

$$t_a = \frac{\hat{a}}{\widehat{\text{se}}(\hat{a})}, \quad \widehat{\text{se}}(\hat{a}) = \hat{s} \sqrt{\frac{1}{T} + \frac{\bar{x}^2}{S_{xx}}}, \quad \hat{s}^2 = \frac{\text{SCR}}{T-2}.$$

4. Loi sous H_0 . $t_a \sim t(T-2)$, loi exacte sous normalité des erreurs.

5. p-value. $p = 2(1 - F_{t, T-2}(|t_a|))$. Cette p-value est **exacte** sous normalité des erreurs : elle est donc retenue en priorité par le moteur, la p-value de Monte-Carlo n'étant calculée qu'à titre de recoupement (les deux concordent étroitement sur le jeu de référence).

6. Usage et limites. On souhaite *ne pas* rejeter H_0 , ce qui constitue la faiblesse logique de ce test : **l'absence de preuve n'est pas une preuve d'absence**. Un non-rejet ne démontre pas la proportionnalité, alors que c'est précisément ce que le règlement demande d'établir. Limite aggravante dans le contexte USP : x_t est un volume toujours très éloigné de zéro et de faible amplitude relative. La constante est donc extrapolée loin du domaine des données et $\widehat{\text{se}}(\hat{a})$ est mécaniquement très grande (le terme $\bar{x}^2/S_{xx}$ domine), si bien que le test ne rejette pratiquement jamais. Le test d'équivalence de la fiche suivante renverse cette charge de la preuve.

6.2 Équivalence de la constante à zéro (TOST)

Référence. D.J. Schuirmann, *A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability*, *Journal of Pharmacokinetics and Biopharmaceutics*, 15(6), 1987, p. 657–680; W.J. Westlake, *Response to T.B.L. Kirkwood : bioequivalence testing — a need to rethink*, *Biometrics*, 37(3), 1981, p. 589–594.

1. Cadre, notations et hypothèses de validité (non testées). Même régression auxiliaire et mêmes hypothèses de validité que la fiche précédente. On se donne en outre une *marge d'équivalence* $\Delta > 0$, qui n'est pas une quantité statistique mais un seuil économique : en deçà de Δ , une composante fixe de sinistralité est jugée sans portée pratique. Le moteur propose deux modes : Δ fixée a priori (`delta_equiv`), ou $\Delta = \theta \bar{y}$ (`theta_equiv`, 10 % par défaut), c'est-à-dire une fraction de la perte annuelle moyenne.

2. Hypothèse nulle.

$$H_0 : |a| \geq \Delta \quad (\text{la constante n'est pas négligeable}) \quad \text{contre} \quad H_1 : |a| < \Delta.$$

Les rôles sont inversés par rapport au test précédent : c'est le *rejet* de H_0 qui établit la proportionnalité pratique. L'hypothèse à démontrer est passée en H_1 , ce qui est la construction correcte lorsque l'on veut prouver une absence d'effet.

3. Statistique de test. Décomposition en deux tests unilatéraux (procédure d'intersection-union) :

$$t_{\text{bas}} = \frac{\hat{a} + \Delta}{\widehat{\text{se}}(\hat{a})} \quad (H_0^- : a \leq -\Delta), \quad t_{\text{haut}} = \frac{\hat{a} - \Delta}{\widehat{\text{se}}(\hat{a})} \quad (H_0^+ : a \geq +\Delta).$$

On rejette H_0 au niveau α si et seulement si les deux sous-hypothèses sont rejetées, soit $t_{\text{bas}} > t_{1-\alpha, T-2}$ et $t_{\text{haut}} < -t_{1-\alpha, T-2}$.

4. Loi sous H_0 . Chaque statistique unilatérale suit *exactement* une loi de Student à $T - 2$ degrés de liberté sous normalité des erreurs. Aucun résultat asymptotique n'intervient.

5. p-value. Règle du maximum, propre aux procédures d'intersection-union :

$$p_{\text{TOST}} = \max \left(1 - F_{t, T-2}(t_{\text{bas}}), F_{t, T-2}(t_{\text{haut}}) \right).$$

Cette p-value est exacte **si Δ est fixée a priori**. Avec la marge relative $\Delta = \theta \bar{y}$, la marge dépend des données et l'exactitude n'est plus qu'approchée ; le moteur signale alors la nature de la p-value comme *quasi-exacte* et non comme exacte. Pour un dossier ACPR, il est recommandé d'arrêter Δ à l'avance et de le documenter. Deux cas sont restitués « non applicable », sans p-value retenue et en INFO (issue #58) : les volumes constants (x_t tous égaux, garde `sd(x) == 0` de `test_tost_intercept()`), où la régression auxiliaire n'est pas définie, et une marge invalide (sans `delta_equiv` : `theta_equiv` non fini ou $\theta \leq 0$; avec `delta_equiv` : Δ non finie ou non strictement positive, θ étant alors ignoré) ; les volumes constants priment sur la marge, et le commentaire de la ligne nomme le motif.

6. Usage et limites. C'est le seul test du dispositif qui puisse fournir une *preuve positive* de la proportionnalité exigée par l'annexe XVII. Sa limite est celle de tous les tests à $T = 8$: la puissance est faible. Une étude de simulation sous $a = 0$ avec $\theta = 10\%$ donne une probabilité de conclure à l'équivalence de 46 % à $T = 8$, 80 % à $T = 15$ et 98 % à $T = 30$. Autrement dit, à $T = 8$, l'échec à démontrer l'équivalence est le résultat le plus probable *même lorsque la proportionnalité est parfaitement vérifiée* : ce résultat ne doit donc pas être présenté comme un indice défavorable, mais comme une limite d'information.

Formulation écartée. Poser $H_0 : a > 0$ et $H_0 : a < 0$ comme deux tests séparés sans marge ne répond pas au besoin : rejeter $H_0 : a \geq 0$ prouve $a < 0$, donc une preuve *contre* la proportionnalité. Quant à l'union $H_0 : a \neq 0$, elle n'est pas testable : la valeur $a = 0$ est adhérente à cet ensemble, la borne supérieure de la probabilité de rejet sur H_0 y vaut 1, et aucun test de niveau $\alpha < 1$ n'existe. L'introduction d'une marge $\Delta > 0$ strictement positive est ce qui rend le problème bien posé.

6.3 Test de Student sur la pente

Référence. Student (1908), *op. cit.*

1. Cadre, notations et hypothèses de validité (non testées). Identique à la fiche précédente (mêmes hypothèses de validité non testées).

2. Hypothèse nulle. $H_0 : b = 0$, absence de tout lien linéaire entre le volume et les pertes.

3. Statistique de test.

$$t_b = \frac{\hat{b}}{\widehat{\text{se}}(\hat{b})}, \quad \hat{b} = \frac{S_{xy}}{S_{xx}}, \quad \widehat{\text{se}}(\hat{b}) = \frac{\hat{s}}{\sqrt{S_{xx}}}.$$

4. Loi sous H_0 . $t_b \sim t(T - 2)$.

5. p-value. $p = 2(1 - F_{t, T-2}(|t_b|))$.

6. Usage et limites. Ce test s'interprète en sens inverse des autres tests de cette section : on souhaite ici *rejeter* H_0 . Une pente non significative signifierait que le volume n'explique pas les pertes, ce qui priverait de fondement le modèle réglementaire sur ce segment. Le script traduit cette inversion dans ses verdicts (p faible $\Rightarrow$ OK). Limites : avec $T = 10$ la puissance reste modeste ; et la significativité de la pente ne dit rien sur la *proportionnalité* (absence de constante), qui relève de la fiche précédente. Les deux tests sont complémentaires et non substituables.

6.4 Test de Fisher de significativité globale

Référence. R. A. Fisher, *On the mathematical foundations of theoretical statistics*, *Philosophical Transactions of the Royal Society A*, 222, 1922, p. 309–368 ; *Statistical Methods for Research Workers*, Oliver & Boyd, Édimbourg, 1925.

1. Cadre, notations et hypothèses de validité (non testées). Identique aux deux fiches précédentes. On note k le nombre de régresseurs hors constante (ici $k = 1$).

2. Hypothèse nulle. $H_0 : b = 0$ (plus généralement, nullité conjointe de tous les coefficients de pente).

3. Statistique de test.

$$F = \frac{(\text{SCT} - \text{SCR})/k}{\text{SCR}/(T - k - 1)} = \frac{R^2/k}{(1 - R^2)/(T - k - 1)}.$$

4. Loi sous H_0 . $F \sim \mathcal{F}(k, T - k - 1)$, soit ici $\mathcal{F}(1, T - 2)$.

5. p-value. $p = 1 - F_{\mathcal{F}, k, T-k-1}(F)$.

6. Usage et limites. On souhaite, comme pour la pente, *rejeter* H_0 . En régression simple ce test est strictement équivalent au test de Student sur la pente ($F = t_b^2$, p-values identiques) : il est conservé pour la lisibilité du rapport et redeviendrait informatif si l'on ajoutait des régresseurs (indicatrices d'année, variable d'inflation). Même limite de puissance à T faible.

6.5 Coefficient de détermination R^2

Référence. Sortie standard de `lm()`. Sur la loi sous H_0 : R. A. Fisher, *The general sampling distribution of the multiple correlation coefficient*, *Proceedings of the Royal Society A*, 121, 1928, p. 654–673.

1. Cadre, notations et hypothèses de validité (non testées). Même régression auxiliaire. **Il ne s’agit pas d’un test** mais d’un diagnostic descriptif ; les rubriques sont renseignées par cohérence de présentation.

2. Hypothèse nulle. Aucune en tant que diagnostic. Si l’on souhaite néanmoins tester R^2 , l’hypothèse pertinente est celle du test de Fisher ci-dessus, $H_0 : b = 0$.

3. Statistique de test.

$$R^2 = 1 - \frac{\text{SCR}}{\text{SCT}} = \frac{S_{xy}^2}{S_{xx}S_{yy}}, \quad R_{\text{aj}}^2 = 1 - (1 - R^2) \frac{T - 1}{T - k - 1}.$$

4. Loi sous H_0 . Sous $H_0 : b = 0$ et normalité des erreurs, $R^2 \sim \mathcal{B}\left(\frac{k}{2}, \frac{T-k-1}{2}\right)$ (loi bêta), d’espérance $k/(T - 1)$.

5. p-value. Celle du test de Fisher, $p = 1 - F_{\mathcal{F}, k, T-k-1}\left(\frac{R^2/k}{(1-R^2)/(T-k-1)}\right)$. Le script n’affiche pas de p-value sur cette ligne et lui donne le type diagnostic : elle est restituée INFO, sans verdict ni sens du test (sens_du_test à NA). Le commentaire donne R_{aj}^2 , l’espérance $1/(T - 1)$ de R^2 sous $b = 0$ et la position de R^2 par rapport au repère conventionnel 0,5 (« en dessous » ou « au-dessus ») ; ce repère n’est associé à aucune loi de référence ni à aucun niveau, et ne produit aucun verdict.

6. Usage et limites. La loi bêta donne la clé de lecture essentielle : sous H_0 , l’espérance de R^2 vaut $k/(T - 1)$, soit 11 % pour $T = 10$. Autrement dit, un R^2 apparemment « correct » est mécaniquement facile à atteindre sur un petit échantillon et ne doit jamais être lu comme une validation du modèle. Le script signale $R^2 < 0,5$ comme point d’attention, par le seul commentaire, et il convient de privilégier R_{aj}^2 , qui pénalise le nombre de paramètres. *Pourquoi aucun verdict* (ADR 0001, amendement du 23/09/2026) : l’hypothèse $b = 0$ sous laquelle la loi bêta vaut n’est pas une alternative candidate du modèle réglementaire, où $\beta > 0$, et elle est déjà portée par les tests de Student sur la pente et de Fisher ; sous le modèle réglementaire, R^2 est gouverné par la dispersion des volumes rapportée à celle du bruit, de sorte qu’un R^2 faible peut décrire l’étroitesse de la plage des x_t plutôt qu’une inadéquation. Mesuré sur le jeu de contrôle : $R^2 = 0,244$, sous le repère ; cette valeur ne permet, à elle seule, de conclure à aucun écart au modèle.

6.6 Test RESET de Ramsey

Référence. J. B. Ramsey, *Tests for specification errors in classical linear least-squares regression analysis*, *Journal of the Royal Statistical Society, Series B*, 31(2), 1969, p. 350–371.

1. Cadre, notations et hypothèses de validité (non testées). On part du modèle contraint réglementaire $y_t = \beta x_t + \varepsilon_t$ (sans constante), d’où $\hat{y}_t = \hat{\beta} x_t$, puis l’on estime le modèle augmenté $y_t = \beta x_t + \gamma_2 \hat{y}_t^2 + \gamma_3 \hat{y}_t^3 + \varepsilon_t$. Hypothèses non testées : erreurs indépendantes, homoscédastiques, normales. Nécessite $T > k + q = 3$.

2. Hypothèse nulle. $H_0 : \gamma_2 = \gamma_3 = 0$, soit « la forme linéaire est correctement spécifiée ».

3. Statistique de test. Avec SCR_0 et SCR_1 les sommes de carrés résiduels des modèles contraint et augmenté, $q = 2$ restrictions et $k = 1$ paramètre contraint :

$$F = \frac{(\text{SCR}_0 - \text{SCR}_1)/q}{\text{SCR}_1/(T - k - q)}.$$

4. Loi sous H_0 . $F \sim \mathcal{F}(q, T - k - q)$, soit $\mathcal{F}(2, T - 3)$.

5. p-value. $p = 1 - F_{\mathcal{F}, q, T-k-q}(F)$.

6. Usage et limites. On souhaite *ne pas* rejeter. Le test est générique : il détecte une non-linéarité sans en indiquer la forme. Limites à T faible : avec $T = 5$ il ne reste que 2 degrés de liberté au dénominateur, ce qui le rend presque inopérant ; et $\hat{y}^2, \hat{y}^3$ sont fortement colinéaires lorsque l'amplitude des volumes est faible, ce qui réduit encore la puissance. À utiliser en complément, non en substitution, de l'examen graphique.

6.7 Corrélation de rang de Spearman (ratio contre volume, ratio contre temps)

Référence. C. Spearman, *The proof and measurement of association between two things*, *American Journal of Psychology*, 15(1), 1904, p. 72–101.

1. Cadre, notations et hypothèses de validité (non testées). Couple de séries $(u_t, v_t) : (r_t, x_t)$ pour la variante « ratio contre volume », (r_t, t) pour la variante « ratio contre temps ». On note R_t, Q_t les rangs respectifs et $d_t = R_t - Q_t$. Hypothèses non testées : observations indépendantes, variables continues (peu ou pas d'ex æquo).

2. Hypothèse nulle. H_0 : indépendance des deux séries, donc absence de toute association monotone.

3. Statistique de test. En l'absence d'ex æquo,

$$\hat{\rho}_s = 1 - \frac{6 \sum_{t=1}^T d_t^2}{T(T^2 - 1)}, \quad \text{le script rapportant } S = \sum_t d_t^2.$$

En présence d'ex æquo, $\hat{\rho}_s$ est le coefficient de Pearson calculé sur les rangs.

4. Loi sous H_0 . Sous H_0 , la loi exacte de S est la loi de permutation : les $T!$ appariements de rangs sont équiprobables. Pour T modéré on utilise l'approximation

$$t = \hat{\rho}_s \sqrt{\frac{T-2}{1-\hat{\rho}_s^2}} \sim t(T-2).$$

5. p-value. p-value exacte de la loi de permutation, retenue par le moteur : `stats::cor.test()` avec `exact = TRUE`, qui met en œuvre l'algorithme de D. J. Best, D. E. Roberts, *Algorithm AS 89 : the upper tail probabilities of Spearman's rho*, *Applied Statistics*, 24(3), 1975, p. 377–379. À $T = 8$, sans ex æquo, la p-value rendue coïncide avec celle de l'énumération des $8!$ permutations, doublement bilatéral compris (écart nul sur 50 séries tirées au hasard, mesure). L'approximation de Student, $p = 2(1 - F_{t, T-2}(|t|))$ (appel avec `exact = FALSE`), est restituée comme p-value asymptotique, sans être retenue. La p-value de Monte-Carlo (clés `SpearVol` et `SpearTps`), bilatérale, est calculée sans être retenue. Depuis l'issue #41, la statistique simulée est S , celle qu'affiche la ligne, et non plus $\hat{\rho}_s$; $S = T(T^2 - 1)(1 - \hat{\rho}_s)/6$ étant une fonction affine décroissante de $\hat{\rho}_s$, la région de rejet bilatérale est la même et la p-value de Monte-Carlo aussi (mesure sur le cas de contrôle de la méthode prime : 0,878 et 0,872, identiques au bit près dans les deux codages). L'équiprobabilité des $T!$ appariements suppose les r_t échangeables, donc identiquement distribués : sous le modèle ajusté, ils ne le sont qu'à $\hat{\pi}_t$ constant, et la variante « ratio contre volume » exigeant des volumes non constants, cela signifie $\hat{\delta} = 1$. La p-value n'est exacte au sens de l'ADR 0002 que dans ce régime ; le moteur l'étiquette exacte et la retient dans tous les régimes (section 5.6, issue #25).

6. Usage et limites. Test non paramétrique robuste aux valeurs extrêmes et à la non-normalité, bon complément des tests paramétriques précédents. Deux limites : (i) il ne détecte que les associations *monotones* – une relation en U passera inaperçue ; (ii) l'approximation de Student est médiocre pour

$T < 10$, raison pour laquelle le moteur retient la loi exacte de permutation. Sur la variante « ratio contre volume », un rejet signale un effet d'échelle non capté par la proportionnalité stricte.

6.8 Test de tendance de Mann–Kendall

Référence. H. B. Mann, *Nonparametric tests against trend*, *Econometrica*, 13(3), 1945, p. 245–259; M. G. Kendall, *Rank Correlation Methods*, 4^e éd., Griffin, Londres, 1975.

1. Cadre, notations et hypothèses de validité (non testées). Série chronologique $r_1, \dots, r_T$. Hypothèses non testées : sous H_0 les r_t sont indépendants et identiquement distribués, la variable est continue. On note g le nombre de groupes d'ex æquo et t_g leurs effectifs.

2. Hypothèse nulle. H_0 : absence de tendance monotone, les r_t étant i.i.d. (toutes les permutations chronologiques sont équiprobables).

3. Statistique de test.

$$S = \sum_{i=1}^{T-1} \sum_{j=i+1}^T \text{sign}(r_j - r_i), \quad \text{Var}(S) = \frac{T(T-1)(2T+5) - \sum_g t_g(t_g-1)(2t_g+5)}{18},$$

puis la statistique standardisée avec correction de continuité

$$Z = \begin{cases} (S-1)/\sqrt{\text{Var}(S)} & \text{si } S > 0, \\ 0 & \text{si } S = 0, \\ (S+1)/\sqrt{\text{Var}(S)} & \text{si } S < 0. \end{cases}$$

4. Loi sous H_0 . Sous H_0 , S suit une loi exacte tabulée, symétrique autour de 0; asymptotiquement $Z \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$.

5. p-value. p-value exacte, retenue par le moteur : `mk_p_exacte()` somme, sur la loi exacte de S obtenue par la distribution mahonienne du nombre d'inversions (M. G. Kendall, J. D. Gibbons, *Rank Correlation Methods*, 5^e éd., Edward Arnold, 1990, ch. 4–5), les probabilités des issues telles que $|S| \geq |S_{\text{obs}}|$; elle est calculée pour $T \leq 12$ sans ex æquo. L'approximation normale $p = 2(1 - \Phi(|Z|))$ est restituée comme p-value asymptotique, sans être retenue. L'équiprobabilité des ordres chronologiques suppose les r_t identiquement distribués : sous le modèle ajusté, ils ne le sont qu'à $\hat{\pi}_t$ constant. La p-value n'est exacte au sens de l'ADR 0002 que dans ce régime ; le moteur l'étiquette exacte et la retient dans tous les régimes (section 5.6, issue #25).

6. Usage et limites. Test de référence pour détecter une dérive progressive du ratio S/P (dérive tarifaire, inflation des sinistres, évolution de la politique de provisionnement), ce qui contredirait directement la constance de β . Limites : l'approximation normale n'est acceptable qu'à partir de $T \approx 10$, en-deçà la loi exacte est nécessaire. Surtout, le test suppose l'indépendance des observations : en présence d'autocorrélation positive il rejette beaucoup trop souvent, ce qui impose de le lire conjointement avec les tests de la section 9.

6.9 Test de tendance par signes de Cox–Stuart

Référence. D. R. Cox, A. Stuart, *Some quick sign tests for trend in location and dispersion*, *Biometrika*, 42(1/2), 1955, p. 80–95.

1. Cadre, notations et hypothèses de validité (non testées). On pose $c = \lceil T/2 \rceil$ et l'on forme les paires (r_t, r_{t+c}) . Soit $D_t = r_{t+c} - r_t$ et m le nombre de paires avec $D_t \neq 0$. Hypothèses non testées : indépendance des observations, continuité.

2. Hypothèse nulle. H_0 : absence de tendance, formalisée par $\mathbb{P}(D_t > 0) = 1/2$ pour toute paire.

3. Statistique de test. $K = \#\{t : D_t > 0\}$, nombre de différences positives parmi les m paires non nulles.

4. Loi sous H_0 . $K \sim \mathcal{B}(m, 1/2)$, loi binomiale *exacte* (aucune approximation asymptotique), pourvu que chaque différence D_t soit de loi symétrique autour de 0. C'est le cas si les r_t sont i.i.d., donc sous le modèle ajusté à $\hat{\pi}_t$ constant ; à $\hat{\pi}_t$ variable, deux ratios lognormaux de même espérance et de variances différentes n'ont pas la même médiane, et $\mathbb{P}(D_t > 0) \neq 1/2$. La p-value n'est exacte au sens de l'ADR 0002 qu'à $\hat{\pi}_t$ constant ; le moteur l'étiquette exacte et la retient dans tous les régimes (section 5.6, issue #25).

5. p-value. Test binomial bilatéral exact :

$$p = \sum_{j : \mathbb{P}(K=j) \leq \mathbb{P}(K=k_{\text{obs}})} \binom{m}{j} \left(\frac{1}{2}\right)^m,$$

somme des probabilités des issues au moins aussi improbables que celle observée. C'est la p-value retenue. La p-value de Monte-Carlo (clé CoxStuart), calculée sans être retenue, ne simule pas K lui-même mais $|K - n_p/2|$, $n_p = T - c$ étant le nombre de paires, avec rejet en queue haute : la loi de K étant symétrique sous H_0 , la queue haute de $|K - n_p/2|$ est la région de rejet bilatérale de K . C'est une transformation qui conserve la région de rejet, et non une autre statistique (ADR 0003, annotation du 24 septembre 2026) ; la chaîne loi de la ligne la mentionne. Sans différence nulle, $m = n_p$ et $n_p/2$ est le centre de la loi de K ; en présence de différences nulles ($m < n_p$), le choix de recentrer sur $n_p/2$ plutôt que sur $m/2$ est une question relevée et non tranchée à ce jour. Sur le jeu de contrôle ($T = 8$, $n_p = 4$), $K = 2$, au centre : la p-value exacte et la p-value de Monte-Carlo valent 1, et l'erreur de Monte-Carlo affichée est nulle, ce qui signifie une erreur inférieure à la granularité et non une absence d'erreur (section 5.2).

6. Usage et limites. Avantage décisif : la loi est exacte, sans hypothèse de normalité ni approximation asymptotique. **Limite rédhibitoire à petit T** : le test n'utilise que le signe de $m \approx T/2$ différences. Pour $T = 10$, $m = 5$ et la p-value bilatérale minimale atteignable vaut $2 \times (1/2)^5 = 0,0625 > 0,05$: *le test ne peut structurellement jamais rejeter au seuil de 5 %*, quelle que soit la force de la tendance. Il faut $m \geq 6$ (donc $T \geq 12$) pour qu'un rejet à 5 % devienne possible. À T faible, ce test est purement indicatif et Mann–Kendall doit lui être préféré.

Hypothèse H2 — structure de variance quadratique

Énoncé réglementaire (annexe XVII, B/C(2)(f)(ii)). La variance des pertes agrégées est $\text{Var}(Y_t) = \sigma^2[(1 - \delta)\bar{x}x_t + \delta x_t^2]$, mélange convexe d’une composante linéaire en volume (risque mutualisable) et d’une composante quadratique (risque systématique). Le paramètre $\delta \in [0, 1]$ est estimé conjointement à γ .

Les tests de cette section portent sur les résidus *déjà standardisés* z_t : si la pondération $\hat{\pi}_t$ capture correctement l’hétéroscédasticité, il ne doit subsister *aucune* relation entre z_t^2 et x_t . Un rejet signale donc une structure de variance mal spécifiée, et non une hétéroscédasticité en soi (qui est attendue sur les données brutes).

7.1 Test de Breusch–Pagan, version studentisée de Koenker

Référence. T. S. Breusch, A. R. Pagan, *A simple test for heteroscedasticity and random coefficient variation*, *Econometrica*, 47(5), 1979, p. 1287–1294 ; version robuste TR^2 due à R. Koenker, *A note on studentizing a test for heteroscedasticity*, *Journal of Econometrics*, 17(1), 1981, p. 107–112.

1. Cadre, notations et hypothèses de validité (non testées). Régression auxiliaire $z_t^2 = c_0 + c_1x_t + \eta_t$, de coefficient de détermination R_{aux}^2 . Hypothèses non testées : indépendance des observations et validité de l’approximation asymptotique.

2. Hypothèse nulle. $H_0 : c_1 = 0$: la variance des résidus standardisés ne dépend pas du volume, donc la pondération réglementaire π_t est correctement spécifiée.

3. Statistique de test.

$$\text{LM} = T \cdot R_{\text{aux}}^2.$$

4. Loi sous H_0 . $\text{LM} \xrightarrow{\mathcal{L}} \chi^2(q)$, q étant le nombre de régresseurs auxiliaires hors constante, ici $q = 1$.

5. p-value. $p = 1 - F_{\chi_q^2}(\text{LM})$.

6. Usage et limites. On souhaite *ne pas* rejeter. Limites sérieuses à T faible : la convergence vers la loi du khi-deux est lente et la taille effective du test s’écarte notablement du niveau nominal pour $T < 30$. De plus, la forme testée est *linéaire* en x_t : une hétéroscédasticité résiduelle de forme différente peut échapper au test, d’où la variante de White. Enfin, la version originale de Breusch–Pagan exige la normalité des erreurs ; la forme TR^2 retenue ici (Koenker) s’en affranchit et est donc préférable dans ce contexte.

7.2 Test de Breusch–Pagan, version originale de 1979

Référence. T. S. Breusch, A. R. Pagan, *A simple test for heteroscedasticity and random coefficient variation*, *Econometrica*, 47(5), 1979, p. 1287–1294.

1. Cadre, notations et hypothèses de validité (non testées). Mêmes données et mêmes notations que la fiche précédente. **Hypothèse de validité supplémentaire, et déterminante : la normalité des erreurs.** C’est elle qui justifie $\text{Var}(u_t^2) = 2\sigma^4$, d’où le facteur $\frac{1}{2}$ de la statistique. Cette hypothèse n’est pas testée ici : elle relève de H3, examinée séparément en partie III.

2. Hypothèse nulle. $H_0 : c_1 = 0$, la variance des résidus standardisés ne dépend pas du volume.

3. Statistique de test. En posant $g_t = z_t^2 / \hat{\sigma}^2$ avec $\hat{\sigma}^2 = T^{-1} \sum_t z_t^2$, on régresse g sur x et l'on retient la moitié de la somme des carrés expliqués :

$$LM = \frac{1}{2} \sum_{t=1}^T (\hat{g}_t - \bar{g})^2.$$

4. Loi sous H_0 . $LM \xrightarrow{\mathcal{L}} \chi^2(q)$ sous H_0 et normalité des erreurs, avec $q = 1$ régresseur auxiliaire.

5. p-value. $p = 1 - F_{\chi_1^2}(LM)$, p-value non simulée. Une p-value de Monte-Carlo est calculée en parallèle et reste celle retenue pour le verdict à $T = 8$.

6. Usage et limites. Cette version est celle qui est publiée et citée dans la littérature ; elle figure dans l'outil à ce titre, et pour permettre la confrontation avec la version studentisée. **Elle n'est pas robuste à la non-normalité** : si les erreurs ont des queues plus lourdes que la normale, alors $\text{Var}(u_t^2) > 2\sigma^4$, le facteur $\frac{1}{2}$ sous-estime la variance de la statistique et le test sur-rejette massivement. L'ampleur du phénomène a été mesurée par simulation.

Loi des erreurs sous H_0	BP 1979	Koenker 1981
Normale, $T = 8$	0,021	0,043
Normale, $T = 30$	0,039	0,047
Normale, $T = 200$	0,051	0,051
Student à 3 ddl (queues lourdes), $T = 200$	0,380	0,041
Exponentielle (asymétrique), $T = 200$	0,270	0,038

Fréquence de rejet au seuil nominal de 5 % sous H_0 vraie, 4 000 réplifications. Sous erreurs normales, les deux versions convergent vers le niveau nominal, la version originale étant seulement conservatrice en petit échantillon. Sous erreurs à queues lourdes, la version originale rejette près de huit fois trop souvent, alors que la version studentisée reste calibrée.

Règle de lecture. Les deux versions doivent être lues *ensemble*. Une divergence marquée entre elles ne signale pas une hétéroscédasticité, mais un écart à la normalité : elle renvoie à H3 et non à H2. Pour conclure sur la structure de variance, c'est la version studentisée qui fait foi, la normalité n'étant jamais acquise à $T = 8$.

7.3 Test de White

Référence. H. White, *A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity*, *Econometrica*, 48(4), 1980, p. 817–838.

1. Cadre, notations et hypothèses de validité (non testées). Régression auxiliaire enrichie $z_t^2 = c_0 + c_1 x_t + c_2 x_t^2 + \eta_t$. Mêmes hypothèses de validité que Breusch–Pagan. Nécessite $T > 3$.

2. Hypothèse nulle. $H_0 : c_1 = c_2 = 0$.

3. Statistique de test. $LM = T \cdot R_{\text{aux}}^2$, avec le R^2 de la régression enrichie.

4. Loi sous H_0 . $LM \xrightarrow{\mathcal{L}} \chi^2(q)$ avec $q = 2$.

5. p-value. $p = 1 - F_{\chi_2^2}(LM)$.

6. Usage et limites. Plus général que Breusch–Pagan (il capte une hétéroscédasticité quadratique) au prix d'un degré de liberté supplémentaire, ce qui le rend peu adapté au régime USP : avec $T = 5$ à 8, estimer

trois coefficients auxiliaires laisse trop peu d'information et la puissance devient très faible. Le test est par ailleurs un test de mauvaise spécification *générale* plutôt que d'hétéroscédasticité stricto sensu : un rejet peut aussi traduire une erreur de forme fonctionnelle relevant de H1.

7.4 Test de Goldfeld–Quandt

Référence. S. M. Goldfeld, R. E. Quandt, *Some tests for homoscedasticity*, *Journal of the American Statistical Association*, 60(310), 1965, p. 539–547.

1. Cadre, notations et hypothèses de validité (non testées). Résidus triés selon x_t croissant, puis scindés en deux sous-groupes de taille $h = \lfloor T/2 \rfloor$ (observation centrale écartée si T impair). Hypothèses non testées : normalité et indépendance des résidus ; la variance, si elle varie, est monotone en x_t .

2. Hypothèse nulle. $H_0 : \sigma_1^2 = \sigma_2^2$, égalité des variances entre le sous-groupe des faibles volumes et celui des forts volumes.

3. Statistique de test.

$$F = \frac{\frac{1}{h} \sum_{t \in \text{groupe haut}} z_t^2}{\frac{1}{h} \sum_{t \in \text{groupe bas}} z_t^2}.$$

4. Loi sous H_0 . $F \sim \mathcal{F}(h, h)$ sous H_0 et normalité. *Approximation* : les z_t provenant d'un ajustement global et non de deux régressions séparées, les degrés de liberté sont légèrement surestimés.

5. p-value. Bilatérale : $p = 2 \min(F_{\mathcal{F}, h, h}(F), 1 - F_{\mathcal{F}, h, h}(F))$.

6. Usage et limites. Test simple et lisible dont le principal défaut est de *jeter la moitié de l'information* utile : il ne compare que deux blocs et ignore la structure interne à chacun. Avec $T = 10$, on compare deux blocs de 5 observations : un rapport de variances de 2 ou 3 ne sera pas détecté. Sensible à la non-normalité, contrairement à Brown–Forsythe.

7.5 Test de Brown–Forsythe

Référence. M. B. Brown, A. B. Forsythe, *Robust tests for the equality of variances*, *Journal of the American Statistical Association*, 69(346), 1974, p. 364–367 ; variante robuste de H. Levene, *Robust tests for equality of variances*, in *Contributions to Probability and Statistics*, Stanford University Press, 1960.

1. Cadre, notations et hypothèses de validité (non testées). Deux groupes $g \in \{1, 2\}$ définis par $x_t \leq \text{med}(x)$ et $x_t > \text{med}(x)$, d'effectifs n_1, n_2 , $N = n_1 + n_2$, $k = 2$. On calcule les écarts absolus à la médiane du groupe, $d_{gi} = |z_{gi} - \text{med}_g(z)|$, de moyennes $\bar{d}_g$ et $\bar{d}$. Hypothèse non testée : indépendance des observations. La normalité n'est *pas* requise, c'est l'apport de la méthode.

2. Hypothèse nulle. H_0 : égalité des dispersions entre les deux groupes.

3. Statistique de test.

$$W = \frac{(N - k) \sum_{g=1}^k n_g (\bar{d}_g - \bar{d})^2}{(k - 1) \sum_{g=1}^k \sum_{i=1}^{n_g} (d_{gi} - \bar{d}_g)^2}.$$

4. Loi sous H_0 . $W \sim \mathcal{F}(k - 1, N - k)$ approximativement, soit ici $\mathcal{F}(1, T - 2)$.

5. p-value. $p = 1 - F_{\mathcal{F}, k-1, N-k}(W)$.

6. Usage et limites. L'usage de la médiane (plutôt que de la moyenne, comme chez Levene) confère une bonne robustesse aux distributions asymétriques ou à queues lourdes, ce qui est précieux en assurance

non-vie. Limite : comme Goldfeld–Quandt, il ne compare que deux blocs et la loi de Fisher n’est qu’approximative. À $T \leq 10$, à considérer comme un simple indicateur.

7.6 Test de Smirnov à deux échantillons

Référence. N. V. Smirnov, *Sur les écarts de la courbe de distribution empirique*, *Recueil Mathématique (Matematicheskii Sbornik)*, 6(48), 1939, p. 3–26.

1. Cadre, notations et hypothèses de validité (non testées). Deux sous-échantillons de résidus standardisés : $z^{(1)}$ (années à faible volume, effectif n_1) et $z^{(2)}$ (années à fort volume, effectif n_2), de fonctions de répartition empiriques $\hat{F}_1, \hat{F}_2$. Hypothèses non testées : indépendance intra et inter échantillons, continuité des lois. Le script n’active ce test que si $T \geq 8$ et $n_1, n_2 \geq 3$.

2. Hypothèse nulle. $H_0 : F_1 = F_2$, égalité complète des lois – hypothèse plus forte que la seule égalité des variances.

3. Statistique de test.

$$D_{n_1, n_2} = \sup_{u \in \mathbb{R}} |\hat{F}_1(u) - \hat{F}_2(u)|.$$

4. Loi sous H_0 . Sous H_0 , pour un vecteur z échangeable, la loi exacte de D_{n_1, n_2} est combinatoire (dénombrement de chemins), calculée exactement par `ks.test` en l’absence d’ex æquo ; les z_t ne sont échangeables sous le modèle ajusté qu’à $\hat{\pi}_t$ constant (rubrique 6). Asymptotiquement, avec $\lambda = \sqrt{n_1 n_2 / (n_1 + n_2)}$:

$$\mathbb{P}(\lambda D_{n_1, n_2} \leq u) \longrightarrow K(u) = 1 - 2 \sum_{j=1}^{\infty} (-1)^{j-1} e^{-2j^2 u^2}.$$

5. p-value. Exacte par énumération pour $n_1 n_2$ petit ; sinon

$$p \approx 2 \sum_{j \geq 1} (-1)^{j-1} \exp(-2j^2 \lambda^2 D_{n_1, n_2}^2).$$

6. Usage et limites. Complément utile aux tests de variance : il détecte aussi un décalage de niveau ou un changement de forme entre petits et gros volumes. Deux limites : (i) puissance faible à effectifs réduits – avec $n_1 = n_2 = 5$, la plus petite p-value atteignable est $2 / \binom{10}{5} \approx 0,008$, le rejet reste donc possible mais exige un écart maximal ; (ii) les deux échantillons ne sont pas indépendants puisque les z_t partagent les mêmes paramètres estimés $(\hat{\beta}, \hat{\delta}, \hat{\gamma}) : z \sim \mathcal{N}(0, P)$ sous le modèle ajusté (section 5.6, issue #25). La loi combinatoire suppose seulement les z_t échangeables, la partition en petits et gros volumes ne dépendant que des x_t ; elle est donc exacte à $\hat{\pi}_t$ constant, soit ici à $\hat{\delta} = 1$ (le test exige des volumes non constants). À $\hat{\pi}_t$ variable, c’est une approximation dont l’écart n’est pas borné ; le moteur étiquette néanmoins la p-value exacte et la retient dans tous les régimes. Le *QQ-plot* à deux échantillons associé (section 12) reste le diagnostic le plus lisible.

7.7 Position de $\hat{\delta}$ dans son domaine (diagnostic)

Référence. Annexe XVII, sections B et C, paragraphe 6 (contrainte $0 \leq \delta \leq 1$).

1. Cadre, notations et hypothèses de validité (non testées). $\hat{\delta}$ est obtenu par minimisation sous contrainte de bornes de la log-vraisemblance négative. **Il ne s’agit pas d’un test** mais d’un diagnostic d’identifiabilité.

2. Hypothèse nulle. Sans objet en tant que diagnostic. Le test formel correspondant est le test du rapport de vraisemblance $H_0 : \delta = 0$ ou $\delta = 1$, documenté en section 11.

3. Statistique de test. La valeur $\hat{\delta}$ elle-même, avec le drapeau $\mathbb{1}\{\hat{\delta} \leq 10^{-6} \text{ ou } \hat{\delta} \geq 1 - 10^{-6}\}$ (champ `$delta_au_bord`, calculé par `usp_regime()` avec la tolérance `TOL_DELTA_BORD = 10-6`, inégalités larges). Cette tolérance n'est pas une valeur réglementaire mais une résolution numérique, commune au drapeau de constance de $\hat{\pi}_t$; sa justification est donnée à la fiche 9.5.

4. Loi sous H_0 . Sans objet.

5. p-value. Sans objet. La ligne est restituée INFO, sans verdict ni sens du test (`sens_du_test` à NA), que la solution soit au bord ou non ; la position de $\hat{\delta}$ est dite par le commentaire, qui porte l'un de trois libellés : `VOLUMES CONSTANTS` (prioritaire, avec sa variante dans la bande de tolérance, voir ci-dessous), `SOLUTION AU BORD` si `$delta_au_bord` est vrai, et « intérieur du domaine » sinon. Jusqu'à l'issue #24, le script marquait la ligne ALERTE au bord et OK à l'intérieur.

6. Usage et limites. Une solution *au bord* signifie que les données ne permettent pas d'identifier un mélange interne des deux composantes de variance : la vraisemblance est monotone en δ sur $[0, 1]$ et l'optimum est poussé sur une borne. Ce n'est pas une erreur mais un signal fort à documenter, car (i) l'écart-type asymptotique de $\hat{\delta}$ n'est alors pas défini de manière usuelle, (ii) le paramètre final peut varier fortement selon la borne retenue, et (iii) la théorie asymptotique standard des tests sur δ ne s'applique plus (voir la correction de Chernoff en section 11). Sur des historiques de 5 à 12 points, la solution au bord est le cas de figure le plus fréquent en pratique. *Pourquoi aucun verdict* (ADR 0001, amendement du 23/09/2026) : la position de $\hat{\delta}$ décrit l'identifiabilité de la structure de variance, non l'adéquation du modèle, et n'a ni hypothèse nulle ni loi de référence ; un marquage ALERTE au bord, cas le plus fréquent sur ces historiques, ne distinguerait aucun dossier d'un autre. La décision formelle sur $\delta = 0$ ou $\delta = 1$ relève du test du rapport de vraisemblance (fiche 11.1).

Volumes constants (issue #58). Si les x_t sont constants (drapeau `$volumes_constants` de `usp_regime()`, tolérance relative `TOL_DELTA_BORD`), $a_t = 1$ pour tout $t : \pi_t$ ne dépend plus de δ et la vraisemblance est plate en δ , qui n'est pas identifié. La valeur affichée est celle du démarrage retenu par `usp_ajuster()` : le premier de la grille ($\delta = 0$), les autres démarrages finissant à moins de 10^{-12} de la même valeur de l'objectif, en deçà de l'écart de 10^{-10} exigé pour remplacer le meilleur (constat numérique : $\hat{\delta} = 0$ pour x_t constant égal à 80, 110, 200 ou 5 000 sur les pertes du jeu de contrôle, un démarrage se déplaçant d'au plus $4 \cdot 10^{-13}$ en δ , et l'objectif est identique pour $\delta \in \{0; 0,125; \dots; 1\}$ à γ fixé). Le commentaire de la ligne l'écrit (`VOLUMES CONSTANTS : la vraisemblance ne depend pas de delta, qui n'est pas identifie`), à la place de `SOLUTION AU BORD`, qui serait vrai pour une mauvaise raison ; dans la bande de tolérance (étendue relative des volumes non nulle mais au plus `TOL_DELTA_BORD`), il précise que la vraisemblance ne dépend *presque* pas de δ .

Hypothèse H3 — lognormalité des pertes agrégées

Énoncé réglementaire (annexe XVII, B/C(2)(f)(iii)). Les pertes agrégées (ou le montant de liquidation) suivent une loi lognormale. Cette hypothèse se teste de façon équivalente comme la normalité des résidus standardisés z_t .

Point commun à toute cette section. Les z_t ne sont pas des observations brutes mais des résidus d'un modèle dont trois paramètres $(\hat{\beta}, \hat{\delta}, \hat{\gamma})$ ont été estimés sur les mêmes données. La loi de référence de tous les tests de normalité en est modifiée (elle devient stochastiquement plus concentrée), ce qui rend ces tests *conservateurs* si l'on utilise les p-values tabulées pour paramètres connus. D'où le recalcul systématique d'une p-value de Monte-Carlo (section 4).

8.1 Test de Shapiro–Wilk

Référence. S. S. Shapiro, M. B. Wilk, *An analysis of variance test for normality (complete samples)*, *Biometrika*, 52(3/4), 1965, p. 591–611 ; normalisation de J. P. Royston, *Approximating the Shapiro-Wilk W-test for non-normality*, *Statistics and Computing*, 2, 1992, p. 117–119.

1. Cadre, notations et hypothèses de validité (non testées). Échantillon $z_1, \dots, z_T$ supposé (hypothèse non testée) i.i.d., sans ex æquo. Valable pour $3 \leq T \leq 5000$. On note $m = (m_1, \dots, m_T)'$ le vecteur des espérances des statistiques d'ordre d'un échantillon normal centré réduit et V leur matrice de covariance.

2. Hypothèse nulle. H_0 : les z_t sont issus d'une loi normale $\mathcal{N}(\mu, \sigma^2)$, μ et σ non spécifiés.

3. Statistique de test.

$$W = \frac{\left(\sum_{i=1}^T a_i z_{(i)}\right)^2}{\sum_{t=1}^T (z_t - \bar{z})^2}, \quad a' = \frac{m'V^{-1}}{\sqrt{m'V^{-1}V^{-1}m}}.$$

$W \in]0, 1]$, une valeur proche de 1 étant favorable à la normalité.

4. Loi sous H_0 . Aucune forme analytique fermée. Royston (1992) fournit une transformation normalisante : pour $12 \leq T \leq 5000$, $\ln(1 - W)$ est approximativement $\mathcal{N}(\mu_W, \sigma_W^2)$, où μ_W et σ_W sont des polynômes en $\ln T$; pour $4 \leq T \leq 11$, la transformation utilisée est $-\ln(\varsigma - \ln(1 - W))$ avec ς dépendant de T .

5. p-value. $p = 1 - \Phi\left(\frac{\ln(1 - W) - \mu_W}{\sigma_W}\right)$ pour $T \geq 12$, avec la transformation adaptée pour $T \leq 11$.

6. Usage et limites. Test de référence pour les petits échantillons et généralement le plus puissant contre un large éventail d'alternatives. Ses limites en régime USP restent néanmoins sévères : à $T = 8$, sa puissance contre une loi à queues lourdes réaliste n'est que de quelques dizaines de pour cent, si bien qu'un p élevé n'apporte quasiment aucune information. Il est par ailleurs sensible aux ex æquo (fréquents si les montants sont arrondis) et à l'estimation préalable des paramètres. **Lire prioritairement p_mc.**

8.2 Test de Shapiro–Francia

Référence. S. S. Shapiro, R. S. Francia, *An approximate analysis of variance test for normality*, *Journal of the American Statistical Association*, 67(337), 1972, p. 215–216 ; p-values selon J. P. Royston, *A toolkit for testing for non-normality in complete and censored samples*, *The Statistician*, 42(1), 1993, p. 37–43.

1. Cadre, notations et hypothèses de validité (non testées). Mêmes hypothèses que Shapiro–Wilk. Valable pour $5 \leq T \leq 5000$. On utilise les scores normaux approchés de Blom, $\tilde{m}_i = \Phi^{-1}((i - 3/8)/(T + 1/4))$.

2. Hypothèse nulle. H_0 : les z_t sont issus d’une loi normale.

3. Statistique de test.

$$W' = \text{corr}(z_{(i)}, \tilde{m}_i)^2 = \frac{\left(\sum_i \tilde{m}_i z_{(i)}\right)^2}{\left(\sum_i \tilde{m}_i^2\right)\left(\sum_t (z_t - \bar{z})^2\right)},$$

soit exactement le carré du coefficient de corrélation du QQ-plot normal.

4. Loi sous H_0 . Pas de forme fermée. Royston (1993) : en posant $u = \ln T$ et $v = \ln u$,

$$\ln(1 - W') \approx \mathcal{N}(\mu, \sigma^2), \quad \mu = -1,2725 + 1,0521(v - u), \quad \sigma = 1,0308 - 0,26758(v + 2/u).$$

5. p-value. $p = 1 - \Phi\left(\frac{\ln(1 - W') - \mu}{\sigma}\right)$.

6. Usage et limites. Simplification de Shapiro–Wilk (remplacement de V^{-1} par l’identité), souvent plus puissante contre les alternatives à *queues lourdes* et légèrement moins contre les alternatives asymétriques. Son intérêt est d’être la traduction numérique exacte du QQ-plot, ce qui facilite la justification en dossier. Mêmes limites de puissance qu’à la fiche précédente.

8.3 Test d’Anderson–Darling

Référence. T. W. Anderson, D. A. Darling, *A test of goodness of fit*, *Journal of the American Statistical Association*, 49(268), 1954, p. 765–769 ; approximations de R. B. D’Agostino, M. A. Stephens (dir.), *Goodness-of-Fit Techniques*, Marcel Dekker, 1986.

1. Cadre, notations et hypothèses de validité (non testées). Échantillon i.i.d. (hypothèse non testée), $p_{(i)} = \Phi(z_{(i)})$. Statistique de distance à la fonction de répartition empirique (famille EDF).

2. Hypothèse nulle. H_0 : les z_t suivent la loi $\mathcal{N}(0, 1)$ de référence.

3. Statistique de test.

$$A^2 = -T - \frac{1}{T} \sum_{i=1}^T (2i - 1) \left[\ln p_{(i)} + \ln(1 - p_{(T+1-i)}) \right],$$

forme discrète de $A^2 = T \int \frac{(\hat{F}(u) - F_0(u))^2}{F_0(u)(1 - F_0(u))} dF_0(u)$: la pondération $[F_0(1 - F_0)]^{-1}$ amplifie les écarts dans les *queues*.

4. Loi sous H_0 . Sous H_0 à paramètres connus, A^2 converge vers une loi limite tabulée indépendante de F_0 . Lorsque les paramètres sont estimés, on utilise la statistique modifiée $A^{*2} = A^2(1 + 0,75/T + 2,25/T^2)$, de loi différente.

5. p-value. Deux p-values sont rapportées. La première est *non simulée* : approximations par morceaux de D’Agostino & Stephens (1986) pour le cas où moyenne et variance sont estimées, par exemple $p \approx \exp(1,2937 - 5,709 A^{*2} + 0,0186 A^{*4})$ sur la plage $0,60 < A^{*2} < 13$, avec d’autres branches ailleurs. Ce sont des ajustements empiriques et non un résultat exact ; leur calibration a été vérifiée par simulation (5,2 % de rejets au seuil de 5 % à $T = 8$). La seconde est la p-value de Monte-Carlo, qui reste celle retenue pour le verdict car elle tient compte du modèle effectivement ajusté.

6. Usage et limites. Test le plus pertinent pour un usage actuariel : la pondération en queue le rend sensible précisément là où se joue le capital réglementaire. Limite propre à ce contexte : cette sensibilité est aussi sa fragilité, car sur 8 à 12 points les deux ou trois observations extrêmes déterminent presque entièrement A^2 . À croiser impérativement avec les tests de valeurs aberrantes de la section 10.

8.4 Test de Cramér–von Mises

Référence. H. Cramér, *On the composition of elementary errors*, *Skandinavisk Aktuarietidskrift*, 11, 1928 ; R. von Mises, *Wahrscheinlichkeit, Statistik und Wahrheit*, Springer, 1928 ; forme et approximations selon M. A. Stephens, *EDF statistics for goodness of fit and some comparisons*, *JASA*, 69(347), 1974, p. 730–737.

1. Cadre, notations et hypothèses de validité (non testées). Identique à Anderson–Darling.

2. Hypothèse nulle. H_0 : les z_t suivent $\mathcal{N}(0, 1)$.

3. Statistique de test.

$$W^2 = \frac{1}{12T} + \sum_{i=1}^T \left(p_{(i)} - \frac{2i-1}{2T} \right)^2 = T \int (\hat{F} - F_0)^2 dF_0.$$

4. Loi sous H_0 . Loi limite de Cramér–von Mises sous H_0 à paramètres connus ; statistique modifiée $W^{*2} = W^2(1 + 0,5/T)$ lorsque les paramètres sont estimés.

5. p-value. Approximations par morceaux de Stephens pour le cas à paramètres estimés, rapportées comme p-value non simulée (calibration vérifiée par simulation : 4,9 % de rejets au seuil de 5 % à $T = 8$) ; la p-value de Monte-Carlo reste celle retenue pour le verdict.

6. Usage et limites. Version non pondérée d’Anderson–Darling : elle accorde le même poids à toute la distribution, et est donc *moins* sensible aux queues, ce qui la rend plus stable mais moins pertinente pour un usage prudentiel. Utile en recoupement : un rejet par A^2 non confirmé par W^2 oriente vers un problème localisé en queue plutôt que vers une non-normalité d’ensemble.

8.5 Test de Kolmogorov–Smirnov contre $\mathcal{N}(0, 1)$

Référence. A. N. Kolmogorov, *Sulla determinazione empirica di una legge di distribuzione*, *Giornale dell’Istituto Italiano degli Attuari*, 4, 1933, p. 83–91 ; H. W. Lilliefors, *On the Kolmogorov–Smirnov test for normality with mean and variance unknown*, *JASA*, 62(318), 1967, p. 399–402.

1. Cadre, notations et hypothèses de validité (non testées). Identique aux deux fiches précédentes.

2. Hypothèse nulle. H_0 : les z_t suivent $\mathcal{N}(0, 1)$.

3. Statistique de test.

$$D = \sup_u |\hat{F}(u) - \Phi(u)| = \max_{1 \leq i \leq T} \max \left(\frac{i}{T} - p_{(i)}, p_{(i)} - \frac{i-1}{T} \right).$$

4. Loi sous H_0 . À paramètres connus, $\sqrt{T} D$ converge vers la loi de Kolmogorov :

$$\mathbb{P}(\sqrt{T} D \leq u) \longrightarrow K(u) = 1 - 2 \sum_{j=1}^{\infty} (-1)^{j-1} e^{-2j^2 u^2}.$$

À paramètres *estimés*, la loi correcte est celle de Lilliefors, stochastiquement plus concentrée et sans forme analytique.

5. p-value. $p \approx 2 \sum_{j \geq 1} (-1)^{j-1} \exp(-2j^2 T D^2)$, formule de Kolmogorov, rapportée à titre de p-value non simulée. La p-value de Monte-Carlo reste celle retenue pour le verdict.

6. Usage et limites. Test historiquement dominant mais *le moins puissant* de cette section : le supremum ne retient qu'un seul point d'écart et sous-pondère les queues. Piège classique, quantifié ici : appliquer la loi de Kolmogorov alors que les paramètres ont été estimés rend le test extrêmement conservateur. Une simulation à $T = 8$ donne **zéro rejet sur 3 000 répliques** au seuil de 5 %, ce qui produirait une fausse impression de validation. Le test de Lilliefors (fiche suivante) est la réponse correcte à cette situation.

8.6 Test de Lilliefors

Référence. H. W. Lilliefors, *On the Kolmogorov-Smirnov test for normality with mean and variance unknown*, *Journal of the American Statistical Association*, 62(318), 1967, p. 399–402 ; p-value : G. E. Dallal, L. Wilkinson, *An analytic approximation to the distribution of Lilliefors' test statistic for normality*, *The American Statistician*, 40(4), 1986, p. 294–296, prolongée au-delà de 0,10 par les polynômes de Stephens (1974).

1. Cadre, notations et hypothèses de validité (non testées). Échantillon i.i.d. (hypothèse non testée). **Différence essentielle avec la fiche précédente :** la moyenne et l'écart-type ne sont pas ceux du modèle mais sont *estimés sur l'échantillon lui-même*, ce qui correspond à la situation réelle lorsque l'on teste la normalité sans connaître les paramètres.

2. Hypothèse nulle. H_0 : les z_t sont issus d'une loi normale de moyenne et de variance quelconques.

3. Statistique de test.

$$D_L = \sup_u \left| \hat{F}(u) - \Phi\left(\frac{u - \bar{z}}{s_z}\right) \right|,$$

soit la statistique de Kolmogorov–Smirnov calculée après standardisation empirique.

4. Loi sous H_0 . Loi de Lilliefors, *stochastiquement plus concentrée* que celle de Kolmogorov puisque l'ajustement des paramètres rapproche mécaniquement $\hat{F}$ de la loi de référence. Elle n'a pas de forme analytique fermée.

5. p-value. Approximation analytique de Dallal & Wilkinson (1986), valable pour $p < 0,10$:

$$p \approx \exp\left(-7,01256 K^2(T + 2,78019) + 2,99587 K \sqrt{T + 2,78019} - 0,122119 + \frac{0,974598}{\sqrt{T}} + \frac{1,67997}{T}\right),$$

prolongée au-delà par les polynômes de Stephens. Il s'agit d'une p-value **non simulée**, disponible dès $T \geq 5$. Une p-value de Monte-Carlo est calculée en parallèle.

6. Usage et limites. C'est la version correcte du test de Kolmogorov–Smirnov lorsque les paramètres sont estimés. La calibration a été vérifiée par simulation à $T = 8$: 10,6 % de rejets au seuil nominal de 10 % et 5,2 % au seuil de 5 %, à comparer aux 0 % du test de Kolmogorov mal appliqué. Sa puissance reste néanmoins celle de la famille Kolmogorov–Smirnov, c'est-à-dire faible devant Shapiro–Wilk et Anderson–Darling.

8.7 Shapiro–Wilk sans la normalisation de Royston

Référence. Shapiro & Wilk (1965), *op. cit.*; loi nulle évaluée par simulation directe. Sur la légitimité de l’invariance : la statistique W est invariante par translation et par changement d’échelle, propriété établie dans l’article original.

1. Cadre, notations et hypothèses de validité (non testées). Même statistique W que la fiche « Shapiro–Wilk »; seule la *loi de référence* change.

2. Hypothèse nulle. H_0 : les z_t sont issus d’une loi normale.

3. Statistique de test. W , identique à la fiche précédente.

4. Loi sous H_0 . W étant invariante par translation et par changement d’échelle, sa loi sur un échantillon i.i.d. normal ne dépend d’*aucun paramètre* : elle ne dépend que de T . Elle peut donc être évaluée numériquement en simulant des échantillons $\mathcal{N}(0, 1)$ de taille T . Cette loi est celle de $W(z)$ sous le modèle ajusté à $\hat{\pi}_t$ **constant seulement** : z est alors $M\varepsilon$ à un facteur près, avec ε i.i.d. normal, et $W(z) = W(\varepsilon)$. À $\hat{\pi}_t$ variable, $z \sim \mathcal{N}(0, P)$ n’est pas un échantillon i.i.d. translaté (section 5.6, issue #25) : la loi de $W(z)$ dépend alors de $\hat{\pi}_t$, et la loi simulée n’en est qu’une approximation, sans borne d’erreur connue à $T = 8$. L’outil emploie 20 000 tirages, mis en cache par valeur de T et pilotés par une graine dédiée.

5. p-value. $\hat{p} = (1 + \#\{W^{(b)} \leq W_{\text{obs}}\}) / (B_{\text{null}} + 1)$, rejet en queue basse.

6. Usage et limites. Cette variante répond à une objection de principe : la p-value de `shapiro.test()` repose sur la transformation normalisante de Royston (1992), qui est un *ajustement empirique*, non un résultat exact. La version proposée ici évalue directement la loi exacte de W , à l’erreur de Monte-Carlo près, en $\mathcal{O}(B_{\text{null}}^{-1/2})$.

Point important à ne pas confondre. Cette simulation n’est *pas* un bootstrap paramétrique : elle ne dépend pas du modèle USP ajusté, mais seulement de T . Elle relève donc de la catégorie « exacte, évaluée numériquement » et non de la catégorie « Monte-Carlo » du tableau 5.4 — au sens strict de l’ADR 0002, à $\hat{\pi}_t$ constant seulement (rubrique 4) ; le moteur l’étiquette exacte dans tous les régimes, et le commentaire de la ligne, qui la dit indépendante du modèle ajusté, ne mentionne pas cette condition. En pratique, les deux versions concordent étroitement : sur 2 000 répliques à $T = 8$, la fréquence de rejet au seuil de 5 % vaut 4,95 % pour la loi simulée contre 5,05 % pour la normalisation de Royston, ce qui valide a posteriori l’approximation de Royston à cette taille d’échantillon (constat de simulation dont le régime de $\hat{\pi}_t$ n’est pas consigné ; la calibration par régime figure à la section 5.6).

8.8 Test de Jarque–Bera

Référence. C. M. Jarque, A. K. Bera, *Efficient tests for normality, homoscedasticity and serial independence of regression residuals*, *Economics Letters*, 6(3), 1980, p. 255–259.

1. Cadre, notations et hypothèses de validité (non testées). Échantillon i.i.d., moments d’ordre 4 finis (hypothèses non testées). Test du multiplicateur de Lagrange contre la famille de Pearson.

2. Hypothèse nulle. H_0 : asymétrie et aplatissement conformes à la loi normale, soit $\mathbb{E}[\sqrt{b_1}] = 0$ et $\mathbb{E}[b_2] = 3$ conjointement.

3. Statistique de test.

$$\text{JB} = \frac{T}{6} \left(b_1 + \frac{(b_2 - 3)^2}{4} \right), \quad \sqrt{b_1} = \frac{m_3}{m_2^{3/2}}, \quad b_2 = \frac{m_4}{m_2^2}.$$

4. Loi sous H_0 . $JB \xrightarrow{\mathcal{L}} \chi^2(2)$, comme somme des carrés de deux statistiques asymptotiquement normales et indépendantes.

5. p-value. $p = 1 - F_{\chi^2_2}(JB)$. Le commentaire de la ligne n'imprime ni $\sqrt{b_1}$ ni b_2 : il renvoie aux champs estim des lignes de D'Agostino et d'Anscombe–Glynn (fiches 8.9 et 8.10), qui les portent même lorsque le test d'Anscombe–Glynn n'est pas défini ($T < 20$), et rappelle que l'aplatissement est borné mécaniquement par une quantité de l'ordre de T (décision M24 du mainteneur, issue #24, §1.5).

6. Usage et limites. À manier avec une grande prudence en régime USP. La convergence vers $\chi^2(2)$ est notoirement lente : pour $T < 50$, la taille effective s'écarte fortement du niveau nominal. Surtout, l'aplatissement empirique est *mécaniquement borné*, b_2 ne pouvant dépasser une quantité de l'ordre de T : avec $T = 8$, l'échantillon est structurellement incapable de manifester une queue lourde et le test ne peut pratiquement pas rejeter pour excès d'aplatissement. La p-value `p_mc` est ici indispensable ; en son absence, ce test n'apporte à peu près rien sur un historique réglementaire minimal.

8.9 Test d'asymétrie de D'Agostino

Référence. R. B. D'Agostino, *Transformation to normality of the null distribution of g_1* , *Biometrika*, 57(3), 1970, p. 679–681.

1. Cadre, notations et hypothèses de validité (non testées). Échantillon i.i.d. ; nécessite $T \geq 8$ pour que la transformation normalisante soit définie, le script marquant le test non applicable en-deçà.

2. Hypothèse nulle. H_0 : coefficient d'asymétrie de la population nul.

3. Statistique de test. En posant $\sqrt{b_1} = m_3/m_2^{3/2}$:

$$Y = \sqrt{b_1} \sqrt{\frac{(T+1)(T+3)}{6(T-2)}}, \quad \beta_2 = \frac{3(T^2 + 27T - 70)(T+1)(T+3)}{(T-2)(T+5)(T+7)(T+9)},$$

$$W^2 = -1 + \sqrt{2(\beta_2 - 1)}, \quad \alpha = \sqrt{\frac{2}{W^2 - 1}}, \quad \varsigma = \frac{1}{\sqrt{\ln W}},$$

$$Z = \varsigma \ln \left(\frac{Y}{\alpha} + \sqrt{\left(\frac{Y}{\alpha} \right)^2 + 1} \right) = \varsigma \operatorname{arcsinh} \left(\frac{Y}{\alpha} \right).$$

4. Loi sous H_0 . $Z \sim \mathcal{N}(0, 1)$ approximativement sous H_0 , la transformation de Johnson S_U ci-dessus corrigeant l'asymétrie de la loi exacte de $\sqrt{b_1}$ à T fini.

5. p-value. $p = 2(1 - \Phi(|Z|))$.

6. Usage et limites. Utile pour *localiser* la cause d'un rejet global de normalité : une asymétrie significative oriente vers un mélange de sinistres graves et attritionnels mal séparés, diagnostic actionnable au regard de l'exigence de l'annexe XVII sur le retraitement des événements déjà couverts par les sous-modules catastrophe. Limite : la correction de petit échantillon vaut dès $T \geq 8$, mais la puissance ne devient réellement exploitable que vers $T \geq 20$.

8.10 Test d'aplatissement d'Anscombe–Glynn

Référence. F. J. Anscombe, W. J. Glynn, *Distribution of the kurtosis statistic b_2 for normal samples*, *Biometrika*, 70(1), 1983, p. 227–234.

1. Cadre, notations et hypothèses de validité (non testées). Échantillon i.i.d.; nécessite $T \geq 20$. Sur un historique réglementaire de 5 à 15 années, ce test est donc presque toujours *non applicable* et le script l'indique explicitement.

2. Hypothèse nulle. H_0 : aplatissement de la population égal à 3 (valeur normale).

3. Statistique de test. Avec $b_2 = m_4/m_2^2$,

$$\begin{aligned} \mathbb{E}[b_2] &= \frac{3(T-1)}{T+1}, & \text{Var}(b_2) &= \frac{24T(T-2)(T-3)}{(T+1)^2(T+3)(T+5)}, & x &= \frac{b_2 - \mathbb{E}[b_2]}{\sqrt{\text{Var}(b_2)}}, \\ \sqrt{\beta_1} &= \frac{6(T^2 - 5T + 2)}{(T+7)(T+9)} \sqrt{\frac{6(T+3)(T+5)}{T(T-2)(T-3)}}, & A &= 6 + \frac{8}{\sqrt{\beta_1}} \left(\frac{2}{\sqrt{\beta_1}} + \sqrt{1 + \frac{4}{\beta_1}} \right), \\ Z &= \frac{\left(1 - \frac{2}{9A}\right) - \left(\frac{1 - 2/A}{1 + x\sqrt{2/(A-4)}}\right)^{1/3}}{\sqrt{2/(9A)}}. \end{aligned}$$

4. Loi sous H_0 . $Z \sim \mathcal{N}(0, 1)$ approximativement (transformation de Wilson–Hilferty).

5. p-value. $p = 2(1 - \Phi(|Z|))$.

6. Usage et limites. C'est le test le plus directement pertinent pour un actuair (l'épaisseur de queue conditionne le quantile à 99,5 %), mais aussi le moins souvent disponible : il exige $T \geq 20$, davantage que ce qu'exige la crédibilité pleine de l'annexe XVII. Lorsqu'il n'est pas applicable, l'analyse de queue doit reposer sur le QQ-plot, sur Anderson–Darling et sur les tests de valeurs aberrantes.

Hypothèse H4 — indépendance et validité du maximum de vraisemblance

Énoncé réglementaire (annexe XVII, B/C(2)(f)(iv)). L'estimation par maximum de vraisemblance est appropriée, ce qui suppose notamment l'indépendance des Y_t conditionnellement aux x_t , sans autocorrélation résiduelle.

9.1 Test de Durbin–Watson

Référence. J. Durbin, G. S. Watson, *Testing for serial correlation in least squares regression, I, Biometrika*, 37(3/4), 1950, p. 409–428 ; *II, Biometrika*, 38(1/2), 1951, p. 159–178.

1. Cadre, notations et hypothèses de validité (non testées). Série de résidus $z_1, \dots, z_T$ ordonnée chronologiquement. Hypothèses non testées : résidus issus d'un modèle correctement spécifié, homoscedastiques et gaussiens ; régresseurs exogènes et non aléatoires.

2. Hypothèse nulle. $H_0 : \rho = 0$ dans le schéma $z_t = \rho z_{t-1} + \nu_t$, soit l'absence d'autocorrélation d'ordre 1.

3. Statistique de test.

$$DW = \frac{\sum_{t=2}^T (z_t - z_{t-1})^2}{\sum_{t=1}^T z_t^2} \approx 2(1 - \hat{\rho}_1).$$

$DW \in [0, 4]$: proche de 2 sous H_0 , proche de 0 en autocorrélation positive forte, proche de 4 en autocorrélation négative forte.

4. Loi sous H_0 . Sous H_0 et sous le modèle ajusté pris pour vrai, les résidus standardisés suivent $\mathcal{N}(0, P)$ et **non** $\mathcal{N}(0, I_T)$, P étant le projecteur de rang $T - 1$ défini à la section 5.6 (issue #25). La statistique étant calculée sur les résidus centrés, Mz avec $M = I_T - \mathbf{1}\mathbf{1}'/T$, et invariante par changement d'échelle, $DW = \varepsilon' P M A M P \varepsilon / \varepsilon' P M P \varepsilon$, $\varepsilon \sim \mathcal{N}(0, I_T)$, où A est la matrice des différences secondes. À $\hat{\pi}_t$ **constant**, $P = M$ et, M étant idempotente, $DW = \varepsilon' M A M \varepsilon / \varepsilon' M \varepsilon$: *rapport de deux formes quadratiques* en variables normales i.i.d., dont la loi est **exactement calculable**, sans tabulation ni approximation. Les valeurs propres de A sont connues analytiquement, $\lambda_j = 2(1 - \cos(\pi j/T))$, $j = 0, \dots, T - 1$ (vérification numérique faite). À $\hat{\pi}_t$ **variable**, la loi calculée par le moteur, celle du cas $P = M$, n'est plus qu'une approximation de la loi de DW, sans borne d'erreur connue à $T = 8$.

5. p-value. On écrit $\mathbb{P}(DW \leq c) = \mathbb{P}(z'(A - cI)z \leq 0)$, queue d'une forme quadratique évaluée par la méthode d'Imhof (1961) :

$$\mathbb{P}(Q > 0) = \frac{1}{2} - \frac{1}{\pi} \int_0^\infty \frac{\sin \theta(u)}{u \rho(u)} du, \quad \theta(u) = \frac{1}{2} \sum_j \arctan(h_j u), \quad \rho(u) = \prod_j (1 + h_j^2 u^2)^{1/4},$$

avec $h_j = \lambda_j - c$. La p-value bilatérale est $2 \min(\mathbb{P}(DW \leq d), \mathbb{P}(DW \geq d))$. Le centrage retirant une dimension, l'intégration porte sur les $T - 1$ valeurs propres non nulles de A projetée sur l'orthogonal du vecteur constant, soit $M A M$ (`dw_p_exacte()`). Cette p-value est *exacte* au sens de l'ADR 0002 à $\hat{\pi}_t$ **constant seulement** ($\hat{\delta} = 1$ ou volumes constants, au sens de `usp_regime()`). Le moteur l'étiquette

exacte et la retient dans tous les régimes : à $\hat{\pi}_t$ variable, la p-value retenue est donc une approximation (section 5.6).

6. Usage et limites. Deux points d'implémentation méritent d'être signalés. *Le centrage* : la statistique est calculée sur des résidus centrés, car la définition classique porte sur des résidus de moindres carrés, de moyenne nulle par construction. Les z_t satisfont la contrainte $\sum_t \sqrt{\hat{\pi}_t} z_t = 0$ mais pas $\bar{z} = 0$; sans centrage, le dénominateur serait majoré de $T\bar{z}^2$ et DW biaisée vers le bas. Le centrage rend en outre la statistique cohérente avec l'autocorrélation employée par les tests portmanteau. *La p-value* : elle est exacte, et non asymptotique, à $\hat{\pi}_t$ constant (rubrique 4); une première validation par simulation a donné 10,1 % de rejets au seuil nominal de 10 % et 5,2 % au seuil de 5 % (1 500 répliques à $T = 8$), sans que le régime de $\hat{\delta}$ sous lequel elle a été faite soit consigné. La calibration mesurée séparément dans chaque régime figure à la section 5.6 : compatible avec le niveau nominal dans le scénario où π_t est constant, inférieure au nominal (9,0 % au seuil de 10 %) dans le scénario à $\hat{\pi}_t$ variable, constat propre à ce scénario. Les bornes d_L/d_U , établies pour des résidus de moindres carrés, ne sont pas utilisées. Le test ne détecte par ailleurs qu'une dépendance d'ordre 1.

9.2 Tests portmanteau de Ljung–Box et de Box–Pierce

Référence. G. E. P. Box, D. A. Pierce, *Distribution of residual autocorrelations in autoregressive-integrated moving average time series models*, JASA, 65(332), 1970, p. 1509–1526; G. M. Ljung, G. E. P. Box, *On a measure of lack of fit in time series models*, Biometrika, 65(2), 1978, p. 297–303.

1. Cadre, notations et hypothèses de validité (non testées). Série $z_1, \dots, z_T$, autocorrélations empiriques $\hat{\rho}_k = \sum_{t=k+1}^T (z_t - \bar{z})(z_{t-k} - \bar{z}) / \sum_{t=1}^T (z_t - \bar{z})^2$. Le script teste $h = 1$ et, si $T \geq 8$, $h = 2$. Hypothèses non testées : stationnarité et existence des moments d'ordre 2.

2. Hypothèse nulle. $H_0 : \rho_1 = \dots = \rho_h = 0$, absence d'autocorrélation jusqu'au retard h .

3. Statistique de test.

$$Q_{BP} = T \sum_{k=1}^h \hat{\rho}_k^2, \quad Q_{LB} = T(T+2) \sum_{k=1}^h \frac{\hat{\rho}_k^2}{T-k}.$$

La pondération $(T+2)/(T-k)$ de Ljung–Box corrige le biais de Q_{BP} à T fini.

4. Loi sous H_0 . $Q \xrightarrow{\mathcal{L}} \chi^2(h)$ sous H_0 (et $\chi^2(h-p-q)$ si les résidus proviennent d'un ARMA(p, q) ajusté, ce qui n'est pas le cas ici).

5. p-value. $p = 1 - F_{\chi^2_h}(Q)$.

6. Usage et limites. Ljung–Box est à préférer systématiquement à Box–Pierce, dont l'approximation est plus grossière à T faible; le script affiche les deux en recoupement. Limites : l'approximation χ^2 n'est fiable qu'à partir de $T \approx 30$, et la règle d'usage $h \leq T/5$ impose de se restreindre à $h \leq 2$ ou 3 sur un historique réglementaire. Un rejet au retard 2 non confirmé au retard 1 doit être interprété avec prudence : sur 12 points, il s'agit souvent d'un artefact.

9.3 Test des suites de Wald–Wolfowitz

Référence. A. Wald, J. Wolfowitz, *On a test whether two samples are from the same population*, Annals of Mathematical Statistics, 11(2), 1940, p. 147–162.

1. Cadre, notations et hypothèses de validité (non testées). On transforme la série en une suite binaire de signes $s_t = \text{sign}(z_t - \text{med}(z))$, en écartant les valeurs nulles. Soit n_1 le nombre de signes positifs,

n_2 le nombre de négatifs, $n = n_1 + n_2$, et R le nombre de « suites » (séquences maximales de signes identiques). Hypothèse non testée : continuité de la variable.

2. Hypothèse nulle. H_0 : la suite des signes est un arrangement aléatoire, les $\binom{n}{n_1}$ arrangements étant équiprobables.

3. Statistique de test.

$$\mathbb{E}[R] = \frac{2n_1n_2}{n} + 1, \quad \text{Var}(R) = \frac{2n_1n_2(2n_1n_2 - n)}{n^2(n-1)}, \quad Z = \frac{R - \mathbb{E}[R]}{\sqrt{\text{Var}(R)}}.$$

4. Loi sous H_0 . Loi exacte combinatoire pour R (dénombrement des compositions) ; asymptotiquement $Z \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$.

5. p-value. p-value exacte, retenue par le moteur : elle est calculée par `runs_p_exacte()` sur la loi exacte de R conditionnelle à (n_1, n_2) , celle de F. Swed et C. Eisenhart (1943, section 21), tabulée par `.runs_dens()`. L'approximation normale $p = 2(1 - \Phi(|Z|))$ est également calculée et restituée comme p-value asymptotique, sans être retenue. L'équiprobabilité des $\binom{n}{n_1}$ arrangements suppose les z_t échangeables, ce qu'ils ne sont qu'à $\hat{\pi}_t$ constant ($z \sim \mathcal{N}(0, P)$, section 5.6, issue #25) : la p-value n'est exacte au sens de l'ADR 0002 que dans ce régime. Sur la ligne calculée sur z_t , le moteur l'étiquette exacte et la retient dans tous les régimes ; à $\hat{\pi}_t$ variable, c'est une approximation, sans borne d'erreur connue à $T = 8$.

Convention bilatérale. Le moteur applique le doublement (issue #29) :

$$p = \min \left\{ 1, 2 \min (P(R \leq R_{\text{obs}}), P(R \geq R_{\text{obs}})) \right\},$$

les probabilités étant celles de la loi exacte de R à (n_1, n_2) fixés. Le test est bilatéral parce que H_1 couvre le regroupement (trop peu de suites, $Z < 0$) aussi bien que l'alternance (trop de suites, $Z > 0$), comme le test de Durbin–Watson (fiche 9.1), dont la p-value exacte est elle aussi obtenue par doublement. Le doublement est en outre la convention de la p-value de Monte-Carlo de la même ligne (rejet bilatéral du bootstrap, section 4) : les colonnes `p_exacte` et `p_mc` d'une même ligne estiment ainsi la même quantité. C'est une convention, l'une des définitions de la p-value bilatérale discutées par J. D. Gibbons et J. W. Pratt (1975, section 21). Elle remplace la sommation des probabilités des issues au plus aussi probables que l'issue observée, appliquée jusqu'à l'issue #29, qui donnait $p = 1$ pour toute valeur modale de R (section 5.6, « Ce contrôle est sans objet lorsque $\hat{\pi}_t$ est constant »).

Valeurs atteignables. À $T = 8$ sans ex æquo, la médiane sépare $n_1 = n_2 = 4$ signes, 70 $P(R = 2, \dots, 8) = (2, 6, 18, 18, 18, 6, 2)$, et la p-value ne prend que quatre valeurs : 1 ($R = 5$), $52/70 = 0,743$ ($R \in \{4, 6\}$), $16/70 = 0,229$ ($R \in \{3, 7\}$) et $4/70 = 0,057$ ($R \in \{2, 8\}$). Le test est donc *inopérant* — sa plus petite p-value atteignable dépasse le seuil — à tout seuil $\alpha < 4/70$, soit $\alpha \leq 0,057$; le moteur le restitue néanmoins comme test dans tous les cas (le traitement des tests inopérants relève de l'issue #44). À $T = 5$, l'observation médiane est écartée, $n_1 = n_2 = 2$, R est uniforme sur $\{2, 3, 4\}$ et $p \in \{2/3$ ($R \in \{2, 4\}$), 1 ($R = 3$)}. **Réserve** : $n_1 \neq n_2$ ne se produit qu'en présence d'ex æquo sur la médiane (pour T impair, l'observation médiane est écartée et, sans autre ex æquo, $n_1 = n_2 = (T-1)/2$). La loi de R est alors asymétrique — à $n_1 = 3, n_2 = 4$, 35 $P(R = 2, \dots, 7) = (2, 5, 12, 9, 6, 1)$ — et le doublement n'y est qu'une convention parmi d'autres.

Ligne des suites sur ratios bruts. La même statistique est calculée sur les ratios centrés $u_t = r_t - \bar{r}$ (section 5.6). Elle reçoit la p-value exacte, calculée par `usp_runsr_p_exacte()` (`runs_p_exacte()` appliquée à u_t), sous deux conditions cumulatives : (i) $\hat{\pi}_t$ constant au sens de `usp_regime()` ($\hat{\delta} \geq 1 - 10^{-6}$ ou volumes égaux à 10^{-6} près en relatif, tolérance `TOL_DELTA_BORD`) : c'est la raison actuarielle, les r_t étant alors i.i.d. sous le modèle ajusté et les $\binom{n}{n_1}$ arrangements de signes équiprobables ; (ii) signes de

$u_t - \text{med}(u)$ et de $z_t - \text{med}(z)$ identiques terme à terme : c'est la garantie exacte. À $\hat{\pi}_t$ exactement constant, (ii) découle mathématiquement de (i), z_t étant une transformation croissante de r_t ; dans la bande de tolérance, la variation résiduelle de $\hat{\pi}_t$ peut inverser un signe (cas construit dans les tests unitaires). La condition porte sur u_t , le vecteur effectivement testé, et non sur r_t : en arithmétique flottante, le centrage peut faire basculer le signe d'une valeur égale ou quasi égale à la médiane. Si la loi de R n'est pas définie — un seul côté de la médiane représenté —, aucune p-value exacte n'est attribuée, même lorsque les deux conditions tiennent (cas 2b de `usp_tests()`). Si l'une des conditions manque, la p-value retenue est celle de Monte-Carlo, simulée sous le modèle ajusté avec ses $\hat{\pi}_t$: lorsque $\hat{\pi}_t$ varie, les r_t sont indépendants mais non identiquement distribués, les arrangements de signes ne sont plus équiprobables et la loi combinatoire n'est qu'une approximation, sans borne d'erreur connue à $T = 8$. Les cinq autres lignes de la base « ratios bruts » restent en Monte-Carlo dans tous les régimes. Mesuré (méthode prime, $B = 999$, graine 20260831) : sur le jeu de contrôle ($\hat{\delta} = 1$), p-value exacte $52/70 = 0,743$ sur les deux lignes, $p_{mc} = 0,762$ sur z_t et $0,768$ sur u_t ; sur ses cinq premières années ($\hat{\delta} = 0$, $\hat{\pi}_t$ variable), p-value exacte $2/3$ sur z_t et p-value de Monte-Carlo $0,692$ retenue sur u_t . Deux limites. Dans la bande de tolérance ($\hat{\pi}_t$ constant à `TOL_DELTA_BORD` près seulement), les arrangements ne sont équiprobables qu'à un écart d'ordre $1 - \hat{\delta}$, ou de l'étendue relative des volumes, près : la p-value n'est exacte qu'à cet ordre près, ce que le commentaire de la ligne indique. Et la p-value exacte est attribuée sur le régime *estimé* $\hat{\delta}$, sans tenir compte de l'incertitude sur $\hat{\delta}$; l'effet de cette incertitude sur la p-value n'est pas évalué. Cette seconde limite n'est pas propre à cette ligne : elle vaut pour les neuf p-values dont l'exactitude est conditionnée à $\hat{\pi}_t$ constant — cette ligne, dont le moteur conditionne l'étiquette au régime estimé, et les huit de la section 5.6, dont l'exactitude n'est acquise que dans ce même régime estimé.

6. Usage et limites. Test non paramétrique très général : il détecte aussi bien une autocorrélation (trop peu de suites) qu'une alternance systématique (trop de suites), sans hypothèse de forme. Limite importante : l'approximation normale n'est recommandée que pour $n_1, n_2 \geq 10$, soit $T \geq 20$. En-deçà, la loi exacte s'impose — c'est elle que le moteur emploie (rubrique 5) —, et la granularité de R (entier compris entre 2 et n) limite fortement le nombre de p-values atteignables. À $T = 8$, au seuil par défaut $\alpha = 0,10$, seules les valeurs extrêmes $R \in \{2, 8\}$ conduisent au rejet ($p = 0,057$, verdict **ALERTE**) ; le verdict **ECHEC**, qui exige $p < \alpha/2 = 0,05$, est inatteignable. Le verdict **OK** couvre les cinq valeurs $R \in \{3, \dots, 7\}$, soit une probabilité $66/70 = 0,943$ sous H_0 : il ne vaut pas validation de l'indépendance.

9.4 Condition du premier ordre (gradient projeté, KKT)

Référence. Contrôle numérique ; conditions d'optimalité de Kuhn et Tucker d'un minimum sous contraintes de bornes : H. W. Kuhn, A. W. Tucker, *Nonlinear programming, Proceedings of the Second Berkeley Symposium on Mathematical Statistics and Probability*, University of California Press, 1951, p. 481–492.

1. Cadre, notations et hypothèses de validité (non testées). **Contrôle numérique de l'estimation, ni test ni diagnostic** (issue #22, décision M11 du mainteneur) : il ne figure pas dans la table des tests mais dans `res$controles`, famille « H. Controles numeriques de l'estimation », au format de `usp_controle_donnees()`, avec un verdict **OK** / **ECHEC non bloquant** : un **ECHEC** est restitué et `run_engine()` produit le calcul.

En annulant la dérivée de l'objectif par rapport à $\ln \beta$, on obtient la contrainte que l'estimation impose mécaniquement aux résidus *quel que soit* le couple (δ, γ) :

$$\sum_{t=1}^T \hat{\pi}_t v_t = 0 \quad \Longleftrightarrow \quad \sum_{t=1}^T \sqrt{\hat{\pi}_t} z_t = 0.$$

Cette relation est une identité (rubrique 6) : elle ne contrôle pas la convergence, et la grandeur

$|\sum_t \hat{\pi}_t v_t| / \sum_t \hat{\pi}_t$ que restituait l'ancienne ligne de diagnostic a été retirée. Le contrôle porte sur les deux autres dérivées, celles de l'objectif *profilé* $\mathcal{O}(\delta, \gamma)$ (`usp_noyau()`\$obj, $\ln \beta$ remplacé par sa forme fermée).

2. Hypothèse nulle. Sans objet.

3. Statistique de test. Gradient analytique de $\mathcal{O}$ (`usp_gradient()`). Comme $\ln \hat{\beta}$ minimise l'objectif à (δ, γ) fixés, la dérivée totale se réduit à la dérivée partielle à $\ln \beta$ fixé, avec $\partial \mathcal{O} / \partial \pi_t = s_t / \pi_t$. En posant $e = e^{2\gamma}$, $a_t = \delta + (1 - \delta) \bar{x} / x_t$ et $s_t = z_t^2 - 1 - z_t / \sqrt{\hat{\pi}_t}$:

$$g_\delta = \sum_{t=1}^T -\hat{\pi}_t \frac{e(1 - \bar{x}/x_t)}{1 + e a_t} s_t, \quad g_\gamma = \sum_{t=1}^T -\hat{\pi}_t \frac{2 e a_t}{1 + e a_t} s_t.$$

À $\hat{\pi}_t$ constant ($\hat{\delta} = 1$ ou volumes constants), $\sum_t z_t = 0$ et $g_\gamma = w (\sum_t z_t^2 - T)$, avec $w = -\pi 2ea / (1 + ea)$ commun à toutes les années. Le gradient est projeté sur les bornes (`usp_condition_premier_ordre()`) : $\delta \in [0, 1]$ et $\gamma \in [-12, 3]$ (constante `BORNES_GAMMA`, bornes numériques et non réglementaires), le bord étant jugé à `TOL_DELTA_BORD` = 10^{-6} près ; sur une borne inférieure la composante projetée vaut $\min(g, 0)$, sur une borne supérieure $\max(g, 0)$, à l'intérieur g . On en tire la courbure $H_{\gamma\gamma}$ par différence centrée du gradient analytique ($h = 10^{-4}$), puis le pas de Newton $\Delta\gamma = -pg_\gamma / H_{\gamma\gamma}$. Lorsque $\hat{\gamma}$ est sur une borne numérique, le pas de Newton n'a pas de sens : $\Delta\gamma$ vaut NA. Ces grandeurs sont calculées au point d'arrêt de chacun des démarrages à l'optimum, pour la décision (rubrique 5), et au point du démarrage retenu, pour la restitution.

4. Loi sous H_0 . Sans objet.

5. p-value. Aucune. Le contrôle est OK si et seulement si **au moins un démarrage à l'optimum** — démarrage abouti dont l'objectif est à moins de `TOL_OPTIMUM` = 10^{-6} de l'objectif minimal, même ensemble que pour la convergence multi-démarrages (fiche 11.4) — satisfait **en un même point** (δ_s, γ_s) toutes les conditions suivantes (`usp_kkt_satisfaite()`) : le gradient et le gradient projeté sont finis ; γ_s n'est pas sur une borne numérique ; $H_{\gamma\gamma}$ est finie et $H_{\gamma\gamma} > 0$; $|\Delta\gamma| \leq \text{REP_PAS_KKT} = 10^{-6}$; $|pg_\delta| \leq \text{REP_GD_KKT} = 10^{-4}$, **règle unique au bord comme à l'intérieur** (à l'intérieur, $pg_\delta = g_\delta$). `usp_ajuster()` évalue tous les démarrages à l'optimum, sans s'arrêter au premier succès qui réintroduirait un ordre, et restitue la décision dans le champ `$kkt_au_moins_un` de `res$ajustement` ; aucun décompte des démarrages qui satisfont la condition n'est stocké ni imprimé, car il dépendrait, comme n_0^* (fiche 11.4), du chemin d'optimisation. Le commentaire, concis depuis la décision M27 du mainteneur (issue #76), nomme la règle sans en rappeler les repères et y répond par « oui » ou « non » ; il signale ensuite, s'il y a lieu, des volumes constants (δ non identifié), puis, en une seule phrase consacrée au démarrage retenu, ses anomalies dans cet ordre : gradient non fini ; courbure non finie ($H_{\gamma\gamma}$ égale à NaN ou $\pm\infty$) ou non strictement positive ($H_{\gamma\gamma}$ finie et ≤ 0) ; $\hat{\gamma}$ sur une borne numérique. La courbure n'est pas mentionnée lorsque $\hat{\gamma}$ est sur une borne, le pas de Newton n'étant alors pas défini. Ces anomalies décrivent le seul démarrage retenu ; chacune suffisant à lui faire manquer la condition (`usp_kkt_satisfaite()`), un « oui » qui les accompagne est nécessairement obtenu sur un autre démarrage à l'optimum (conséquence de la construction du code, non illustrée par une mesure ; aucun cas sur les jeux de contrôle). Le commentaire ne dit pas si $\hat{\delta}$ est au bord ou intérieur (fiche 7.7) et ne compare pas le démarrage retenu aux repères ; sur le jeu de contrôle, il se réduit à la réponse « oui » (mesure).

La règle « au moins un démarrage » (décision M25 du mainteneur, issue #22, sur spécification d'actuary) aligne ce contrôle sur la convergence multi-démarrages. Jusqu'à cette décision, le contrôle jugeait le seul démarrage retenu, c'est-à-dire le premier de la grille parmi des démarrages équivalents (marge de 10^{-10} sur l'objectif) : son verdict dépendait de l'ordre de la grille et de la plateforme, alors que le pas de Newton $|\Delta\gamma|$ des points d'arrêt équivalents atteint environ $2,5 \cdot 10^{-6}$. Sur le jeu à $\hat{\delta}$ intérieur des tests unitaires, 50

des 54 démarrages à l'optimum satisfont la condition et 4 ne la satisfont pas ($|\Delta\gamma|$ jusqu'à $1,84 \cdot 10^{-6}$), le démarrage retenu la satisfaisant ($\Delta\gamma = 1,24 \cdot 10^{-7}$); sur le jeu de contrôle, les 54 la satisfont ($|\Delta\gamma|$ de $9,3 \cdot 10^{-9}$ à $3,5 \cdot 10^{-7}$) (mesures sous Linux, R 4.3.3). La règle unique a remplacé, après audit, l'exigence $pg_\delta = 0$ au bord (décision du mainteneur, issue #22) : celle-ci créait une discontinuité, un résidu $pg_\delta = 3,6 \cdot 10^{-6}$ à $\hat{\delta} = 1$ sortant ECHEC, alors qu'une perturbation relative des données inférieure à 10^{-12} plaçait $\hat{\delta}$ à l'intérieur (0,99999809, $g_\delta = 2,3 \cdot 10^{-6}$) et le contrôle en OK (mesure sur un jeu construit à cet effet : volumes $x_t^3/10^4$ tirés du jeu de contrôle, pertes déformées d'une tendance dont le coefficient, réglé par bisection, place $\hat{\delta}$ à la bascule du bord ; les deux calculs diffèrent de $1,6 \cdot 10^{-13}$ au plus en relatif sur les données). Le repère 10^{-4} est fixé d'après ces mesures, sans référence. À volumes constants, $g_\delta = 0$ et δ n'est pas identifié (fiche 7.7, issue #58) : le commentaire le dit, au lieu de présenter la valeur rendue par l'optimiseur comme un bord.

Le repère 10^{-6} est ancré sur la décision M9 : l'erreur relative sur $\hat{\sigma}$ est de l'ordre de $\Delta\gamma$. Son plancher est $\Delta\gamma \approx -h^2/3 \approx -3,3 \cdot 10^{-7}$, biais de la différence centrée par laquelle `optim()` dérive l'objectif (pas $ndeps = h = 10^{-3}$ par défaut) ; c'est une dérivation d'actuary, vérifiée par simulation (900 ajustements simulés sous le modèle, aucun ECHEC à tort de ce fait), et non un résultat tiré de la littérature. Sur le jeu de contrôle, $\Delta\gamma = -3,4 \cdot 10^{-7}$. Les valeurs g , pg , $H_{\gamma\gamma}$ et $\Delta\gamma$ du démarrage retenu sont restituées dans les champs numériques `$gradient`, `$gradient_projete`, `$hessien_gamma` et `$pas_newton_gamma` de `res$ajustement`, et $\Delta\gamma$ dans le champ `stat` du contrôle ; le commentaire ne donne que la décision et les particularités du démarrage retenu (depuis l'issue #76, il n'imprime plus les repères `TOL_OPTIMUM`, `REP_PAS_KKT` et `REP_GD_KKT`, énoncés dans la présente fiche), car ces valeurs relèvent du bruit d'optimiseur et varient d'une plateforme à l'autre. Pour la même raison, `$gradient` et `$gradient_projete` sont exclus par conception de la comparaison aux références de non-régression (`EXCLUS_AJUSTEMENT`, `tests/outils_tests.R`, qui exclut aussi un décompte et le code de retour du démarrage retenu, fiche 11.4 ; la décision `$kkt_au_moins_un`, elle, reste comparée) : sur le jeu de contrôle, les 54 démarrages s'arrêtent à objectif égal ($1,88 \cdot 10^{-12}$ près) avec g_γ compris entre $-3,8 \cdot 10^{-7}$ et $1,09 \cdot 10^{-5}$, si bien que la valeur stockée dépend du démarrage retenu, non des données.

6. Usage et limites. Réserve sur le repère 10^{-6} . Sous la règle antérieure à la décision M25, qui jugeait le seul démarrage retenu, le taux de faux ECHEC était de l'ordre de 0,5 à 1 % à $\hat{\delta}$ intérieur, nul au bord (mesure sur données simulées sous le modèle, consignée dans la décision du mainteneur du 23/09/2026, issue #22) : la cause en est la dispersion des points d'arrêt équivalents de l'optimiseur, dont le pas de Newton atteint environ $2,5 \cdot 10^{-6}$. La règle « au moins un démarrage » (rubrique 5) y répond sans relâcher le repère. Mesures d'actuary sur un prototype (200 jeux simulés sous le modèle à $\hat{\delta}$ intérieur, graine 20260924, Linux, R 4.3.3) : 2 faux ECHEC sur 200 sous l'ancienne règle ($|\Delta\gamma|$ du démarrage retenu $1,24 \cdot 10^{-6}$ et $1,39 \cdot 10^{-6}$), aucun sous la nouvelle ; sur ces 200 jeux, le plus petit $|\Delta\gamma_s|$ parmi les démarrages à l'optimum ne dépasse pas $1,96 \cdot 10^{-7}$, soit une marge d'environ cinq sous le repère ; verdict inchangé sous cinq perturbations relatives des données de 10^{-12} (200 jeux sur 200). La contrepartie est une perte de puissance limitée sur des ajustements délibérément non convergés : sur 60 autres jeux simulés (graine 7, sans condition sur $\hat{\delta}$), chacun ajusté sous les deux réglages `factr` = 10^{13} et `maxit` = 2, 46 et 47 ECHEC contre 47 et 48 sous l'ancienne règle. Ce sont des constats de simulation, non des propriétés démontrées ; 0 faux ECHEC sur 200 borne seulement le taux à environ 1,5 % (borne supérieure unilatérale exacte à 95 % de Clopper–Pearson, $1 - 0,05^{1/200}$, pour 200 jeux indépendants ; taux moyen sous ce générateur, conditionnel au régime $\hat{\delta}$ intérieur et propre à la plateforme de mesure ; section 21). Le repère est maintenu (décision du mainteneur) ; l'issue #63 (gradient analytique fourni à `optim()`) vise la dispersion elle-même. À $\hat{\delta}$ intérieur, $\Delta\gamma$ est en outre calculé à δ fixé et ignore le terme croisé $H_{\delta\gamma}$: un résidu g_δ toléré ($\leq 10^{-4}$) déplace l'optimum en γ de $-(H_{\delta\gamma}/H_{\gamma\gamma}) \Delta\delta$, $\Delta\delta$ étant la composante en δ du pas de Newton complet. Mesuré sur le jeu à $\hat{\delta}$ intérieur des tests unitaires ($\hat{\delta} = 0,664$; $H_{\delta\delta} = 1,99$, $H_{\delta\gamma} = -3,34$, $H_{\gamma\gamma} = 31,66$, par différence centrée du gradient analytique, $h = 10^{-4}$), un résidu

$g_\delta = 10^{-4}$ correspondrait à une erreur relative de $6,4 \cdot 10^{-6}$ sur $\hat{\sigma}$, six fois le repère; le résidu observé, $g_\delta = 8,3 \cdot 10^{-7}$, est environ cent vingt fois plus petit. Le pas de Newton complet relève de l'issue #71, qui l'évaluera démarrage par démarrage : `usp_kkt_satisfaite()` en est le point d'accroche.

Portée mesurée. Sur le jeu de contrôle ($\hat{\delta} = 1$) : $g_\delta = -0,53$ (composante projetée nulle, condition de Kuhn et Tucker satisfaite au bord supérieur), $H_{\gamma\gamma} = 31,3$, $\Delta\gamma = -3,4 \cdot 10^{-7}$ au démarrage retenu, contrôle OK. Un ajustement délibérément non convergé à démarrage unique (`factr = 1013` ou `maxit = 2`) donne $|\Delta\gamma|$ compris entre $7,3 \cdot 10^{-3}$ et $1,7 \cdot 10^{-2}$ et sort ECHEC; avec la grille complète de démarrages, le meilleur point non convergé est plus proche de l'optimum ($|\Delta\gamma|$ de $1,5 \cdot 10^{-5}$ à $4,0 \cdot 10^{-3}$), et le contrôle sort encore ECHEC, y compris lorsque `optim()` renvoie le code 0 (`factr = 1013`) : dans les quatre cas (deux jeux, deux réglages), aucun démarrage à l'optimum ne satisfait la condition (`$kkt_au_moins_un faux`; mesure sous Linux, R 4.3.3, sous la règle de la décision M25).

Ancienne grandeur. Jusqu'à l'issue #22, une ligne de diagnostic de la table des tests restituait $\text{FOC} = |\sum_t \hat{\pi}_t v_t| / \sum_t \hat{\pi}_t$ (champ `$foc` de l'ajustement, supprimé), avec le repère 10^{-6} ; jusqu'à l'issue #24, le moteur posait ECHEC au-delà de ce repère. Les deux paragraphes suivants expliquent pourquoi cette grandeur ne contrôlait rien.

Point de vigilance essentiel. C'est la moyenne *pondérée* $\sum_t \hat{\pi}_t v_t$ qui est contrainte à zéro, et non la moyenne simple $\bar{z}$ des résidus standardisés. Les deux ne coïncident que si $\hat{\pi}_t$ est constant, c'est-à-dire si $\hat{\delta} = 1$ ou si les volumes x_t sont constants. Sur un jeu de données où $\hat{\delta}$ est intérieur au domaine, on observe typiquement $\text{FOC} \approx 10^{-17}$ (précision machine) alors que $\bar{z} \approx 10^{-2}$: la moyenne simple des résidus n'est donc *pas* un contrôle de convergence. Elle n'est pas pour autant une quantité libre : l'écart entre les deux moyennes est de l'ordre de la dispersion des poids $\hat{\pi}_t$, ce qui interdit d'en faire un test et conduit à la restituer comme diagnostic (fiche 9.5).

Pourquoi l'ancienne grandeur a été retirée. FOC ne mesure pas non plus la convergence. `usp_noyau()` calcule $\ln \hat{\beta}$ en forme fermée, $\ln \hat{\beta} = (T/2 + \sum_t \hat{\pi}_t \ln r_t) / \sum_t \hat{\pi}_t$; en reportant dans $v_t = \ln r_t + 1/(2\hat{\pi}_t) - \ln \hat{\beta}$, on obtient $\sum_t \hat{\pi}_t v_t = 0$ *identiquement*, pour tout couple (δ, γ) et non seulement à l'optimum. Vérifié numériquement sur des couples arbitraires — $(0,5; -1)$, $(0; -3)$, $(1; 0)$, $(0,3; -2,5)$, $(1; 3)$ — où FOC reste inférieur à 10^{-15} . Un dépassement du repère de la rubrique 5 ne peut donc survenir qu'en cas d'anomalie arithmétique (débordement, valeur non finie), jamais parce que l'optimisation se serait arrêtée trop tôt; c'est pourquoi la ligne ne portait plus aucun verdict (ADR 0001, amendement du 23/09/2026) : un OK qui ne peut être perdu que sur une anomalie arithmétique n'apporterait aucune information sur l'estimation. La convergence en γ est désormais jugée par le pas de Newton $\Delta\gamma$ du présent contrôle; l'écart de $\sum_t z_t^2$ à T (fiche 9.6) en est la lecture sur les résidus, exacte à $\hat{\pi}_t$ constant ($g_\gamma = w(\sum_t z_t^2 - T)$).

Pourquoi un verdict de contrôle et non de test (ADR 0001) : le gradient projeté et le pas de Newton sont des grandeurs de calcul, non des statistiques; ils n'ont ni hypothèse nulle ni loi de référence, les repères 10^{-6} et 10^{-4} sont des tolérances numériques et non des niveaux, et le verdict OK / ECHEC juge l'exécution de l'optimisation, non le modèle réglementaire. *Lecture à $T = 8$* : le contrôle ne se lit pas comme une statistique dont la loi dépendrait de T . Il vérifie seulement qu'un point d'arrêt au moins, parmi ceux qui atteignent l'objectif minimal à `TOL_OPTIMUM` près, satisfait la condition d'optimalité *locale* à la précision numérique annoncée; le point rapporté, celui du démarrage retenu, atteint l'objectif minimal à la marge de sélection 10^{-10} près sans être nécessairement ce point, et son $\Delta\gamma$ reste lisible dans le champ stat (le caractère global du minimum relève de la fiche 11.4); l'erreur relative qu'il tolère sur $\hat{\sigma}$, de l'ordre de 10^{-6} pour le point qui satisfait la règle et d'au plus quelques 10^{-6} pour le point rapporté ($|\Delta\gamma| \lesssim \sqrt{2 \cdot 10^{-10} / H_{\gamma\gamma}} \approx 2,6 \cdot 10^{-6}$ pour $H_{\gamma\gamma} \approx 30$, par développement quadratique de l'objectif à δ fixé : dérivation d'actuary, non tirée de la littérature; $2,5 \cdot 10^{-6}$ observé au plus), est sans commune mesure avec l'incertitude d'échantillonnage de $\hat{\sigma}$ sur huit points (fiche 11.3), qu'il ne mesure pas.

9.5 Centrage des résidus standardisés (diagnostic)

Référence. Diagnostic ; conditions du premier ordre du maximum de vraisemblance (fiche 9.4).

1. Cadre, notations et hypothèses de validité (non testées). Résidus standardisés $z_t = \sqrt{\hat{\pi}_t} v_t$ et leur moyenne simple $\bar{z}$. **Diagnostic, non test.** La relation $\sum_t \sqrt{\hat{\pi}_t} z_t = 0$ vaut *toujours*, et pas seulement à l'optimum : $\ln \hat{\beta}$ étant obtenu en forme fermée, $\ln \hat{\beta} = (T/2 + \sum_t \hat{\pi}_t \ln r_t) / \sum_t \hat{\pi}_t$, elle est une **identité algébrique** vérifiée pour tout couple (δ, γ) , convergé ou non (fiche 9.4). $\bar{z}$ est donc rivé par l'estimation en toute circonstance. Cette contrainte pondérée ne se réduit à $\sum_t z_t = 0$ que lorsque $\hat{\pi}_t$ est *constant*, c'est-à-dire lorsque $\hat{\delta} = 1$ ou lorsque les volumes x_t le sont. Le seul fait que $\hat{\delta}$ soit au bord de $[0, 1]$ ne suffit pas : à $\hat{\delta} = 0$ avec des volumes variables, $\hat{\pi}_t$ varie et l'égalité $\sum_t z_t = 0$ ne tient pas. Le moteur distingue ces trois situations dans le commentaire attaché à la ligne, en séparant en outre, parmi les cas où $\hat{\pi}_t$ est déclaré constant, la constance exacte de la constance à la tolérance près (ci-dessous).

Décision de la constance de $\hat{\pi}_t$. $\pi_t = 1 / \ln(1 + e^{2\gamma}(\delta + (1 - \delta)\bar{x}/x_t))$ est constant en t si et seulement si $\delta = 1$ ou les volumes x_t sont constants. Le moteur décide donc sur cette *cause*, par `usp_regime()`, et non sur l'étendue observée des $\hat{\pi}_t$: $\hat{\pi}_t$ est tenu pour constant lorsque $\hat{\delta} \geq 1 - 10^{-6}$ ou que $\max_t x_t - \min_t x_t \leq 10^{-6} \bar{x}$. La tolérance `TOL_DELTA_BORD` = 10^{-6} est la même que celle du drapeau « $\hat{\delta}$ au bord » (fiche 7.7), de sorte que les deux drapeaux ne peuvent plus se contredire ; un seuil distinct sur l'étendue des $\hat{\pi}_t$ laissait auparavant une zone où $\hat{\delta}$ était déclaré au bord sans que $\hat{\pi}_t$ soit déclaré constant. Ce n'est pas une valeur réglementaire mais une résolution numérique, choisie au-dessus de celle du critère d'arrêt de l'optimiseur L-BFGS-B sur δ . Ce critère porte sur la réduction relative de l'objectif, $\text{factr} \times \varepsilon_{\text{machine}}$, soit $2,2 \cdot 10^{-11}$ pour l'ajustement complet `usp_ajuster()` (`factr` = 1e5) et $2,2 \cdot 10^{-9}$ pour le réajustement rapide `usp_ajuster_rapide()` (`factr` = 1e7) des réplifications bootstrap ; or, sur le jeu de contrôle, l'objectif profilé en γ ne varie près de $\delta = 1$ que de $2,3 \cdot 10^{-2} (1 - \delta)$ en relatif (mesuré pour $1 - \delta$ de 10^{-4} à 10^{-2}). La résolution sur δ est donc de l'ordre de 10^{-9} pour l'ajustement complet et de 10^{-7} pour le réajustement rapide (approximation numérique, issue #31 du dépôt). Constat de simulation sur le jeu de contrôle ($B = 999$, graine 20260831) : 953 des 999 valeurs $\hat{\delta}^*$ sont exactement sur une borne, et les 46 autres en sont distantes d'au moins $1,74 \cdot 10^{-4}$; aucune ne tombe entre 0 et ce minimum, de sorte que le seuil 10^{-6} ne sépare aucun optimum intérieur observé.

Constance exacte et constance à la tolérance près. La tolérance fait coexister deux situations que le moteur distingue (champs `$pi_constant_exact`, `$delta_dans_bande` et `$volumes_dans_bande` de `usp_regime()`). À constance *exacte* — $\hat{\delta} = 1$ exactement, ou volumes x_t rigoureusement égaux —, $\hat{\pi}_t$ est le même nombre flottant pour tout t , et $\bar{z} = 0$ est l'identité algébrique ci-dessus, vraie à la précision machine. Dans la *bande de tolérance* — $1 - 10^{-6} \leq \hat{\delta} < 1$, ou volumes d'étendue relative non nulle mais au plus 10^{-6} —, $\hat{\pi}_t$ varie encore légèrement : seule $\sum_t \sqrt{\hat{\pi}_t} z_t = 0$ reste une identité, et $\bar{z}$ n'est nulle qu'à un écart d'ordre $(1 - \hat{\delta})$, ou de l'étendue relative des volumes, près. Cet écart ne résulte pas de l'annulation d'une dérivée : il suit la position de $\hat{\delta}$ (ou l'étendue des volumes), déjà affichée, et ne renseigne **pas** sur la convergence en γ . Mesuré sur le jeu de contrôle, au $\hat{\gamma}$ de l'ajustement comme à γ réoptimisé à δ fixé : $\bar{z} = 3,575 \cdot 10^{-3} (1 - \delta)$ pour $1 - \delta$ de 10^{-9} à 10^{-6} , contre $-2,0 \cdot 10^{-16}$ à $\delta = 1$ (constat numérique sur ces données ; seul l'ordre $(1 - \delta)$ est général, le coefficient dépend des données). Le champ `detail` de la ligne le dit dans ce cas, avec la valeur de $1 - \hat{\delta}$ ou de l'étendue relative des volumes ; à constance exacte, il énonce l'identité.

2. Hypothèse nulle. Sans objet. L'hypothèse $\mathbb{E}[z_t] = 0$, sous laquelle cette grandeur était auparavant restituée comme un test, ne peut pas être mise en défaut par les données : $\bar{z}$ est déterminé par l'estimation, non librement observé.

3. Statistique de test. Aucune statistique de test. La grandeur restituée est l'estimation $\bar{z}$, portée par le champ `estim` de la table des tests ; les champs `stat` et `loi` sont vides.

4. Loi sous H_0 . Sans objet, pour deux raisons distinctes. *Loi nominale.* La loi $t(T - 1)$ de $\bar{z}\sqrt{T}/s_z$ est optimiste : les z_t dépendent de trois paramètres estimés ($\hat{\beta}, \hat{\delta}, \hat{\gamma}$) et satisfont la contrainte linéaire ci-dessus, de sorte que le nombre effectif de degrés de liberté est inférieur à $T - 1$. Cet argument, exact, reste faible : il suggère une p-value seulement trop optimiste, donc utilisable avec prudence. **Le fait qui tranche est plus radical.** Lorsque $\hat{\pi}_t$ est exactement constant, $\bar{z} = 0$ est une identité algébrique ; la valeur affichée est un zéro machine, le rapport $\bar{z}\sqrt{T}/s_z$ l'est aussi, et la p-value bilatérale vaut 1 *quelles que soient les données*. Ce n'est pas une p-value élevée : c'est une **constante de T** , qui ne contient aucune information sur l'échantillon. Conséquence algébrique exacte, vérifiée numériquement sur deux jeux sans rapport l'un avec l'autre, à $T = 8$:

Jeu de données	$\hat{\delta}$	t observé	p nominale bilatérale
Jeu de contrôle du dossier	1	$-5,3 \cdot 10^{-16}$	1,0000000000
Jeu étranger, volumes x_t constants ^(a)	0	$-8,7 \cdot 10^{-17}$	1,0000000000

^(a) $x_t \equiv 100$ et $y_t = 55, 70, 61, 84, 48, 92, 66, 73$, jeu construit pour cette vérification et sans rapport avec le dossier.

Le second jeu n'a aucun point commun avec le premier et conduit même à $\hat{\delta} = 0$; il donne pourtant la même p-value, parce que la constance de $\hat{\pi}_t$ y résulte non de $\hat{\delta}$ mais de celle des volumes. Sur les 493 réplifications à $\delta^* = 1$ de la simulation décrite ci-dessous, la p-value nominale vaut 1 sur toutes, sans exception. Un verdict fondé sur cette p-value serait un OK qu'**aucune donnée ne peut faire perdre** — l'assurance d'un contrôle qui n'en est pas un, que la rubrique 6 écarte. La même vérification, conduite sur la variance unitaire dont la loi nominale est un χ^2 et non un t , donne le même constat (fiche 9.6) : ce n'est donc pas une particularité de la loi de Student.

Loi simulée. La loi de $\bar{z}$ sous le modèle ajusté n'est pas davantage exploitable, non parce qu'elle serait constante, mais parce qu'elle est un *mélange*. Constat de simulation sur le jeu de contrôle ($T = 8, \hat{\delta} = 1, B = 999$ réplifications, graine 20260831) : 493 réplifications donnent $\delta^* = 1$ et une moyenne $\bar{z}^*$ d'écart-type $2,2 \cdot 10^{-16}$, soit un zéro machine ; 460 donnent $\delta^* = 0$ et un écart-type de $1,7 \cdot 10^{-2}$, composante diffuse ; 46 un δ^* intérieur.

Ce n'est pas le mélange en lui-même qui prive la p-value de sens, mais le fait que la loi simulée porte un **atome en la valeur observée**. La valeur observée est elle-même un zéro machine ($\bar{z} = -2,0 \cdot 10^{-16}$) et les 493 réplifications de la première composante le sont aussi ($|\bar{z}^*| \leq 7,8 \cdot 10^{-16}$) : une p-value bilatérale $2 \min(\mathbb{P}(\bar{z}^* \geq \bar{z}), \mathbb{P}(\bar{z}^* \leq \bar{z}))$ se décide alors par le classement d'ex æquo numériques. Mesuré : sur ces 493 réplifications, 420 vérifient $\bar{z}^* \geq \bar{z}$ et 74 vérifient $\bar{z}^* \leq \bar{z}$, uniquement d'après le signe d'un bruit de l'ordre de 10^{-16} — d'où la dépendance du résultat à la plateforme de calcul. La somme $420 + 74 = 494$ excède 493 d'une unité : une réplification tombe exactement sur la valeur observée et est comptée dans les deux queues, les deux inégalités de la p-value bilatérale étant larges.

Se restreindre à la composante diffuse ne sauverait pas la vérification : la p-value recalculée sur les seules 506 réplifications à $\hat{\pi}_t^*$ non constant vaut 0,966. La valeur observée est par construction au centre de cette composante, de sorte qu'un test conditionnel serait *inopérant* et non simplement mal calibré. Ces deux chiffres sont des constats de simulation sur ce jeu de données, non des propriétés démontrées du modèle.

5. p-value. Aucune. La grandeur a été retirée des statistiques simulées par `.stats_bootstrapables()` : ni p-value exacte, ni p-value de Monte-Carlo, ni p-value asymptotique n'est calculée ni affichée pour cette ligne, et aucune p-value n'est retenue.

6. Usage et limites. Pourquoi aucun verdict. Une grandeur que l'estimation rive ne peut pas contredire le modèle ; lui attacher un verdict OK donnerait au lecteur du dossier l'assurance d'un contrôle qui n'en est pas un. La ligne est donc restituée comme diagnostic, avec le verdict INFO, et accompagnée du motif. Ce qu'elle apporte à $T = 8$ est très limité, et il faut le dire sans détour. Lorsque $\hat{\pi}_t$ est exactement constant, $\bar{z}$ n'est que du bruit d'arrondi et ne renseigne sur rien — en particulier **pas** sur la qualité de l'arrêt de

l'optimiseur, puisque l'identité rappelée en rubrique 1 ne dépend pas de la convergence : mesuré, $\bar{z}$ vaut $-1,7 \cdot 10^{-17}$ à $(\hat{\delta}, \gamma) = (1, 0)$ et $1,6 \cdot 10^{-16}$ à $(1, 3)$, deux points très éloignés de l'optimum. Dans la bande de tolérance (rubrique 1), $\bar{z}$ est proportionnel à $1 - \hat{\delta}$, ou à l'étendue relative des volumes, et n'en dit pas davantage. Lorsque $\hat{\pi}_t$ varie, $\bar{z}$ est l'écart entre centrage pondéré et centrage non pondéré : l'identité $\sum_t \sqrt{\hat{\pi}_t} z_t = 0$ donne la borne exacte

$$|\bar{z}| \leq \frac{\max_t |\sqrt{\hat{\pi}_t} - \bar{c}|}{\bar{c}} \cdot \frac{1}{T} \sum_t |z_t|, \quad \bar{c} = \frac{1}{T} \sum_t \sqrt{\hat{\pi}_t}.$$

$\bar{z}$ est donc *de l'ordre de* la dispersion des poids, sans en être une fonction : le coefficient qui les relie est aléatoire. Mesuré sur les 506 répliquions à $\hat{\pi}_t^*$ non constant, la corrélation entre $|\bar{z}^*|$ et l'amplitude relative de $\hat{\pi}_t^*$ n'est que de 0,26, et le rapport des deux s'étend de 0,006 à 0,12 entre les quantiles 5 % et 95 %. Dans les deux cas, $\bar{z}$ n'est pas une propriété libre des résidus. Un biais systématique de niveau non capté par $\hat{\beta}$ reste recherché ailleurs, par des vérifications qui portent, elles, un verdict : les tests de tendance de l'hypothèse H1 (section 6) pour une dérive du ratio S/P, les fiches 10.1 et 10.2 pour une rupture de régime.

9.6 Variance unitaire des résidus standardisés (diagnostic)

Référence. Diagnostic ; conditions du premier ordre du maximum de vraisemblance (fiche 9.4).

1. Cadre, notations et hypothèses de validité (non testées). Résidus standardisés $z_t = \sqrt{\hat{\pi}_t} v_t$ et leur variance empirique $\text{Var}(z)$. **Diagnostic, non test.** La condition du premier ordre en γ rive l'échelle des z_t comme celle en $\ln \beta$ en rive le niveau : lorsque $\hat{\pi}_t$ est constant ($\hat{\delta} = 1$, ou volumes x_t constants), la condition en γ donne $\sum_t z_t^2 = T$ (condition du premier ordre de l'objectif *profilé* que minimise `usp_objectif()`, $\ln \hat{\beta}$ y étant substitué en forme fermée ; dans la vraisemblance complète en $(\ln \beta, \delta, \gamma)$, la condition en γ s'écrit $\sum_t z_t^2 = T + \sum_t v_t$ et n'aboutit à $\sum_t z_t^2 = T$ que jointe à celle en $\ln \beta$) et, jointe à $\sum_t z_t = 0$ que donne celle en $\ln \beta$, $\text{Var}(z) = T/(T-1)$ — c'est-à-dire 1,143 à $T = 8$, et non 1. C'est donc la condition en γ , et non celle en $\ln \beta$, qui rive la variance : $\sum_t \sqrt{\hat{\pi}_t} z_t = 0$ ne dit rien de $\sum_t z_t^2$.

Forme explicite de la condition en γ . Avec $\pi_t = 1/\ln(1 + e^{2\gamma a_t})$, $a_t = \delta + (1 - \delta) \bar{x}/x_t$ (`usp_pi()`), la condition du premier ordre en γ s'écrit

$$\sum_{t=1}^T k_t \left(z_t^2 - \frac{z_t}{\sqrt{\hat{\pi}_t}} - 1 \right) = 0, \quad k_t = \hat{\pi}_t (1 - e^{-1/\hat{\pi}_t}) > 0.$$

Dérivation : à $\ln \beta$ fixé, $v_t = \ln r_t + 1/(2\pi_t) - \ln \beta$ donne $\partial(\pi_t v_t^2 - \ln \pi_t)/\partial \pi_t = (z_t^2 - z_t/\sqrt{\pi_t} - 1)/\pi_t$, et $d\pi_t/d\gamma = -2\pi_t^2(1 - e^{-1/\pi_t})$ puisque $1 + e^{2\gamma a_t} = e^{1/\pi_t}$; la dérivée de l'objectif en γ vaut donc $-2 \sum_t k_t (z_t^2 - z_t/\sqrt{\pi_t} - 1)$, et, la dérivée partielle en $\ln \beta$ étant nulle à la forme fermée, c'est aussi celle de l'objectif *profilé*. Vérifiée numériquement : au point $(\delta, \gamma) = (0,4 ; -2)$, la différence finie centrée de l'objectif de `usp_noyau()` et la formule concordent sur neuf chiffres significatifs. Lorsque $\hat{\pi}_t$ est constant, k_t l'est aussi et la relation se réduit à $\sum_t z_t^2 - \sum_t z_t/\sqrt{\hat{\pi}_t} = T$, soit, jointe à $\sum_t z_t = 0$, $\sum_t z_t^2 = T$. Sinon, elle mêle z_t^2 et z_t sous des poids k_t et $k_t/\sqrt{\hat{\pi}_t}$ variables : $\text{Var}(z)$ reste *rivée* par cette condition mais n'est pas *déterminée* par elle, et son écart à $T/(T-1)$ n'a pas de valeur de référence. Mesuré sur le jeu de contrôle à δ fixé à 0 (volumes variables) et γ à son optimum : la somme ci-dessus vaut $7 \cdot 10^{-10}$, tandis que $\sum_t z_t^2 - T = 3,2 \cdot 10^{-3}$.

À la différence de celle en $\ln \beta$ (fiche 9.4), cette seconde relation n'est *pas* une identité algébrique : elle suppose la dérivée en γ effectivement annulée, donc l'optimisation aboutie. L'argument suppose en outre l'optimum *intérieur* en γ : si $\hat{\gamma}$ butait sur une borne de son domaine $[-12, 3]$, la dérivée ne serait pas

annulée et l'égalité tomberait. Cette réserve est théorique : $\sigma = \hat{\beta} e^\gamma$, de sorte que $\gamma = 3$ signifierait $\sigma \approx 20 \hat{\beta}$ et $\gamma = -12$, $\sigma \approx 6 \cdot 10^{-6} \hat{\beta}$, deux situations sans réalité pour un ratio S/P ; sur le jeu de contrôle, aucune des 999 réplifications n'atteint une borne ($\hat{\gamma}^*$ reste entre $-3,34$ et $-1,37$).

Constance à la tolérance près. Ce qui précède vaut à constance *exacte* de $\hat{\pi}_t$. Dans la bande de tolérance définie au centrage (fiche 9.5), $\hat{\pi}_t$ varie encore légèrement et l'égalité $\text{Var}(z) = T/(T-1)$, à optimum intérieur en γ , ne tient qu'à **deux écarts** près : la tolérance d'arrêt de l'optimiseur, et un écart d'ordre $(1 - \hat{\delta})$, ou de l'étendue relative des volumes, dû à la variation résiduelle de $\hat{\pi}_t$. Mesuré sur le jeu de contrôle : la tolérance d'arrêt laisse $\sum_t z_t^2 - T = -5,4 \cdot 10^{-6}$ sur l'ajustement ($\hat{\delta} = 1$) ; à γ annulant la dérivée en γ à 10^{-14} près (uniroot), $\sum_t z_t^2 - T$ vaut $-1,8 \cdot 10^{-15}$ à $\delta = 1$ mais $2,74 \cdot 10^{-3} (1 - \delta)$ pour $1 - \delta$ de 10^{-8} à 10^{-6} (constat numérique sur ces données, coefficient propre aux données). L'écart résiduel renseigne donc sur la convergence en γ sous ces deux réserves, que le champ detail de la ligne énonce dans ce cas.

2. Hypothèse nulle. Sans objet. L'hypothèse $\text{Var}(z_t) = 1$, sous laquelle cette grandeur était auparavant restituée comme un test, n'est pas celle que l'estimation laisse libre : la valeur de référence imposée par les conditions du premier ordre est $T/(T-1)$, et non 1.

3. Statistique de test. Aucune statistique de test ; la quantité $C = (T-1) s_z^2$ n'est plus calculée. La grandeur restituée est l'estimation $\text{Var}(z)$, portée par le champ estim de la table des tests.

4. Loi sous H_0 . Sans objet. La loi $\chi^2(T-1)$ de C est nominale : elle ignore l'estimation préalable de $(\hat{\beta}, \hat{\delta}, \hat{\gamma})$ et la contrainte d'échelle qui en résulte. Comme au centrage (fiche 9.5), l'argument décisif n'est pas que cette loi serait optimiste, mais qu'à $\hat{\pi}_t$ constant elle produit une p-value **indépendante des données**. Les conditions du premier ordre donnent alors $\sum_t z_t^2 = T$ et $\bar{z} = 0$, d'où $C = (T-1) s_z^2 = \sum_t z_t^2 - T \bar{z}^2 = T$ à la tolérance d'arrêt près, et la p-value bilatérale $2 \min(F_{\chi^2(T-1)}(T), 1 - F_{\chi^2(T-1)}(T))$ ne dépend plus que de T : elle vaut 0,6651878 à $T = 8$. Cette conséquence est algébrique, mais — à la différence de celle du centrage — elle n'est exacte qu'à la tolérance d'arrêt de l'optimiseur près, puisqu'elle repose sur la condition en γ et non sur la forme fermée de $\ln \hat{\beta}$ (rubrique 1). Vérifiée numériquement : sur le jeu de contrôle comme sur un jeu étranger à volumes constants (fiche 9.5), la p-value nominale vaut 0,6651888, les deux valeurs coïncidant jusqu'à la huitième décimale ; sur les 493 réplifications à $\delta^* = 1$, elle reste comprise entre 0,665100 et 0,665224, l'amplitude résiduelle n'étant due qu'à cette même tolérance d'arrêt, discutée plus bas. Le verdict qui en découlerait serait donc, lui aussi, un OK qu'aucune donnée ne peut faire perdre.

La loi simulée sous le modèle ajusté porte, comme celle du centrage (fiche 9.5), un atome en la valeur observée. Constat de simulation sur les mêmes $B = 999$ réplifications (graine 20260831) : les 493 à $\hat{\pi}_t^*$ constant donnent une valeur rivée à $T/(T-1)$, d'écart-type $3,5 \cdot 10^{-6}$; les 506 autres une valeur diffuse, d'écart-type $4,9 \cdot 10^{-3}$.

Une différence avec le centrage mérite d'être relevée, car elle change la nature du bruit comparé : ici, ce n'est pas l'arrondi machine mais la **tolérance d'arrêt de l'optimiseur**. Sur les 493 réplifications concernées, $\text{Var}(z^*) - T/(T-1)$ s'étend de $-3,0 \cdot 10^{-5}$ à $+7,1 \cdot 10^{-5}$, de médiane $-7,7 \cdot 10^{-7}$, quand la valeur observée vaut $-7,8 \cdot 10^{-7}$. Or les deux ne sont pas produites au même réglage : l'ajustement observé emploie factr = 1e5 et le réajustement des réplifications factr = 1e7. La p-value de Monte-Carlo autrefois retenue (0,864) comparait donc deux tolérances d'optimiseur différentes. Se restreindre à la composante diffuse ne sauverait pas davantage la vérification qu'au centrage : la p-value recalculée sur les seules 506 réplifications à $\hat{\pi}_t^*$ non constant vaut 0,998.

5. p-value. Aucune. La grandeur a été retirée des statistiques simulées par stats_bootstrapables() ; aucune p-value n'est calculée ni retenue pour cette ligne.

6. Usage et limites. Pourquoi aucun verdict. Comme pour le centrage, la grandeur est rivée par

l'estimation : elle est restituée comme diagnostic, avec le verdict INFO et le motif. Sur le jeu de contrôle ($T = 8$, $\hat{\delta} = 1$), $\text{Var}(z) = 1,142856$ contre $T/(T - 1) = 1,142857$: l'écart, $-6,8 \cdot 10^{-7}$ en relatif, provient de la tolérance d'arrêt de l'optimiseur et non des données.

Ce que ce diagnostic apporte, et qu'aucun autre n'apporte. L'écart de $\sum_t z_t^2$ à T est, à ce jour, le *seul* indicateur de la convergence en γ de toute la restitution : la condition en $\ln \beta$ étant une identité (fiche 9.4), elle ne peut rien signaler, tandis que celle en γ n'est satisfaite qu'à l'optimum. Les ordres de grandeur mesurés situent ce que « notable » veut dire : à l'optimum, 10^{-6} en relatif avec `factr = 1e5`, et jusqu'à $6 \cdot 10^{-5}$ sur les réplifications réajustées avec `factr = 1e7` ; à $\hat{\delta} = 1$ mais γ forcé hors de l'optimum, $\sum_t z_t^2 - T$ vaut $-7,8$ pour $\gamma = 0$ et $-7,97$ pour $\gamma = 3$. Un écart de cet ordre est donc un défaut de convergence, non une propriété des données. Lorsque $\hat{\pi}_t$ varie, l'écart n'a en revanche pas de valeur de référence (rubrique 1) : la condition en γ ne fixe plus $\sum_t z_t^2$, et l'écart ne se lit plus comme un contrôle numérique. Le contrôle de l'échelle de σ proprement dit relève de l'intervalle bootstrap et du jackknife (section 11), qui portent, eux, sur σ_{USP} .

9.7 Durbin–Watson sur ratios bruts

Référence. J. Durbin, G. S. Watson (1950, 1951), *op. cit.* (fiche 9.1).

1. Cadre, notations et hypothèses de validité (non testées). Même statistique que la fiche 9.1, appliquée aux ratios centrés $u_t = r_t - \bar{r}$, $r_t = y_t/x_t$, ordonnés chronologiquement (base « ratios bruts », section 5.6). La base ne dépend d'aucun ajustement : elle sert à vérifier que la conclusion d'indépendance tirée des z_t n'est pas un artefact de la pondération $\hat{\pi}_t$. Hypothèse non testée : le modèle ajusté, sous lequel la loi de référence est simulée. Sous ce modèle, les r_t sont indépendants et lognormaux, de variance dépendant de x_t dès que $\hat{\pi}_t$ varie : les u_t ne sont ni gaussiens ni de même variance.

2. Hypothèse nulle. H_0 : absence d'autocorrélation d'ordre 1 du ratio S/P, contre H_1 : autocorrélation du ratio S/P.

3. Statistique de test. $DW = \sum_{t=2}^T (u_t - u_{t-1})^2 / \sum_{t=1}^T u_t^2$, calculée par `stat_dw()`, qui recentre la série. La statistique est invariante par translation et par changement d'échelle : elle vaut DW calculée sur les r_t eux-mêmes (écart nul, mesure sur le jeu de contrôle).

4. Loi sous H_0 . Aucune loi exacte ni asymptotique n'est employée : la loi d'Imhof de la fiche 9.1 suppose des variables gaussiennes, ce que les u_t ne sont pas. La loi de référence est simulée par le bootstrap paramétrique sous le modèle ajusté, qui reproduit l'hétéroscédasticité des r_t (section 5.6, « Statut des p-values selon la base »).

5. p-value. p-value de Monte-Carlo, bilatérale (clé `DWr`, procédure de la fiche 4.1), seule calculée et seule retenue, avec son erreur de Monte-Carlo `err_mc` en $\mathcal{O}(B^{-1/2})$. Mesuré sur le jeu de contrôle ($\hat{\delta} = 1$, $B = 999$, graine 20260831) : $DW = 1,630$, $p_{\text{mc}} = 0,566$ (erreur de Monte-Carlo 0,029), contre $DW = 1,618$ et une p-value exacte de 0,565 sur z_t .

6. Usage et limites. Même portée que le test sur z_t (ordre 1 seulement), sans passer par le modèle. À $\hat{\pi}_t$ constant — cas du jeu de contrôle —, la ligne est un quasi-doublon de son homologue sur z_t , dont elle ne diffère qu'au second ordre en coefficient de variation des r_t ; son commentaire commence alors par « CONTROLE SANS OBJET ICI » (section 5.6). Elle n'apporte une information propre que lorsque $\hat{\pi}_t$ varie. À $T = 8$, la p-value de Monte-Carlo n'est exacte qu'à l'erreur de Monte-Carlo près *et* sous le modèle ajusté pris pour vrai : sa validité est celle du bootstrap paramétrique, asymptotique en T et non quantifiable à $T = 8$ (section 4) ; la calibration mesurée sur cette base est un constat de simulation (section 5.6).

9.8 Ljung–Box au retard 1 sur ratios bruts

Référence. G. M. Ljung, G. E. P. Box (1978), *op. cit.* (fiche 9.2).

1. Cadre, notations et hypothèses de validité (non testées). Statistique de Ljung–Box au seul retard 1, appliquée aux ratios centrés u_t (base « ratios bruts », section 5.6). Mêmes hypothèses non testées et même objet que la fiche 9.7. Le retard 2 n’est pas restitué sur cette base : $\hat{\rho}_2$ n’y reposerait que sur $T - 2$ produits (commentaire qui précède le catalogue USP_CATALOGUE_MC).

2. Hypothèse nulle. $H_0 : \rho_1 = 0$ pour le ratio S/P, contre H_1 : autocorrélation au retard 1.

3. Statistique de test. $Q_{LB} = T(T + 2) \hat{\rho}_1^2 / (T - 1)$, $\hat{\rho}_1$ étant l’autocorrélation empirique de la fiche 9.2 calculée sur les u_t (`stats::Box.test()`, appel direct dans `.stats_bootstrapables()`). Invariante par translation et changement d’échelle.

4. Loi sous H_0 . La loi $\chi^2(1)$ de la fiche 9.2 n’est ni calculée ni employée sur cette base. La loi de référence est simulée par le bootstrap paramétrique sous le modèle ajusté.

5. p-value. p-value de Monte-Carlo en queue haute (clé LB1r), seule calculée et seule retenue, avec son erreur de Monte-Carlo. Mesuré sur le jeu de contrôle : $Q = 1,3 \cdot 10^{-4}$, $p_{mc} = 0,996$ (erreur 0,002), contre $Q = 9,2 \cdot 10^{-3}$ et une p-value de Monte-Carlo de 0,937 sur z_t .

6. Usage et limites. Redondant avec la fiche 9.7 au premier ordre (les deux statistiques sont fonctions de l’autocorrélation d’ordre 1). Q repose sur une quasi-annulation de $\hat{\rho}_1$: sa valeur relative varie fortement d’une base à l’autre sans que la p-value en dépende à ce niveau (section 5.6). Même réserve à $\hat{\pi}_t$ constant (quasi-doublon, « CONTROLE SANS OBJET ICI ») et même portée de la p-value de Monte-Carlo à $T = 8$ que pour la fiche 9.7.

9.9 Test des suites sur ratios bruts

Référence. A. Wald, J. Wolfowitz (1940), *op. cit.* ; loi exacte : F. Swed, C. Eisenhart (1943) (fiche 9.3, section 21).

1. Cadre, notations et hypothèses de validité (non testées). Suite des signes de $u_t - \text{med}(u)$, ratios centrés de la base « ratios bruts » (section 5.6) ; n_1, n_2 et R comme à la fiche 9.3. Hypothèse non testée : continuité de la variable.

2. Hypothèse nulle. H_0 : arrangement aléatoire des signes du ratio centré, contre H_1 : arrangement non aléatoire (regroupement ou alternance).

3. Statistique de test. R et sa forme centrée réduite Z (`test_runs()` appliquée à u_t), définis à la fiche 9.3. Seuls les signes par rapport à la médiane interviennent : la statistique est invariante par toute transformation croissante des r_t .

4. Loi sous H_0 . Loi combinatoire exacte de R à (n_1, n_2) fixés si les $\binom{n}{n_1}$ arrangements sont équiprobables, ce qui suppose les r_t i.i.d. : c’est le cas sous le modèle ajusté à $\hat{\pi}_t$ constant seulement. À $\hat{\pi}_t$ variable, les r_t sont indépendants mais de médianes et d’échelles propres à chaque année, et la loi combinatoire n’est qu’une approximation, sans borne d’erreur connue à $T = 8$; la loi de référence est alors simulée par le bootstrap paramétrique.

5. p-value. Sous la double condition de `usp_runsr_p_exacte()` — $\hat{\pi}_t$ constant au sens de `usp_regime()`, et signes de $u_t - \text{med}(u)$ et de $z_t - \text{med}(z)$ identiques terme à terme —, p-value exacte de `runs_p_exacte()`, convention bilatérale du doublement (issue #29) ; sinon, p-value de Monte-Carlo (clé Runsr), bilatérale. La condition, ses deux motifs et les deux limites (bande de tolérance, régime estimé) sont détaillés à la fiche 9.3, rubrique 5. Mesuré sur le jeu de contrôle ($\hat{\delta} = 1$) : $Z = -0,764$ sur u_t comme sur z_t , p-value exacte $52/70 = 0,743$ retenue sur les deux lignes, $p_{mc} = 0,768$ (erreur 0,031).

6. Usage et limites. À $\hat{\pi}_t$ constant, la ligne est un **doublon exact** de la ligne des suites sur z_t : même statistique, même p-value exacte, même verdict (section 5.6). Elle n'apporte une information propre que lorsque $\hat{\pi}_t$ varie, où elle retient alors la p-value de Monte-Carlo, dont la portée à $T = 8$ est celle du bootstrap paramétrique (section 4). Granularité et test inopérant : mêmes valeurs atteignables qu'à la fiche 9.3 lorsque la p-value exacte est retenue.

Diagnostics de stabilité, ruptures et points aberrants

Ces diagnostics ne correspondent pas directement à l'une des quatre hypothèses réglementaires, mais conditionnent la validité pratique des tests précédents : un point aberrant ou une rupture de régime peut à lui seul provoquer ou masquer un rejet ailleurs.

10.1 Test de rupture sup-F (Quandt / Chow / Andrews)

Référence. R. E. Quandt, *Tests of the hypothesis that a linear regression system obeys two separate regimes*, *JASA*, 55(290), 1960, p. 324–330 ; G. C. Chow, *Tests of equality between sets of coefficients in two linear regressions*, *Econometrica*, 28(3), 1960, p. 591–605 ; loi limite : D. W. K. Andrews, *Tests for parameter instability and structural change with unknown change point*, *Econometrica*, 61(4), 1993, p. 821–856.

1. Cadre, notations et hypothèses de validité (non testées). Série $z_1, \dots, z_T$ et ensemble des points de rupture candidats $\mathcal{K} = \{k : \max(2, \lfloor \tau T \rfloor) \leq k \leq \min(T-2, T - \lfloor \tau T \rfloor)\}$ avec un écrêtement $\tau = 0,15$ (indispensable : sans lui la statistique diverge aux extrémités). Les bornes 2 et $T-2$ garantissent au moins deux observations de chaque côté, sans quoi la variance intra-segment n'est pas définie. Hypothèses non testées : erreurs indépendantes, homoscédastiques, gaussiennes.

2. Hypothèse nulle. H_0 : absence de rupture de niveau, soit $\mathbb{E}[z_t]$ constant sur toute la période.

3. Statistique de test. Pour un point de rupture k fixé, en notant $\bar{z}_1^{(k)}$ et $\bar{z}_2^{(k)}$ les moyennes avant et après :

$$\text{SCR}(k) = \sum_{t \leq k} (z_t - \bar{z}_1^{(k)})^2 + \sum_{t > k} (z_t - \bar{z}_2^{(k)})^2, \quad F(k) = \frac{\text{SCT} - \text{SCR}(k)}{\text{SCR}(k)/(T-2)},$$

puis $\sup F = \max_{k \in \mathcal{K}} F(k)$.

4. Loi sous H_0 . Pas $\mathcal{F}(1, T-2)$: le point de rupture étant *estimé* et non fixé a priori, la loi de $\sup F$ est celle d'un supremum de processus, tabulée par Andrews (1993) et dépendant de τ . Ses quantiles sont sensiblement supérieurs à ceux de la loi de Fisher.

5. p-value. Approximation analytique de B. E. Hansen (*Approximate asymptotic p values for structural-change tests*, *Journal of Business & Economic Statistics*, 15(1), 1997, p. 60–67). Le script utilise la p-value de Monte-Carlo.

6. Usage et limites. Erreur classique à éviter : comparer $\sup F$ aux quantiles de $\mathcal{F}(1, T-2)$, ce qui surestime massivement le nombre de ruptures détectées, le maximum sur une dizaine de candidats étant mécaniquement grand sous H_0 . La simulation règle ce problème. Un rejet est très informatif : il signale un changement de politique de souscription, de provisionnement ou de périmètre, et peut justifier de restreindre la profondeur T retenue.

10.2 Test de stabilité OLS-CUSUM

Référence. R. L. Brown, J. Durbin, J. M. Evans, *Techniques for testing the constancy of regression relationships over time*, *Journal of the Royal Statistical Society, Series B*, 37(2), 1975, p. 149–192 ; version fondée sur les résidus MCO : W. Ploberger, W. Krämer, *The CUSUM test with OLS residuals*, *Econometrica*, 60(2), 1992, p. 271–285.

1. Cadre, notations et hypothèses de validité (non testées). Série de résidus z_t , $\hat{\sigma}$ leur écart-type empirique. Hypothèses non testées : indépendance et homoscedasticité sous H_0 .

2. Hypothèse nulle. H_0 : constance des paramètres du modèle sur toute la période.

3. Statistique de test.

$$S(j) = \frac{1}{\hat{\sigma}\sqrt{T}} \sum_{t=1}^j (z_t - \bar{z}), \quad \text{CUSUM} = \max_{1 \leq j \leq T} |S(j)|.$$

4. Loi sous H_0 . Sous H_0 , $S(\lfloor uT \rfloor) \Rightarrow B^\circ(u)$, pont brownien standard sur $[0, 1]$. La statistique converge donc vers $\sup_{u \in [0,1]} |B^\circ(u)|$, de loi de Kolmogorov.

5. p-value. Asymptotiquement $p = 2 \sum_{j=1}^{\infty} (-1)^{j-1} \exp(-2j^2 \text{CUSUM}^2)$. Le script retient la p-value de Monte-Carlo, l'approximation brownienne étant inutilisable à $T \leq 15$.

6. Usage et limites. Complémentaire du sup-F : le CUSUM détecte plutôt des dérives *graduelles*, là où le sup-F détecte des ruptures *brutales*. Sa limite majeure ici est que la convergence vers le pont brownien suppose T grand : sur 10 points, le processus cumulé n'a aucune chance de ressembler à une trajectoire brownienne et seule la simulation donne un niveau correct.

10.3 Test de Grubbs

Référence. F.E. Grubbs, *Sample criteria for testing outlying observations*, *Annals of Mathematical Statistics*, 21(1), 1950, p. 27–58; *Procedures for detecting outlying observations in samples*, *Technometrics*, 11(1), 1969, p. 1–21.

1. Cadre, notations et hypothèses de validité (non testées). Échantillon $z_1, \dots, z_T$, $T \geq 3$. Hypothèse non testée *et* déterminante : sous H_0 , les observations sont i.i.d. *normales*.

2. Hypothèse nulle. H_0 : toutes les observations proviennent de la même loi normale (aucune valeur aberrante). L'alternative est la présence d'*exactement une* valeur aberrante.

3. Statistique de test.

$$G = \frac{\max_t |z_t - \bar{z}|}{s_z}.$$

4. Loi sous H_0 . Sous H_0 , la loi exacte de G se déduit de celle de Student : en posant

$$t^* = \sqrt{\frac{T(T-2)G^2}{(T-1)^2 - T G^2}},$$

on a $t^* \sim t(T-2)$ pour une observation fixée ; G étant un maximum sur T observations, la loi de référence intègre une correction de multiplicité.

5. p-value. Borne de Bonferroni utilisée par le script, tronquée à 1 :

$$p = \min \left(1, 2T(1 - F_{t, T-2}(t^*)) \right).$$

6. Usage et limites. Deux limites structurelles. (i) *Masquage* : en présence de deux valeurs aberrantes ou plus, celles-ci gonflent s_z et le test ne détecte plus rien, d'où la nécessité du test de Rosner. (ii) La statistique est bornée : $G \leq (T-1)/\sqrt{T}$, soit 2,85 pour $T = 10$; sur de très petits échantillons, aucune observation ne peut être « suffisamment » extrême. Enfin, la sensibilité à l'hypothèse de normalité est totale : sur une vraie loi à queue lourde, le test signale des aberrations qui n'en sont pas.

10.4 Procédure ESD généralisée de Rosner

Référence. B. Rosner, *Percentage points for a generalized ESD many-outlier procedure*, *Technometrics*, 25(2), 1983, p. 165–172.

1. Cadre, notations et hypothèses de validité (non testées). Généralisation itérative de Grubbs. On fixe a priori un nombre maximal k de valeurs aberrantes recherchées (le script prend $k = \max(1, \lfloor T/4 \rfloor)$) et un niveau α , qui est celui passé à `run_engine()` (0,10 par défaut) et non une valeur figée. Hypothèse non testée : normalité de la population sous-jacente.

2. Hypothèse nulle. H_0 : aucune valeur aberrante. On teste séquentiellement les alternatives « il y a exactement i valeurs aberrantes », $i = 1, \dots, k$.

3. Statistique de test. Pour $i = 1, \dots, k$, sur l'échantillon S_i obtenu en retirant les $i - 1$ observations déjà écartées :

$$R_i = \frac{\max_{z \in S_i} |z - \bar{z}_{S_i}|}{s_{S_i}}.$$

4. Loi sous H_0 . Valeurs critiques exactes, avec $n_i = T - i + 1$ et $t_{\text{crit}} = F_{t, n_i-2}^{-1}(1 - \frac{\alpha}{2n_i})$:

$$\lambda_i = \frac{(n_i - 1) t_{\text{crit}}}{\sqrt{(n_i - 2 + t_{\text{crit}}^2) n_i}}.$$

5. p-value. Aucune p-value : il s'agit d'une procédure de décision à niveau α fixé. Le nombre retenu de valeurs aberrantes est $\hat{k} = \max\{i : R_i > \lambda_i\}$, et 0 si aucun dépassement.

6. Usage et limites. Résout le problème de masquage de Grubbs et constitue la référence pour la détection multiple. Limites : la littérature recommande $T \geq 25$ pour une fiabilité correcte des valeurs critiques, ce qui n'est jamais atteint en régime USP ; le choix de k est arbitraire et influence le résultat ; l'hypothèse de normalité reste critique. À $T \leq 15$, la procédure est un simple signal d'attention, non une justification d'exclusion de données – laquelle doit toujours reposer sur une analyse métier (sinistre exceptionnel identifié, erreur de saisie avérée).

10.5 Distance de Cook (diagnostic)

Référence. R. D. Cook, *Detection of influential observation in linear regression*, *Technometrics*, 19(1), 1977, p. 15–18.

1. Cadre, notations et hypothèses de validité (non testées). Régression contrainte $y_t = \beta x_t + \varepsilon_t$ à k paramètres ($k = 1$), de résidus e_t , de variance résiduelle estimée $\hat{s}^2$ et de leviers h_t (fiche suivante). **Diagnostic d'influence, non test.**

2. Hypothèse nulle. Sans objet.

3. Statistique de test.

$$D_t = \frac{e_t^2}{k \hat{s}^2} \cdot \frac{h_t}{(1 - h_t)^2} = \frac{\sum_i (\hat{y}_i - \hat{y}_{i(-t)})^2}{k \hat{s}^2},$$

où $\hat{y}_{i(-t)}$ est la prévision obtenue en retirant l'observation t .

4. Loi sous H_0 . Aucune loi exacte. On rapproche parfois D_t des quantiles de $\mathcal{F}(k, T - k)$, mais il s'agit d'une heuristique sans fondement rigoureux.

5. p-value. Aucune. La ligne est restituée INFO, sans verdict ni sens du test (`sens_du_test` à NA) ; le champ `estim` porte $\max_t D_t$. Le commentaire donne le repère conventionnel $4/T$ (0,500 à $T = 8$), le

nombre d'observations au-dessus et leurs rangs ; ce repère n'est associé à aucune loi de référence ni à aucun niveau, et ne produit aucun verdict. Jusqu'à l'issue #24, le script marquait ALERTE une observation au-dessus de $4/T$ et ECHEC deux ou plus.

6. Usage et limites. Mesure combinée du levier et de l'ampleur du résidu : elle répond à la question « de combien le modèle changerait-il si je retirais cette année ? ». C'est le diagnostic le plus directement utile en régime USP, où une seule année peut déterminer le paramètre. Limites : le repère $4/T$ est purement conventionnel (d'autres auteurs retiennent 1), et la distance porte sur la régression contrainte des moindres carrés, non sur le modèle de vraisemblance complet – le jackknife de la section 11 fournit la mesure exacte pour ce dernier. *Pourquoi aucun verdict* (ADR 0001, amendement du 23/09/2026) : D_t n'a pas de loi de référence (rubrique 4) et le repère n'est pas un niveau de test ; l'hypothèse sous-jacente, une année atypique, est testée avec p-value par Grubbs (fiche 10.3), et l'effet d'une année sur σ_{USP} est mesuré par le jackknife (fiche 11.2). Mesuré sur le jeu de contrôle : $\max_t D_t = 0,554$, atteint à l'année 8, seule au-dessus du repère.

10.6 Leviers (*hat values*, diagnostic)

Référence. D. C. Hoaglin, R. E. Welsch, *The hat matrix in regression and ANOVA*, *The American Statistician*, 32(1), 1978, p. 17–22.

1. Cadre, notations et hypothèses de validité (non testées). Matrice de projection $H = X(X'X)^{-1}X'$ de la régression contrainte. **Diagnostic, non test.**

2. Hypothèse nulle. Sans objet.

3. Statistique de test. $h_t = H_{tt}$, soit ici, en régression simple sans constante, $h_t = \frac{x_t^2}{\sum_{i=1}^T x_i^2}$, avec $\sum_t h_t = k$ et $0 \leq h_t \leq 1$.

4. Loi sous H_0 . Aucune.

5. p-value. Aucune. La ligne est restituée INFO, sans verdict ni sens du test (`sens_du_test` à NA) ; le champ `estim` porte $\max_t h_t$. Le commentaire donne le repère conventionnel $2k/T$ ($2/T = 0,250$ à $T = 8$, $k = 1$) et le nombre d'observations au-dessus ; ce repère n'est associé à aucune loi de référence ni à aucun niveau, et ne produit aucun verdict. Jusqu'à l'issue #24, le script marquait ALERTE tout dépassement.

6. Usage et limites. Le levier ne dépend que des x_t : il identifie les années dont le *volume* est atypique, indépendamment de la sinistralité observée. Une année à fort levier n'est pas problématique en soi, mais elle le devient si son résidu est également grand – c'est exactement ce que combine la distance de Cook. En contexte USP, un levier élevé signale généralement une année de forte croissance ou une intégration de portefeuille, à rapprocher du contrôle d'amplitude du volume de la section 3. *Pourquoi aucun verdict* (ADR 0001, amendement du 23/09/2026) : h_t ne dépend que des volumes, que le modèle réglementaire traite comme des covariables fixes et sur lesquels aucune de ses hypothèses ne porte ; il n'existe donc ni hypothèse nulle ni loi de référence, et le repère $2k/T$ — deux fois le levier moyen k/T — est une règle de lecture. Mesuré sur le jeu de contrôle : $\max_t h_t = 0,160$, aucune observation au-dessus du repère.

10.7 Rupture sup-F sur ratios bruts

Référence. R. E. Quandt (1960), G. C. Chow (1960), D. W. K. Andrews (1993), *op. cit.* (fiche 10.1).

1. Cadre, notations et hypothèses de validité (non testées). Statistique de la fiche 10.1 (même écrêtement $\tau = 0,15$, mêmes points de rupture candidats), appliquée aux ratios centrés u_t de la base « ratios

bruts » (section 5.6). Hypothèse non testée : le modèle ajusté, sous lequel la loi de référence est simulée ; les u_t n'y sont ni gaussiens ni, dès que $\hat{\pi}_t$ varie, de même variance.

2. Hypothèse nulle. H_0 : niveau du ratio S/P constant, contre H_1 : rupture de niveau du ratio S/P.

3. Statistique de test. $\sup F$ de la fiche 10.1, z_t remplacé par u_t (`stat_supF()`). Invariante par translation et changement d'échelle : elle vaut la statistique calculée sur les r_t (écart nul, mesure sur le jeu de contrôle).

4. Loi sous H_0 . Ni la loi de Fisher, qui ne vaut pas pour un point de rupture estimé, ni la loi limite d'Andrews ne sont employées : la loi de référence est simulée par le bootstrap paramétrique sous le modèle ajusté.

5. p-value. p-value de Monte-Carlo en queue haute (clé `supFr`), seule calculée et seule retenue, avec son erreur de Monte-Carlo. Mesuré sur le jeu de contrôle : $\sup F = 0,559$, $p_{mc} = 0,931$ (erreur 0,008), contre $\sup F = 0,841$ et $p_{mc} = 0,840$ sur z_t — l'écart le plus grand des cinq paires en Monte-Carlo (section 5.6).

6. Usage et limites. Détecte un changement de régime du ratio S/P sans passer par le modèle ; un rejet s'interprète directement comme une rupture du ratio (changement de politique de souscription, de provisionnement ou de périmètre). À $\hat{\pi}_t$ constant, quasi-doublon de son homologue sur z_t (« CONTROLE SANS OBJET ICI »). À $T = 8$, l'ensemble des points de rupture ne compte que quelques candidats et la p-value de Monte-Carlo a la portée du bootstrap paramétrique (section 4).

10.8 Stabilité OLS-CUSUM sur ratios bruts

Référence. R. L. Brown, J. Durbin, J. M. Evans (1975) ; W. Ploberger, W. Krämer (1992), *op. cit.* (fiche 10.2).

1. Cadre, notations et hypothèses de validité (non testées). Statistique de la fiche 10.2 appliquée aux ratios centrés u_t de la base « ratios bruts » (section 5.6) ; mêmes hypothèses non testées que la fiche 10.7.

2. Hypothèse nulle. H_0 : constance du niveau du ratio S/P, contre H_1 : dérive graduelle.

3. Statistique de test. $CUSUM = \max_j \left| \sum_{t \leq j} (u_t - \bar{u}) \right| / (s_u \sqrt{T})$ (`stat_cusum()`), invariante par translation et changement d'échelle.

4. Loi sous H_0 . La loi de Kolmogorov, limite de la fiche 10.2, n'est ni calculée ni employée : la loi de référence est simulée par le bootstrap paramétrique sous le modèle ajusté.

5. p-value. p-value de Monte-Carlo en queue haute (clé `CUSUMr`), seule calculée et seule retenue, avec son erreur de Monte-Carlo. Mesuré sur le jeu de contrôle : $CUSUM = 0,533$, $p_{mc} = 0,756$ (erreur 0,014), contre 0,495 et 0,817 sur z_t .

6. Usage et limites. Complément graduel du sup-F sur la même base. À $\hat{\pi}_t$ constant, quasi-doublon de son homologue sur z_t (« CONTROLE SANS OBJET ICI »). À $T = 8$, le processus cumulé ne compte que huit points : seule la simulation fournit une loi de référence, avec la portée du bootstrap paramétrique (section 4).

10.9 Grubbs sur ratios bruts

Référence. F. E. Grubbs (1950, 1969), *op. cit.* (fiche 10.3).

1. Cadre, notations et hypothèses de validité (non testées). Statistique de la fiche 10.3 appliquée aux ratios centrés u_t de la base « ratios bruts » (section 5.6). L'hypothèse de normalité i.i.d. qui fonde la loi de Grubbs n'est pas celle du modèle : sous le modèle ajusté, les r_t sont lognormaux, donc asymétriques, et de variances inégales dès que $\hat{\pi}_t$ varie.

2. Hypothèse nulle. H_0 : aucun ratio S/P aberrant, contre H_1 : exactement un ratio aberrant.

3. Statistique de test. $G = \max_t |u_t - \bar{u}| / s_u$ (`test_grubbs()` appliquée à u_t), invariante par translation et changement d'échelle; le champ `estim` porte le rang chronologique du ratio le plus éloigné de la moyenne.

4. Loi sous H_0 . La borne de Bonferroni de la fiche 10.3 n'est pas calculée sur cette base : la loi de référence est simulée par le bootstrap paramétrique sous le modèle ajusté, asymétrie et hétéroscédasticité des r_t comprises.

5. p-value. p-value de Monte-Carlo en queue haute (clé `Grubbsr`), seule calculée et seule retenue, avec son erreur de Monte-Carlo. Mesuré sur le jeu de contrôle : $G = 1,506$, $p_{mc} = 0,777$ (erreur 0,013), contre $G = 1,429$ et une p-value retenue de 0,861 sur z_t .

6. Usage et limites. Identifie l'année au boni ou au mali le plus atypique sans passer par le modèle. Mêmes limites structurelles qu'à la fiche 10.3 : masquage par plusieurs valeurs aberrantes, et borne $G \leq (T - 1) / \sqrt{T} = 2,47$ à $T = 8$. À $\hat{\pi}_t$ constant, quasi-doublon de son homologue sur z_t (« CONTROLE SANS OBJET ICI »). À $T = 8$, la p-value de Monte-Carlo a la portée du bootstrap paramétrique (section 4); la calibration mesurée sur cette base est un constat de simulation (section 5.6).

Diagnostics de robustesse de l'estimation

11.1 Test du rapport de vraisemblance sur les cas limites de δ

Référence. S. S. Wilks, *The large-sample distribution of the likelihood ratio for testing composite hypotheses*, *Annals of Mathematical Statistics*, 9(1), 1938, p. 60–62 ; correction de frontière : H. Chernoff, *On the distribution of the likelihood ratio*, *Annals of Mathematical Statistics*, 25(3), 1954, p. 573–578 ; D. O. Stram, J. W. Lee, *Variance components testing in the longitudinal mixed effects model*, *Biometrics*, 50(4), 1994, p. 1171–1177.

1. Cadre, notations et hypothèses de validité (non testées). On note $\ell(\delta, \gamma)$ la log-vraisemblance et $\mathcal{O}(\delta, \gamma) = -2\ell$ à une constante près, soit la fonction objectif minimisée par le script. Hypothèses non testées : régularité du modèle, identifiabilité, échantillon suffisant pour la théorie asymptotique.

2. Hypothèse nulle. $H_0 : \delta = \delta_0$ avec $\delta_0 \in \{0, 1\}$, c'est-à-dire structure de variance purement linéaire en volume ($\delta_0 = 0$) ou purement quadratique ($\delta_0 = 1$).

3. Statistique de test. Statistique du rapport de vraisemblance, obtenue par profilage sur γ :

$$\text{LR}(\delta_0) = \min_{\gamma} \mathcal{O}(\delta_0, \gamma) - \min_{\delta \in [0, 1], \gamma} \mathcal{O}(\delta, \gamma).$$

4. Loi sous H_0 . Sous les conditions de régularité de Wilks, $\text{LR} \xrightarrow{\mathcal{L}} \chi^2(1)$. **Mais $\delta_0 = 0$ et $\delta_0 = 1$ sont sur la frontière du domaine $[0, 1]$:** la condition de régularité est violée et le résultat de Chernoff (1954) s'applique, la loi limite devenant le mélange

$$\frac{1}{2} \chi^2(0) + \frac{1}{2} \chi^2(1),$$

où $\chi^2(0)$ désigne la masse de Dirac en 0.

5. p-value. p-value naïve rapportée par le script : $p = 1 - F_{\chi^2_1}(\text{LR})$. p-value corrigée pour la frontière : $p_{\text{Chernoff}} = \frac{1}{2}(1 - F_{\chi^2_1}(\text{LR})) = p/2$.

6. Usage et limites. Point d'attention majeur. La p-value affichée est *conservatrice d'un facteur 2* lorsque $\hat{\delta}$ est au bord : la vraie p-value est la moitié de celle rapportée. Le script affiche volontairement la version naïve, plus prudente, mais la note de justification doit mentionner la correction. Sur le fond, ce test répond à la question pratique décisive : la structure de mélange imposée par le règlement est-elle réellement identifiée par les données, ou un cas limite serait-il statistiquement aussi défendable ? Une LR faible pour les deux bornes signifie que δ n'est pas identifié et que le paramètre final repose sur une convention plutôt que sur l'information contenue dans l'historique.

11.2 Jackknife (sensibilité au retrait d'une année)

Référence. M. H. Quenouille, *Approximate tests of correlation in time series*, *Journal of the Royal Statistical Society, Series B*, 11(1), 1949, p. 68–84 ; J. W. Tukey, *Bias and confidence in not quite large samples*, *Annals of Mathematical Statistics*, 29(2), 1958, p. 614.

1. Cadre, notations et hypothèses de validité (non testées). Pour chaque t , on réestime intégralement le modèle sur l'échantillon privé de l'observation t , d'où $\hat{\sigma}^{(-t)}$ et $\sigma_{\text{USP}}^{(-t)}$. Le facteur de crédibilité c et la

correction $\sqrt{(T+1)/(T-1)}$ sont maintenus à ceux de l'échantillon complet, l'objectif étant d'isoler l'effet de l'observation retirée et non de rejouer les règles de l'annexe XVII sur $T-1$ années. **Diagnostic, non test.**

2. Hypothèse nulle. Sans objet.

3. Statistique de test.

$$\Delta_{\max} = \max_{1 \leq t \leq T} \frac{|\sigma_{\text{USP}}^{(-t)} - \sigma_{\text{USP}}|}{\sigma_{\text{USP}}}.$$

L'estimateur jackknife du biais, $\widehat{\text{biais}} = (T-1)(\overline{\sigma^{(-\cdot)}} - \hat{\sigma})$, est également calculable à partir de la table produite.

Part estimée et part standard. Notons $\hat{\sigma} = \sigma(\hat{\delta}, \hat{\gamma})$. On appelle *part estimée* de σ_{USP} sa composante $c\sqrt{(T+1)/(T-1)}\hat{\sigma}$, par opposition à la *part standard* $(1-c)\sigma_{\text{std}}$, qui ne dépend que de la table de l'annexe et du barème. Le facteur c et la correction étant maintenus à ceux de l'échantillon complet (rubrique 1), la table produite par `usp_jackknife()` vérifie l'identité

$$\sigma_{\text{USP}}^{(-t)} - \sigma_{\text{USP}} = c\sqrt{\frac{T+1}{T-1}}(\hat{\sigma}^{(-t)} - \hat{\sigma}),$$

d'où

$$\frac{\sigma_{\text{USP}}^{(-t)} - \sigma_{\text{USP}}}{\sigma_{\text{USP}}} = \frac{c\sqrt{(T+1)/(T-1)}\hat{\sigma}}{\sigma_{\text{USP}}} \cdot \frac{\hat{\sigma}^{(-t)} - \hat{\sigma}}{\hat{\sigma}};$$

l'écart relatif de la part estimée est celui de $\hat{\sigma}$. Le facteur de gauche, compris entre 0 et 1, dépend de σ_{std} (il vaut 1 lorsque $c = 1$, cas où les deux échelles coïncident); le second n'en dépend pas, ni de c . Le coefficient $c\sqrt{(T+1)/(T-1)}$ étant strictement positif, les deux échelles désignent, par construction, la même année d'écart maximal et donnent à l'écart le même signe. Le moteur restitue $\Delta_{\max}$ dans le champ `estim`, non signé, et, dans le commentaire, l'année t^* qui l'atteint et le *sens* de l'écart sur σ_{USP} (« en baisse », « en hausse » ou « inchangé », sa valeur absolue étant celle du champ `estim`); faute d'année déterminée, le commentaire le dit. Jusqu'à la décision M24 du mainteneur (issue #24), le commentaire imprimait aussi l'écart signé sur σ_{USP} : valeur issue des réajustements du jackknife et déjà restituée dans `estim`, elle a été retirée du libellé en application de la règle d'écriture des libellés (§1.5). Jusqu'à la décision M27 du mainteneur (issue #76), il imprimait en outre, à un chiffre après la virgule, l'écart signé de la part estimée à l'année t^* , $(\hat{\sigma}^{(-t^*)} - \hat{\sigma})/\hat{\sigma}$, qui n'est stocké nulle part; il a été retiré pour la même raison, et se recalcule à partir de la colonne `sigma` de `res$jackknife` (valeurs $\hat{\sigma}^{(-t)}$) et du champ `sigma` de `res$ajustement` ($\hat{\sigma}$). Le maximum ne porte que sur les années dont le réajustement a abouti : une année dont le réajustement échoue n'a de valeur sur aucune des deux échelles et ne peut pas être désignée, même si elle était la plus influente. Si tous les réajustements échouent, la ligne est absente de la table.

4. Loi sous H_0 . Aucune loi de référence n'est utilisée pour $\Delta_{\max}$.

5. p-value. Aucune. La ligne est restituée `INFO`, sans verdict ni sens du test (`sens_du_test` à `NA`). Le repère conventionnel 10 % / 20 % s'entend sur l'échelle de σ_{USP} seulement (celle du champ `estim`); il n'est associé à aucune loi de référence ni à aucun niveau et ne produit aucun verdict; jusqu'à l'issue #24, le script marquait `ALERTE` au-delà de 10 % et `ECHEC` au-delà de 20 %. Le commentaire le rappelait jusqu'à la décision M27 du mainteneur (issue #76); il est désormais énoncé ici seulement. Aucun repère n'est donné sur l'échelle de la part estimée : transposer 10 % ou 20 % sur cette échelle reviendrait à les multiplier par $\sigma_{\text{USP}}/(c\sqrt{(T+1)/(T-1)}\hat{\sigma})$, rapport qui dépend de la table de l'annexe, et un repère fixe propre à cette échelle n'aurait aucune référence.

6. Usage et limites. C'est, à T faible, le diagnostic le plus informatif de tout le dispositif. Il répond directement à la question que posera le superviseur : le paramètre proposé résiste-t-il au retrait d'une

seule année ? Un $\Delta_{\max}$ de 25 % signifie que le calibrage est déterminé par une observation unique, ce qui fragilise le dossier bien davantage qu'un test de normalité en échec. Limite : le jackknife suppose une influence approximativement linéaire de chaque observation, hypothèse discutable en présence d'une solution au bord sur δ , où le retrait d'un point peut faire basculer l'optimum d'une borne à l'autre de façon discontinue.

Deux échelles. L'écart sur σ_{USP} est celui que subit le paramètre proposé ; il dépend de la table de l'annexe par la part standard $(1 - c) \sigma_{\text{std}}$ du dénominateur, à données identiques. L'écart sur la part estimée mesure la seule sensibilité de l'estimation, indépendamment de la table et du barème. Mesuré (méthode prime, jeu de contrôle, $B = 999$, graine 20260831) : au segment 1 de l'annexe II, retrait de l'année 8, $-9,4\%$ sur σ_{USP} et $-14,8\%$ sur la part estimée ; au segment 6, $-7,0\%$ sur σ_{USP} avec l'écart-type standard de 19% de la version consolidée du règlement, $-8,7\%$ avec celui de 12% de la version d'origine de 2015, et $-14,8\%$ sur la part estimée dans les deux cas. L'écart de $14,8\%$ est un constat sur ce jeu ; il est de l'ordre de grandeur attendu pour un paramètre d'échelle estimé sur huit points : au premier ordre, à résidus z_t fixés (sans réajustement de δ , γ et β), le retrait de l'année t déplace $\hat{\sigma}$ de $(1 - z_t^2)/(2(T - 1))$ en relatif, soit jusqu'à 10% environ sur ce jeu (approximation heuristique, non un résultat). L'heuristique et la mesure ne désignent pas la même année : l'heuristique désigne l'année 6 ($-9,5\%$), la mesure l'année 8 ($-14,8\%$) ; la différence tient au réajustement de $\hat{\beta}$ et $\hat{\gamma}$, que l'heuristique néglige ($\hat{\delta}$ reste égal à 1 pour les huit retraits, mesure). *Pourquoi aucun verdict* (ADR 0001, amendement du 23/09/2026) : $\Delta_{\max}$ n'a pas de loi de référence, et le repère $10\% / 20\%$ n'est pas un niveau de test ; sur l'échelle de σ_{USP} , son franchissement dépend en outre de la table de l'annexe, non des seules données.

11.3 Intervalle de confiance par bootstrap paramétrique

Référence. Efron (1979), *op. cit.* ; B. Efron, R. J. Tibshirani, *An Introduction to the Bootstrap*, Chapman & Hall, 1993.

1. Cadre, notations et hypothèses de validité (non testées). On réutilise les B répliques décrites en section 4, dont on extrait $\sigma_{\text{USP}}^{(b)} = c \hat{\sigma}^{(b)} \sqrt{(T + 1)/(T - 1)} + (1 - c) \sigma_{\text{std}}$. **Diagnostic, non test.**

2. Hypothèse nulle. Sans objet (procédure d'estimation d'incertitude, non de décision).

3. Statistique de test. Quantiles empiriques de la distribution bootstrap : $[\hat{q}_{\alpha/2}, \hat{q}_{1-\alpha/2}]$ (intervalle de percentile), et largeur relative $L = (\hat{q}_{0,95} - \hat{q}_{0,05}) / \sigma_{\text{USP}}$. $\sigma_{\text{USP}}^{(b)}$ étant une fonction affine croissante de $\hat{\sigma}^{(b)}$, de coefficient $c \sqrt{(T + 1)/(T - 1)} > 0$, et le quantile empirique commutant avec une telle application, la largeur de l'intervalle vaut $c \sqrt{(T + 1)/(T - 1)}$ fois celle des quantiles de $\hat{\sigma}^{(b)}$. On en déduit la largeur relative sur la *part estimée* (définie à la fiche 11.2) :

$$L_{\text{est}} = \frac{\hat{q}_{0,95}(\hat{\sigma}^{(\cdot)}) - \hat{q}_{0,05}(\hat{\sigma}^{(\cdot)})}{\hat{\sigma}}, \quad L = \frac{c \sqrt{(T + 1)/(T - 1)} \hat{\sigma}}{\sigma_{\text{USP}}} L_{\text{est}},$$

où L_{est} ne dépend ni de la table de l'annexe ni du barème. Le champ `estim porte L` ; le commentaire renvoie seulement, pour les bornes de l'intervalle à 90% de σ_{USP} , à `res$ic_bootstrap`. Jusqu'à la décision M24 du mainteneur (issue #24), il imprimait aussi L et ces bornes, quantiles bootstrap restitués ailleurs dans l'objet et retirés du libellé en application de la règle d'écriture des libellés (§1.5). Jusqu'à la décision M27 du mainteneur (issue #76), il donnait en outre L_{est} , à un chiffre après la virgule ; ce nombre, qui n'est stocké nulle part, a été retiré pour la même raison et n'est plus restitué par le moteur : il se recalcule à partir de `res$bootstrap$sigma_boot` (répliques $\hat{\sigma}^{(b)}$) et du champ `sigma` de `res$ajustement` ($\hat{\sigma}$).

4. Loi sous H_0 . La distribution bootstrap approxime la loi d'échantillonnage de $\hat{\sigma}_{\text{USP}}$ conditionnellement au modèle ajusté.

5. p-value. Aucune. La ligne est restituée INFO, sans verdict ni sens du test (sens_du_test à NA). Le repère conventionnel 50 % / 80 % porte sur L , sur l'échelle de σ_{USP} seulement ; il n'est associé à aucune loi de référence ni à aucun niveau et ne produit aucun verdict ; jusqu'à l'issue #24, le script marquait ALERTE au-delà de 50 % et ECHEC au-delà de 80 %. Le commentaire le rappelait jusqu'à la décision M27 du mainteneur (issue #76) ; il est désormais énoncé ici seulement. Aucun repère n'est donné sur L_{est} , pour la raison exposée à la fiche 11.2 : un repère transposé sur cette échelle bougerait avec la table de l'annexe.

6. Usage et limites. Quantifie l'incertitude d'échantillonnage du paramètre final, ce que ne fait aucun test d'hypothèse. Il est fréquent d'obtenir, sur un historique de 10 ans, un intervalle à 90 % dont la largeur dépasse 50 % de la valeur centrale : cela ne disqualifie pas le calibrage (le mélange par crédibilité en amortit une partie) mais doit être présenté explicitement. Limites : l'intervalle de percentile n'est corrigé ni du biais ni de l'asymétrie – les variantes BCa seraient plus exactes – et il reste conditionnel à la validité du modèle paramétrique, donc optimiste si le modèle est mal spécifié.

Dépendance de L à la table de l'annexe. À données identiques, L varie avec σ_{std} par le dénominateur. Mesuré (méthode prime, jeu de contrôle, segment 6 de l'annexe II, $B = 999$, graine 20260831) : la largeur $\hat{q}_{0,95} - \hat{q}_{0,05} = 0,06173$ est la même avec l'écart-type standard de 12 % de la version d'origine de 2015 et avec celui de 19 % de la version consolidée, mais σ_{USP} passe de 0,11965 à 0,14835 et L de 0,5159 à 0,4161, de part et d'autre du repère de 50 % ; L_{est} vaut 87,6 % dans les deux cas. Au segment 1, $L = 55,4$ % et $L_{\text{est}} = 87,6$ %. Cette dernière valeur est un constat sur ce jeu ; elle est de l'ordre de grandeur attendu pour un paramètre d'échelle estimé sur huit points : pour un écart-type estimé à ν degrés de liberté sous normalité, la largeur relative de l'intervalle 5 %-95 % vaut $\sqrt{\chi_{0,95}^2(\nu)/\nu} - \sqrt{\chi_{0,05}^2(\nu)/\nu}$, soit 0,86 pour $\nu = 7$ et 0,93 pour $\nu = 6$ (approximation heuristique, non un résultat). *Pourquoi aucun verdict* (ADR 0001, amendement du 23/09/2026) : L quantifie l'incertitude d'échantillonnage sous le modèle ajusté, mais ne peut pas contredire ce modèle ; aucune loi de référence ni aucun niveau n'est attaché aux repères 50 % / 80 %, et leur franchissement dépend, sur l'échelle de σ_{USP} , de la table de l'annexe autant que des données.

11.4 Convergence multi-démarrages

Référence. Diagnostic numérique ; sur l'optimisation sous contraintes de bornes : R. H. Byrd, P. Lu, J. Nocedal, C. Zhu, *A limited memory algorithm for bound constrained optimization*, *SIAM Journal on Scientific Computing*, 16(5), 1995, p. 1190–1208 (algorithme L-BFGS-B).

1. Cadre, notations et hypothèses de validité (non testées). L'optimisation de $\mathcal{O}(\delta, \gamma)$ est relancée depuis une grille de points de départ ($9 \times 6 = 54$ démarrages dans la configuration par défaut). **Contrôle numérique de l'estimation, ni test ni diagnostic** (issue #22, décision M11 du mainteneur) : il figure dans res\$controles, famille « H. Controles numeriques de l'estimation », avec un verdict OK / ECHEC non bloquant, et non dans la table des tests.

2. Hypothèse nulle. Sans objet.

3. Statistique de test. Nombre n^* de démarrages atteignant le minimum global à $\text{TOL_OPTIMUM} = 10^{-6}$ près (champ \$n_starts_optimum), nombre n_0^* d'entre eux dont optim() rend le code de retour 0 (champ \$n_starts_optimum_code0, que le commentaire n'imprime pas : il dit seulement si $n_0^* \geq 1$, « oui » ou « non »), nombre de démarrages sans résultat, en erreur d'optim() (champ \$n_starts_echec) et, à titre descriptif, la part parmi les S démarrages aboutis :

$$\hat{\kappa} = \frac{1}{S} \sum_{s=1}^S \mathbb{1} \left\{ \left| \mathcal{O}_s^* - \min_{s'} \mathcal{O}_{s'}^* \right| < 10^{-6} \right\} = \frac{n^*}{S},$$

restituée dans le champ `stat` du contrôle (champ `$part_starts_convergen`). Le code de retour du démarrage retenu reste dans le champ `$convergence` de `res$ajustement` ; le contrôle ne le lit pas et le commentaire ne l'imprime plus (rubrique 5).

4. Loi sous H_0 . Sans objet.

5. p-value. Aucune. Le contrôle est OK si et seulement si *au moins un* démarrage à l'optimum rend le code 0 ($n_0^* \geq 1$) et si au moins deux démarrages atteignent le minimum ($n^* \geq 2$). C'est une **convention minimale, sans référence** ; le commentaire le disait jusqu'à la décision M27 du mainteneur (issue #76), qui l'a ramené à une phrase : le nombre n^* de démarrages à l'optimum, la réponse « oui » ou « non » à $n_0^* \geq 1$ (formulée sans « au moins un » lorsque $n^* = 1$), puis, s'il est non nul, le nombre de démarrages sans résultat. Précision apportée après audit (décision du mainteneur, issue #22) : la règle initiale exigeait le code 0 du seul démarrage retenu. Or, à égalité d'objectif, le démarrage retenu est le premier de la grille (la marge de 10^{-10} de la sélection, conservée car elle stabilise $\hat{\gamma}$ d'une plateforme à l'autre) ; sur deux jeux simulés sous le modèle (cas d'audit 176 et 187, repris par les tests unitaires du moteur), les 54 démarrages s'arrêtent à $1,9 \cdot 10^{-12}$ près, le premier rend le code 52 et 53 (resp. 52) autres rendent le code 0 (mesure sur le poste du mainteneur) : la règle initiale sortait ECHEC à tort, environ une fois sur cent sur données du modèle. Aucune estimation ne change. Le même phénomène rend n_0^* lui-même instable : sous une perturbation relative des données de 10^{-12} , un démarrage bascule entre les codes 0 et 52 (sur le jeu de contrôle, n_0^* vaut 54 pour 36 des 49 couples de motifs de Walsh–Hadamard du test anti-bruit, 53 pour 11 et 52 pour 2, n^* restant égal à 54 et le code du démarrage retenu à 0 dans les 49 cas ; mesure sous Linux, R 4.3.3, §1.5). C'est pourquoi le commentaire ne donne que la réponse « oui » ou « non » à $n_0^* \geq 1$, et pourquoi `$n_starts_optimum_code0` est exclu par conception de la comparaison aux références (EXCLUS_AJUSTEMENT, décision du mainteneur, constat de la CI Linux par le test anti-bruit). La décision n'en dépend pas tant qu'un démarrage au moins rend le code 0. Le code de retour du démarrage retenu obéit au même mécanisme, le démarrage retenu étant départagé par l'ordre de la grille : le cas d'audit 187, retenu au code 52 sur le poste du mainteneur, l'est au code 0 sous Linux (R 4.3.3), où ses 54 démarrages à l'optimum rendent le code 0 ; le cas 176 y reste retenu au code 52, 53 démarrages rendant le code 0 (mesure). Le commentaire, qui imprimait ce code, ne l'imprime donc plus, et le champ `$convergence` rejoint EXCLUS_AJUSTEMENT (décision M23 du mainteneur, issue #22) ; la règle et le verdict sont inchangés, le code du démarrage retenu ne décidant plus du verdict depuis la précision ci-dessus. $\hat{\kappa}$ n'a plus de repère : le repère conventionnel 0,5 a été abandonné (décision M11), un modèle vrai ayant donné $\hat{\kappa} = 0,37$ une fois sur 300 (mesure consignée dans l'issue #22). Jusqu'à l'issue #24, le script marquait ALERTE si $\hat{\kappa} < 0,5$ ou si le code de retour était non nul ; de l'issue #24 à l'issue #22, la ligne était un diagnostic INFO de la table des tests. Sur le jeu de contrôle, les 54 démarrages aboutissent à moins de $1,9 \cdot 10^{-12}$ de l'objectif minimal (mesure), loin du repère 10^{-6} .

6. Usage et limites. Vise à écarter un minimum local, ce qui n'a rien d'automatique, sans pouvoir le garantir : deux démarrages ou plus arrêtés au même objectif rendent un minimum local isolé peu vraisemblable, mais ne prouvent pas que la grille de 54 démarrages, dont les points de départ couvrent $\delta \in [0, 1]$ et $e^\gamma \in [0,01 ; 0,40]$, a exploré toute la région utile. La fonction objectif de l'annexe XVII peut présenter un plateau très plat en δ lorsque l'amplitude des volumes x_t est faible (car π_t dépend alors peu de δ), situation dans laquelle l'optimiseur s'arrête en des points différents selon son initialisation. Un ECHEC est un signal d'alerte à traiter *avant* toute interprétation des tests, au même titre qu'un ECHEC de la condition du premier ordre (fiche 9.4) ; la nullité de la moyenne pondérée des résidus, elle, est une identité et ne signale rien (fiche 9.4). *Pourquoi un verdict de contrôle et non de test* : $\hat{\kappa}$ et n^* sont des grandeurs de calcul, non des statistiques ; elles n'ont ni hypothèse nulle ni loi de référence, et le verdict OK / ECHEC juge l'exécution de l'optimisation, non le modèle (ADR 0001). *Lecture à $T = 8$* : la règle ne dépend pas de T et ne porte aucun niveau ; c'est le plateau en δ décrit ci-dessus, et non une propriété statistique de $\hat{\kappa}$ (qui n'a pas de loi), qui rend le contrôle utile.

Diagnostics graphiques complémentaires

Les graphiques ne comportent ni hypothèse nulle ni p-value. Toutes les quantités qu'ils représentent sont calculées dans R/engine.R (`engine_plots_data()` et `mw_plots_data()`) et exposées dans `res$plots_data`; la couche d'affichage ne fait que les tracer. Ils sont documentés ici car, aux profondeurs réglementaires, leur pouvoir informatif dépasse souvent celui des tests formels.

12.1 Couverture exhaustive

Les vingt-six représentations produites par l'outil sont recensées ci-dessous. Celles qui appellent un commentaire méthodologique font l'objet d'une fiche; les autres sont d'interprétation directe et sont décrites dans le tableau.

Fonction	Méthode	Rattachement	Objet
<i>Données et ajustement</i>			
plot_ajustement()	LN	—	Nuage (x_t, y_t) et droite $\hat{\beta}x$: contrôle visuel direct de la proportionnalité (H1).
plot_ratio()	LN	H1	Ratio r_t dans le temps, avec le niveau $\hat{\beta}$: une dérive contredit la constance de β .
plot_residus()	LN	H2	Résidus z_t contre le volume : structure résiduelle après pondération.
plot_mw_facteurs()	MW	—	Facteurs $\hat{f}_j$ par année de développement, avec la référence $f = 1$: visualise la cadence de liquidation.
plot_mw_reserve()	MW	M6	Réserve par année de survenance : montre la concentration sur les années récentes.
<i>Structure de variance</i>			
plot_spread()	LN	H2	Fiche dédiée.
plot_qq2ech()	LN	H2	Fiche dédiée.
plot_mw_regressions()	MW	M1	Fiche dédiée. Petits multiples $C(i, j + 1)$ contre $C(i, j)$, une vignette par année de développement.
plot_mw_origine()	MW	M1	Fiche dédiée. Ordonnée à l'origine estimée par colonne, avec son intervalle à 95 %.
plot_mw_alpha()	MW	M1	Fiche dédiée. Facteur estimé selon $\alpha = 0, 1$ et 2.
plot_mw_residus_C()	MW	M1, M2	Résidus de Mack contre $C(i, j)$: teste conjointement la proportionnalité de la moyenne et celle de la variance.
plot_mw_residus_dev()	MW	M2	Résidus par année de développement : localise la colonne dont la variance est mal spécifiée.
<i>Normalité</i>			
plot_qqnorm()	LN	H3	Fiche dédiée.
plot_mw_qq()	MW	M5	QQ-plot des résidus de Mack. Diagnostic seulement : la normalité n'est pas une hypothèse du modèle.
<i>Indépendance</i>			
plot_mw_residus_acc()	MW	M3	Résidus par année de survenance : détecte une ligne atypique du triangle.
plot_mw_residus_cal()	MW	M3	Résidus par année calendaire : contrepartie graphique du test des effets calendaires, la plus directement lisible des trois vues de résidus.

Suite du recensement : diagnostics d'influence, estimation et calibration.

Fonction	Méthode	Rattachement	Objet
<i>Influence et leviers</i>			
plot_influence_levier()	LN	—	Fiche dédiée.
plot_influence_cook()	LN	—	Fiche dédiée.
plot_influence_sigma()	LN	—	Fiche dédiée.
plot_mw_levier()	MW	—	Fiche dédiée.
plot_mw_dfbeta()	MW	—	Fiche dédiée.
plot_mw_contributions()	MW	M6	Fiche dédiée.
<i>Estimation et calibration</i>			
plot_profil_delta()	LN	—	Profil de vraisemblance en δ : un plateau signale une structure de variance non identifiée.
plot_surface_objectif()	LN	—	Surface $-2 \ln L$ sur la grille (δ, γ) : montre si l'optimum au bord est un vrai minimum.
plot_coupe_delta()	LN	—	Coupe de la surface à $\hat{\gamma}$: lecture bidimensionnelle de la même platitude, avec son amplitude chiffrée.
plot_boot_sigma()	LN MW	+ —	Distribution bootstrap de $\hat{\sigma}$: matérialise l'incertitude d'échantillonnage du paramètre.
plot_calibration()	LN MW	+ —	Valeurs candidates et paramètre retenu : situe σ_{USP} entre le standard et l'estimé seul.

12.2 Fiches détaillées

12.3 QQ-plot normal

Référence. M. B. Wilk, R. Gnanadesikan, *Probability plotting methods for the analysis of data*, *Biometrika*, 55(1), 1968, p. 1–17.

1. Cadre, notations et hypothèses de validité (non testées). Nuage des couples $(\Phi^{-1}((i - \frac{3}{8})/(T + \frac{1}{4})), z_{(i)})$, $i = 1, \dots, T$, avec droite de référence passant par les premier et troisième quartiles. Rattaché à l'hypothèse H3.

2. Hypothèse nulle. Sans objet. Le test numérique correspondant est Shapiro–Francia, dont la statistique W' est exactement le carré du coefficient de corrélation de ce nuage.

3. Statistique de test. Sans objet (représentation graphique).

4. Loi sous H_0 . Sans objet.

5. p-value. Sans objet.

6. Usage et limites. Lecture : un alignement sur la droite conforte la normalité ; une courbure en S traduit des queues plus lourdes (points extrêmes au-dessus à droite et en dessous à gauche) ou plus légères ; une courbure convexe ou concave traduit une asymétrie. Limite : sur 8 à 12 points, l'œil surestime facilement les écarts – il est utile de superposer une enveloppe de simulation pour calibrer la lecture. Celle que calcule `engine_plots_data()` est formée, point par point, des quantiles à 5 % et 95 % des statistiques d'ordre de 499 échantillons $\mathcal{N}(0, 1)$ indépendants de taille T , tirés sous une graine fixe (§1.5) : ce n'est pas un bootstrap paramétrique sous le modèle ajusté, car les échantillons simulés ne sont pas des résidus d'un modèle réestimé, et la bande est ponctuelle, non simultanée.

Ces deux écarts jouent en sens contraires, et le premier l'emporte. Une bande ponctuelle à 90 % est franchie en au moins un point bien plus souvent que dans 10 % des cas ; mais les résidus d'un modèle à trois paramètres estimés sur $T = 8$ observations sont nettement moins dispersés que 8 variables $\mathcal{N}(0, 1)$ indépendantes : lorsque $\hat{\pi}_t$ est constant ($\hat{\delta} = 1$, ou volumes x_t constants), $\sum_t z_t^2 = T$ à la tolérance d'arrêt de l'optimiseur près (fiche 9.6), alors que la somme des carrés de 8 variables $\mathcal{N}(0, 1)$ indépendantes suit une loi $\chi^2(8)$, dont les quantiles à 5 % et 95 % valent 2,73 et 15,51. La bande est donc trop large

pour eux. Constats de simulation sur le jeu de contrôle, avec l’enveloppe que calcule le moteur : un échantillon simulé sous le modèle ajusté puis réajusté comme dans `usp_bootstrap()` ne sort de la bande en au moins un point que dans 94 cas sur 4 000 (2,4 %, graine 123), contre 4 269 sur 10 000 (42,7 %, graine 1) pour un échantillon de 8 variables $\mathcal{N}(0, 1)$ indépendantes ; l’erreur de Monte-Carlo sur ces proportions est de l’ordre de 0,2 et 0,5 point. La bande est donc à lire comme une aide conservatrice, non comme un contrôle : un point hors bande est un signal fort, une allure contenue dans la bande n’est pas une validation. L’enveloppe construite à partir des résidus des réplifications réestimées du bootstrap, conformément à la construction d’Atkinson (1981), est prévue (issue #5, § 4.3 ; ADR 0004, décision 2) ; une bande simultanée, au sens d’Aldor-Noiman et al. (2013), serait plus large que la bande ponctuelle actuelle (§21).

12.4 QQ-plot à deux échantillons (faible volume contre fort volume)

Référence. Wilk & Gnanadesikan (1968), *op. cit.*

1. Cadre, notations et hypothèses de validité (non testées). Les résidus sont scindés en deux groupes selon x_t inférieur ou supérieur à $\text{med}(x)$. On porte en abscisse les quantiles empiriques du groupe « faible volume » et en ordonnée ceux du groupe « fort volume », évalués aux mêmes probabilités avec $n = \min(n_1, n_2)$. Droite de référence : la première bissectrice. Rattaché à l’hypothèse H2.

2. Hypothèse nulle. Sans objet. Le test numérique correspondant est le test de Smirnov à deux échantillons (section 7).

3. Statistique de test. Sans objet.

4. Loi sous H_0 . Sans objet.

5. p-value. Sans objet.

6. Usage et limites. Diagnostic visuel direct de l’hypothèse de structure de variance : si la pondération π_t est correcte, les résidus standardisés des petits et des gros volumes suivent la même loi et les points s’alignent sur la bissectrice. Une *pente* supérieure à 1 signale une dispersion résiduelle plus forte sur les gros volumes (donc un δ sous-estimé), une pente inférieure à 1 l’inverse ; un décalage vertical d’ensemble signale une différence de niveau relevant plutôt de H1. Limite : avec 5 points par groupe, la pente apparente est très instable.

12.5 Graphiques d’influence et de levier

Référence. R.D. Cook (1977), *op. cit.* ; D.C. Hoaglin, R.E. Welsch (1978), *op. cit.* ; pour la représentation conjointe, J.M. Chambers, W.S. Cleveland, B. Kleiner, P.A. Tukey, *Graphical Methods for Data Analysis*, Wadsworth, 1983.

1. Cadre, notations et hypothèses de validité (non testées). Trois représentations, rattachées aux diagnostics d’influence des sections 10 (distance de Cook, leviers) et 11 (jackknife). Pour la méthode lognormale, la régression de référence est le modèle réglementaire contraint $y_t = \beta x_t$, à $k = 1$ paramètre, de leviers $h_t = x_t^2 / \sum_i x_i^2$ (de somme k) et de résidus standardisés $e_t / (s\sqrt{1 - h_t})$.

2. Hypothèse nulle. Sans objet. Les diagnostics numériques correspondants sont la distance de Cook et les leviers, documentés en section 10.

3. Statistique de test. Sans objet (représentations graphiques). Les iso-distances de Cook tracées dans

le plan (h, r) sont les courbes

$$r = \pm \sqrt{\frac{D k (1 - h)}{h}}, \quad D \in \{0,5; 1\},$$

qui découlent directement de l'identité $D_t = r_t^2 h_t / (k(1 - h_t))$, vérifiée numériquement à 10^{-10} près par le moteur.

4. Loi sous H_0 . Sans objet.

5. p-value. Sans objet.

6. Usage et limites. Le premier graphique croise levier et résidu standardisé : il sépare visuellement les observations *atypiques en volume* (levier élevé, résidu faible) de celles qui sont *réellement influentes* (au-delà d'une iso-courbe de Cook). Un levier élevé seul n'est pas problématique ; c'est sa combinaison avec un résidu important qui l'est. Le deuxième donne la distance de Cook par année avec son repère conventionnel $4/T$ (sans verdict, fiche 10.5). Le troisième, propre au projet, est le plus directement exploitable en dossier : il représente l'écart relatif sur σ_{USP} induit par le retrait de chaque année, issu du jackknife. À $T = 8$, il n'est pas rare qu'une seule année déplace le paramètre de plus de 10 %, ce que la seule lecture des distances de Cook ne montre pas.

Transposition à la méthode Merz-Wüthrich. Le facteur $\hat{f}_j$ étant une moyenne pondérée des facteurs individuels de poids $C(i, j)$, le levier exact de la cellule (i, j) vaut $h(i, j) = C(i, j)/S_j$, de somme 1 par colonne (vérifié numériquement). L'influence exacte se mesure par le DFBETA

$$\hat{f}_j^{(-i)} = \frac{\sum_{i'} C(i', j+1) - C(i, j+1)}{\sum_{i'} C(i', j) - C(i, j)},$$

obtenu sans réajustement itératif. S'y ajoute la décomposition de la réserve et de la variance de processus de la MSEP par année de survenance. Cette dernière est une *décomposition* et non un leave-one-out : le terme d'erreur d'estimation de la MSEP comporte des termes croisés, partagés entre paires d'années, qui ne sont pas attribuables à une année isolée, ce que le graphique ne prétend pas faire.

12.6 Graphique dispersion-niveau (*spread-location*)

Référence. J. W. Tukey, *Exploratory Data Analysis*, Addison-Wesley, 1977 ; lissage local de W. S. Cleveland, *Robust locally weighted regression and smoothing scatterplots*, JASA, 74(368), 1979, p. 829–836.

1. Cadre, notations et hypothèses de validité (non testées). Nuage $(x_t, \sqrt{|z_t|})$ avec courbe de lissage local (*lowess*). Rattaché à l'hypothèse H2.

2. Hypothèse nulle. Sans objet.

3. Statistique de test. Sans objet. La transformation $\sqrt{|\cdot|}$ stabilise la variance de la mesure de dispersion et rend la courbe plus lisible que $|z_t|$ ou z_t^2 .

4. Loi sous H_0 . Sans objet.

5. p-value. Sans objet.

6. Usage et limites. Une courbe lissée horizontale confirme que la pondération capture l'hétéroscédasticité ; une pente marquée signale une structure de variance résiduelle non modélisée, en cohérence avec un rejet de Breusch-Pagan ou de White. Limite : le lissage local n'a aucune stabilité en-dessous d'une dizaine de points et sa forme dépend fortement du paramètre de fenêtre ; à T faible, seule une pente très prononcée doit être retenue.

12.7 Visualisation de la régression chain-ladder (Merz–Wüthrich)

Référence. T. Mack (1993), *op. cit.*, section 3, qui recommande explicitement l'examen graphique des nuages $C(i, j + 1)$ contre $C(i, j)$ avant tout test formel.

1. Cadre, notations et hypothèses de validité (non testées). Trois représentations, rattachées à l'hypothèse M1. La première est un ensemble de petits multiples : pour chaque année de développement j , le nuage des couples $(C(i, j), C(i, j + 1))$, la droite $y = \hat{f}_j x$ — celle qu'impose le règlement, passant par l'origine — et la droite ajustée avec constante. La deuxième porte les ordonnées à l'origine estimées $\hat{a}_j$ avec leur intervalle à 95 %. La troisième compare les estimateurs $\hat{f}_j^{(\alpha)}$ pour $\alpha = 0, 1$ et 2.

2. Hypothèse nulle. Sans objet. Les tests numériques correspondants sont les fiches 14.2 et 14.5.

3. Statistique de test. Sans objet (représentations graphiques).

4. Loi sous H_0 . Sans objet.

5. p-value. Sans objet.

6. Usage et limites. Les petits multiples sont la contrepartie visuelle directe du test de nullité de l'ordonnée à l'origine : **l'écart entre les deux droites est le test**. Ils permettent en outre trois lectures qu'aucun test ne fournit : identifier la colonne responsable d'un rejet, repérer le point qui l'entraîne, et constater le rétrécissement du nuage à mesure que n_j décroît — rappel visuel que les dernières colonnes ne reposent que sur deux ou trois points.

Le graphique des ordonnées à l'origine résume les mêmes informations sous forme compacte, les colonnes significatives étant mises en évidence. Celui de la famille α chiffre l'enjeu du choix de pondération : des courbes confondues signifient que la question est sans portée pratique sur le triangle considéré ; des courbes qui divergent sur une colonne désignent celle où l'hypothèse de proportionnalité ou de variance est la plus fragile.

Limite : seules les neuf premières années de développement sont représentées en petits multiples, au-delà la lisibilité s'effondre. Les colonnes suivantes comptent de toute façon moins de trois observations et ne sont pas testées.

12.8 Influence et leviers du triangle (Merz–Wüthrich)

Référence. T. Mack (1993), *op. cit.*, pour la structure de pondération ; R. D. Cook (1977) et D. C. Hoaglin, R. E. Welsch (1978), *op. cit.*, pour les notions de levier et d'influence transposées ici.

1. Cadre, notations et hypothèses de validité (non testées). Trois représentations. Le facteur $\hat{f}_j$ étant une moyenne pondérée des facteurs individuels de poids $C(i, j)$, le levier *exact* de la cellule (i, j) dans son estimation vaut $h(i, j) = C(i, j)/S_j$, de somme 1 par colonne (vérifié numériquement). L'influence exacte se mesure par le DFBETA

$$\hat{f}_j^{(-i)} = \frac{\sum_{i'} C(i', j + 1) - C(i, j + 1)}{\sum_{i'} C(i', j) - C(i, j)},$$

obtenu sans réajustement itératif. **Diagnostics, non tests.**

2. Hypothèse nulle. Sans objet.

3. Statistique de test. Sans objet (représentations graphiques). Les quantités tracées sont $h(i, j)$, la variation relative $(\hat{f}_j^{(-i)} - \hat{f}_j)/\hat{f}_j$, et la décomposition de la réserve et de la variance de processus par année de survenance (champ `$terme_variance` de `mw_msep()`).

4. Loi sous H_0 . Sans objet.

5. p-value. Sans objet.

6. Usage et limites. Le premier graphique croise levier et résidu de Mack : il sépare les cellules atypiques par leur *poids* de celles qui sont réellement influentes. Le deuxième donne le DFBETA cellule par cellule, directement interprétable : de combien le facteur de développement bougerait si cette cellule était retirée. Le troisième compare, année de survenance par année de survenance, la part de la réserve et la part de la variance de processus de la MSEP.

Réserve de lecture importante. Ce troisième graphique est une *décomposition* et non un leave-one-out. Le terme d'erreur d'estimation de la MSEP (champ `$terme_covariance` de `mw_msep()`) comporte des termes croisés, partagés entre paires d'années de survenance, qui ne sont pas attribuables à une année isolée : seule la variance de processus, attribuable année par année, y figure. Il n'existe donc pas, pour la méthode Merz–Wüthrich, d'équivalent exact du jackknife sur σ_{USP} disponible pour la méthode lognormale ; c'est le diagnostic de concentration (fiche 19.2) qui en tient lieu.

Méthode Merz–Wüthrich — cadre et spécification

13.1 Positionnement par rapport à la méthode lognormale

L'annexe XVII ouvre deux voies pour l'écart-type propre du risque de réserve. La section C (méthode n° 1) repose sur un modèle lognormal appliqué à deux vecteurs annuels ; la section D (méthode n° 2) repose sur un modèle de chaîne d'échelle appliqué à un *triangle* de paiements cumulés, et sur l'erreur de prédiction à un an de Merz–Wüthrich. Les deux méthodes visent le même paramètre mais reposent sur des hypothèses de nature différente, ce qui commande des batteries de tests distinctes.

	Méthode lognormale (B et C)	Merz–Wüthrich (D)
Donnée d'entrée	deux vecteurs x_t, y_t de longueur T	triangle $C(i, j)$, $(I + 1) \times (J + 1)$
Modèle	$\mathbb{E}[Y_t] = \beta x_t$, variance quadratique, loi lognormale	chaîne d'échelle : $\mathbb{E}[C(i, j + 1) C(i, j)] = f_j C(i, j)$, variance proportionnelle à $C(i, j)$
Loi spécifiée	oui, entièrement	non : seuls les deux premiers moments
Paramètres estimés	β, δ, γ (maximum de vraisemblance)	f_j, σ_j^2 (moindres carrés pondérés)
Estimation de l'écart-type	fonction $\sigma(\delta, \gamma)$	$\sqrt{\text{MSEP}}$ rapportée à la réserve
Correction de taille finie	$\sqrt{(T + 1)/(T - 1)}$	aucune
Durée de crédibilité	années de survénance (B) ou exercices (C)	années de survénance, section G(3)(c)
Nature du bootstrap	paramétrique (loi entièrement spécifiée)	semi-paramétrique, par rééchantillonnage des résidus

13.2 Spécification réglementaire

Les formules ci-dessous sont la transcription littérale de l'annexe XVII, section D, paragraphes 3 à 5, sous leur *forme imprimée* et non sous une forme algébriquement équivalente plus compacte : un relecteur doit pouvoir les comparer au texte terme à terme. Les années de survénance sont indexées $i = 0, \dots, I$, les années de développement $j = 0, \dots, J$, et $C(i, j)$ désigne les sinistres cumulés.

Version du texte et pagination. Les formules ont été relevées sur la version consolidée en vigueur de l'annexe XVII (version consolidée au 14 novembre 2024). Les paragraphes 1 à 4 de la section D sont identiques dans la version d'origine et dans la version consolidée : le texte consolidé (format xhtml) ne marque aucune modification dans la section D, et la comparaison de leurs formules, faite en rendu graphique le 22 septembre 2026, ne relève aucune différence. Seul le paragraphe 5, le dernier de la section, diffère : le libellé publié en 2015 n'est pas celui en vigueur, et c'est ce dernier qui est reproduit ci-dessous et qu'implémente `mw_msep()`. L'acte qui a opéré cette correction n'est pas identifié à ce jour ; l'hypothèse d'un rectificatif refondu sans marqueur de modification, la seule que suggèrent les pièces consultées, est signalée comme une hypothèse et non comme un fait établi. La pagination au *Journal officiel* (L 12 du 17 janvier 2015) a été vérifiée à l'image le 22 septembre 2026 : la section D occupe les p. 276–278 et le paragraphe 5 les p. 277–278. Cette pagination est celle de la *version d'origine*, dont le paragraphe 5 imprime le libellé de 2015 et non la formule reproduite ci-dessous ; la version consolidée, qu'applique `mw_msep()`, n'est pas une publication paginée du *Journal officiel*. Les formules du paragraphe 5 ne sont donc pas une transcription des p. 277–278 : un relecteur qui s'y reporterait y lirait une autre formule.

Facteurs de développement.

$$\hat{f}_j = \frac{\sum_{i=0}^{I-j-1} C(i, j+1)}{\sum_{i=0}^{I-j-1} C(i, j)}, \quad \hat{C}(i, j) = C(i, I-i) \hat{f}_{I-i} \cdots \hat{f}_{j-2} \hat{f}_{j-1}.$$

Variances de développement. Pour $j = 0, \dots, J-2$,

$$\hat{\sigma}_j^2 = \frac{1}{I-j-1} \sum_{i=0}^{I-j-1} C(i, j) \left(\frac{C(i, j+1)}{C(i, j)} - \hat{f}_j \right)^2,$$

et, pour la dernière année de développement, le règlement impose l'extrapolation

$$\hat{\sigma}_{J-1}^2 = \min \left(\hat{\sigma}_{J-2}^2, \hat{\sigma}_{J-3}^2, \frac{\hat{\sigma}_{J-2}^4}{\hat{\sigma}_{J-3}^2} \right).$$

Le cas $\hat{\sigma}_{J-3}^2 = 0$. Le troisième argument divise alors par zéro. Le texte ne prévoit aucune clause de dégénérescence : ni la section D, ni aucune autre section de l'annexe XVII, ni les articles 218 à 220 ne traitent ce cas. Ce silence contraste avec la rédaction retenue ailleurs dans le même règlement pour une difficulté de même nature, où la valeur de repli est écrite explicitement — les notations d_1 , SS et SC ci-dessous sont celles de l'annexe XVIII et n'ont pas d'équivalent dans la section D.

Annexe XVIII du règlement délégué (UE) 2015/35

[...] d_1 est égal à 1 lorsque SS ou SC est égal à zéro.

Le minimum reste pourtant **déterminé**, et c'est un *fait arithmétique exact*, non une convention de l'outil. Par la première ligne ci-dessus, $\hat{\sigma}_j^2$ est une somme de carrés pondérée par des cumulés $C(i, j) > 0$: les trois arguments du minimum sont donc positifs ou nuls, et le quotient appartient à $[0, +\infty]$. Le deuxième argument valant 0, on a $\min(\hat{\sigma}_{J-2}^2, 0, q) = 0$ pour tout $q \geq 0$: l'indétermination arithmétique du quotient est *sans effet*, le minimum étant déjà atteint par $\hat{\sigma}_{J-3}^2$. La règle littérale est de surcroît *continue* en zéro — à $\hat{\sigma}_{J-2}^2 > 0$ fixé, le minimum tend vers 0 lorsque $\hat{\sigma}_{J-3}^2 \rightarrow 0^+$.

`mw_ajuster()` applique donc la lettre du texte, **sans branche spéciale** : le quotient est remplacé par sa limite $+\infty$ lorsqu'il n'est pas défini, et le minimum rend 0 de lui-même. Pour $\hat{\sigma}_{J-3}^2 > 0$, l'expression est arithmétiquement identique à celle qui la précédait — mêmes opérations, dans le même ordre —, y compris à l'intérieur de chaque réplification du bootstrap.

La lettre est ici moins prudente que le repli pratiqué auparavant, et ce constat doit être porté au dossier tel quel. Jusqu'à cette correction, le moteur posait silencieusement $\hat{\sigma}_{J-1}^2 = \hat{\sigma}_{J-2}^2$: valeur non prescrite, et *supérieure* à la borne $\hat{\sigma}_{J-3}^2 = 0$ que le texte impose. Sur un triangle dégénéré construit pour ce contrôle ($B = 999$), le passage à la règle littérale fait passer $\sigma_{(\text{res}, s, \text{USP})}$ de 0,0837988 à 0,0779835, soit $-6,94\%$; aucun verdict et aucune p-value de Monte-Carlo n'en sont modifiés, ce qui a été mesuré et s'explique : $\hat{\sigma}_{J-1}^2$ n'intervient que dans la MSEP, et non dans les résidus de Mack qui portent les statistiques simulées — la dernière colonne de développement, qui ne compte qu'un facteur individuel, ne fournit aucun résidu. Ces deux nombres sont une *mesure sur un jeu de données*, non un ordre de grandeur général. Le triangle de contrôle du dépôt n'est pas dégénéré, et aucune valeur de référence n'est modifiée. Le repli introduisait par ailleurs une *discontinuité* : sur un contrôle mené à 400 réplifications bootstrap, 307 d'entre elles empruntaient le repli dans un cas et 93 dans l'autre selon le dernier bit des cumulés, deux triangles numériquement indiscernables produisant alors deux lois simulées différentes.

Parce que la variance ainsi annulée n'est, en général, pas nulle en réalité, `mw_valider_ajustement()` émet un *avertissement* — et non un refus, le cas étant licite au regard du texte — nommant la ou les colonnes dégénérées, le nombre de facteurs individuels concernés, leur valeur commune, l'écart relatif maximal mesuré, les trois arguments du minimum et la valeur retenue. Lorsque des facteurs

individuels des colonnes dégénérées n'ont pas de résidu de Mack ($\hat{\sigma}_j^2$ exactement nul), leur nombre, lu dans la sortie de `mw_residus()`, est donné avec les onze lignes de M1 à M5 qui consomment ces résidus (constante `.MW_LIGNES_RESIDUS`) : M1, absence de tendance des facteurs ; M2, hétéroscédasticité résiduelle, adéquation de l'exposant de variance et variance unitaire des résidus ; M3, homogénéité entre années de survenance, Durbin–Watson et test des suites ; M4, Grubbs et ESD généralisé ; M5, Shapiro–Wilk et Lilliefors. Lorsque $\hat{f}_{J-2}$ ou $\hat{f}_{J-1}$ diffère de 1, il ajoute que le développement n'est pas achevé, que la variance omise n'est donc pas nulle en réalité et que $\sigma_{(\text{res},s,\text{USP})}$ s'en trouve sous-estimé. La détection porte sur l'égalité des facteurs individuels des colonnes $J - 3$ et $J - 2$, et non sur une égalité à zéro en virgule flottante (section 3) ; elle ne sert **qu'au diagnostic**, la valeur calculée étant, elle, indépendante de ce critère.

Cas symétrique. $\hat{\sigma}_{J-2}^2 = 0$ avec $\hat{\sigma}_{J-3}^2 > 0$ conduit également à $\hat{\sigma}_{J-1}^2 = 0$ — sans indétermination cette fois, les premier et troisième arguments étant nuls — donc à la même conséquence actuarielle. Les trois arguments étant positifs ou nuls, et le quotient n'étant nul que si $\hat{\sigma}_{J-2}^2$ l'est, $\hat{\sigma}_{J-1}^2 = 0$ si et seulement si $\hat{\sigma}_{J-2}^2 = 0$ ou $\hat{\sigma}_{J-3}^2 = 0$: il n'existe que ces deux chemins, qui peuvent se cumuler. Le moteur les traite à l'identique : `mw_extrapolation_sigma2()` applique le critère de dégénérescence aux deux colonnes, et `mw_valider_ajustement()` émet **un seul** avertissement par triangle, de même structure pour la colonne $J - 3$, la colonne $J - 2$ ou les deux, seule la cause nommée variant.

Erreur quadratique moyenne de prédiction. En posant $\hat{Q}_j = \hat{\sigma}_j^2 / \hat{f}_j^2$, $S_j = \sum_{i=0}^{I-j-1} C(i, j)$ et $S'_j = \sum_{i=0}^{I-j} C(i, j)$:

$$\begin{aligned} \text{MSEP} = & \sum_{i=1}^I \hat{C}(i, J)^2 \left(\frac{\hat{Q}_{I-i}}{C(i, I-i)} + \frac{\hat{Q}_{I-i}}{S_{I-i}} + \sum_{j=I-i+1}^{J-1} \frac{C(I-j, j)}{S'_j} \cdot \frac{\hat{Q}_j}{S_j} \right) \\ & + 2 \sum_{i=1}^I \sum_{k=i+1}^I \hat{C}(i, J) \hat{C}(k, J) \left(\frac{\hat{Q}_{I-i}}{S_{I-i}} + \sum_{j=I-i+1}^{J-1} \frac{C(I-j, j)}{S'_j} \cdot \frac{\hat{Q}_j}{S_j} \right). \end{aligned}$$

Le crochet, noté Δ_i comme dans `mw_msep()`, figure **deux fois** : une première fois à l'intérieur de la première somme, à côté du terme de variance de processus $\hat{Q}_{I-i}/C(i, I-i)$, et une seconde fois dans la double somme, affectée du **facteur 2**. La première somme contient donc les termes diagonaux $\hat{C}(i, J)^2 \Delta_i$. Les bornes $k = i + 1, \dots, I$, l'indice $I - i$ porté par le crochet, le facteur 2 et l'exposant 1 sur $C(I - j, j)/S'_j$ sont ceux du texte. Cette notation Δ_i , propre à la méthode Merz–Wüthrich, est sans rapport avec la marge d'équivalence Δ du test TOST de la méthode lognormale.

Forme imprimée et forme de Merz–Wüthrich. Pour $k > i$, le crochet indexé par i est celui indexé par $\min(i, k)$, et $2 \sum_{i < k}$ reproduit exactement la double somme complète hors diagonale ; les termes diagonaux étant portés par la première somme, la formule imprimée ci-dessus est identiquement l'erreur de prédiction à un an de Merz–Wüthrich (2008). Le moteur transcrit la *forme imprimée* ; cette identité est *vérifiée* numériquement (section 20) et non présumée.

Restitution du résultat. `mw_msep()` renvoie la MSEF et deux composantes : `$terme_variance` = $\sum_{i=1}^I \hat{C}(i, J)^2 \hat{Q}_{I-i}/C(i, I-i)$, la variance de processus seule, et `$terme_covariance` = $\sum_{i=1}^I \hat{C}(i, J)^2 \Delta_i + 2 \sum_{i < k} \hat{C}(i, J) \hat{C}(k, J) \Delta_i$, l'erreur d'estimation, ses termes diagonaux compris. Leur somme est exactement la MSEF du texte. Ce découpage est un choix de présentation : le règlement ne prescrit aucune décomposition.

Paramètre propre.

$$\sigma_{(\text{res},s,\text{USP})} = c \cdot \frac{\sqrt{\text{MSEP}}}{\sum_{i=0}^I (\hat{C}(i, J) - C(i, I-i))} + (1 - c) \sigma_{(\text{res},s)}.$$

Domaine de définition. Le dénominateur $\hat{R} = \sum_{i=0}^I (\hat{C}(i, J) - C(i, I-i))$ est l'estimation chain-ladder de la réserve totale. Le rapport $\sqrt{\text{MSEP}}/\hat{R}$ que le paragraphe 4 met en facteur de c est un *coefficient de variation à horizon un an* de cette réserve : la MSEF du paragraphe 5 mesure l'erreur de prédiction à un an de l'engagement réévalué, dont $\hat{R}$ est l'espérance conditionnelle estimée. **Le paragraphe ne le nomme pas ainsi** : c 'est une caractérisation de la grandeur, pas une citation du texte.

Le moteur refuse le calcul lorsque $\hat{R} \leq 0$, et lorsque la MSEF n'est pas finie ou est négative ; il retourne alors `ok = FALSE` et le champ `validation` (`mw_valider_ajustement()`, section 3). **Ces refus n'ont pas tous le même statut**, et le document les distingue.

(i) $\hat{R} = 0$: *fait mathématique*. La division n'est pas définie et l'expression du paragraphe 4 ne produit aucune valeur. Il n'y a rien à interpréter.

(ii) $\hat{R} < 0$: *interprétation, déclarée comme telle*. L'expression arithmétique du paragraphe 4 est ici **parfaitement définie et rend un nombre** : sur un triangle à cumulés décroissants de réserve totale $\hat{R} = -372,397$, elle rend 0,034877. Le refus n'est donc **pas** imposé par l'arithmétique : c'est une interprétation du texte, retenue par l'outil, et fondée sur trois appuis.

- **La grandeur que le paragraphe 4 annonce est « l'écart type »** propre à l'entreprise. Un écart type est non négatif par définition de ce que le paragraphe prétend produire : un nombre négatif n'est pas un écart type mal calibré, ce n'est pas un écart type. Or, pour $\hat{R} < 0$, le rapport $\sqrt{\text{MSEP}}/\hat{R}$ est négatif, et le mélange de crédibilité rend un $\sigma_{(\text{res},s,\text{USP})}$ *inférieur* à l'écart-type standard $\sigma_{(\text{res},s)}$ — un allègement d'exigence obtenu par une division par un nombre négatif. C'est l'appui principal.
- **Le refus ne prive l'entreprise d'aucun droit**. L'article 220, paragraphe 1, point b) présente les méthodes du risque de réserve n° 1 (section C) et n° 2 (section D) comme *alternatives* : l'entreprise à qui l'outil refuse la seconde conserve la première. Le refus ne crée donc aucune impasse réglementaire, ce qui est la condition de son admissibilité.
- **Le règlement envisage lui-même le cas**. L'article 220, paragraphe 2, prévoit qu'une entreprise puisse ne pas être « en mesure d'utiliser » une méthode standardisée, et impose alors de retenir « le résultat le plus prudent ». Un paramètre propre *inférieur* au paramètre standard, obtenu par une division par un nombre négatif, en est l'exact contraire.

Un quatrième appui, hors annexe XVII, va dans le même sens : le règlement refuse explicitement qu'un risque de réserve soit porté par un volume négatif.

Article 116, paragraphe 6, du règlement délégué (UE) 2015/35

Pour tous les segments visés à l'annexe II, la mesure de volume pour le risque de réserve pour un segment donné est égale à la meilleure estimation des provisions pour sinistres à payer [...]. La mesure de volume n'est pas un montant négatif.

Les deux grandeurs ne se confondent pas : la mesure de volume de l'article 116 est la meilleure estimation des provisions pour sinistres à payer, tandis que $\hat{R}$ est l'estimation que la chaîne d'échelle produit sur le triangle fourni. Mais l'écart-type que la section D calibre est précisément celui que la formule standard applique à cette mesure de volume, dont le règlement exige qu'elle ne soit pas négative. Refuser de calibrer $\sigma_{(\text{res},s,\text{USP})}$ sur une réserve négative prolonge donc une exigence du texte plutôt que d'y ajouter une règle propre à l'outil.

(iii) *MSEF non finie ou négative : convention d'implémentation*. Tous les termes du paragraphe 5 sont positifs ou nuls sur un triangle recevable ; ce cas est inatteignable depuis `run_engine()`. Le contrôle est

une garde défensive, qui préserve le domaine de $\sqrt{\text{MSEP}}$ si `mw_valider_ajustement()` est appelée hors de la chaîne. Ce n’est pas une lecture du texte.

Le refus porte sur le **total** $\hat{R}$, et sur lui seul. **Le texte ne se prononce ni sur l’un ni sur l’autre** : aucun paragraphe de la section D ne traite le cas d’une réserve négative, au total comme par année de survenance. La distinction est donc une **décision de l’outil**, et non une lecture du règlement : seule la somme $\sum_{i=0}^I (\hat{C}(i, J) - C(i, I - i))$ figure au dénominateur du paragraphe 4, et l’outil ne refuse que ce que cette formule rend inexploitable, à savoir le total. Des réserves négatives sur certaines années de survenance — bonis de liquidation, recours sur années anciennes —, ou un facteur $\hat{f}_j < 1$ isolé, restent donc licites : dès lors que $\hat{R} > 0$, le calcul est mené normalement et ces situations ne donnent lieu qu’à l’avertissement sur les cumulés décroissants (section 3).

Restriction d’implémentation. Le paragraphe 2(e) autorise $I \geq J$, mais la formule du paragraphe 4 fait intervenir $C(i, I - i)$, qui n’est définie que si $I - i \leq J$. Le cas $I > J$ produirait un trapèze dont le texte ne précise pas le traitement. Le moteur impose donc $I = J$ (triangle carré) et refuse explicitement les autres géométries, plutôt que de les traiter par une convention implicite non prévue par le règlement.

13.3 Hypothèses testables et résidus

Le paragraphe 2(h) énonce quatre hypothèses, qui structurent la batterie de tests au même titre que H1 à H4 pour la méthode lognormale :

Code	Énoncé (annexe XVII, D(2)(h))	Correspondance lognormale
M1	(iii) $\mathbb{E}[C(i, j + 1) \mid C(i, j)] = f_j C(i, j)$	H1 — même forme de proportionnalité sans constante
M2	(iv) $\text{Var}[C(i, j + 1) \mid C(i, j)] = \sigma_j^2 C(i, j)$	H2 — mais puissance 1 imposée, sans mélange δ à estimer
M3	(i) et (ii) indépendance entre années de survenance et entre montants incrémentaux	H4 — indépendance
M5	<i>aucune</i>	H3 — sans équivalent : la lognormalité n’est pas requise

Le support des tests est le résidu standardisé de Mack

$$r(i, j) = \frac{\sqrt{C(i, j)}}{\hat{\sigma}_j} \left(\frac{C(i, j + 1)}{C(i, j)} - \hat{f}_j \right),$$

centré, d’échelle approximativement unitaire et non corrélé sous M1 à M3. Ces trois propriétés portent sur le *modèle* : l’échelle *observée* est, elle, contrainte par construction, la somme des carrés des résidus d’une colonne valant exactement $n_j - 1$ (fiche 15.3).

La normalité n’est pas une hypothèse de la méthode. Le paragraphe 2(h) ne spécifie que les deux premiers moments conditionnels. Les tests de normalité figurent donc dans la famille M5 comme *diagnostics*, et non comme vérifications d’une hypothèse réglementaire. Ils ne deviennent pertinents que si l’on souhaite exploiter la MSEP pour construire un quantile, usage qui excède la méthode elle-même.

13.4 Réemploi et adaptation des tests

Test	Statut	Commentaire
Durbin–Watson, test des suites, Grubbs, Rosner, Shapiro–Wilk, Lilliefors	réemployés	Appliqués aux résidus de Mack au lieu des résidus standardisés z_t ; la statistique est inchangée, seule la loi de référence est réévaluée.
Breusch–Pagan studentisé	adapté	Régression des carrés des résidus sur $C(i, j)$ et non sur le volume x_t : teste la puissance 1 de M2.
Test de proportionnalité	adapté	Régression pondérée des facteurs $F(i, j)$ sur $C(i, j)$: une pente non nulle contredit M1.
Test des effets d’année calendaire	nouveau	Propre aux triangles : les diagonales représentent les exercices comptables. Sans équivalent dans la méthode lognormale.
Corrélation entre années de développement	nouveau	Teste M3(ii) entre colonnes adjacentes.
Mann–Kendall, Cox–Stuart, Spearman, RESET, TOST, sup-F, CU-SUM	sans objet	Ces tests portent sur une série chronologique de ratios, objet qui n’existe pas dans la géométrie du triangle.

Synthèse de couverture

Famille	Entrées	Type	p-value retenue
M1	Tendance avec le cumulé, à colonne donnée	test	Monte-Carlo
M1	Ordonnée à l’origine, colonne par colonne	test	Monte-Carlo
M1	Homogénéité de f_j entre années de survenance	test	Monte-Carlo
M1	Absence de courbure	test	Monte-Carlo
M1	Famille α (pondération)	test	Monte-Carlo
M2	Hétéroscédasticité résiduelle contre le cumulé	test	Monte-Carlo
M2	Exposant de variance, colonne par colonne	test	Monte-Carlo
M2	Variance unitaire des résidus	diagnostic	—
M3	Homogénéité des résidus entre années de survenance	test	Monte-Carlo
M3	Effets d’année calendaire	test	Monte-Carlo
M3	Corrélation entre années de développement	test	Monte-Carlo
M3	Autocorrélation (Durbin–Watson)	test	Monte-Carlo
M3	Test des suites	test	Monte-Carlo
M4	Cellule aberrante (Grubbs)	test	Monte-Carlo
M4	Cellules aberrantes multiples (Rosner)	procédure de décision	—
M5	Shapiro–Wilk	test (diagnostic)	exacte simulée
M5	Lilliefors	test (diagnostic), secondaire	asymptotique
M6	Extrapolation de $\hat{\sigma}_{J-1}^2$	diagnostic	—
M6	Concentration de la réserve	diagnostic	—

Dix-neuf entrées, dont **quinze** tests d’hypothèse, une procédure de décision et **trois** diagnostics, conformément au champ type que `mw_tests()` attribue à chaque ligne et qu’`engine_table_tests()` restitue. Les deux tests de normalité sont comptés parmi les tests : la famille M5 est intitulée « diagnostic » parce que la normalité n’est pas exigée par le modèle réglementaire (D(2)(h)), mais chacun d’eux comporte bien une hypothèse nulle, une statistique, une p-value et un verdict. Inversement, la variance unitaire des résidus (M2) est un diagnostic : elle n’a ni hypothèse nulle ni loi de référence, et sa valeur est de

surcroît *contrainte par construction* (fiche 15.3). Aucun des trois diagnostics ne porte de verdict : tous sont restitués INFO, conformément à l'ADR 0001. Treize de ces quinze tests reposent sur le bootstrap de résidus ; Shapiro–Wilk dispose d'une loi nulle propre, pour la raison exposée dans sa fiche, et Lilliefors d'une p-value asymptotique. Les six entrées en gras ci-dessus sont celles qui vérifient les hypothèses de chaîne d'échelle *colonne par colonne*, comme l'exige la formulation « pour toutes les années d'accident » du texte ; la régression agrégée initiale, conservée en tête, ne le permettait pas.

Hypothèse M1 — proportionnalité des cumulés

Énoncé. annexe XVII, D(2)(h)(iii) : $\mathbb{E}[C(i, j+1) \mid C(i, j)] = f_j C(i, j)$.

Les fiches ci-dessous suivent la structure en six rubriques employée pour les hypothèses H1 à H4 de la méthode lognormale. Les notations sont celles de la section 2.

14.1 M1 — Absence de tendance des facteurs avec le cumulé, à colonne donnée

Référence. T. Mack, *Distribution-free calculation of the standard error of chain ladder reserve estimates*, *ASTIN Bulletin*, 23(2), 1993, section 3.

1. Cadre, notations et hypothèses de validité (non testées). Régression auxiliaire menée sur l'ensemble des cellules du triangle :

$$F(i, j) = \mu_j + b C(i, j) + \varepsilon_{ij}, \quad \text{poids } w_{ij} = C(i, j) / \hat{\sigma}_j^2,$$

où μ_j est un **effet fixe d'année de développement**. Deux points de construction sont déterminants et ont été établis par simulation.

L'effet fixe de colonne est indispensable. Le facteur f_j décroît fortement avec j (de 3,49 à 1,02 sur le triangle de contrôle) alors que le cumulé $C(i, j)$ croît : une régression agrégée *sans* terme de colonne capte cette relation mécanique et non une dépendance au volume. Sur des triangles simulés *exactement* sous H_0 , une telle régression rejette dans **100 % des cas**. Avec l'effet fixe, la fréquence de rejet revient à 0,068 au seuil nominal de 0,10.

La pondération doit être celle des moindres carrés généralisés. Puisque $\text{Var}(F(i, j)) = \sigma_j^2 / C(i, j)$, le poids exact est $C(i, j) / \sigma_j^2$ et non $C(i, j)$ seul : σ_j^2 varie de plusieurs ordres de grandeur entre la première et la dernière colonne, et pondérer par $C(i, j)$ seul rend l'échelle résiduelle dominée par les premières colonnes — au point que le test ne rejette *jamaïs* sous l'alternative comme sous l'hypothèse nulle.

2. Hypothèse nulle. $H_0 : b = 0$ — à année de développement donnée, le facteur de développement ne dépend pas du niveau du cumulé.

3. Statistique de test. $t = \hat{b} / \widehat{\text{se}}(\hat{b})$ dans la régression pondérée à effet fixe de colonne.

4. Loi sous H_0 . Loi de Student approchée : les cellules d'une même colonne partagent $\hat{f}_j$ et $\hat{\sigma}_j$, ce qui invalide les degrés de liberté nominaux. Loi de référence : bootstrap de résidus.

5. p-value. p-value de Monte-Carlo retenue, au bilatéral. Sa clé, `PenteIntra`, désigne la statistique t de `.mw_pente_intra()`, la même que celle qu'affiche la ligne ; elle s'appelait `Intercept` jusqu'à l'issue #41, nom qui ne disait pas ce qu'elle simule. La p-value de Student est fournie comme complément non simulé.

6. Usage et limites. Ce test est le pendant *agrégé* du test d'ordonnée à l'origine par colonne qui suit : il gagne en puissance ce que l'autre gagne en localisation. Puissance mesurée sous une alternative où le facteur dépend linéairement du volume : 100 % de rejets au seuil de 10 %. Il ne dit pas, en revanche, quelle colonne est en cause : c'est le rôle du test par colonne et du graphique en petits multiples.

14.2 M1 — Nullité de l'ordonnée à l'origine, colonne par colonne

Référence. T. Mack, *Distribution-free calculation of the standard error of chain ladder reserve estimates*, *ASTIN Bulletin*, 23(2), 1993, section 3 ; combinaison des p-values : R. A. Fisher, *Statistical Methods for Research Workers*, 4^e éd., Oliver & Boyd, 1932, §21.1.

1. Cadre, notations et hypothèses de validité (non testées). Pour chaque année de développement j comptant au moins trois observations, on ajuste la régression pondérée

$$C(i, j + 1) = a_j + b_j C(i, j) + \varepsilon_{ij}, \quad \text{poids } w_{ij} = 1/C(i, j),$$

sur les $n_j = I - j$ couples disponibles. Le choix du poids n'est pas arbitraire : il découle de l'hypothèse de variance M2, et il possède une propriété remarquable établie par Mack — **la régression pondérée sans constante et de poids $1/C(i, j)$ a pour estimateur des moindres carrés exactement le facteur chain-ladder** :

$$\hat{b}_j^{(\text{sans constante})} = \frac{\sum_i w_{ij} C(i, j) C(i, j + 1)}{\sum_i w_{ij} C(i, j)^2} = \frac{\sum_i C(i, j + 1)}{\sum_i C(i, j)} = \hat{f}_j.$$

Cette identité a été vérifiée numériquement colonne par colonne, à 10^{-16} près. Elle est ce qui fait de l'ajout d'une constante le test *naturel* de l'hypothèse réglementaire. Hypothèses de validité non testées : indépendance des lignes, variance correctement pondérée, erreurs approximativement normales.

2. Hypothèse nulle. $H_0 : a_j = 0$ pour toute année de développement j , c'est-à-dire la proportionnalité stricte exigée par D(2)(h)(iii).

3. Statistique de test. Statistique de Student $t_j = \hat{a}_j / \widehat{\text{se}}(\hat{a}_j)$ dans chaque colonne, puis combinaison des K p-values par la méthode de Fisher : $X = -2 \sum_k \ln p_k$.

4. Loi sous H_0 . $X \sim \chi^2(2K)$ si les colonnes étaient indépendantes. Elles ne le sont pas tout à fait : les colonnes j et $j + 1$ partagent le vecteur $C(\cdot, j + 1)$. La p-value du khi-deux est donc rapportée comme non simulée et *indicative* ; la loi de référence retenue est celle du bootstrap de résidus.

5. p-value. p-value de Monte-Carlo retenue. Calibration vérifiée par simulation sous H_0 (1 500 triangles 10×10) : 10,7 % de rejets au seuil nominal de 10 % et 4,7 % au seuil de 5 %.

6. Usage et limites. C'est le test central de M1, et celui que la régression agrégée ne pouvait pas fournir. Il répond à la première des deux exigences du texte réglementaire : une proportionnalité *sans constante*, vérifiée *pour chaque* année de développement. Le graphique des petits multiples (section 12.7) en donne la contrepartie visuelle : la droite pleine est la proportionnalité imposée par le règlement, la droite pointillée l'ajustement libre ; l'écart entre les deux *est* le test.

Limite : le nombre d'observations décroît de I à 3 le long du triangle, si bien que les dernières colonnes ne contribuent presque rien. Le tableau détaillé restitué par le moteur donne la colonne responsable, ce qui est la seule lecture actionnable.

14.3 M1 — Homogénéité de f_j entre années de survenance

Référence. Annexe XVII, D(2)(h)(iii), dont la formulation « pour toutes les années d'accident » constitue la seconde exigence ; C. Spearman (1904), *op. cit.* pour la corrélation de rang.

1. Cadre, notations et hypothèses de validité (non testées). Dans chaque colonne j comptant au moins quatre observations, on mesure la corrélation de rang entre les facteurs individuels $F(i, j)$ et l'indice i de l'année de survenance. Hypothèses non testées : continuité, absence d'ex æquo.

2. Hypothèse nulle. H_0 : le facteur f_j est commun à toutes les années de survenance ; les facteurs individuels ne présentent aucune tendance en i .

3. Statistique de test. $\hat{p}_{s,j}$ par colonne, p-values combinées par la méthode de Fisher.

4. Loi sous H_0 . $\chi^2(2K)$ approchée, avec la même réserve d'indépendance que la fiche précédente. Loi de référence : bootstrap de résidus.

5. p-value. p-value de Monte-Carlo retenue.

6. Usage et limites. Ce test répond à la *seconde* exigence du texte, distincte de la première : même si la proportionnalité vaut dans chaque colonne, un facteur qui dériverait d'une année de survenance à l'autre invaliderait le modèle. En pratique, une telle dérive traduit un changement de politique de règlement ou de mix de portefeuille. Elle n'est pas détectable par le test d'ordonnée à l'origine, qui porte sur le niveau et non sur la pente.

14.4 M1 — Absence de courbure de la régression

Référence. Test du terme quadratique, dans l'esprit de J. B. Ramsey (1969), *op. cit.* ; appliqué ici colonne par colonne.

1. Cadre, notations et hypothèses de validité (non testées). Régression pondérée augmentée d'un terme quadratique, $C(i, j+1) = a_j + b_j C(i, j) + c_j C(i, j)^2 + \varepsilon_{ij}$, poids $1/C(i, j)$, sur les colonnes comptant au moins quatre observations.

2. Hypothèse nulle. $H_0 : c_j = 0$ dans chaque colonne.

3. Statistique de test. Statistique de Student sur $\hat{c}_j$, p-values combinées par Fisher.

4. Loi sous H_0 . $\chi^2(2K)$ approchée. Loi de référence : bootstrap de résidus.

5. p-value. p-value de Monte-Carlo retenue.

6. Usage et limites. La linéarité et la nullité de la constante sont deux propriétés distinctes : une relation courbe peut passer par l'origine et satisfaire le test précédent tout en contredisant $\mathbb{E}[C(i, j+1) \mid C(i, j)] = f_j C(i, j)$. Ce test ferme cette possibilité. Limite sévère à faible profondeur : estimer trois paramètres sur quatre à six observations laisse très peu de degrés de liberté, et la puissance est faible.

14.5 M1 — Stabilité du facteur selon la pondération (famille α)

Référence. T. Mack, *Which stochastic model is underlying the chain ladder method?*, *Insurance : Mathematics and Economics*, 15(2–3), 1994.

1. Cadre, notations et hypothèses de validité (non testées). On considère la famille d'estimateurs

$$\hat{f}_j^{(\alpha)} = \frac{\sum_i C(i, j)^\alpha F(i, j)}{\sum_i C(i, j)^\alpha}, \quad \alpha \in \{0, 1, 2\},$$

où $\alpha = 0$ donne la moyenne simple des facteurs individuels, $\alpha = 1$ le facteur chain-ladder du règlement, et $\alpha = 2$ une pondération par le carré du volume. **Sous l'hypothèse M1, les trois estiment la même quantité** : l'espérance conditionnelle étant proportionnelle à $C(i, j)$, tout jeu de poids positifs fournit un estimateur sans biais de f_j .

2. Hypothèse nulle. H_0 : les trois estimateurs visent le même f_j dans chaque colonne.

3. Statistique de test. Amplitude relative moyenne, pondérée par les effectifs :

$$A = \frac{\sum_j n_j (\max_{\alpha} \hat{f}_j^{(\alpha)} - \min_{\alpha} \hat{f}_j^{(\alpha)}) / \hat{f}_j^{(1)}}{\sum_j n_j}.$$

4. Loi sous H_0 . **Aucune loi analytique** : la statistique agrège trois estimateurs fortement corrélés sur des colonnes de tailles décroissantes.

5. p-value. p-value de Monte-Carlo exclusivement.

6. Usage et limites. Diagnostic de robustesse plus que test d'hypothèse. Une divergence marquée signale soit que l'espérance n'est pas proportionnelle à $C(i, j)$ (violation de M1), soit que la pondération en $C(i, j)$ est inadaptée (violation de M2) : le test ne sépare pas les deux causes, et doit donc être lu conjointement avec la fiche 15.2. Son intérêt propre est de chiffrer l'enjeu : si A est faible, le choix de pondération imposé par le règlement est sans conséquence matérielle sur le paramètre final.

Hypothèse M2 — variance proportionnelle au cumulé

Énoncé. annexe XVII, D(2)(h)(iv) : « pour toutes les années d’accident, la variance du montant de sinistres cumulé d’une année de développement est proportionnelle au montant de sinistres cumulé de l’année de développement précédente », soit $\text{Var}[C(i, j+1) \mid C(i, j)] = \sigma_j^2 C(i, j)$.

Les fiches ci-dessous suivent la structure en six rubriques employée pour les hypothèses H1 à H4 de la méthode lognormale. Les notations sont celles de la section 2.

15.1 M2 — Hétéroscédasticité résiduelle contre le cumulé

Référence. T. S. Breusch, A. R. Pagan (1979), *op. cit.* ; version studentisée de R. Koenker (1981), *op. cit.*, appliquée ici aux résidus de Mack.

1. Cadre, notations et hypothèses de validité (non testées). Régression auxiliaire $r(i, j)^2 = c_0 + c_1 C(i, j) + \eta$, de coefficient de détermination R_{aux}^2 , sur les $\sum_j n_j$ cellules du triangle. Hypothèses non testées : indépendance des cellules, validité de l’approximation asymptotique.

2. Hypothèse nulle. $H_0 : c_1 = 0$ — les résidus standardisés ne dépendent plus de $C(i, j)$, donc la pondération en $C(i, j)$ imposée par M2 capture correctement la variance.

3. Statistique de test. $\text{LM} = n R_{\text{aux}}^2$, où n est le nombre de résidus.

4. Loi sous H_0 . $\chi^2(1)$ asymptotique. L’approximation est doublement fragile ici : le nombre de cellules est modeste et les résidus d’une même colonne sont liés par $\hat{f}_j$ et $\hat{\sigma}_j$.

5. p-value. p-value de Monte-Carlo retenue ; la p-value du khi-deux est fournie comme complément non simulé. **Celle-ci sous-rejette massivement** : 0,5 % de rejets mesurés au seuil nominal de 10 % (section 20.2), car $\hat{\sigma}_j^2$ est estimé sur la colonne même, ce qui réduit la dispersion des résidus standardisés et donc le R^2 de la régression auxiliaire ; c’est la contrainte exacte $\sum_i r(i, j)^2 = n_j - 1$ établie à la fiche 15.3.

6. Usage et limites. Ce test porte spécifiquement sur l’exposant 1 de la structure de variance $\text{Var}[C(i, j+1) \mid C(i, j)] = \sigma_j^2 C(i, j)$. Un rejet suggère un exposant différent — variance constante ($\alpha = 0$) ou proportionnelle au carré ($\alpha = 2$) — alternatives discutées par Barnett & Zehnwrith mais *non prévues par l’annexe XVII*, qui impose $\alpha = 1$. Le rejet doit donc être documenté comme une limite du modèle réglementaire, non comme un motif de changement de méthode.

15.2 M2 — Adéquation de l’exposant de variance, colonne par colonne

Référence. Annexe XVII, D(2)(h)(iv) ; complément par colonne du test de Breusch–Pagan de la fiche précédente.

1. Cadre, notations et hypothèses de validité (non testées). Dans chaque colonne j comptant au moins quatre résidus, on mesure la corrélation de rang entre $|r(i, j)|$ et $C(i, j)$.

2. Hypothèse nulle. H_0 : l’amplitude des résidus standardisés ne dépend pas de $C(i, j)$ à l’intérieur d’une colonne, ce qui est la traduction directe de $\text{Var}[C(i, j+1) \mid C(i, j)] = \sigma_j^2 C(i, j)$.

3. Statistique de test. $\hat{\rho}_{s,j}$ par colonne, p-values combinées par Fisher.

4. Loi sous H_0 . $\chi^2(2K)$ approchée. Loi de référence : bootstrap de résidus.

5. p-value. p-value de Monte-Carlo retenue.

6. Usage et limites. Le test de Breusch–Pagan de la fiche précédente agrège toutes les colonnes ; ce test-ci localise. Un rejet signale que l'exposant 1 imposé par le règlement est inadapté — l'alternative étant un exposant 0 (variance constante) ou 2 (proportionnelle au carré). **Le règlement ne laissant pas ce choix ouvert**, un rejet doit être documenté comme une limite du modèle réglementaire et non comme un motif de changement de méthode.

15.3 M2 — Variance unitaire des résidus de Mack (diagnostic)

Référence. Diagnostic d'échelle ; Mack (1993), *op. cit.*, définition de $\hat{\sigma}_j^2$.

1. Cadre, notations et hypothèses de validité (non testées). Résidus standardisés $r(i, j)$ (section 2), tels que `mw_residus()` les restitue : seules entrent les colonnes dont $\hat{\sigma}_j^2$ est estimé, strictement positif, sur au moins deux facteurs individuels. On note k le nombre de ces colonnes et $N = \sum_j n_j$ le nombre total de résidus. **Diagnostic, non test** : la rubrique est renseignée par cohérence de présentation.

La grandeur est contrainte par construction. $\hat{\sigma}_j^2$ étant l'estimateur de Mack rappelé à la section 2, chaque colonne retenue vérifie

$$\sum_{i=0}^{n_j-1} r(i, j)^2 = \frac{1}{\hat{\sigma}_j^2} \sum_{i=0}^{n_j-1} C(i, j) (F(i, j) - \hat{f}_j)^2 = n_j - 1,$$

puisque $\hat{\sigma}_j^2$ est précisément cette somme pondérée divisée par $n_j - 1$. C'est un **résultat exact** : une identité algébrique, vraie à I fini, sur tout triangle et quelle que soit la structure de variance des données — ni une propriété asymptotique, ni une approximation numérique. En sommant sur les colonnes, $\sum_{i,j} r(i, j)^2 = N - k$. Sur le triangle de contrôle du dépôt ($I = J = 7$, soit un triangle 8×8), les six colonnes retenues donnent $\sum_i r(i, j)^2 = 6, 5, 4, 3, 2, 1$ pour $n_j = 7, 6, 5, 4, 3, 2$, soit $N = 27$, $k = 6$ et $N - k = 21$. La dernière colonne ($j = J - 1$) ne fournit qu'un seul facteur individuel — c'est d'ailleurs pourquoi $\hat{\sigma}_{J-1}^2$ y est extrapolée et non estimée (fiche 19.1) — et n'entre donc pas dans les résidus : sur un triangle carré $n \times n$ sans colonne dégénérée, $N = n(n - 1)/2 - 1$ et $k = n - 2$. L'identité est vérifiée colonne par colonne par la batterie de tests unitaires du dépôt (section 20).

2. Hypothèse nulle. Sans objet : le diagnostic n'oppose aucune hypothèse nulle à une alternative.

3. Statistique de test. $\text{Var}(r(i, j))$ sur l'ensemble du triangle, calculée par `stats::var()` sur la sortie de `mw_residus()`. Sa valeur de référence **n'est pas 1** mais

$$\frac{N - k}{N - 1},$$

conséquence immédiate de l'identité ci-dessus. Plus précisément, en notant $\bar{r}$ la moyenne des résidus,

$$\text{Var}(r) = \frac{N - k}{N - 1} - \frac{N \bar{r}^2}{N - 1} \leq \frac{N - k}{N - 1},$$

avec égalité si et seulement si $\bar{r} = 0$. Sur le triangle de contrôle, $(N - k)/(N - 1) = 21/26 = 0,8077$ et la valeur observée vaut 0,8075 : l'écart, $2,4 \times 10^{-4}$, est exactement $N \bar{r}^2/(N - 1)$. Le moteur recalcule cette valeur de référence et la restitue dans le champ `detai1` de la ligne, avec N , k et la somme des carrés attendue $N - k$, de sorte que le relecteur puisse la refaire.

4. Loi sous H_0 . Sans objet.

5. p-value. Aucune, et le moteur ne compare la valeur à aucun seuil. **Aucune des trois voies de la hiérarchie n'est ouverte ici**, et il faut le dire pour les trois : faute d'hypothèse nulle et de loi de référence, il n'existe ni p-value exacte ni p-value asymptotique ; et la voie de Monte-Carlo serait vide de sens, puisque tout triangle rééchantillonné de même géométrie vérifie la même identité, avec les mêmes N et k . Constat de simulation à l'appui : en rejouant hors moteur le bootstrap de résidus du triangle de contrôle (999 triangles produits par `mw_simuler_triangle()` sur le vivier de résidus recentré, graine 20260831) et en recalculant $\text{Var}(r)$ sur chacun, la valeur reste comprise entre 0,80741 et 0,80769, soit une étendue de $2,8 \times 10^{-4}$ autour de la référence 0,80769.

6. Usage et limites. La contrainte change ce que ce diagnostic peut apporter, et il faut l'énoncer nettement : **il ne détecte pas une mauvaise spécification de σ_j** . L'identité valant quelle que soit la structure de variance des données, $\text{Var}(r)$ reste collée à $(N - k)/(N - 1)$ même lorsque l'exposant 1 imposé par le règlement est faux. Constat de simulation : sur des triangles 8×8 engendrés avec une variance en $C(i, j)^0$ puis en $C(i, j)^2$ — les deux alternatives que nomme la fiche 15.2 —, l'écart à $(N - k)/(N - 1)$ reste inférieur à 10^{-3} en valeur absolue, alors que l'hypothèse M2 est fausse par construction. Ce sont les tests des fiches 15.1 et 15.2 qui portent cette détection, non celui-ci.

Ce que la grandeur apporte encore est d'un autre ordre, et utile au dossier. D'une part elle contrôle la cohérence interne de la standardisation : un écart appréciable à $(N - k)/(N - 1)$ signalerait que les résidus ne sont pas divisés par l'écart type de Mack de leur propre colonne — donc une anomalie de calcul, non une propriété des données. D'autre part l'écart vaut exactement $N\bar{r}^2/(N - 1)$ et donne à lire le *centrage* des résidus, qui n'est lui pas imposé par la construction : seule la somme pondérée par $C(i, j)$ est nulle dans chaque colonne, et non la somme simple des $r(i, j)$.

À $T = 8$ — triangle 8×8 —, $N = 27$ et $k = 6$, donc une référence de 0,8077. La valeur ne tend vers 1 qu'avec la taille du triangle, et lentement : 0,7692 sur un 6×6 , 0,8372 sur un 10×10 , 0,8594 sur un 12×12 . Lire la valeur observée comme un écart à 1 conduirait donc, à la profondeur qui nous occupe, à conclure à une anomalie là où la construction seule est en cause.

Diagnostic, sans verdict. La ligne est restituée INFO. Elle portait auparavant un verdict ALERTE dès que $|\text{Var}(r) - 1|$ dépassait 0,5 ; ce seuil n'était ni un niveau de test ni une règle de l'annexe XVII, et il était de surcroît armé sur une valeur de référence fausse, que la construction fixe ailleurs : il ne pouvait pas détecter ce qu'il annonçait détecter. Conformément à l'ADR 0001, un diagnostic n'a pas de verdict — le rendre en OK ou en ALERTE donnerait à une convention d'affichage l'apparence d'une conclusion au seuil α . Le moteur restitue la valeur observée et la valeur de référence recalculée ; c'est au rédacteur du dossier de les commenter. À lire conjointement avec la fiche 19.1 sur l'extrapolation de $\hat{\sigma}_{j-1}^2$, qui porte, elle, l'incertitude réelle des dernières colonnes.

Hypothèse M3 — indépendance

Énoncé. annexe XVII, D(2)(h)(i) et (ii) : indépendance des années de survenance et des montants incrémentaux.

Les fiches ci-dessous suivent la structure en six rubriques employée pour les hypothèses H1 à H4 de la méthode lognormale. Les notations sont celles de la section 2.

16.1 M3 — Effets d'année calendaire (test de Mack)

Référence. T. Mack, *Which stochastic model is underlying the chain ladder method?*, *Insurance : Mathematics and Economics*, 15(2–3), 1994, p. 133–138 ; T. Mack (1993), *op. cit.*, section 5.

1. Cadre, notations et hypothèses de validité (non testées). Dans chaque colonne j , les facteurs observés $F(i, j)$ sont classés en « grands » (L) et « petits » (S) par rapport à leur médiane, les valeurs égales à la médiane étant écartées. Les diagonales $k = i + j$ correspondent aux exercices comptables. Hypothèses non testées : continuité des facteurs, indépendance des colonnes.

2. Hypothèse nulle. H_0 : absence d'effet d'année calendaire — la répartition des L et des S le long de chaque diagonale est purement aléatoire, tous les arrangements étant équiprobables.

3. Statistique de test. Sur la diagonale k comportant n_k étiquettes dont L_k « grandes » : $Z_k = \min(L_k, n_k - L_k)$, puis $Z = \sum_k Z_k$ et

$$\frac{Z - \mathbb{E}[Z]}{\sqrt{\text{Var}[Z]}}.$$

4. Loi sous H_0 . Sous H_0 , $L_k \sim \mathcal{B}(n_k, 1/2)$, d'où les moments **exacts**, avec $m_k = \lfloor (n_k - 1)/2 \rfloor$:

$$\mathbb{E}[Z_k] = \frac{n_k}{2} - \binom{n_k - 1}{m_k} \frac{n_k}{2^{n_k}}, \quad \text{Var}[Z_k] = \frac{n_k(n_k - 1)}{4} - \binom{n_k - 1}{m_k} \frac{n_k(n_k - 1)}{2^{n_k}} + \mathbb{E}[Z_k] - \mathbb{E}[Z_k]^2.$$

Ces deux expressions ont été vérifiées par énumération exhaustive de la loi de $\min(L, n - L)$ pour $n = 2, \dots, 12$: concordance à 10^{-10} près. En revanche, la normalité de la *somme* Z n'est qu'approchée.

5. p-value. $p = 2(1 - \Phi(|Z^*|))$ pour la version asymptotique ; la p-value de Monte-Carlo est celle retenue.

6. Usage et limites. C'est le test le plus informatif du dispositif Merz–Wüthrich, car il détecte ce que ni M1 ni M2 ne voient : un choc affectant un exercice comptable entier (inflation, changement de cadence de règlement, modification de la politique de provisionnement). Un tel choc viole l'indépendance des années de survenance posée par D(2)(h)(i). Limite à $T = 8$: la somme ne porte que sur $I - 1$ diagonales exploitables, dont plusieurs ne comptent que deux ou trois étiquettes, d'où le recours au bootstrap plutôt qu'à l'approximation normale.

16.2 M3 — Homogénéité des résidus entre années de survenance

Référence. W. H. Kruskal, W. A. Wallis, *Use of ranks in one-criterion variance analysis*, *Journal of the American Statistical Association*, 47(260), 1952, p. 583–621.

1. Cadre, notations et hypothèses de validité (non testées). Les résidus de Mack sont groupés par année de survenance i . Le test compare les rangs entre groupes, sans hypothèse de loi. Hypothèses non testées : indépendance des résidus, continuité.

2. Hypothèse nulle. H_0 : les résidus ont la même distribution dans toutes les années de survenance, ce qui est la traduction testable de l'indépendance stochastique des années de survenance posée par D(2)(h)(i).

3. Statistique de test. H de Kruskal–Wallis, sur $k - 1$ degrés de liberté où k est le nombre d'années de survenance comportant au moins un résidu.

4. Loi sous H_0 . $\chi^2(k - 1)$ asymptotique, approximation médiocre lorsque les groupes comptent une ou deux observations — ce qui est le cas des dernières lignes du triangle. Loi de référence : bootstrap de résidus.

5. p-value. p-value de Monte-Carlo retenue ; le khi-deux est fourni comme complément non simulé.

6. Usage et limites. Complète le test des effets d'année calendaire, qui porte sur les diagonales : celui-ci porte sur les *lignes*. Un rejet signale qu'une année de survenance se comporte différemment des autres, ce qui viole l'hypothèse d'indépendance et d'identité de distribution. Limite structurelle : les groupes sont très déséquilibrés, la première ligne comptant J résidus et la dernière un seul.

16.3 M3 — Corrélation entre années de développement adjacentes

Référence. T. Mack (1993), *op. cit.*, section 4 ; C. Spearman (1904), *op. cit.* pour la corrélation de rang.

1. Cadre, notations et hypothèses de validité (non testées). Pour chaque paire de colonnes adjacentes $(k - 1 \rightarrow k)$ et $(k \rightarrow k + 1)$, on calcule la corrélation de rang de Spearman entre les facteurs individuels observés sur les mêmes années de survenance. L'agrégation est pondérée par $n_k - 1$. Hypothèses non testées : continuité, absence d'ex æquo.

2. Hypothèse nulle. H_0 : les facteurs de développement successifs ne sont pas corrélés, ce qui est la traduction testable de D(2)(h)(ii), l'indépendance des montants incrémentaux à l'intérieur d'une année de survenance.

3. Statistique de test. $\hat{\rho} = \frac{\sum_k (n_k - 1) \hat{\rho}_{s,k}}{\sum_k (n_k - 1)}$, moyenne pondérée des corrélations de rang par paire de colonnes.

4. Loi sous H_0 . **Aucune loi analytique** : la géométrie du triangle fait que les paires de colonnes se recouvrent partiellement et reposent sur des effectifs décroissants. Aucune approximation asymptotique n'est mobilisable.

5. p-value. p-value de Monte-Carlo exclusivement. C'est, avec la corrélation, le seul test du dispositif pour lequel aucune p-value non simulée n'existe.

6. Usage et limites. Un rejet signale que la cadence de liquidation d'une année de survenance est persistante : une année qui se développe vite sur une colonne continue de le faire sur la suivante. Cela contredit l'indépendance des incréments et biaise la MSEP, qui suppose que les erreurs de projection ne se cumulent pas. Limite : sur un triangle 8×8 , seules cinq ou six paires de colonnes comptent au moins trois observations, ce qui rend le test très peu puissant.

16.4 M3 — Autocorrélation des résidus de Mack (Durbin–Watson)

Référence. J. Durbin, G. S. Watson (1950, 1951), *op. cit.*

1. Cadre, notations et hypothèses de validité (non testées). Résidus de Mack ordonnés selon leur parcours du triangle (colonne par colonne, années de survenance croissantes). Hypothèses non testées : résidus homoscédastiques et de moyenne nulle sous le modèle.

2. Hypothèse nulle. H_0 : absence d'autocorrélation d'ordre 1 des résidus de Mack.

3. Statistique de test. $DW = \sum_{t=2}^n (z_t - z_{t-1})^2 / \sum_{t=1}^n z_t^2$, calculée sur les résidus centrés.

4. Loi sous H_0 . Contrairement à la méthode lognormale, la loi exacte d'Imhof n'est pas applicable ici : les résidus de Mack ne forment pas un vecteur gaussien de matrice de covariance connue, la structure de dépendance dépendant de la géométrie du triangle. La loi de référence est celle du bootstrap de résidus.

5. p-value. p-value de Monte-Carlo exclusivement.

6. Usage et limites. Complément aux deux tests précédents : l'ordre de parcours étant conventionnel, un rejet est plus difficile à interpréter que pour une série chronologique. Il faut alors se reporter aux graphiques des résidus par année de survenance, de développement et calendrier, qui localisent la structure.

16.5 M3 — Test des suites sur les résidus de Mack

Référence. A. Wald, J. Wolfowitz (1940), *op. cit.*

1. Cadre, notations et hypothèses de validité (non testées). Suite des signes des résidus de Mack par rapport à leur médiane, dans le même ordre de parcours que ci-dessus ; comme pour la méthode lognormale (`test_runs()`), un résidu égal à la médiane, de signe nul, est écarté. On note n_1 le nombre de signes positifs, n_2 le nombre de négatifs, $n = n_1 + n_2$ et R le nombre de suites. Le nombre de résidus étant impair sur le triangle de contrôle (27), la médiane y est l'un d'eux : un résidu est écarté, et $n_1 = n_2 = 13$ (mesuré).

2. Hypothèse nulle. H_0 : la suite des signes est un arrangement aléatoire.

3. Statistique de test. $Z = (R - \mathbb{E}[R]) / \sqrt{\text{Var}[R]}$, avec $\mathbb{E}[R] = 2n_1n_2/n + 1$ et $\text{Var}[R] = 2n_1n_2(2n_1n_2 - n) / (n^2(n - 1))$.

4. Loi sous H_0 . La loi combinatoire exacte du nombre de suites suppose l'échangeabilité des signes, mise en défaut ici par la dépendance intra-colonne : elle n'est donc pas retenue, contrairement à ce qui est fait pour la méthode lognormale. Loi de référence : bootstrap de résidus.

5. p-value. p-value de Monte-Carlo retenue ; l'approximation normale est fournie comme complément non simulé. **Celle-ci sur-rejette nettement** : 15,3 % de rejets mesurés au seuil nominal de 10 % (section 20.2). La cause est identifiée : la contrainte $\sum_i \sqrt{C(i, j)} r(i, j) = 0$ rend les résidus d'une même colonne négativement corrélés, donc leurs signes plus alternés que sous l'échangeabilité supposée.

6. Usage et limites. Test non paramétrique robuste, sensible aussi bien au regroupement qu'à l'alternance excessive des signes. Sa lecture souffre, comme celle de Durbin-Watson, du caractère conventionnel de l'ordre de parcours.

Diagnostics M4 — points aberrants du triangle

Énoncé. hors énoncé réglementaire : conditionne la lecture de M1 à M3.

Les fiches ci-dessous suivent la structure en six rubriques employée pour les hypothèses H1 à H4 de la méthode lognormale. Les notations sont celles de la section 2.

17.1 M4 — Cellule aberrante du triangle (Grubbs)

Référence. F. E. Grubbs (1950, 1969), *op. cit.*

1. Cadre, notations et hypothèses de validité (non testées). Résidus de Mack, considérés comme un échantillon unique. Hypothèse non testée et déterminante : normalité des résidus sous H_0 , laquelle n'est pas une hypothèse du modèle de Mack (voir M5).

2. Hypothèse nulle. H_0 : aucun résidu aberrant — toutes les cellules proviennent du même modèle. L'alternative est la présence d'exactly une cellule aberrante.

3. Statistique de test. $G = \max_{i,j} |r(i,j) - \bar{r}| / s_r$.

4. Loi sous H_0 . Borne de Bonferroni fondée sur la loi de Student, conservatrice ; elle suppose la normalité et l'indépendance, toutes deux approximatives ici. Loi de référence : bootstrap de résidus.

5. p-value. p-value de Monte-Carlo retenue ; la borne de Bonferroni est fournie comme majorant non simulé. **Ce majorant est extrêmement conservateur** sur des résidus de Mack : aucun rejet en 600 simulations sous H_0 au seuil de 10 % (section 20.2). Il ne doit donc jamais servir de critère de décision.

6. Usage et limites. Le moteur indique les coordonnées (i, j) de la cellule la plus extrême, ce qui rend le résultat directement actionnable : il s'agit typiquement d'un sinistre exceptionnel ou d'une erreur de saisie sur une année de développement donnée. **Aucune exclusion de cellule ne doit être opérée sur ce seul fondement** : la justification doit être métier.

17.2 M4 — Cellules aberrantes multiples (ESD généralisé de Rosner)

Référence. B. Rosner (1983), *op. cit.*

1. Cadre, notations et hypothèses de validité (non testées). Généralisation itérative de Grubbs, appliquée aux résidus de Mack, avec $k = \lfloor n/4 \rfloor$ candidats au plus. Hypothèse non testée : normalité.

2. Hypothèse nulle. H_0 : aucune cellule aberrante. On teste séquentiellement les alternatives « il y a exactement i cellules aberrantes », $i = 1, \dots, k$.

3. Statistique de test. $R_i = \max |r - \bar{r}_{\mathcal{S}_i}| / s_{\mathcal{S}_i}$ sur l'échantillon privé des $i - 1$ cellules déjà écartées.

4. Loi sous H_0 . Valeurs critiques λ_i tabulées, fondées sur la loi de Student.

5. p-value. **Aucune** : il s'agit d'une procédure de décision à niveau α fixé, non d'un test produisant une p-value.

6. Usage et limites. Résout le problème de masquage de Grubbs lorsque plusieurs cellules sont atypiques. La littérature recommande $n \geq 25$ pour la fiabilité des valeurs critiques ; un triangle 8×8 fournit 27

résidus de Mack — et non 28 : la colonne $j = J - 1$ ne comporte qu'un seul facteur individuel et n'entre pas dans les résidus (fiche 15.3) —, ce qui place la procédure à la limite de son domaine. À traiter comme un signal d'attention.

Diagnostics M5 — normalité des résidus de Mack

Énoncé. hors annexe XVII : la normalité n'est pas une hypothèse du modèle, qui ne spécifie que les deux premiers moments conditionnels.

Les fiches ci-dessous suivent la structure en six rubriques employée pour les hypothèses H1 à H4 de la méthode lognormale. Les notations sont celles de la section 2.

18.1 M5 — Shapiro–Wilk sur les résidus de Mack

Référence. S. S. Shapiro, M. B. Wilk (1965), *op. cit.* ; loi nulle évaluée par simulation directe.

1. Cadre, notations et hypothèses de validité (non testées). Résidus de Mack. **La normalité n'est pas une hypothèse du modèle :** le paragraphe D(2)(h) ne spécifie que les deux premiers moments conditionnels. Ce test est donc un *diagnostic* et non la vérification d'une exigence réglementaire.

2. Hypothèse nulle. H_0 : les résidus de Mack sont issus d'une loi normale.

3. Statistique de test. W , statistique de Shapiro–Wilk.

4. Loi sous H_0 . W étant invariante par translation et changement d'échelle, sa loi sous H_0 ne dépend que de l'effectif : elle est évaluée numériquement par simulation directe de 20 000 échantillons normaux.

5. p-value. p-value exacte à l'erreur de Monte-Carlo près, en $\mathcal{O}(B_{\text{null}}^{-1/2})$.

6. Usage et limites. Point de méthode déterminant. Ce test ne peut pas passer par le bootstrap de résidus employé pour tous les autres tests de la méthode, car celui-ci tire dans la loi *empirique* des résidus observés : son hypothèse nulle serait « les résidus suivent leur propre loi empirique », ce qui rendrait le test vide de sens (la simulation confirme une fréquence de rejet nulle au lieu de 5 %). D'où le recours à une loi nulle propre, indépendante du triangle ajusté. Le résultat n'est pertinent que si l'on souhaite exploiter la MSEP pour construire un quantile, usage qui excède la méthode réglementaire.

18.2 M5 — Lilliefors sur les résidus de Mack

Référence. H. W. Lilliefors (1967), *op. cit.* ; p-value : G. E. Dallal, L. Wilkinson (1986), *op. cit.*

1. Cadre, notations et hypothèses de validité (non testées). Identique à la fiche précédente. Variante *secondaire* : masquée par défaut dans l'application, conservée dans l'export.

2. Hypothèse nulle. H_0 : les résidus de Mack sont issus d'une loi normale, de moyenne et de variance quelconques.

3. Statistique de test. $D_L = \sup_u |\hat{F}(u) - \Phi((u - \bar{r})/s_r)|$.

4. Loi sous H_0 . Loi de Lilliefors, tenant compte de l'estimation de la moyenne et de l'écart-type sur l'échantillon.

5. p-value. Approximation analytique de Dallal & Wilkinson, prolongée par les polynômes de Stephens. p-value non simulée, disponible dès $n \geq 5$.

6. Usage et limites. Complément de recoupement à Shapiro–Wilk, moins puissant. Même réserve de fond : la normalité n’est pas exigée par la méthode.

Diagnostics M6 — robustesse de l'estimation

Énoncé. hors énoncé réglementaire : mesure la concentration du résultat et la part de convention dans le calcul.

Les fiches ci-dessous suivent la structure en six rubriques employée pour les hypothèses H1 à H4 de la méthode lognormale. Les notations sont celles de la section 2.

19.1 M6 — Extrapolation de $\hat{\sigma}_{J-1}^2$ (diagnostic)

Référence. Annexe XVII, section D, paragraphe 5(d)(ii), seconde ligne.

1. Cadre, notations et hypothèses de validité (non testées). La variance de la dernière année de développement ne peut être estimée, faute d'observations. **Diagnostic, non test.**

2. Hypothèse nulle. Sans objet.

3. Statistique de test. La valeur retenue, $\hat{\sigma}_{J-1}^2 = \min(\hat{\sigma}_{J-2}^2, \hat{\sigma}_{J-3}^2, \hat{\sigma}_{J-2}^4/\hat{\sigma}_{J-3}^2)$, calculée par `mw_ajuster()` (champ `$sigma2`). `mw_extrapolation_sigma2()` en recompose les trois arguments et celui qui atteint le minimum, et `mw_detail_extrapolation()` les restitue dans le champ `detail` de la ligne, de sorte que le calcul soit refaisable à la lecture. Lorsque $\hat{\sigma}_{J-3}^2 = 0$, le troisième argument n'est pas défini ; le minimum vaut alors 0 par application littérale du texte, sans que l'indétermination ait d'effet (§13), et le champ `detail` le signale. Le champ `detail` nomme la *cause* du minimum, et non le seul argument qui l'atteint au sens littéral (champ `$retenu` de `mw_extrapolation_sigma2()`) : colonne $J - 2$ dégénérée, il nomme $\hat{\sigma}_{J-2}^2$ et précise que le quotient, nul par voie de conséquence, n'est pas compté comme argument distinct ; colonnes $J - 3$ et $J - 2$ toutes deux dégénérées, il nomme les deux variances ex aequo ; dans les autres cas, il nomme tous les arguments égaux au minimum à 10^{-12} près en relatif, ex aequo s'ils sont plusieurs.

4. Loi sous H_0 . Sans objet : la quantité n'est pas estimée mais *imposée* par une règle d'extrapolation.

5. p-value. Aucune.

6. Usage et limites. Ce diagnostic existe pour rendre visible dans le dossier un point que le calcul masque : une des entrées de la MSEP ne provient pas des données mais d'une convention réglementaire, reposant sur deux colonnes seulement. Comme la dernière année de développement contribue à la MSEP de toutes les années de survénance récentes — celles qui portent l'essentiel de la réserve — cette convention a un effet non négligeable sur le paramètre final. Elle doit être mentionnée explicitement.

À $T = 8$, c'est-à-dire sur un triangle 8×8 , les deux quantités qui bornent l'extrapolation sont les plus mal estimées de toutes : $\hat{\sigma}_{J-2}^2$ repose sur deux facteurs individuels et un degré de liberté, $\hat{\sigma}_{J-3}^2$ sur trois facteurs et deux degrés de liberté. La valeur extrapolée hérite de cette imprécision, qu'aucune p-value ne mesure ici.

Diagnostic, sans verdict. La ligne est restituée INFO : elle n'oppose aucune hypothèse nulle à une alternative et ne dispose d'aucune loi de référence, de sorte qu'aucun seuil ne pourrait fonder un verdict. Les cas dégénérés $\hat{\sigma}_{J-3}^2 = 0$ et $\hat{\sigma}_{J-2}^2 = 0$ ne modifient pas ce statut : ils sont portés par l'avertissement unique de `mw_valider_ajustement()` (section 3), non par un verdict, et le calcul n'est jamais refusé. Sur

un tel triangle, et si le développement n'est pas achevé, la MSEP ne porte aucune variance sur la dernière année de développement et $\sigma_{(\text{res},s,\text{USP})}$ est sous-estimé, que la colonne dégénérée soit $J - 3$, $J - 2$ ou les deux (§13).

19.2 M6 — Concentration de la réserve sur la dernière année

Référence. Diagnostic de concentration ; décomposition du paragraphe 4.

1. Cadre, notations et hypothèses de validité (non testées). Part de la réserve totale portée par la dernière année de survénance, $(\hat{C}(I, J) - C(I, 0)) / \sum_i (\hat{C}(i, J) - C(i, I - i))$. Le dénominateur est la réserve chain-ladder totale $\hat{R}$, strictement positive partout où ce diagnostic est restitué, le calcul étant refusé sinon (section 3) : la part est donc toujours définie. Elle n'est en revanche encadrée par rien (rubrique 6). **Diagnostic, non test.**

2. Hypothèse nulle. Sans objet.

3. Statistique de test. La part elle-même. Le moteur la restitue accompagnée d'un *repère indicatif* de 40 %, dont le champ détail de la ligne nomme le statut : ce repère est sans fondement réglementaire ni statistique et n'emporte aucun verdict. Sur le triangle de contrôle du dépôt, la part vaut 36,0 %.

4. Loi sous H_0 . Sans objet.

5. p-value. Aucune.

6. Usage et limites. La dernière année de survénance n'est observée que sur une seule cellule : son ultime résulte du produit de *tous* les facteurs de développement, et son erreur de prédiction domine la MSEP. Une part élevée signifie que le paramètre propre repose principalement sur la ligne la moins informative du triangle. Ce diagnostic joue, pour la méthode Merz–Wüthrich, le rôle que joue le jackknife pour la méthode lognormale : il mesure la concentration du résultat sur une observation unique.

Limite connue. La part n'est *ni majorée par 1 ni minorée par 0*. Le refus d'une réserve totale non positive (section 3) garantit le signe du dénominateur, pas celui du numérateur : dès qu'une année de survénance porte une réserve négative — situation licite tant que $\hat{R}$ reste strictement positive —, la part peut dépasser 1 ou devenir négative. Le repère de 40 % n'a donc de sens que si toutes les réserves par année de survénance sont positives ou nulles, condition que le moteur ne vérifie pas : une part négative reste en deçà du repère alors qu'elle traduit une répartition au moins aussi atypique que celle qu'il vise. Cette limite est antérieure à la règle de refus et n'est pas corrigée par elle ; elle doit être lue avec le diagnostic, et la répartition de la réserve par année de survénance examinée directement.

Diagnostic, sans verdict. La ligne est restituée INFO. Le repère de 40 % n'est ni un niveau de test ni une règle de l'annexe XVII : le rendre en ALERTE ou en OK donnerait à une convention d'affichage l'apparence d'une conclusion au seuil α , alors que la part n'a ni hypothèse nulle ni loi de référence. Le moteur ne signale donc aucun dépassement ; il restitue la part et le repère en nommant le statut de ce dernier, et c'est au rédacteur du dossier de commenter la concentration observée. À $T = 8$ — triangle 8×8 — la dernière année de survénance n'est observée que sur une cellule et son ultime est le produit des sept facteurs de développement estimés : la lecture de la part n'en est que plus nécessaire, faute de jackknife disponible pour cette méthode.

PARTIE IV

Validation, références et synthèse

Vérification empirique de l'implémentation

L'implémentation a été validée par trois voies indépendantes.

Recalcul indépendant des statistiques

Chaque statistique a été confrontée à un recalcul direct ou à une identité connue : égalité $F = t_b^2$ et égalité des p-values de Fisher et de Student en régression simple ; égalité de W' (Shapiro–Francia) et du carré du coefficient de corrélation du QQ-plot ; recalcul par boucle explicite de A^2 , W^2 , D et du S de Mann–Kendall ; cohérence de D avec `ks.test` ; vérification de la borne $G \leq (T - 1)/\sqrt{T}$ pour Grubbs ; et vérification numérique que la p-value bilatérale minimale de Cox–Stuart vaut exactement 0,0625 pour $T = 10$, ce qui confirme l'affirmation de la fiche 6.9 (section 6). Le gradient analytique de l'objectif profilé (`usp_gradient()`, fiche 9.4) a été confronté à la différence centrée de l'objectif, de pas 10^{-5} , en 16 couples (δ, γ) sur chacun de deux jeux (le jeu de contrôle et un jeu à $\hat{\delta}$ intérieur) : l'écart maximal, rapporté à $\max(1, |\text{dérivée numérique}|)$, vaut $2,8 \cdot 10^{-9}$ (mesure).

Taille effective et puissance

Sur 3 000 échantillons normaux de taille 200, la fréquence de rejet au seuil nominal de 5 % ressort à 4,9 % (D'Agostino), 4,5 % (Anscombe–Glynn), 4,1 % (Jarque–Bera) et 5,6 % (Wald–Wolfowitz) ; la borne de Bonferroni de Grubbs donne 4,6 % pour $T = 20$, conformément à son caractère conservateur. Côté puissance, D'Agostino détecte l'asymétrie d'une loi exponentielle dans 100 % des cas et Anscombe–Glynn les queues d'une loi de Student à 4 degrés de liberté dans 92,5 % des cas.

Calibration des p-values de Monte-Carlo

C'est le point le plus important, puisque ces p-values sont celles retenues pour la majorité des tests — mesuré sur le jeu de contrôle (méthode prime, $T = 8$, $B = 999$), 25 des 48 lignes de la table auditable retiennent une p-value de Monte-Carlo, contre 10 une p-value exacte, 1 une p-value quasi-exacte et 2 une p-value asymptotique, les 10 dernières n'ayant aucune p-value retenue (8 diagnostics, 1 procédure de décision et 1 ligne non applicable). Sur 400 jeux de données simulés *depuis le modèle* de l'annexe XVII, la fréquence de rejet au seuil nominal de 10 % a été mesurée pour chacune des statistiques bootstrapées.

Statistique	$T = 10$	$T = 20$
Anderson–Darling	0,092	0,113
Cramér–von Mises	0,075	0,102
Kolmogorov–Smirnov	0,092	0,115
Shapiro–Wilk	0,090	0,110
Shapiro–Francia	0,083	0,107
Jarque–Bera	0,087	0,095
Durbin–Watson	0,092	0,105
Ljung–Box (retard 1)	0,095	0,090
sup-F	0,083	0,083
OLS-CUSUM	0,075	0,087
Grubbs	0,090	0,085

Toutes les valeurs sont compatibles avec le niveau nominal de 10 % à l'intérieur de l'intervalle de confiance à 95 % ($\pm 0,029$ pour 400 réplifications). La procédure de bootstrap paramétrique est donc correctement calibrée, y compris à $T = 10$ où aucune des lois asymptotiques utilisées par les tests classiques ne l'est.

Réserve. Cette validation est conditionnelle au modèle : elle établit que, *si* les données sont engendrées par le modèle de l'annexe XVII, les p-values de Monte-Carlo ont le bon niveau. Elle ne dit rien de la puissance du dispositif contre des écarts réalistes au modèle, laquelle reste faible à ces tailles d'échantillon.

20.1 Vérification de l'implémentation Merz–Wüthrich

Le triangle de Taylor & Ashe (1983), référence classique de la littérature, sert de jeu de contrôle.

Contrôle	Résultat	Statut
Facteurs de développement $\hat{f}_j$	3,4906 ; 1,7473 ; 1,4574 ; ...	conformes aux valeurs publiées
Réserve chain-ladder totale	18 680 856	conforme
Erreur type <i>ultime</i> de Mack	2 447 095	conforme à la valeur publiée
MSEP à un an = transcription littérale du paragraphe D(5), version consolidée	écart relatif nul (précision machine)	conforme au texte
$\sqrt{\text{MSEP}}$ à un an = ChainLadder::CDR (Merz–Wüthrich 2008)	1 778 967,66336 contre 1 778 967,66335758	écart relatif $-2,6 \times 10^{-15}$
Erreur à un an < erreur ultime	$1\,778\,968 < 2\,447\,095$	conforme à la théorie
Homogénéité : $\lambda \cdot C \Rightarrow CV$ invariant	vérifié à 10^{-10}	
Triangle déterministe $\Rightarrow \text{MSEP} = 0$	$2,7 \times 10^{-18}$	
Moments de Z (test calendaire) par énumération exhaustive	$n = 2, \dots, 12$	exacts
Identité $\sum_i r(i, j)^2 = n_j - 1$ sur les résidus de Mack, colonne par colonne	écart maximal $8,9 \times 10^{-16}$	exacte (fiche 15.3)

La conformité de l'erreur type ultime de Mack à sa valeur publiée valide simultanément $\hat{f}_j$, $\hat{\sigma}_j^2$ et la règle d'extrapolation de $\hat{\sigma}_{j-1}^2$, qui sont les entrées de la MSEP à un an. Ce triangle n'étant pas dégénéré, le contrôle ne porte que sur le cas $\hat{\sigma}_{j-3}^2 > 0$ et $\hat{\sigma}_{j-2}^2 > 0$; les cas $\hat{\sigma}_{j-3}^2 = 0$ et $\hat{\sigma}_{j-2}^2 = 0$ (§13) sont vérifiés séparément, sur des triangles construits à cet effet, par la batterie de tests unitaires du dépôt.

Sur quoi repose la validation de la MSEP à un an. Elle repose sur deux voies distinctes : d'une part la confrontation du moteur à une transcription littérale du paragraphe D(5) dans sa version consolidée en vigueur (§13), réécrite depuis le texte et implémentée séparément dans la batterie de tests unitaires ; d'autre part une comparaison *externe* avec ChainLadder::CDR (paquet R ChainLadder 0.2.18), implémentation publique de Merz–Wüthrich (2008), reproduite à $-2,6 \times 10^{-15}$ en écart relatif. Nous n'avons pas identifié de valeur *publiée* de la MSEP à un an sur ce triangle : la comparaison externe porte sur une implémentation de référence, non sur un nombre publié.

Ce que les versions antérieures de ce document affirmaient à tort. Jusqu'à la correction de la transcription du paragraphe D(5) (section 13), la validation de cette grandeur était présentée comme reposant sur une « double implémentation indépendante ». Elle ne l'était pas : les deux implémentations reprenaient la même transcription fautive du paragraphe D(5) — termes diagonaux $\hat{C}(i, J)^2 \Delta_i$ et facteur 2 omis — et ne pouvaient donc rien détecter. La MSEP en était sous-estimée (1 519 876 au lieu de 1 778 968 sur ce triangle), dans le sens favorable à l'entreprise. C'est ce défaut que la transcription de la section 13 et les deux voies ci-dessus corrigent.

20.2 Calibration des p-values asymptotiques (Merz–Wüthrich)

Les p-values non simulées de la méthode Merz–Wüthrich sont rapportées à titre de complément, la p-value retenue étant celle du bootstrap. Il importe néanmoins de savoir *de combien* elles s'en écartent, et pourquoi. Fréquences de rejet mesurées sur 600 triangles 10×10 simulés exactement sous H_0 , au seuil nominal de 10 % (intervalle de confiance à 95 % : $\pm 0,024$) :

Test	Rejets à 10 %	Interprétation
Ordonnée à l'origine (Fisher)	0,092	Conforme
Homogénéité de f_j (Fisher)	0,125	Léger sur-rejet, dans l'incertitude
Courbure (Fisher)	0,112	Conforme
Exposant de variance (Fisher)	0,097	Conforme
Kruskal–Wallis	0,135	Sur-rejet : groupes très déséquilibrés
Effets d'année calendaire	0,123	Sur-rejet : approximation normale d'une somme portant sur peu de diagonales
Test des suites	0,153	Sur-rejet marqué. La contrainte $\sum_i \sqrt{C(i, j)} r(i, j) = 0$ rend les résidus d'une colonne négativement corrélés, d'où une alternance des signes plus fréquente que sous l'échangeabilité supposée par l'approximation normale
Grubbs (borne de Bonferroni)	0,000	Extrêmement conservatrice. La borne est un majorant, et les résidus étant déjà standardisés par colonne, l'écart au maximum est faible
Breusch–Pagan (χ^2)	0,005	Très conservatrice. $\hat{\sigma}_j^2$ est estimé sur la colonne même ; les résidus standardisés ont une dispersion réduite, donc un R^2 auxiliaire trop faible

Conséquence pratique. Les écarts observés entre p-value asymptotique et p-value de Monte-Carlo ne traduisent pas une erreur de calcul mais la *non-validité* des lois de référence classiques sur des résidus de triangle, qui ne sont ni indépendants ni échangeables. Trois tests s'en écartent fortement et dans des sens opposés : le test des suites sur-rejette, Grubbs et Breusch–Pagan sous-rejettent massivement. Dans les trois cas, c'est la p-value de Monte-Carlo qui est retenue par le moteur, et elle seule doit être utilisée en dossier. La p-value non simulée n'est conservée que pour documenter l'écart.

20.3 Calibration des p-values de Monte-Carlo (Merz–Wüthrich)

Sur 160 triangles 10×10 simulés sous le modèle de Mack, fréquence de rejet au seuil nominal de 10 % (intervalle de confiance à 95 % : $\pm 0,046$) :

Statistique	rejets à 10 %	rejets à 5 %
Effets d'année calendaire	0,062	0,019
Corrélation entre années de développement	0,119	0,037
Breusch–Pagan sur résidus de Mack	0,100	0,062
Grubbs	0,113	0,044
Durbin–Watson	0,100	0,050
Test des suites	0,056	0,025
Proportionnalité (pente)	0,069	0,044

Toutes les valeurs sont compatibles avec les niveaux nominaux à l'intérieur de l'intervalle de confiance.

Compléments bibliographiques

Les fiches de la partie III citent les articles *fondateurs* de chaque test : ils établissent la statistique et sa loi. Les affirmations relatives à la *qualité de l'approximation* à $T = 8$ et à la *validité du bootstrap* relèvent en revanche d'une littérature distincte, rassemblée ici. Chaque entrée précise la portée exacte de la référence, c'est-à-dire l'affirmation qu'elle soutient dans le présent document.

Vitesse de convergence et bornes d'erreur

- A. C. Berry, *The accuracy of the Gaussian approximation to the sum of independent variates*, *Transactions of the American Mathematical Society*, 49(1), 1941, p. 122–136 ; C.-G. Esseen, *On the Liapounoff limit of error in the theory of probability*, *Arkiv för Matematik, Astronomi och Fysik*, 28A(9), 1942, p. 1–19. *Portée*. Les fiches citaient jusqu'ici uniquement les auteurs des tests. Le théorème de Berry–Esseen est la référence qui permet d'énoncer une vitesse $\mathcal{O}(T^{-1/2})$ pour les approximations normales, et donc de montrer qu'à $T = 8$ la borne est de l'ordre de 0,35, c'est-à-dire sans valeur pratique. Aucune référence antérieure du document ne supportait cette affirmation.
- H. Callaert, P. Janssen, *The Berry-Esseen theorem for U-statistics*, *The Annals of Statistics*, 6(2), 1978, p. 417–421. *Portée*. Le S de Mann–Kendall est une U -statistique et non une somme de variables indépendantes : le Berry–Esseen classique ne s'applique pas directement. Cette référence est celle qui couvre exactement le cas rencontré. La référence existante (Mann, 1945) établit la statistique, pas sa vitesse de convergence.

Lois exactes employées à la place des approximations normales

- M. G. Kendall, J. D. Gibbons, *Rank Correlation Methods*, 5^e éd., Edward Arnold / Oxford University Press, 1990. *Portée*. Le document citait Kendall (1975, 4^e éd.). L'édition de 1990 est celle qui est aujourd'hui la référence courante pour la distribution exacte de S et ses tables. Les deux éditions sont conservées : la 4^e pour l'antériorité de la méthode, la 5^e pour le résultat exact effectivement implémenté.
- F. Swed, C. Eisenhart, *Tables for testing randomness of grouping in a sequence of alternatives*, *The Annals of Mathematical Statistics*, 14(1), 1943, p. 66–87. *Portée*. Wald & Wolfowitz (1940), déjà cité, établit le test ; Swed & Eisenhart fournit la distribution combinatoire exacte du nombre de suites, qui est celle implémentée dans le moteur, l'approximation normale n'étant conservée qu'à titre indicatif.
- J. D. Gibbons, J. W. Pratt, *P-values : interpretation and methodology*, *The American Statistician*, 29(1), 1975, p. 20–25. *Portée*. Référence sur les définitions concurrentes de la p-valeur bilatérale, citée pour situer la convention du doublement retenue par `runs_p_exacte()` depuis l'issue #29 (fiche 9.3). Elle n'est invoquée que pour établir que le doublement est une convention ; le choix du moteur est motivé dans la fiche par la cohérence avec la p-value de Monte-Carlo et avec Durbin–Watson, non par une recommandation de cet article.
- D. J. Best, D. E. Roberts, *Algorithm AS 89 : The upper tail probabilities of Spearman's ρ* , *Journal of the Royal Statistical Society, Series C (Applied Statistics)*, 24(3), 1975, p. 377–379. *Portée*.

La référence Spearman (1904) établit le coefficient. Best & Roberts documente le calcul des probabilités exactes en petit échantillon, qui est ce que `cor.test(..., exact = TRUE)` met en œuvre et que le moteur retient à $T = 8$.

Théorie du bootstrap et des tests de Monte-Carlo

- M. Dwass, *Modified randomization tests for nonparametric hypotheses*, *The Annals of Mathematical Statistics*, 28(1), 1957, p. 181–187 ; A. C. A. Hope, *A simplified Monte Carlo significance test procedure*, *Journal of the Royal Statistical Society, Series B*, 30(3), 1968, p. 582–598. *Portée.* Ce sont les références qui établissent que le test de Monte-Carlo fondé sur $\hat{p} = (1 + \#\{S^{(b)} \geq S_{\text{obs}}\})/(B + 1)$ est de niveau *exact* pour B fini lorsque $\alpha(B + 1)$ est entier. Le document invoquait cette propriété en citant Efron (1979), qui ne la démontre pas. C’est une correction de référence, non un simple ajout.
- P. H. Jöckel, *Finite sample properties and asymptotic efficiency of Monte Carlo tests*, *The Annals of Statistics*, 14(1), 1986, p. 336–347 ; R. A. Marriott, *Barnard’s Monte Carlo tests : how many simulations ?*, *Journal of the Royal Statistical Society, Series C*, 28(1), 1979, p. 75–77. *Portée.* Ces travaux quantifient la perte de puissance induite par un B fini, et fondent le choix d’un B de l’ordre du millier. Ils justifient la ligne (B) du tableau 5.5.
- P. J. Bickel, D. A. Freedman, *Some asymptotic theory for the bootstrap*, *The Annals of Statistics*, 9(6), 1981, p. 1196–1217 ; K. Singh, *On the asymptotic accuracy of Efron’s bootstrap*, *The Annals of Statistics*, 9(6), 1981, p. 1187–1195. *Portée.* Efron (1979), seule référence bootstrap du document, introduit la méthode mais n’en établit pas la consistance. Ces deux articles sont ceux qui démontrent la validité asymptotique, et donc ce qui fonde — et ce qui limite — l’emploi du bootstrap ici : la garantie est *asymptotique en T*, ce qui est précisément le point à signaler à $T = 8$.
- P. Hall, *The Bootstrap and Edgeworth Expansion*, Springer, 1992 ; A. C. Davison, D. V. Hinkley, *Bootstrap Methods and their Application*, Cambridge University Press, 1997. *Portée.* Hall (1992) est l’ouvrage de référence sur les raffinements d’ordre supérieur obtenus pour les statistiques pivotales, qui explique pourquoi le bootstrap améliore l’approximation sans la rendre exacte. Davison & Hinkley (1997) traite spécifiquement du bootstrap paramétrique et des tests de Monte-Carlo tels qu’employés ici.
- A. C. Atkinson, *Two graphical displays for outlying and influential observations in regression*, *Biometrika*, 68(1), 1981, p. 13–20 ; S. Aldor-Noiman, L. D. Brown, A. Buja, W. Rolke, R. A. Stine, *The power to see : a new graphical test of normality*, *The American Statistician*, 67(4), 2013, p. 249–260 (errata publiés par les auteurs en 2014). *Portée.* Atkinson (1981) construit l’enveloppe d’un graphique de probabilité des résidus par simulation sous le modèle ajusté, chaque échantillon simulé étant réajusté : l’enveloppe reproduit ainsi la loi des résidus estimés et non celle d’un échantillon indépendant. C’est la construction qui manque à l’enveloppe actuelle du QQ-plot et qui est prévue (fiche 12.3). Aldor-Noiman et al. (2013) construit des bandes *simultanées* pour le QQ-plot normal et soutient la distinction, faite dans la même fiche, entre bande ponctuelle et bande simultanée. Aucune des deux références ne chiffre le comportement de ces bandes pour des résidus d’un modèle à trois paramètres estimés sur $T = 8$ observations : les proportions de sortie de bande citées dans la fiche sont des constats de simulation propres au jeu de contrôle.
- C. J. Clopper, E. S. Pearson, *The use of confidence or fiducial limits illustrated in the case of the binomial*, *Biometrika*, 26(4), 1934, p. 404–413. *Portée.* Intervalle de confiance exact d’une proportion binomiale ; pour 0 succès sur n essais indépendants, la borne supérieure unilatérale au niveau $1 - \alpha$ vaut $1 - \alpha^{1/n}$. Elle soutient la borne de 1,5 % citée à la fiche 9.4 pour le taux de faux

ECHEC (0 sur 200 jeux simulés), borne qui ne vaut que pour le générateur de simulation employé, à $\hat{\delta}$ intérieur et sur la plateforme de mesure.

Comportement en petit échantillon des tests employés

- N. Davies, C. M. Triggs, P. Newbold, *Significance levels of the Box-Pierce portmanteau statistic in finite samples*, *Biometrika*, 64(3), 1977, p. 517–522. *Portée.* Le document affirmait que l’approximation χ^2 des tests portmanteau est mal calibrée en petit échantillon en citant Ljung & Box (1978). Davies, Triggs & Newbold est l’étude dédiée à cette question et constitue la référence appropriée. Ljung & Box reste cité pour la statistique elle-même.
- K. O. Bowman, L. R. Shenton, *Omnibus test contours for departures from normality based on $\sqrt{b_1}$ and b_2* , *Biometrika*, 62(2), 1975, p. 243–250; C. M. Jarque, A. K. Bera, *A test for normality of observations and regression residuals*, *International Statistical Review*, 55(2), 1987, p. 163–172. *Portée.* Bowman & Shenton documente la lenteur de convergence des statistiques fondées sur $\sqrt{b_1}$ et b_2 vers leur loi limite, ce qui est le fondement de la mise en garde du tableau 5.4 sur Jarque–Bera. L’article de 1987 est la version complète du test, la note de 1980 dans *Economics Letters* en étant la forme abrégée : les deux sont conservées.
- S. S. Shapiro, M. B. Wilk, H. J. Chen, *A comparative study of various tests for normality*, *Journal of the American Statistical Association*, 63(324), 1968, p. 1343–1372. *Portée.* Étude de puissance de référence pour les tests de normalité, qui documente leur faiblesse en très petit échantillon. Elle soutient l’affirmation, présente dans les fiches, selon laquelle une p-value élevée n’apporte quasiment aucune information à T faible.
- G. S. Maddala, *Introduction to Econometrics*, 3^e éd., Wiley, 2001, pour la discussion du caractère non exact du test RESET. *Portée.* Ramsey (1969), seule référence citée jusqu’ici, développe le test à partir de résidus BLUS. Dans la forme usuellement implémentée — et retenue ici — les régresseurs auxiliaires sont des puissances des valeurs ajustées, qui dépendent de y : la statistique n’est alors plus exactement de loi de Fisher. Cette nuance, absente de la version précédente de la documentation, motive le recours au bootstrap.
- J. P. Imhof, *Computing the distribution of quadratic forms in normal variables*, *Biometrika*, 48(3/4), 1961, p. 419–426. *Portée.* Référence exacte de la méthode évoquée dans la fiche Durbin–Watson pour le calcul de la loi exacte de la statistique, dont le document mentionnait le nom sans la référencer.

21.1 Traçabilité entre la documentation et le code

L’architecture complète du moteur est décrite en section 1. Le tableau ci-dessous relie chaque développement du présent document à son implémentation.

Chaque affirmation quantitative de ce document correspond à une fonction identifiable du moteur R/engine.R, seul fichier contenant de la logique statistique ou actuarielle.

Élément documenté	Implémentation dans R/engine.R
Noyau du modèle ($\pi_t, \hat{\beta}, z_t$)	<code>usp_pi()</code> , <code>usp_noyau()</code>
Optimisation sous contrainte $\delta \in [0, 1]$	<code>usp_objectif()</code> , <code>usp_ajuster()</code>
$\hat{\delta}$ au bord, $\hat{\pi}_t$ constant (fiches 7.7, 9.5)	<code>usp_regime()</code> , tolérance <code>TOL_DELTA_BORD</code>
Lois exactes (Kendall, suites)	<code>mk_p_exacte()</code> , <code>runs_p_exacte()</code> , <code>usp_runsr_p_exacte()</code>
Statistiques de test	<code>stat_*</code> (), <code>test_*</code> ()

Élément documenté	Implémentation dans R/engine.R
Bootstrap paramétrique et p-values MC	<code>.stats_bootstrapables()</code> , <code>usp_bootstrap()</code> ; catalogues <code>USP_CATALOGUE_MC</code> et <code>MW_CATALOGUE_MC</code> (<code>.mc_entree()</code> , <code>.mc_evaluer()</code>) ; p-value de Monte-Carlo par <code>engine_p_mc()</code> , appliquée par <code>.mc_p_values()</code>
Hiérarchie exacte $\succ$ MC $\succ$ asymptotique	fonction <code>add()</code> d' <code>engine_registre_tests()</code> , unique et partagée par <code>usp_tests()</code> et <code>mw_tests()</code>
Sortie de la hiérarchie (grandeur rivée par l'estimation)	branche finale de <code>add()</code> : <code>p_retenue</code> et <code>nature_p</code> à NA, verdict INFO, seul admis hors des types <code>test</code> et <code>procedure de decision</code>
Réserve sur la base « ratios bruts » à $\hat{\pi}_t$ constant	champ <code>detail</code> des six lignes de base R dans <code>usp_tests()</code>
Erreur de Monte-Carlo (§5.2)	champ <code>err_mc</code> de <code>usp_bootstrap()</code> et de <code>mw_bootstrap()</code> , cal- culé par <code>engine_p_mc()</code> : $\sqrt{\hat{p}(1-\hat{p})/B_{\text{eff}}}$ en queue haute ou basse, $\sqrt{\hat{p}(2-\hat{p})/B_{\text{eff}}}$ au bilatéral ; pas élémentaire de $\hat{p}$, par sta- tistique, dans <code>granularite_stat</code>
Jackknife, profils, rapport de vraisem- blance	<code>usp_jackknife()</code> , <code>usp_profil()</code>
Calibration et paramètre final	<code>usp_parametre()</code> , <code>usp_credibilite()</code>
Merz–Wüthrich : facteurs $\hat{f}_j$, variances $\hat{\sigma}_j^2$, cumulés projetés $\hat{C}(i, J)$, réserve (§13)	<code>mw_ajuster()</code>
Merz–Wüthrich : extrapolation de $\hat{\sigma}_{j-1}^2$ (§13, fiche 19.1)	<code>mw_ajuster()</code> : valeur retenue (<code>\$sigma2</code>) ; <code>mw_extrapolation_sigma2()</code> : trois arguments du minimum ; <code>.mw_detail_extrapolation()</code> : champ <code>detail</code> de la ligne M6
Merz–Wüthrich : erreur de prédiction à un an, paragraphe D(5) (§13)	<code>mw_msep()</code>
Merz–Wüthrich : paramètre propre $\sigma_{(\text{res}, s, \text{USP})}$ et crédibilité (§13)	<code>mw_parametre()</code> , <code>usp_credibilite()</code>
Merz–Wüthrich : résidus standardisés de Mack (§13)	<code>mw_residus()</code>
Merz–Wüthrich : bootstrap semi- paramétrique et p-values de Monte- Carlo (§4.2)	<code>mw_bootstrap()</code> , <code>mw_simuler_triangle()</code> , <code>.mw_stats()</code>
Merz–Wüthrich : tests et diagnostics M1 à M6 (sections 14 à 19)	<code>mw_tests()</code>
Merz–Wüthrich : leviers, DFBETA et contributions par année de survenance (fiche 12.8)	<code>mw_influence()</code> , <code>mw_contributions()</code>
Contrôles de validité	<code>engine_valider_donnees()</code> , <code>usp_controle_donnees()</code> , <code>mw_valider_triangle()</code> , <code>mw_valider_ajustement()</code>
Quantités des graphiques	<code>engine_plots_data()</code> (branche lognormale), <code>mw_plots_data()</code> (branche Merz–Wüthrich)
Tirages aléatoires et graines (§1.5)	<code>usp_bootstrap()</code> , <code>usp_simuler()</code> , <code>mw_bootstrap()</code> , <code>mw_simuler_triangle()</code> , <code>sw_loi_nulle()</code> , <code>engine_plots_data()</code> , <code>engine_ecrire_xlsx()</code> , <code>engine_lire_xlsx()</code>
Orchestration complète	<code>run_engine()</code> ; méthode de réserve n° 2 déléguée à <code>.run_engine_mw()</code>
Table auditable des tests	<code>engine_table_tests()</code>

Élément documenté	Implémentation dans R/engine.R
Empreintes md5 d'un résultat pour le rapport figé : données du calcul (texte canonique, fonction des seules valeurs) et objet sérialisé (stable sur une même machine, dépendant de la plateforme)	<code>engine_empreinte()</code> ; non appelée par <code>run_engine()</code> , sans tirage aléatoire

L'application Shiny (`app.R`, `R/display_helpers.R`) ne contient aucun de ces calculs : elle collecte les entrées, appelle `run_engine()` et affiche l'objet retourné. Le moteur s'exécute indépendamment de toute interface, ce qui permet une revue et une reproduction externes : `source("R/engine.R")` puis `run_engine(xt = ..., yt = ...)`.

Méthode Merz–Wüthrich

Les références ci-dessous fondent la section 13 et les fiches M1 à M6. Elles n'ont pas d'équivalent dans le corpus lognormal, la méthode reposant sur un modèle et un mode d'inférence différents.

- T. Mack, *Distribution-free calculation of the standard error of chain ladder reserve estimates*, *ASTIN Bulletin*, 23(2), 1993, p. 213–225. *Portée*. Article fondateur du modèle de chaîne d'échelle stochastique : il établit les estimateurs $\hat{f}_j$ et $\hat{\sigma}_j^2$, l'erreur type *ultime*, et surtout l'énoncé des trois hypothèses reprises au paragraphe D(2)(h) du règlement. C'est la valeur publiée de l'erreur ultime sur le triangle de Taylor & Ashe qui a servi à valider notre implémentation de $\hat{f}_j$, $\hat{\sigma}_j^2$ et de la règle d'extrapolation.
- T. Mack, *Which stochastic model is underlying the chain ladder method ?*, *Insurance : Mathematics and Economics*, 15(2–3), 1994, p. 133–138. *Portée*. Source du test des effets d'année calendaire et de la discussion des hypothèses testables. C'est de cet article que proviennent les moments de $Z_k = \min(L_k, S_k)$, que nous avons vérifiés par énumération exhaustive.
- M. Merz, M. V. Wüthrich, *Modelling the claims development result for solvency purposes*, *Casualty Actuarial Society E-Forum*, automne 2008, p. 542–568. *Portée*. Article dont dérive la formule d'erreur de prédiction à un an du paragraphe D(5). La distinction entre erreur à un an et erreur ultime est le fondement même de la méthode n° 2, et l'ordre $\sqrt{\text{MSEP}_{1\text{ an}}} < \sqrt{\text{MSEP}_{\text{ultime}}}$ que nous avons vérifié numériquement en découle. C'est également l'implémentation publique de cet article (`ChainLadder::CDR`) qui fournit la valeur de comparaison externe de notre MSEP à un an (section 20).
- M. V. Wüthrich, M. Merz, *Stochastic Claims Reserving Methods in Insurance*, Wiley, 2008. *Portée*. Ouvrage de référence rassemblant le cadre théorique complet (modèle de Mack, résultat de développement des sinistres, erreurs de prédiction). Il est cité pour le cadre général, l'article de 2008 l'étant pour la formule précise.
- P. D. England, R. J. Verrall, *Stochastic claims reserving in general insurance*, *British Actuarial Journal*, 8(3), 2002, p. 443–518. *Portée*. Référence du bootstrap par rééchantillonnage des résidus, seul possible ici puisque le modèle de Mack ne spécifie aucune loi. Elle fonde la nature *semi-paramétrique* des p-values de Monte-Carlo de cette méthode, et donc la réserve exposée en section 4.2.
- G. C. Taylor, F. R. Ashe, *Second moments of estimates of outstanding claims*, *Journal of Econometrics*, 23(1), 1983, p. 37–61. *Portée*. Source du triangle de dix années de survenance utilisé comme jeu de contrôle. Son statut de référence partagée par la littérature est ce qui rend la validation reproductible par un tiers.

- G. Barnett, B. Zehnwirth, *Best estimates for reserves*, *Proceedings of the Casualty Actuarial Society*, 87, 2000, p. 245–321. *Portée*. Discussion des exposants alternatifs de la structure de variance ($\alpha = 0, 1$ ou 2). Citée dans la fiche 15.1 pour situer l'exposant 1 imposé par le règlement parmi les choix possibles, et non pour recommander une alternative — l'annexe XVII ne laissant pas ce choix ouvert.

Points sur lesquels la littérature ne permet pas de conclure

Conformément à l'exigence de ne pas produire de conclusion artificiellement précise, les points suivants sont signalés comme *non tranchés* par la littérature consultée.

1. **Aucune borne d'erreur exploitable à $T = 8$** n'a pu être identifiée pour les statistiques de type multiplicateur de Lagrange (Breusch–Pagan, White) ni pour les statistiques portmanteau. Les résultats disponibles sont soit purement asymptotiques, soit des études de simulation portant sur des tailles supérieures. L'affirmation « la loi χ^2 est inadéquate à $T = 8$ » est donc fondée sur l'absence de justification, non sur une borne quantifiée.
2. **La vitesse de convergence du bootstrap paramétrique dans ce modèle** n'est pas établie. Les résultats de Bickel & Freedman (1981), Singh (1981) et Hall (1992) portent sur des cadres où l'estimateur est asymptotiquement normal et le paramètre intérieur au domaine. Ici, $\hat{\delta}$ est fréquemment sur la frontière $\{0, 1\}$, situation qui sort de ce cadre. Aucun taux ne peut donc être annoncé.
3. **La loi exacte de la statistique agrégée Z** du test des effets d'année calendaire n'est pas établie. Les moments de chaque Z_k sont exacts, mais la normalité de leur somme sur un nombre réduit de diagonales n'est justifiée par aucun résultat que nous ayons identifié ; d'où le recours au bootstrap.
4. **Aucune valeur publiée de la MSEF à un an** n'a pu être identifiée pour le triangle de Taylor & Ashe. La validation de cette grandeur repose donc sur la transcription littérale du paragraphe D(5) (version consolidée), sur des propriétés structurelles et sur la comparaison avec une implémentation externe (ChainLadder : : CDR), non sur un nombre publié dans la littérature.
5. **Le domaine de validité exact de la transformation de Royston** pour $4 \leq T \leq 11$ est documenté par son auteur, mais nous n'avons pas identifié d'étude indépendante en évaluant la précision spécifiquement à $T = 8$.

Articulation des deux corpus. Les références des fiches établissent *ce que calcule* chaque test ; celles de la présente section établissent *ce que vaut* le résultat à la profondeur d'intérêt. Les secondes portent sur les vitesses de convergence, les lois exactes effectivement implémentées et les fondements théoriques du bootstrap et des tests de Monte-Carlo.

Synthèse et lecture des verdicts

Verdict	Signification
OK	p-value <i>retenue</i> — celle que désigne <code>nature_p</code> , choisie dans l'ordre exacte $\succ$ Monte-Carlo $\succ$ asymptotique — au-dessus du seuil d'alerte, ou, pour la procédure ESD de Rosner (fiches 10.4 et 17.2), aucune valeur aberrante détectée au niveau α . Pour le TOST et les tests de Student sur la pente et de Fisher, la logique est inversée : OK correspond à un <i>p faible</i> ($p < \alpha$), ALERTE à $\alpha \leq p < 0,30$ et ECHEC à $p \geq 0,30$.
ALERTE	p-value retenue dans la zone intermédiaire $[\alpha/2; \alpha[$ (par défaut [5 %; 10 %]), ou, pour la procédure ESD, une valeur aberrante détectée.
ECHEC	p-value retenue sous le seuil strict $\alpha/2$, ou, pour la procédure ESD, deux valeurs aberrantes ou plus. N'invalide pas mécaniquement l'USP, mais impose une justification explicite : nature de l'écart, retraitement envisagé, sensibilité du paramètre final.
INFO	Toute ligne dont le type n'est ni <code>test</code> ni <code>procedure de decision</code> (ADR 0001, amendement du 23/09/2026) : diagnostics et lignes non applicables, dont <code>p_retenue</code> , <code>nature_p</code> et <code>sens_du_test</code> valent NA; le moteur refuse qu'un verdict soit fourni pour une telle ligne. Les seuils conventionnels attachés aux diagnostics — $2k/T$ pour les leviers, $4/T$ pour la distance de Cook, 0,5 pour R^2 , 10 % / 20 % pour le jackknife, 50 % / 80 % pour la largeur de l'intervalle bootstrap — et les libellés de la position de $\hat{\delta}$ (fiches 10.6, 10.5, 6.5, 11.2, 11.3 et 7.7) sont des <i>repères</i> , non des seuils de rejet : ils ne produisent aucun verdict. Ils sont conservés dans le commentaire, sauf ceux du jackknife et de l'intervalle bootstrap, énoncés dans leurs fiches seulement depuis la décision M27 du mainteneur (issue #76). La condition du premier ordre et la convergence multi-démarrages ne sont plus des lignes de la table (issue #22) : ce sont des contrôles OK / ECHEC de <code>res\$controles</code> (fiches 9.4 et 11.4). Une ligne de type <code>test</code> sans p-value retenue sort aussi INFO. Relèvent notamment de ce verdict : test non applicable faute d'effectif ($T < 8$ pour D'Agostino, $T < 20$ pour Anscombe–Glynn), grandeur rivée par l'estimation (fiches 9.5 et 9.6), grandeur descriptive, ou lecture graphique. Relève aussi de ce verdict la grandeur dont la valeur est <i>contrainte par construction</i> , aucun seuil ne pouvant alors rien détecter : ainsi la variance des résidus de Mack, fixée à $(N - k)/(N - 1)$ — N résidus, k colonnes retenues — et non à 1 (fiche 15.3). Sont enfin restitués INFO les deux diagnostics M6 de la méthode Merz–Wüthrich, extrapolation de $\hat{\sigma}_{j-1}^2$ et concentration de la réserve (fiches 19.1 et 19.2) : ils n'opposent aucune hypothèse nulle et n'ont pas de loi de référence, et le repère indicatif de 40 % du second n'emporte aucun verdict (ADR 0001).

Hiérarchie de lecture recommandée

1. **Contrôles de données** (section 3) – bloquants pour ceux que les tableaux de cette section désignent comme tels : `run_engine()` rend alors `ok = FALSE` et aucun résultat. Les autres sont des avertissements ou des informations, à examiner avant toute lecture.
2. **Convergence numérique** – préalable technique : contrôles numériques de l'estimation de `res$controles`, famille H, non bloquants mais dont un ECHEC est à traiter avant toute lecture des tests (section 3) — condition du premier ordre (fiche 9.4) et convergence multi-démarrages (fiche 11.4) —, et écart de $\sum_t z_t^2$ à T (fiche 9.6). La nullité de la moyenne *pondérée* des résidus n'en fait pas partie : c'est une identité algébrique, vraie même sans convergence (fiche 9.4). La moyenne simple $\bar{z}$ est, elle, un diagnostic (fiche 9.5).

3. **Jackknife et intervalle bootstrap** (section 11) – la mesure la plus directe de la solidité du calibrage à T faible.
4. **Position de $\hat{\delta}$ et test du rapport de vraisemblance** (fiches 7.7 et 11.1) – identifiabilité de la structure de variance.
5. **Ruptures et points influents** (section 10) – susceptibles d’expliquer tout rejet observé par ailleurs.
6. **Tests des hypothèses H1 à H4** (sections 6 à 9), en lisant pour chacun la p-value *retenue* par le moteur, celle que désigne le champ `nature_p`. La hiérarchie appliquée est *exacte* $\succ$ *Monte-Carlo* $\succ$ *asymptotique* (section 5) : la p-value de Monte-Carlo n’est pas la première servie, elle vient *après* la p-value exacte lorsque celle-ci existe. Mesuré sur le jeu de contrôle (méthode prime, $T = 8$, $B = 999$) : des 48 lignes de la table auditable, 10 retiennent une p-value exacte, et 9 d’entre elles disposent pourtant d’une `p_mc` qui n’est pas retenue : lire systématiquement `p_mc` reviendrait à écarter neuf p-values exactes au profit d’estimations entachées d’une erreur de Monte-Carlo (section 5.2). Les trois colonnes restent affichées : leur comparaison est un contrôle utile, mais elle ne modifie pas le verdict.

Tests structurellement inopérants à faible T

Test	Seuil de validité	Nature du problème
Cox–Stuart	$T \geq 12$	Rejet à 5 % <i>impossible</i> pour $m \leq 5$ paires.
Anscombe–Glynn	$T \geq 20$	Non défini en-deçà ; marqué INFO.
D’Agostino (asymétrie)	$T \geq 8$	Non défini en-deçà ; puissance faible jusqu’à $T \approx 20$.
Jarque–Bera	$T \geq 50$	b_2 borné par $\approx T$; convergence χ^2 très lente.
Ljung–Box / Box–Pierce	$T \geq 30$	Approximation χ^2 mal calibrée.
Wald–Wolfowitz	$n_1, n_2 \geq 10$	Approximation normale ; granularité de R (loi exacte retenue, $p_{\min} = 0,057$ à $T = 8$).
Breusch–Pagan / White	$T \geq 30$	Convergence asymptotique lente.
Rosner ESD	$T \geq 25$	Valeurs critiques peu fiables en-deçà.
Durbin–Watson	—	Bornes invalides sur résidus de maximum de vraisemblance.
sup-F de Quandt	—	Loi de Fisher inapplicable (point de rupture estimé).

Rappel final. Le décompte des tests en échec ne se substitue pas à l’analyse qualitative exigée par le règlement d’exécution (UE) 2015/498 : la note de justification du dossier de candidature doit expliquer, segment par segment, en quoi la méthode retenue est adaptée au profil de risque de l’organisme, y compris pour les segments non retenus. Aucun test isolé, ni aucun comptage de tests, ne peut établir cette démonstration.

ANNEXE

Flux détaillés entre fonctions

Annexe — flux détaillés entre fonctions

La figure 1 donne la vue d'ensemble de la chaîne de calcul. La présente annexe descend au niveau de la fonction individuelle. Elle poursuit un objectif précis : rendre visible, pour chaque test, *combien* de fonctions concourent à son résultat et *lesquelles* sont partagées avec d'autres tests. Cette information conditionne la portée d'une revue de code : une anomalie dans une fonction mutualisée se propage à plusieurs tests, alors qu'une anomalie dans une fonction dédiée reste circonscrite.

23.1 Convention graphique

Forme ou couleur	Signification
Bloc bleu clair	Entrée ou donnée intermédiaire
Bloc blanc, contour bleu	Fonction dédiée à un seul test
Bloc orangé, contour épais	Fonction mutualisée entre plusieurs tests ou entre les deux méthodes
Bloc gris	Fonction interne de support, appelée par une autre fonction du moteur et jamais directement par <code>usp_tests()</code> ou <code>mw_tests()</code> : <code>sw_loi_nulle()</code> , <code>.imhof_p_sup0()</code> , <code>.runs_dens()</code> , <code>.fisher_combine()</code> , <code>.mack_moments_Z()</code> , <code>mw_simuler_triangle()</code> , <code>.mw_stats()</code> . Le préfixe d'un point ne définit pas cette catégorie : <code>.shapiro_sur()</code> , <code>.mw_lm_intra()</code> et <code>.mw_detail_extrapolation()</code> , préfixées d'un point, sont appelées directement par <code>usp_tests()</code> ou <code>mw_tests()</code> et ne sont pas représentées en gris
Bloc vert	Sortie : p-value ou grandeur restituée
Flèche pleine	Transmission d'un objet, dont le nom figure sur la flèche
Flèche pointillée	Dépendance de second rang (mise en cache, loi de référence)

Les fonctions mutualisées appellent une vigilance particulière. Le tableau suivant les recense.

Fonction	Portée	Tests concernés
usp_credibilite()	LN + MW	Calibration des deux méthodes : seule fonction de calibration commune aux deux branches
engine_p_mc(), .mc_evaluer()	LN + MW	Toutes les p-values de Monte-Carlo et leurs erreurs, dans les deux méthodes ; évaluation des deux catalogues
engine_registre_ tests()	LN + MW	Enregistrement de toutes les lignes des tables de tests : hiérarchie des p-values et verdicts des deux méthodes
test_grubbs()	LN + MW	Grubbs sur z_t , sur ratios bruts, et sur résidus de Mack
test_rosner()	LN + MW	ESD généralisé, dans les deux méthodes
test_runs()	LN + MW	Test des suites, dans les deux méthodes
runs_p_exacte()	LN	p-value exacte des suites sur z_t et, par <code>usp_runsr_p_exacte()</code> , sur ratios bruts
stat_dw()	LN + MW	Durbin–Watson, dans les deux méthodes
.shapiro_sur()	LN + MW	Shapiro–Wilk (Royston et loi nulle simulée), dans les deux méthodes
stat_lilliefors(), lillie_p()	LN + MW	Lilliefors, dans les deux méthodes
test_lm_complet()	LN	Student sur la constante, Student sur la pente, Fisher global, R^2 : quatre entrées issues d'un seul appel
usp_noyau(), usp_pi()	LN	Tout le noyau lognormal : résidus z_t , donc l'intégralité de H2, H3, H4
usp_regime()	LN	Drapeau de la position de $\hat{\delta}$, libellés du centrage et de la variance unitaire (constance de $\hat{\pi}_t$ exacte ou à la tolérance près), réserve du champ detail des six lignes sur ratios bruts et première condition de la p-value exacte des suites sur ces ratios : une seule tolérance, TOL_DELTA_BORD
.stats_bootstrapables()	LN	Les 34 statistiques bootstrapées de la méthode lognormale, en un seul appel
mw_ajuster()	MW	$\hat{f}_j, \hat{\sigma}_j^2, \hat{C}(i, j)$: entrée de la MSEP, des résidus, de tous les tests M1 à M6
mw_residus()	MW	Support de M1, M2, M3, M4 et M5
.mw_stats()	MW	Les 13 statistiques bootstrapées de la méthode, en un seul appel

23.2 Graphe chapeau : les deux branches et leurs points de partage




FIGURE 2 : Vue chapeau. Les deux branches sont disjointes jusqu’aux fonctions de statistique, dont sept sont mutualisées (en orange), puis se rejoignent sur `usp_credibilite()`. Une anomalie dans un bloc orange affecterait les deux méthodes.

23.3 Méthode lognormale : hypothèse H1




FIGURE 3 : Hypothèse H1. `test_lm_complet()` alimente **quatre** entrées de la table des tests à partir d'un unique ajustement : une anomalie s'y propagerait aux quatre. Mann-Kendall illustre la configuration inverse : un seul test, mais quatre fonctions dont deux internes.

23.4 Méthode lognormale : hypothèse H2




FIGURE 4 : Hypothèse H2. Chacun des six tests dispose de sa propre fonction : la portée d'une anomalie y est circonscrite à un test, contrairement à H1.

23.5 Méthode lognormale : hypothèses H3 et H4, stabilité




FIGURE 5 : Hypothèses H3 et H4 et diagnostics de stabilité. Tous les tests partent des résidus z_t (une erreur dans `usp_noyau()` affecterait tout ce graphe); six sont aussi calculés sur les ratios centrés u_t (liaisons orangées). Les blocs gris fournissent des lois de référence; `.shapiro_sur()` alimente *deux* entrées.

23.6 Méthode Merz–Wüthrich : de l’ajustement aux tests M1 à M6




FIGURE 6 : Méthode Merz–Wüthrich. `mw_ajuster()` et `mw_residus()` sont les deux points de passage obligés : la première alimente à la fois la MSEP et les résidus, la seconde l’intégralité des tests M1 à M5. Quatre blocs de tests reposent sur des fonctions déjà employées par la méthode lognormale (en orange), ce qui mutualise la revue de code mais étend la portée d’une anomalie éventuelle.

23.7 Lecture en termes de revue de code

Configuration	Exemples	Conséquence pour la revue
Un test, une fonction dédiée	White, Goldfeld– Quandt, Brown– Forsythe, Jarque– Bera, corrélation entre colonnes	Revue circonscrite : une anomalie n’affecte que ce test.
Un test, plusieurs fonctions	Mann–Kendall (<code>test_mann_kendall</code> + <code>mk_p_exacte()</code> + deux internes), Durbin–Watson (<code>stat_dw()</code> + <code>dw_p_exacte()</code> + <code>.imhof_p_sup0()</code>)	La statistique et la loi de référence sont séparées : il faut vérifier les deux, et leur cohérence d’appariement.
Une fonction, plusieurs tests	<code>test_lm_complet()</code> (4 entrées), <code>.shapiro_sur()</code> (2 entrées); <code>stat_dw()</code> , <code>test_runs()</code> , <code>stat_supF()</code> , <code>stat_cusum()</code> et <code>test_grubbs()</code> (2 entrées chacune, sur z_t et sur les ratios bruts u_t)	Une anomalie se propage à toutes les entrées issues de l’appel.
Base « ratios bruts »	six lignes sur u_t , construit par <code>.usp_contexte_</code> <code>mc()</code> , statistiques calculées dans <code>.stats_</code> <code>bootstrapables()</code> suites : <code>usp_runsr_</code> <code>p_exacte()</code> + <code>usp_regime()</code>	La série u_t est construite hors de <code>usp_noyau()</code> : une anomalie du noyau n’atteint pas la statistique observée de ces six lignes, mais atteint leur loi de référence, simulée sous le modèle ajusté. La p-value exacte des suites dépend en outre du régime de $\hat{\pi}_t$ et du test de concordance des signes.
Fonction commune aux deux méthodes	<code>test_grubbs()</code> , <code>test_rosner()</code> , <code>test_runs()</code> , <code>stat_dw()</code> , <code>.shapiro_sur()</code> , <code>stat_lilliefors()</code> , <code>usp_credibilite()</code> , <code>engine_p_mc()</code> , <code>engine_registre_</code> <code>tests()</code>	Portée maximale : une anomalie affecterait les deux dispositifs, donc les deux dossiers. Priorité de revue.

Cette hiérarchie explique l’ordre de vérification retenu lors du développement : les fonctions communes et les noyaux (`usp_noyau()`, `mw_ajuster()`) ont fait l’objet de contrôles indépendants — recalcul manuel, identités analytiques, comparaison à des valeurs publiées — avant les fonctions dédiées, dont la portée d’erreur est limitée à un seul test.