

Documentation de l'outil

Calibrage des paramètres propres à l'entreprise
Moteur de calcul, tests statistiques et application

Règlement délégué (UE) 2015/35, annexe XVII — profondeur d'intérêt $T = 8$

Objet du document

Ce document constitue la documentation de l'**outil de calibrage des paramètres propres à l'entreprise** (USP) au titre des méthodes « risque de prime » et « risque de réserve 1 » de l'annexe XVII du règlement délégué (UE) 2015/35. Il couvre le moteur de calcul `R/engine.R`, les tests statistiques qu'il met en œuvre, et l'application interactive qui l'exploite.

Il est organisé en quatre parties. La **partie I** décrit l'architecture de l'outil, les notations et les contrôles de recevabilité des données. La **partie II** pose le cadre statistique commun : nature des p-values (exactes, asymptotiques, de Monte-Carlo) et séparation de l'erreur numérique liée au nombre B de réplifications d'avec l'erreur d'approximation liée à la taille T de l'échantillon. La **partie III** rassemble les fiches de tests, groupées par hypothèse réglementaire H1 à H4, chacune suivant une structure uniforme en six rubriques : cadre et hypothèses de validité (non testées), hypothèse nulle, statistique de test, loi sous l'hypothèse nulle, p-value, usage et limites. La **partie IV** rassemble la validation empirique de l'implémentation, les références bibliographiques et la synthèse de lecture.

Une attention particulière est portée à la profondeur d'intérêt du projet, $T = 8$, à laquelle plusieurs des tests présentés sont structurellement incapables de rejeter au seuil usuel de 5 %. Le sommaire détaille les sous-sections afin de permettre l'accès direct à chaque test.

Article 218 du règlement délégué (UE) 2015/35

Les entreprises d'assurance et de réassurance peuvent remplacer un sous-ensemble des paramètres standard du module « souscription non-vie », du module « souscription santé » et du module « souscription vie » par des paramètres propres à l'entreprise.

Élément	Référence
Base réglementaire	Directive 2009/138/CE, art. 104(7); règlement délégué (UE) 2015/35, art. 218 à 220 et annexe XVII
Procédure d'agrément	Règlement d'exécution (UE) 2015/498
Transposition	Code des assurances, art. R. 352-5 (V) et R. 356-19 (II)
Moteur de calcul	<code>R/engine.R</code> (R base et stats uniquement)
Interface	<code>app.R</code> , <code>R/display_helpers.R</code> (aucun calcul)
Profondeur d'intérêt	$T = 8$ années de survenance

Sommaire

PARTIE I — Présentation de l'outil	7
1 Architecture du moteur de calcul	7
1.1 Principe de séparation	7
1.2 Chaîne de calcul et flux de données	7
1.3 Inventaire des fonctions	9
1.4 Périmètres couverts et paramètres standard	9
1.5 Reproductibilité et gestion des graines	10
1.6 Index des fonctions de statistique et de p-value	10
2 Notations générales	17
3 Contrôles de qualité des données	20
PARTIE II — Cadre statistique général	23
4 Bootstrap paramétrique et p-values de Monte-Carlo	23
4.1 Procédure générale de p-value de Monte-Carlo	23
4.2 Bootstrap semi-paramétrique de la méthode Merz–Wüthrich	24
5 Nature des p-values et validité à $T = 8$	25
5.1 Quatre statuts épistémiques à ne jamais confondre	25
5.2 Deux sources d'erreur distinctes	26
5.3 Ce que l'on peut et ne peut pas affirmer à $T = 8$	26
5.4 Tableau 1 : disponibilité et choix des p-values	28
5.5 Tableau 2 : nature et vitesse des convergences	34
5.6 Choix de la base de résidus	38
5.7 Variantes principales et secondaires	40
5.8 Tests dont l'usage reste fragile à $T = 8$	41
PARTIE III — Fiches de tests par hypothèse	43
6 Hypothèse H1 — linéarité et proportionnalité	43
6.1 Test de Student sur la constante	43
6.2 Équivalence de la constante à zéro (TOST)	44
6.3 Test de Student sur la pente	45
6.4 Test de Fisher de significativité globale	45
6.5 Coefficient de détermination R^2	45
6.6 Test RESET de Ramsey	46
6.7 Corrélation de rang de Spearman (ratio contre volume, ratio contre temps)	46
6.8 Test de tendance de Mann–Kendall	47
6.9 Test de tendance par signes de Cox–Stuart	48

7	Hypothèse H2 — structure de variance quadratique	49
7.1	Test de Breusch–Pagan, version studentisée de Koenker	49
7.2	Test de Breusch–Pagan, version originale de 1979	49
7.3	Test de White	50
7.4	Test de Goldfeld–Quandt	51
7.5	Test de Brown–Forsythe	51
7.6	Test de Smirnov à deux échantillons	52
7.7	Position de $\hat{\delta}$ dans son domaine (diagnostic)	52
8	Hypothèse H3 — lognormalité des pertes agrégées	54
8.1	Test de Shapiro–Wilk	54
8.2	Test de Shapiro–Francia	55
8.3	Test d’Anderson–Darling	55
8.4	Test de Cramér–von Mises	56
8.5	Test de Kolmogorov–Smirnov contre $\mathcal{N}(0, 1)$	56
8.6	Test de Lilliefors	57
8.7	Shapiro–Wilk sans la normalisation de Royston	58
8.8	Test de Jarque–Bera	58
8.9	Test d’asymétrie de D’Agostino	59
8.10	Test d’aplatissement d’Anscombe–Glynn	59
9	Hypothèse H4 — indépendance et validité du maximum de vraisemblance	61
9.1	Test de Durbin–Watson	61
9.2	Tests portemanteau de Ljung–Box et de Box–Pierce	62
9.3	Test des suites de Wald–Wolfowitz	62
9.4	Condition du premier ordre (diagnostic numérique)	63
9.5	Centrage des résidus standardisés (diagnostic)	63
9.6	Variance unitaire des résidus standardisés (diagnostic)	65
10	Diagnostics de stabilité, ruptures et points aberrants	67
10.1	Test de rupture sup-F (Quandt / Chow / Andrews)	67
10.2	Test de stabilité OLS-CUSUM	67
10.3	Test de Grubbs	68
10.4	Procédure ESD généralisée de Rosner	69
10.5	Distance de Cook (diagnostic)	69
10.6	Leviers (<i>hat values</i> , diagnostic)	70
11	Diagnostics de robustesse de l’estimation	71
11.1	Test du rapport de vraisemblance sur les cas limites de δ	71
11.2	Jackknife (sensibilité au retrait d’une année)	71
11.3	Intervalle de confiance par bootstrap paramétrique	72
11.4	Convergence multi-démarrages	72
12	Diagnostics graphiques complémentaires	74
12.1	Couverture exhaustive	74
12.2	Fiches détaillées	76
12.3	QQ-plot normal	76
12.4	QQ-plot à deux échantillons (faible volume contre fort volume)	76
12.5	Graphiques d’influence et de levier	77

12.6	Graphique dispersion-niveau (<i>spread-location</i>)	78
12.7	Visualisation de la régression chain-ladder (Merz–Wüthrich)	78
12.8	Influence et leviers du triangle (Merz–Wüthrich)	79
13	Méthode Merz–Wüthrich — cadre et spécification	80
13.1	Positionnement par rapport à la méthode lognormale	80
13.2	Spécification réglementaire	80
13.3	Hypothèses testables et résidus	83
13.4	Réemploi et adaptation des tests	83
14	Hypothèse M1 — proportionnalité des cumulés	85
14.1	M1 — Absence de tendance des facteurs avec le cumulé, à colonne donnée	85
14.2	M1 — Nullité de l'ordonnée à l'origine, colonne par colonne	86
14.3	M1 — Homogénéité de f_j entre années de survie	86
14.4	M1 — Absence de courbure de la régression	87
14.5	M1 — Stabilité du facteur selon la pondération (famille α)	87
14.6	M2 — Hétéroscédasticité résiduelle contre le cumulé	88
14.7	M2 — Adéquation de l'exposant de variance, colonne par colonne	88
14.8	M2 — Variance unitaire des résidus de Mack (diagnostic)	89
15	Hypothèse M3 — indépendance	90
15.1	M3 — Effets d'année calendaire (test de Mack)	90
15.2	M3 — Homogénéité des résidus entre années de survie	90
15.3	M3 — Corrélation entre années de développement adjacentes	91
15.4	M3 — Autocorrélation des résidus de Mack (Durbin–Watson)	91
15.5	M3 — Test des suites sur les résidus de Mack	92
16	Diagnostics M4 — points aberrants du triangle	93
16.1	M4 — Cellule aberrante du triangle (Grubbs)	93
16.2	M4 — Cellules aberrantes multiples (ESD généralisé de Rosner)	93
17	Diagnostics M5 — normalité des résidus de Mack	95
17.1	M5 — Shapiro–Wilk sur les résidus de Mack	95
17.2	M5 — Lilliefors sur les résidus de Mack	95
18	Diagnostics M6 — robustesse de l'estimation	97
18.1	M6 — Extrapolation de $\hat{\sigma}_{j-1}^2$ (diagnostic)	97
18.2	M6 — Concentration de la réserve sur la dernière année	97
	PARTIE IV — Validation, références et synthèse	99
19	Vérification empirique de l'implémentation	99
19.1	Vérification de l'implémentation Merz–Wüthrich	101
19.2	Calibration des p-values asymptotiques (Merz–Wüthrich)	101
19.3	Calibration des p-values de Monte-Carlo (Merz–Wüthrich)	102
20	Compléments bibliographiques	103
20.1	Traçabilité entre la documentation et le code	105
21	Synthèse et lecture des verdicts	108

ANNEXE — Flux détaillés entre fonctions	110
22 Annexe — flux détaillés entre fonctions	111
22.1 Convention graphique	111
22.2 Graphe chapeau : les deux branches et leurs points de partage	112
22.3 Méthode lognormale : hypothèse H1	113
22.4 Méthode lognormale : hypothèse H2	113
22.5 Méthode lognormale : hypothèses H3 et H4, stabilité	113
22.6 Méthode Merz–Wüthrich : de l’ajustement aux tests M1 à M6	116
22.7 Lecture en termes de revue de code	118

PARTIE I

Présentation de l'outil

Architecture du moteur de calcul

1.1 Principe de séparation

Le projet applique une séparation stricte entre le *moteur quantitatif* et la *couche d'affichage*. La règle appliquée est la suivante : si un résultat peut être calculé indépendamment de l'interface graphique, son calcul figure dans `R/engine.R`.

Fichier	Contenu	Interdit
<code>R/engine.R</code>	Préparation des données, contrôles, estimation, tests, p-values, bootstrap, jackknife, calibration, quantités des graphiques	Toute primitive Shiny (<code>input\$</code> , <code>output\$</code> , <code>reactive()</code> , <code>render*()</code>)
<code>app.R</code>	Saisie, déclenchement, stockage ré-actif, agencement des onglets	Tout calcul statistique ou actuariel
<code>R/display_helpers.R</code>	Formatage des nombres et des tableaux, tracés à partir de <code>res\$plots_data</code>	Tout calcul de statistique, de p-value ou de paramètre

Cette séparation a été vérifiée automatiquement : aucune primitive Shiny n'est présente dans le moteur, et aucun appel de fonction de calcul (`optim`, `lm`, `*.test`, `rnorm`, `quantile`, `sd`, `var`, `mean`) ne subsiste dans la couche d'affichage. Le moteur s'exécute seul :

```
source("R/engine.R")
res <- run_engine(xt = ..., yt = ..., methode = "premium", segment = 1,
                  T = 8, B = 999, seed = 20260831)
res$parametre_final$sigma_usp ; engine_table_tests(res)
```

1.2 Chaîne de calcul et flux de données

La figure 1 donne l'enchaînement des fonctions du moteur. Les blocs sont les fonctions, les flèches portent les objets transmis. Les blocs bleus sont les entrées, les blancs les étapes de calcul, les verts les sorties exposées à l'application. Le point d'aiguillage est le paramètre `methode` : il oriente vers l'une des deux chaînes, dont les géométries de données et les jeux de tests diffèrent. L'annexe 22 en donne le détail fonction par fonction.




FIGURE 1 : Architecture du moteur R/engine.R. Le paramètre *methode* aiguille vers l’une des deux chaînes : à gauche les méthodes lognormales (sections B et C de l’annexe XVII), à droite la méthode Merz–Wüthrich (section D). Les deux convergent vers un objet de sortie unique, que la couche d’affichage se contente de lire. *usp_credibilite()* est la seule fonction de calcul partagée par les deux branches.

1.3 Inventaire des fonctions

Fonction	Entrées	Sorties
<i>Contrôles et données</i>		
engine_valider_donnees()	xt, yt, T_min	\$ok, \$erreurs, \$avertissements
usp_controle_donnees()	xt, yt, alpha	liste de contrôles de recevabilité
mw_valider_triangle()	tri, T_min	\$ok, \$erreurs, \$avertissements, I, J
mw_valider_ajustement()	sortie de mw_ajuster(), MSEP	\$ok, \$erreurs, \$reserve, \$mse
<i>Noyau du modèle</i>		
usp_pi()	δ, γ, x	vecteur π_t
usp_noyau()	δ, γ, x, y	$\ln \hat{\beta}, v_t, z_t, \sigma$, objectif
usp_objectif()	par, x, y	$-2 \ln L$ (à une constante près)
usp_ajuster()	x, y	fit complet, FOC, convergence
<i>Lois exactes</i>		
mk_p_exacte()	série r_t	p-value exacte (loi mahonienne)
runs_p_exacte()	résidus z_t	p-value exacte (Swed & Eisenhart)
<i>Statistiques et tests</i>		
stat_*(), test_*()	x, y ou z	statistique et p-value
test_tost_intercept()	x, y, θ ou Δ	p-value d'équivalence (TOST)
.stats_bootstrapables()	x, y, z	vecteur de 34 statistiques
usp_bootstrap()	fit, B , seed	p_mc, err_mc, sigma_boot
usp_tests()	fit, boot, alpha	liste des tests (H_0, H_1 , statistique, 3 p-values, nature)
<i>Robustesse et calibration</i>		
usp_jackknife()	fit, σ_{std}	table des $\sigma_{USP}^{(-t)}$
usp_profil()	fit	profils en δ et γ , tests LR
usp_segment_infos()	segment, annexe	libellé, σ standard, barème
usp_credibilite()	T , barème	facteur c
usp_parametre()	fit, σ_{std} , barème	σ_{USP} et ses composantes
<i>Sorties</i>		
engine_plots_data()	fit, boot, profil	toutes les quantités tracées
engine_table_tests()	res	data.frame auditable
run_engine()	entrées utilisateur	objet usp_engine complet

1.4 Périmètres couverts et paramètres standard

L'outil couvre les deux segmentations pour lesquelles l'annexe XVII autorise des paramètres propres au titre du risque de primes et de réserve : l'annexe II (engagements non-vie) et l'annexe XIV (engagements de santé non similaires à la vie, dits « non-SLT »). Les écarts-types standard ci-dessous sont ceux du règlement délégué (UE) 2015/35, *Journal officiel de l'Union européenne*, L 12 du 17 janvier 2015, p. 230–231 et p. 269. Ils sont codés dans les tables ANNEXE_II et ANNEXE_XIV de R/engine.R.

Seg.	Annexe XIV — santé non-SLT	LoB	σ prime	σ réserve
1	Assurance frais médicaux et réassurance proportionnelle y afférente	1 et 13	5 %	5 %
2	Assurance protection du revenu et réassurance proportionnelle y afférente	2 et 14	8,5 %	14 %
3	Assurance indemnisation des travailleurs et réassurance proportionnelle y afférente	3 et 15	8 %	11 %
4	Réassurance santé non proportionnelle	25	17 %	20 %

Le facteur de crédibilité applicable est déterminé par la section G de l'annexe XVII, dont le paragraphe 2 range explicitement *tous* les segments de l'annexe XIV sous le barème court, aux côtés des segments 2 à

4 et 7 à 12 de l'annexe II. Le barème long du paragraphe 1 est réservé aux seuls segments 1, 5 et 6 de l'annexe II. L'annexe d'appartenance fait donc partie de la clé : à $T = 8$, le segment 1 de l'annexe XIV (frais médicaux) reçoit $c = 81\%$, alors que le segment 1 de l'annexe II (responsabilité civile automobile) reçoit $c = 59\%$. La fonction `usp_bareme_segment(segment, annexe)` implémente cette distinction, et `usp_segment_infos()` renvoie l'ensemble des caractéristiques réglementaires d'un segment.

Portée. L'outil ne couvre pas les deux autres paramètres remplaçables de l'article 218 : le facteur d'ajustement pour la réassurance non proportionnelle (segments 1, 4 et 5 de l'annexe II) et l'écart-type du risque de révision. Il met en revanche en œuvre trois des méthodes de calibrage de l'annexe XVII : risque de primes (section B), risque de réserve n° 1 (section C) et risque de réserve n° 2 (section D : chaîne d'échelle et erreur de prédiction à un an, §13).

1.5 Reproductibilité et gestion des graines

Une seule graine pilote l'ensemble des tirages : elle est passée à `run_engine(seed = )` puis à `usp_bootstrap()`, qui appelle `set.seed()` une fois avant la boucle de réplifications. Aucune autre fonction du moteur ne tire de nombres aléatoires, à l'exception de `engine_plots_data()`, qui fixe sa propre graine pour l'enveloppe de simulation du QQ-plot afin que le graphique soit stable d'un appel à l'autre.

Le script `tests/test_reproductibilite.R` vérifie, pour chacune des trois méthodes, deux propriétés qu'il ne faut pas confondre.

La reproductibilité. Deux appels de `run_engine()` avec les mêmes données, les mêmes paramètres et la même graine, **sur une même machine**, produisent des objets identiques au bit près. C'est ce que contrôle la comparaison de deux appels successifs par `identical()`, et cette propriété tient (vérification exécutée).

La non-régression. Le résultat est en outre confronté à des valeurs de référence enregistrées (`tests/reference/`), produites sur une plateforme unique désignée et versionnées avec le code. Cette seconde comparaison n'est **pas** au bit près : elle emploie `all.equal()` à une tolérance relative de 10^{-8} , qui porte sur une différence relative *moyenne* et absorbe donc une dérive diffuse, si nombreuses qu'en soient les valeurs touchées. Une telle dérive existe entre plateformes et a été mesurée : sur le cas de contrôle de la méthode prime, 5 515 des 12 409 valeurs élémentaires de l'objet diffèrent au sens strict, pour une différence relative moyenne de $6,2 \cdot 10^{-10}$ et un écart relatif maximal de $3,5 \cdot 10^{-7}$ sur les tirages bootstrap ; l'écart sur σ_{USP} lui-même est de l'ordre de 10^{-14} en relatif, très en deçà de la précision à laquelle le paramètre est lu. La branche Merz–Wüthrich est, elle, indemne (aucun écart sur le triangle de contrôle). L'origine vraisemblable de cette dérive est l'optimiseur employé par la branche lognormale sur une vraisemblance quasi plate en δ , dont le chemin dépend de l'ordre des opérations en virgule flottante ; cette explication est cohérente avec la répartition observée des écarts, mais elle n'a pas été démontrée par une expérience isolant la bibliothèque d'algèbre linéaire ou la version de R. Ce qui précède ne remet en cause aucun résultat publié : c'est la portée de la garantie qui doit être énoncée exactement.

Point de revue. L'objet retourné contient un champ `$metadata` consignait la méthode, le segment, σ_{standard} , le barème de crédibilité, T , B , la granularité $1/(B+1)$, le seuil α , la graine, l'horodatage, la durée et la version de R. Ce champ suffit à rejouer un calcul à l'identique.

1.6 Index des fonctions de statistique et de p-value

L'inventaire de la section 1.3 regroupe les fonctions par catégorie (`stat_*`), `test_*`). Le tableau ci-dessous descend d'un niveau : il relie **chaque test documenté** — méthode lognormale en partie III, méthode Merz–Wüthrich en sections 14 à 18 — à la ou aux fonctions R qui calculent sa statistique, et à celle(s) qui calculent chacune des p-values disponibles. Les entrées sont groupées par hypothèse :

H1 à H4 pour la méthode lognormale, M1 à M6 pour la méthode Merz–Wüthrich. La colonne « Réf. » renvoie à la fiche correspondante. La méthode générale de p-value de Monte-Carlo est décrite à part (fiche 4.1, page 23) : la colonne « Clé MC » indique, pour chaque test, le nom de la statistique dans `.stats_bootstrapables()` qui lui correspond, lorsqu’une p-value de Monte-Carlo est calculée.

Certains tests s’appuient sur un appel direct à une fonction de `stats` plutôt que sur une fonction dédiée du moteur : cela est indiqué explicitement, la fonction `stats:...` restant néanmoins un élément identifiable et auditable du code de `usp_tests()`.

Test (fiche)	Réf.	Fonction(s) — statistique	Fonction(s) / méthode — p-value non simulée	Clé MC
Hypothèse H1 — linéarité et proportionnalité				
Student, constante	6.1	<code>test_intercept()</code>	<code>test_intercept()</code> (p exacte, loi t)	Intercept
Équivalence (TOST)	6.2	<code>test_tost_intercept()</code>	<code>test_tost_intercept()</code> (p exacte si Δ a priori)	—
Student, pente	6.3	<code>test_lm_complet()</code>	<code>test_lm_complet()</code> (p exacte, loi t)	—
Fisher global	6.4	<code>test_lm_complet()</code>	<code>test_lm_complet()</code> (p exacte, loi F)	—
Coefficient R^2	6.5	<code>test_lm_complet()</code>	indicateur, aucune p-value	—
RESET	6.6	<code>test_reset()</code>	<code>test_reset()</code> (p asymptotique, loi F approchée)	RESET
Spearman ($\times 2$)	6.7	<code>stats::cor.test()</code> (appel direct)	<code>stats::cor.test(..., exact = TRUE)</code> (p exacte, permutation)	SpearVol / SpearTps
Mann–Kendall	6.8	<code>test_mann_kendall()</code>	<code>mk_p_exacte()</code> (p exacte, loi mahonienne, via <code>.mk_loi_exacte()</code> , <code>.poly_mult()</code>)	MK
Cox–Stuart	6.9	<code>test_cox_stuart()</code>	<code>test_cox_stuart()</code> (p exacte, loi binomiale)	CoxStuart
Hypothèse H2 — structure de variance quadratique				
Breusch–Pagan (Koenker)	7.1	<code>test_breusch_pagan()</code>	<code>test_breusch_pagan()</code> (p asymptotique, χ^2)	BP
Breusch–Pagan (1979)	7.2	<code>test_breusch_pagan_original()</code>	idem (p asymptotique, χ^2 sous normalité)	BP79
White	7.3	<code>test_white()</code>	<code>test_white()</code> (p asymptotique, χ^2)	White
Goldfeld–Quandt	7.4	<code>test_goldfeld_quandt()</code>	<code>test_goldfeld_quandt()</code> (p asymptotique, loi F approchée)	GQ
Brown–Forsythe	7.5	<code>test_brown_forsythe()</code>	<code>test_brown_forsythe()</code> (p asymptotique, loi F approchée)	BF
Smirnov (2 éch.)	7.6	<code>stats::ks.test()</code> (appel direct)	<code>stats::ks.test()</code> (p exacte combinatoire, sans ex æquo)	Smirnov
Position de $\hat{\delta}$	7.7	<code>usp_ajuster()</code> (champ <code>\$delta</code>)	diagnostic, aucune p-value	—
Hypothèse H3 — lognormalité des pertes agrégées				
Shapiro–Wilk	8.1	<code>.shapiro_sur()</code> (encapsule <code>stats::shapiro.test()</code>)	<code>.shapiro_sur()</code> (p approx. Royston 1992)	SW
Shapiro–Francia	8.2	<code>test_shapiro_francia()</code>	<code>test_shapiro_francia()</code> (p approx. Royston 1993)	SF
Anderson–Darling	8.3	<code>stat_ad()</code>	<code>ad_p_stephens()</code> (p approx. D’Agostino & Stephens)	AD
Cramér–von Mises	8.4	<code>stat_cvm()</code>	<code>cvm_p_stephens()</code> (p approx. D’Agostino & Stephens)	CvM
KS contre $\mathcal{N}(0, 1)$	8.5	<code>stat_ks()</code>	formule de Kolmogorov, calculée en ligne dans <code>usp_tests()</code>	KS
Lilliefors	8.6	<code>stat_lilliefors()</code>	<code>lillie_p()</code> (p approx. Dallal & Wilkinson)	Lillie
Shapiro–Wilk sans Royston	8.7	<code>.shapiro_sur()</code> (statistique W réutilisée)	<code>sw_p_loi_nulle()</code> (p exacte simulée, via <code>sw_loi_nulle()</code> , mise en cache)	—
Jarque–Bera	8.8	<code>test_jarque_bera()</code>	<code>test_jarque_bera()</code> (p asymptotique, χ^2_2)	JB
D’Agostino (asymétrie)	8.9	<code>test_dagostino_skew()</code>	<code>test_dagostino_skew()</code> (p asymptotique, transf. S_U)	DAgo

Suite page suivante

Test (fiche)	Réf.	Fonction(s) — statistique	Fonction(s) / méthode — p-value non simulée	Clé MC
Anscombe–Glynn (aplat.)	8.10	<code>test_anscombe_kurt()</code>	<code>test_anscombe_kurt()</code> (p asymptotique, Wilson–Hilferty)	—
Hypothèse H4 — indépendance et validité du maximum de vraisemblance				
Durbin–Watson	9.1	<code>stat_dw()</code>	<code>dw_p_exacte()</code> (p exacte, méthode d’Imhof via <code>.imhof_p_sup0()</code>)	DW
Ljung–Box / Box–Pierce	9.2	<code>stats::Box.test()</code> (appel direct, 2 retards)	<code>stats::Box.test()</code> (p asymptotique, χ^2)	LB1, LB2, BP2
Suites (Wald–Wolfowitz)	9.3	<code>test_runs()</code>	<code>runs_p_exacte()</code> (p exacte combinatoire, via <code>.runs_dens()</code>)	Runs
FOC (diagnostic)	9.4	<code>usp_ajuster()</code> (champ <code>\$foc</code>)	diagnostic, aucune p-value	—
Centrage des résidus (diagnostic)	9.5	<code>mean()</code> sur <code>z</code> (appel direct dans <code>usp_tests()</code>)	diagnostic, aucune p-value	—
Variance unitaire (diagnostic)	9.6	<code>stats::var()</code> sur <code>z</code> (appel direct dans <code>usp_tests()</code>)	diagnostic, aucune p-value	—
Stabilité, ruptures et points aberrants				
Rupture sup-F	10.1	<code>stat_supF()</code>	aucune (théorique seulement, Andrews 1993)	supF
OLS-CUSUM	10.2	<code>stat_cusum()</code>	formule de Kolmogorov, calculée en ligne dans <code>usp_tests()</code>	CUSUM
Grubbs	10.3	<code>test_grubbs()</code>	<code>test_grubbs()</code> (p asymptotique, borne de Bonferroni)	Grubbs
Rosner (ESD)	10.4	<code>test_rosner()</code>	procédure de décision, aucune p-value	—
Distance de Cook	10.5	<code>stats::cooks.distance()</code> (appel direct)	diagnostic, aucune p-value	—
Leviers	10.6	<code>stats::hatvalues()</code> (appel direct)	diagnostic, aucune p-value	—
Robustesse de l'estimation (méthode lognormale)				
Rapport de vraisemblance sur δ	11.1	fonction interne <code>lr()</code> dans <code>usp_profil()</code>	calcul direct <code>stats::pchisq()</code> (p asymptotique, correction de Chernoff non appliquée)	—
Jackknife	11.2	<code>usp_jackknife()</code>	diagnostic, aucune p-value	—
IC bootstrap	11.3	<code>usp_bootstrap()</code> (champ <code>\$sigma_boot</code>)	diagnostic, aucune p-value	—
Convergence multi-démarrages	11.4	<code>usp_ajuster()</code> (champ <code>\$part_starts_convergents</code>)	diagnostic, aucune p-value	—
Méthode Merz–Wüthrich — M1 : proportionnalité des cumulés (annexe XVII, D(2)(h)(iii))				
Tendance avec le cumulé, à colonne donnée	14.1	<code>.mw_lm_intra()</code> (via <code>.mw_pente_intra()</code>)	idem (p de Student, approchée)	Intercept
Ordonnée à l'origine par colonne	14.2	<code>mw_test_ordonnee_origine()</code>	idem (p de Fisher, via <code>.fisher_combine()</code>)	Origine
Homogénéité de f_j	14.3	<code>mw_test_homogeneite_f()</code>	idem (p de Fisher)	HomogF

Suite page suivante

Test (fiche)	Réf.	Fonction(s) — statistique	Fonction(s) / méthode — p-value non simulée	Clé MC
Absence de courbure	14.4	<code>mw_test_courbure()</code>	idem (p de Fisher)	Courbure
Famille α	14.5	<code>mw_famille_alpha()</code>	aucune (pas de loi analytique)	Alpha
Méthode Merz–Wüthrich — M2 : variance proportionnelle au cumulé (annexe XVII, D(2)(h)(iv))				
Breusch–Pagan sur résidus de Mack	14.6	<code>stats::lm(r^2 ~ C)</code> dans <code>mw_tests()</code>	<code>stats::pchisq()</code> (p asymptotique)	BP
Exposant de variance par colonne	14.7	<code>mw_test_exposant_variance()</code>	idem (p de Fisher)	ExpVar
Variance unitaire des résidus	14.8	<code>stats::var()</code> sur <code>mw_residus()</code>	diagnostic, aucune p-value	—
Méthode Merz–Wüthrich — M3 : indépendance (annexe XVII, D(2)(h)(i) et (ii))				
Homogénéité entre années de surveillance	15.2	<code>mw_test_homogeneite_accident()</code>	<code>stats::kruskal.test()</code> (p asymptotique)	KruskalAcc
Effets d’année calendaire	15.1	<code>mw_test_annees_calendaires()</code> (via <code>.mack_moments_Z()</code>)	idem (p asymptotique ; moments <i>exacts</i>)	Calendrier
Corrélation entre années de développement	15.3	<code>mw_stat_correlation_dev()</code>	aucune (pas de loi analytique)	CorrDev
Autocorrélation (Durbin–Watson)	15.4	<code>stat_dw()</code>	aucune (loi d’Imhof inapplicable aux résidus de Mack)	DW
Test des suites	15.5	<code>test_runs()</code>	<code>test_runs()</code> (approximation normale)	Runs
Méthode Merz–Wüthrich — M4 : points aberrants				
Cellule aberrante (Grubbs)	16.1	<code>test_grubbs()</code>	<code>test_grubbs()</code> (borne de Bonferroni)	Grubbs
Cellules aberrantes multiples (Rosner)	16.2	<code>test_rosner()</code>	procédure de décision, aucune p-value	—
Méthode Merz–Wüthrich — M5 : normalité (diagnostic, non exigée par le modèle)				
Shapiro–Wilk sur résidus de Mack	17.1	<code>.shapiro_sur()</code>	<code>sw_p_loi_nulle()</code> (p exacte simulée, via <code>sw_loi_nulle()</code>)	—
Lilliefors sur résidus de Mack	17.2	<code>stat_lilliefors()</code>	<code>lillie_p()</code> (approx. Dallal & Wilkinson)	—
Méthode Merz–Wüthrich — M6 : robustesse de l’estimation				
Extrapolation de $\hat{\sigma}_{j-1}^2$	18.1	<code>mw_ajuster()</code> (champ <code>\$sigma2</code>)	diagnostic, aucune p-value	—
Concentration de la réserve	18.2	<code>mw_ajuster()</code> (champ <code>\$reserve_par_annee</code>)	diagnostic, aucune p-value	—
Méthode Merz–Wüthrich — chaîne de calcul (hors tests)				
Recevabilité du triangle (avant ajustement)	§3	<code>mw_valider_triangle()</code>	sans objet	—
Applicabilité de D(4) — réserve $\hat{R}$ et MSEF (après ajustement)	§3	<code>mw_valider_ajustement()</code>	sans objet	—
Facteurs et variances de développement	§13	<code>mw_ajuster()</code>	sans objet	—

Suite page suivante

Test (fiche)	Réf.	Fonction(s) — statistique	Fonction(s) / méthode — p-value non simulée	Clé MC
Erreur de prédiction à un an	§13	<code>mw_msep()</code>	sans objet	—
Paramètre propre $\sigma_{(\text{res}, s, \text{USP})}$	§13	<code>mw_parametre()</code> <code>usp_credibilite()</code>	× sans objet	—
Résidus standardisés de Mack	§13	<code>mw_residus()</code>	sans objet	—
Bootstrap semi-paramétrique	§13	<code>mw_bootstrap()</code> <code>mw_simuler_triangle()</code> <code>.mw_stats()</code>	(via sans objet et	toutes les clés ci-dessus
Leviers et DFBETA du triangle	10.6	<code>mw_influence()</code>	diagnostic, aucune p-value	—
Contributions par année de survenance	10.6	<code>mw_contributions()</code>	diagnostic, aucune p-value	—

Fonctions internes de support. Trois fonctions préfixées d'un point ne sont jamais appelées directement par `usp_tests()` mais seulement par les fonctions de p-value ci-dessus : `.imhof_p_sup0()` (intégrale d'Imhof, utilisée par `dw_p_exacte()`), `.mk_loi_exacte()` et `.poly_mult()` (distribution exacte du S de Kendall par produit de polynômes, utilisées par `mk_p_exacte()`), et `.runs_dens()` (densité exacte du nombre de suites, utilisée par `runs_p_exacte()`). `.shapiro_sur()` et `sw_loi_nulle()` sont deux autres fonctions internes : la première encapsule `stats::shapiro.test()` pour éviter qu'un échantillon dégénéré n'interrompe la boucle de bootstrap, la seconde met en cache la loi nulle simulée de W par valeur de T .

Lecture de la colonne « Clé MC ». Un tiret signifie qu'aucune p-value de Monte-Carlo n'est calculée pour ce test : soit parce que l'hypothèse nulle n'appartient pas au modèle simulé (Student sur la pente, Fisher); soit parce que le test n'est pas de nature à produire de p-value (indicateurs, procédures de décision, diagnostics numériques); soit, troisième motif, parce que la grandeur est *rivée par l'estimation* et qu'il n'y a donc rien à simuler — la loi simulée porterait un atome en la valeur observée (centrage et variance unitaire des résidus standardisés, fiches 9.5 et 9.6). Dans tous les autres cas, la clé correspond au nom de colonne retourné par `.stats_bootstrapables()` et consommé par `usp_bootstrap()`.

Notations générales

L'outil couvre deux familles de méthodes, aux géométries de données distinctes. Les notations sont donc présentées séparément : la sous-section suivante concerne les méthodes lognormales (sections B et C de l'annexe XVII), la section 2 la méthode Merz–Wüthrich (section D). Les conventions communes — lois, fonctions de répartition, convention de restitution — valent pour les deux.

Méthodes lognormales : données et modèle

Pour un segment donné et une profondeur T :

- $x_1, \dots, x_T$: primes acquises par année de survenance (méthode risque de prime) ou meilleure estimation de la provision en début d'exercice (méthode risque de réserve 1) ;
- $y_1, \dots, y_T$: pertes agrégées (méthode prime) ou paiements de l'exercice augmentés de la meilleure estimation de clôture sur les mêmes sinistres (méthode réserve 1) ;
- $r_t = y_t/x_t$: ratio observé (ratio S/P, ou ratio de liquidation) ;
- $\bar{x} = T^{-1} \sum_t x_t$.

Le modèle de l'annexe XVII postule $Y_t \mid x_t \sim \mathcal{LN}(\mu_t, \psi_t)$ avec

$$\mathbb{E}[Y_t] = \beta x_t, \quad \text{Var}(Y_t) = \sigma^2 [(1 - \delta) \bar{x} x_t + \delta x_t^2], \quad \delta \in [0, 1], \quad \sigma = \beta e^\gamma.$$

On en déduit la précision logarithmique et l'estimateur du niveau :

$$\pi_t(\delta, \gamma) = \left[\ln(1 + e^{2\gamma}(\delta + (1 - \delta)\bar{x}/x_t)) \right]^{-1}, \quad \ln \hat{\beta} = \frac{\frac{T}{2} + \sum_t \pi_t \ln r_t}{\sum_t \pi_t}.$$

Résidus

Les tests des sections 5 à 8 portent sur les *résidus normalisés*

$$z_t = \sqrt{\hat{\pi}_t} \left(\ln r_t + \frac{1}{2\hat{\pi}_t} - \ln \hat{\beta} \right), \quad t = 1, \dots, T,$$

qui, si le modèle est correctement spécifié, sont *approximativement* indépendants et de loi $\mathcal{N}(0, 1)$. On note $z_{(1)} \leq \dots \leq z_{(T)}$ la statistique d'ordre associée, $\bar{z}$ la moyenne empirique, $s_z^2 = (T - 1)^{-1} \sum_t (z_t - \bar{z})^2$ la variance empirique corrigée, et $p_{(i)} = \Phi(z_{(i)})$.

Lois et fonctions de répartition

Φ et φ désignent la fonction de répartition et la densité de $\mathcal{N}(0, 1)$; $F_{t,\nu}$, $F_{\chi_\nu^2}$, $F_{\mathcal{F},\nu_1,\nu_2}$ celles des lois de Student, du khi-deux et de Fisher. Les moments empiriques centrés d'ordre k sont notés $m_k = T^{-1} \sum_t (z_t - \bar{z})^k$, l'asymétrie $\sqrt{b_1} = m_3/m_2^{3/2}$ et l'aplatissement $b_2 = m_4/m_2^2$.

Régression auxiliaire

Plusieurs tests de la section 4 s'appuient sur la régression auxiliaire non contrainte $y_t = a + b x_t + \varepsilon_t$, dont on note $S_{xx} = \sum_t (x_t - \bar{x})^2$, $S_{xy} = \sum_t (x_t - \bar{x})(y_t - \bar{y})$, $\hat{b} = S_{xy}/S_{xx}$, $\hat{a} = \bar{y} - \hat{b}\bar{x}$, les résidus $e_t = y_t - \hat{a} - \hat{b}x_t$, ainsi que $SCR = \sum_t e_t^2$, $SCT = \sum_t (y_t - \bar{y})^2$ et $\hat{s}^2 = SCR/(T - 2)$.

Attention. Cette régression auxiliaire n'est *pas* le modèle réglementaire, qui impose $\mathbb{E}[Y_t] = \beta x_t$ sans constante. Elle sert uniquement de support de test aux diagnostics de la section 4.

Méthode Merz–Wüthrich : données et modèle

La donnée d'entrée n'est plus un couple de vecteurs mais un *triangle* de paiements cumulés. Les notations sont celles de l'annexe XVII, section D, paragraphe 3 :

- $i = 0, \dots, I$: années de survénance, la plus ancienne portant l'indice 0 ;
- $j = 0, \dots, J$: années de développement ;
- $C(i, j)$: sinistres cumulés de l'année de survénance i à l'année de développement j , observés pour $i + j \leq I$;
- $F(i, j) = C(i, j + 1)/C(i, j)$: facteur de développement individuel ;
- $n_j = I - j$: nombre d'observations disponibles dans la colonne j .

Le modèle de chaîne d'échelle postule, pour tout i et tout j :

$$\mathbb{E}[C(i, j + 1) \mid C(i, j)] = f_j C(i, j), \quad \text{Var}[C(i, j + 1) \mid C(i, j)] = \sigma_j^2 C(i, j),$$

les années de survénance étant mutuellement indépendantes. **Aucune loi n'est spécifiée** : seuls les deux premiers moments conditionnels le sont, ce qui constitue la différence de nature la plus importante avec les méthodes lognormales et commande l'ensemble des choix de p-values.

Les estimateurs sont

$$\hat{f}_j = \frac{\sum_{i=0}^{I-j-1} C(i, j + 1)}{\sum_{i=0}^{I-j-1} C(i, j)}, \quad \hat{\sigma}_j^2 = \frac{1}{I - j - 1} \sum_{i=0}^{I-j-1} C(i, j) (F(i, j) - \hat{f}_j)^2,$$

la variance de la dernière année de développement étant *extrapolée* et non estimée (section 13).

Résidus des deux méthodes

Chaque méthode a son résidu de référence, support de ses tests :

Méthode	Résidu	Loi sous le modèle
Lognormale	$z_t = \sqrt{\hat{\pi}_t} \left(\ln r_t + \frac{1}{2\hat{\pi}_t} - \ln \hat{\beta} \right)$	i.i.d. $\mathcal{N}(0, 1)$: la loi est entièrement spécifiée
Merz–Wüthrich	$r(i, j) = \frac{\sqrt{C(i, j)}}{\hat{\sigma}_j} (F(i, j) - \hat{f}_j)$	centré, d'échelle approximativement unitaire, non corrélé ; aucune loi n'est spécifiée

Cette asymétrie est déterminante : pour la méthode lognormale, la normalité des résidus est une *hypothèse à tester* (H3) ; pour la méthode Merz–Wüthrich, elle n'est qu'un *diagnostic facultatif* (M5).

Convention de restitution : statistique, estimation, p-value

Les sorties du script distinguent explicitement trois grandeurs, qui ne doivent jamais être confondues et figurent dans des champs séparés :

stat	Statistique de test : la quantité dont la loi sous H_0 est connue (ou simulée). C'est elle, et elle seule, qui est comparée à une loi de référence pour produire une p-value. Le champ loi rappelle cette loi.
estim	Estimation ou grandeur descriptive : pente, constante, $\hat{\rho}_s$, $\hat{\delta}$, R^2 , nombre de valeurs aberrantes, distance de Cook maximale. . . Ces quantités n'ont <i>aucune</i> loi de référence dans ce dispositif et ne doivent pas être lues comme des statistiques de test.
p, p_mc	p-values : respectivement asymptotique (ou exacte selon le test) et par bootstrap paramétrique.

Le champ type classe chaque ligne en *test* (hypothèse nulle et loi de référence), *indicateur* (descriptif, comme R^2), *diagnostic* (numérique ou d'influence), *procédure de décision* (Rosner, qui ne produit pas de p-value) ou *non applicable*. Le champ sens indique enfin si l'on souhaite rejeter ou ne pas rejeter H_0 : pour les tests de Student sur la pente et de Fisher, un p faible est un *bon* résultat, et le verdict du script est inversé en conséquence.

Contrôles de qualité des données

Les contrôles de recevabilité ne sont **pas** des tests statistiques : ils ne comportent ni hypothèse nulle, ni statistique, ni loi de référence. Ce sont des vérifications déterministes au titre des articles 19 et 219 du règlement délégué et des exigences de données propres à chaque méthode — à une exception près, signalée plus bas. Chaque méthode a ses fonctions de contrôle dans le moteur, exécutables indépendamment de l'interface : `engine_valider_donnees()` et `usp_controle_donnees()` pour les méthodes lognormales ; `mw_valider_triangle()` et `mw_valider_ajustement()` pour la méthode Merz–Wüthrich.

La méthode Merz–Wüthrich en compte donc **deux**, appelées à deux moments distincts de la chaîne. `mw_valider_triangle()` s'exécute *avant* l'ajustement et ne porte que sur les données fournies : dimensions, complétude de la partie observée, positivité des cumulés. `mw_valider_ajustement()` s'exécute *après* `mw_ajuster()` et `mw_msep()`, parce que les deux grandeurs dont elle contrôle le domaine — la réserve chain-ladder totale $\hat{R} = \sum_{i=0}^I (\hat{C}(i, J) - C(i, I - i))$ et la MSEF — ne sont pas connues avant lui ; elle précède en revanche le calcul du paramètre propre et le bootstrap.

Son fondement n'est pas le même que celui des autres contrôles, et c'est l'exception annoncée ci-dessus. Tous les autres relèvent des exigences de données des articles 19 et 219 — exhaustivité, exactitude, caractère approprié. Une réserve chain-ladder totale $\hat{R} \leq 0$ n'est pas un défaut de données : le triangle peut satisfaire intégralement le paragraphe 2 de la section D, et c'est l'*estimation* qui place le paramètre hors de ce que la méthode peut produire. Le refus se fonde donc sur l'article 220, dont la justification détaillée figure au §13.

Dans les deux cas, un refus conduit `run_engine()` à retourner un objet portant `ok = FALSE` et le champ `validation` détaillant les motifs : aucune erreur R n'est levée. `mw_parametre()` porte en outre une garde défensive sur le même diagnostic, destinée à un appel direct de la fonction hors de la chaîne ; elle est inatteignable depuis `run_engine()`.

Un refus n'est pas un avertissement que l'on peut laisser passer : l'interface le restitue par un bandeau persistant portant les motifs renvoyés par le moteur, vide les onglets de résultat et rend indisponible l'export du calcul précédent, de sorte qu'un paramètre calculé sur d'autres données ne puisse être ni lu ni exporté à côté d'un triangle refusé.

Méthodes lognormales (annexe XVII, section B/C, paragraphe 2)

Contrôle	Critère	Justification
Profondeur minimale	$T \geq 5$	Annexe XVII, B/C(2)(b). Bloquant.
Valeurs manquantes	aucun NA	Art. 19 : exhaustivité.
Positivité de x_t	$\min_t x_t > 0$	$r_t = y_t/x_t$ doit être défini.
Positivité de y_t	$\min_t y_t > 0$	Support de la loi lognormale.
Doublons	aucun couple (x_t, y_t) répété	Signale une duplication de ligne.
Plausibilité du ratio	$r_t \in]0 ; 5[$	Erreurs d'unité ou de saisie.
Amplitude du volume	$\max_t x_t / \min_t x_t < 10$	Rupture de périmètre probable.
Crédibilité pleine	$T \geq 10$ (barème court)	Informatif, section G annexe XVII.

Méthode Merz–Wüthrich (annexe XVII, section D, paragraphes 2, 4 et 5)

Contrôle	Critère	Justification
Années de survénance	$I + 1 \geq 5$	D(2)(b). Bloquant.
Années de développement	$J + 1 \geq 5$	D(2)(c). Bloquant.
Forme du triangle	$I + 1 \geq J + 1$	D(2)(e). Bloquant.
Géométrie carrée	$I = J$	Restriction d'implémentation : la formule du paragraphe 4 fait intervenir $C(i, I - i)$, indéfinie si $I - i > J$. Bloquant.
Cellules observées	aucune valeur manquante pour $i + j \leq I$	Le chain-ladder exige la partie supérieure gauche complète.
Positivité des cumulés	$C(i, j) > 0$	Les facteurs $F(i, j)$ et la pondération en $C(i, j)$ doivent être définis.
Monotonie des cumulés	$C(i, j + 1) \geq C(i, j)$	Avertissement <i>actuariel</i> , sans fondement réglementaire : le paragraphe 2(h)(iii) ne pose qu'une proportionnalité en espérance et ne contraint pas $f_j \geq 1$. Un recul traduit un recouvrement ou un boni de liquidation, licite mais à signaler. Ce n'est pas un motif de refus , pas plus qu'une réserve négative sur certaines années de survénance ou qu'un $\hat{f}_j < 1$ isolé.
Applicabilité de D(4) (<i>post-ajustement</i>)	$\hat{R} > 0$ et $0 \leq \text{MSEP} < \infty$	Le paragraphe 4 définit l'écart type $\sigma_{(\text{res}, s, \text{USP})}$ à partir de $\sqrt{\text{MSEP}}/\hat{R}$ (MSEP : paragraphe 5), coefficient de variation à horizon un an de la réserve — le paragraphe ne le nomme pas ainsi. Non défini pour $\hat{R} = 0$; négatif, donc pas un écart type, pour $\hat{R} < 0$ (article 220, §13). Bloquant.
Crédibilité pleine	$I + 1 \geq 10$ (barème court)	Informatif; à défaut, $\hat{\sigma}_j^2$ repose sur deux ou trois observations en fin de triangle.

Différence de nature. Les contrôles lognormaux portent sur la *plausibilité économique* des séries (ratio dans une plage admissible, amplitude des volumes). Ceux de la méthode Merz–Wüthrich portent d'abord sur la *géométrie* du triangle, dont dépend la simple définition des estimateurs : un triangle non carré ou incomplet ne permet pas d'appliquer la formule du paragraphe 4. C'est pourquoi la plupart sont bloquants et non de simples avertissements.

Le contrôle d'applicabilité de D(4) fait cependant exception à cette description : exécuté après l'ajustement, il ne porte pas sur les données mais sur des *grandeurs estimées* — la réserve chain-ladder totale $\hat{R}$ et la MSEF, issues du même ajustement. Il n'énonce donc pas un défaut du triangle — un triangle parfaitement recevable au titre du paragraphe 2 peut conduire à $\hat{R} \leq 0$ — mais une condition d'*applicabilité de la méthode* : hors de ce domaine, ce que la formule du paragraphe 4 produit — quand elle produit quelque chose — n'est pas l'écart type qu'elle prétend définir (§13). C'est aussi pourquoi il est le seul à ne pas pouvoir être anticipé à la saisie. Cohérence interne : `mw_bootstrap()` écarte depuis l'origine toute réplcation dont la réserve simulée est ≤ 0 ; la règle appliquée à l'estimation ponctuelle ne pouvait pas rester plus permissive que celle appliquée à

chacune de ses répliques.

PARTIE II

Cadre statistique général

Bootstrap paramétrique et p-values de Monte-Carlo

La profondeur exigée par l'annexe XVII (cinq années au minimum) rend inutilisables, en toute rigueur, les lois asymptotiques de la majorité des tests documentés ci-après. Le script recalcule donc, pour les statistiques les plus sensibles, une p-value de Monte-Carlo par bootstrap paramétrique.

4.1 Procédure générale de p-value de Monte-Carlo

Référence. B. Efron, *Bootstrap methods : another look at the jackknife*, *Annals of Statistics*, 7(1), 1979, p. 1–26 ; G. A. Barnard, discussion, *JRSS B*, 25, 1963, p. 294 ; J. G. MacKinnon, *Bootstrap hypothesis testing*, in *Handbook of Computational Econometrics*, Wiley, 2009.

1. Cadre, notations et hypothèses de validité (non testées). On dispose d'un modèle paramétrique entièrement estimé $\widehat{M} = (\hat{\delta}, \hat{\gamma}, \hat{\beta})$ et d'une statistique S dont la loi exacte sous H_0 est inconnue ou mal approchée. L'hypothèse de validité, non testée, est que $\widehat{M}$ constitue une approximation suffisante du vrai modèle sous H_0 (bootstrap *paramétrique*, par opposition au rééchantillonnage non paramétrique).

2. Hypothèse nulle. Celle du test sous-jacent, inchangée : la statistique S a été calculée sur des données conformes au modèle.

3. Statistique de test. S_{obs} , calculée sur l'échantillon réel. Pour $b = 1, \dots, B$, on simule $y_t^{(b)} \sim \mathcal{LN}(\ln(\hat{\beta}x_t) - \frac{1}{2\hat{\pi}_t}, \hat{\pi}_t^{-1})$, on **réestime intégralement** (δ, γ) sur $(x_t, y_t^{(b)})$, et l'on recalcule $S^{(b)}$.

4. Loi sous H_0 . La loi empirique de $\{S^{(1)}, \dots, S^{(B)}\}$ est, par construction, un échantillon de la loi exacte de S sous H_0 conditionnellement au modèle ajusté – y compris l'effet de l'estimation des paramètres, source principale du biais des lois asymptotiques à petit T .

5. p-value. Pour un test unilatéral à droite,

$$\hat{p}_{\text{MC}} = \frac{1 + \#\{b : S^{(b)} \geq S_{\text{obs}}\}}{B + 1},$$

avec l'adaptation évidente à gauche, et $\hat{p} = 2 \min(\hat{p}_{\text{gauche}}, \hat{p}_{\text{droite}})$ au bilatéral.

La portée de l'ajout de 1 au numérateur et au dénominateur mérite d'être énoncée avec précision, car elle est souvent surestimée. Deux situations doivent être distinguées.

Lorsque la loi de S sous H_0 est exactement simulable — cas des tests de permutation et de randomisation — les B valeurs simulées et la valeur observée sont échangeables sous H_0 . Le rang de S_{obs} est alors uniforme sur $\{1, \dots, B + 1\}$ et la règle ci-dessus fournit un test **exactement** de niveau α dès que $\alpha(B + 1)$

est entier (Dwass, 1957 ; Hope, 1968). Vérification numérique sur 200 000 répliques avec $B = 99$: la fréquence de rejet vaut 0,0506 pour $\alpha = 0,05$ et 0,1003 pour $\alpha = 0,10$.

Dans le cas présent, la loi de référence n'est pas connue : elle est celle du *modèle estimé* $\widehat{M}$. Les $S^{(b)}$ sont tirés sous $\widehat{M}$ et non sous le vrai modèle, de sorte que l'échangeabilité avec S_{obs} n'est pas acquise. Le résultat d'exactitude ci-dessus **ne se transporte donc pas** au bootstrap paramétrique. L'ajout de 1 corrige la seule discrétisation liée à un B fini ; il ne corrige pas l'écart entre la loi sous $\widehat{M}$ et la loi sous le vrai modèle, dont la disparition est un résultat *asymptotique en T* (Bickel & Freedman, 1981 ; Singh, 1981 ; Hall, 1992). La validité du dispositif reste par conséquent asymptotique, et l'étude de simulation de la section 19 en constitue la seule mesure disponible à $T = 8$.

6. Usage et limites. C'est la seule p-value réellement calibrée aux tailles d'échantillon du régime USP. Sa granularité est bornée par $1/(B + 1)$: avec $B = 999$, la plus petite p-value atteignable vaut 0,001. Sa limite est qu'elle teste la conformité au *modèle ajusté* : si le modèle est mal spécifié dans une direction que S ne détecte pas, la p-value sera élevée à tort. Dans les sorties du script, elle figure en colonne `p_mc` et prime sur la p-value asymptotique lorsque les deux sont disponibles.

4.2 Bootstrap semi-paramétrique de la méthode Merz–Wüthrich

Le modèle de Mack ne spécifiant aucune loi, aucun bootstrap *paramétrique* n'est possible. Le moteur emploie un rééchantillonnage des résidus standardisés (England & Verrall, 2002, *British Actuarial Journal* 8(3), 443–518), qui ne suppose que leur échangeabilité : les p-values correspondantes sont donc *semi-paramétriques* et non paramétriques.

Limite structurelle du rééchantillonnage de résidus. Cette procédure tire dans la loi *empirique* des résidus observés. Son hypothèse nulle est « les résidus suivent leur propre loi empirique », et non « les résidus sont normaux ». Une p-value de Monte-Carlo pour un test de normalité y serait donc vide de sens ; la vérification par simulation le confirme, la fréquence de rejet tombant à zéro au lieu de 5 %. Les tests de normalité de la famille M5 sont en conséquence exclus du bootstrap et rapportés avec leur propre loi nulle : loi exacte de W évaluée par simulation directe pour Shapiro–Wilk, approximation de Dallal & Wilkinson pour Lilliefors.

Nature des p-values et validité à $T = 8$

5.1 Quatre statuts épistémiques à ne jamais confondre

Toute conclusion du dispositif relève de l'un des quatre statuts suivants. La distinction est reprise systématiquement dans les tableaux 5.4 et 5.5.

Statut	Signification et portée
Exact	La loi de la statistique sous H_0 est connue pour la taille d'échantillon considérée, sans approximation (loi combinatoire, de permutation, binomiale, ou loi de Student/Fisher sous normalité exacte des erreurs). La p-value est alors valide à $T = 8$ comme à $T = 1000$.
Asymptotique	La loi n'est connue qu'à la limite $T \rightarrow \infty$. L'existence du résultat limite ne dit <i>rien</i> de la qualité de l'approximation à T fini : il faut disposer, séparément, d'un résultat sur la <i>vitesse</i> de convergence ou d'une étude de simulation.
Approximation numérique	La loi exacte existe mais n'est pas calculable analytiquement, et l'on emploie une formule d'ajustement (Royston pour Shapiro–Wilk, Stephens pour Anderson–Darling). La qualité de l'approximation dépend du domaine de validité annoncé par ses auteurs, qui doit être vérifié pour $T = 8$.
Comportement empirique	Résultat d'une étude de simulation. Il documente le niveau effectif observé, mais ne transforme jamais une approximation en résultat exact et ne vaut que pour le modèle sous lequel la simulation a été conduite.

Principe de sélection retenu dans le moteur. Pour chaque test, la p-value effectivement utilisée pour le verdict suit la hiérarchie *exacte* $\succ$ *Monte-Carlo* $\succ$ *asymptotique*. Le champ `nature_p` de la sortie indique laquelle a été retenue, et les trois valeurs (`p_exacte`, `p_asymptotique`, `p_monte_carlo`) restent affichées séparément pour permettre la revue. Aucune p-value asymptotique n'est retenue lorsqu'une p-value exacte ou de Monte-Carlo est disponible.

Ce que cette hiérarchie ne dit pas : la règle de sortie. La hiérarchie *ordonne des p-values qui existent*. Elle ne se lit pas à l'envers : l'absence de p-value exacte et de p-value de Monte-Carlo n'autorise pas un repli sur l'asymptotique, ni, plus généralement, sur la loi *nominale* — celle que la statistique suivrait si les paramètres n'avaient pas été estimés. Lorsqu'une grandeur est **rivée par l'estimation**, c'est-à-dire fixée par les conditions du premier ordre du maximum de vraisemblance plutôt que librement observée, aucune des trois voies n'est ouverte, et il faut le dire des trois et non de la seule qui a échoué en premier : (i) il n'existe pas de loi exacte sous H_0 pour une quantité que H_0 ne laisse pas varier ; (ii) la loi simulée sous le modèle ajusté porte un atome en la valeur observée, de sorte que la p-value de Monte-Carlo se décide au signe d'un bruit numérique ; (iii) la loi nominale ne décrit pas la grandeur restituée, puisque la valeur observée n'est pas une observation. Le point (iii) est le plus important pour le lecteur, car c'est le repli le plus tentant : à $\hat{\pi}_t$ constant, la p-value nominale de ces grandeurs est une *constante de T* qui ne dépend plus des données, identique pour deux jeux étrangers l'un à l'autre. Le « OK » qu'elle produirait ne pourrait être perdu par aucune donnée ; c'est exactement la fausse assurance que la restitution en diagnostic vise à éviter. Le calcul et les mesures figurent aux fiches 9.5 et 9.6. Ces lignes sont donc restituées

comme *diagnostics*, sans p-value retenue et avec le motif. Cette règle de sortie ne concerne ni le test de Student sur la pente ni le test de Fisher global : leur statistique est librement observée et leur loi est exacte sous normalité des erreurs ; ils conservent leur p-value, pour la raison exposée à la sous-section 5.3.

5.2 Deux sources d'erreur distinctes

Lorsqu'une p-value est estimée par B simulations, deux erreurs se superposent ; elles ont des causes, des ordres de grandeur et des remèdes différents, et ne doivent en aucun cas être confondues.

	Erreur de Monte-Carlo	Erreur d'approximation statistique
Source	Nombre fini B de réplifications	Taille finie T de l'échantillon
Grandeur affectée	L'estimateur $\hat{p}_{MC}$ de la p-value bootstrap	L'écart entre la loi bootstrap et la vraie loi sous H_0
Ordre de grandeur	$\sqrt{p(1-p)/B}$, soit $\mathcal{O}(B^{-1/2})$	Dépend du test ; typiquement $\mathcal{O}(T^{-1/2})$ ou $\mathcal{O}(T^{-1})$
Réduction	Augmenter B (gratuit, purement numérique)	Impossible : $T = 8$ est une donnée du problème
Mesure dans le moteur	champ <code>erreur_MC</code>	non mesurable directement ; approchée par l'étude de simulation de la section 11

Avec $B = 999$ et $\hat{p} \approx 0,10$, l'erreur de Monte-Carlo vaut environ 0,009. Il serait erroné d'en conclure que la p-value est « précise à $\pm 0,01$ » : cette précision porte sur l'estimation de la p-value *bootstrap*, pas sur son écart à la vraie p-value sous H_0 . La granularité de $\hat{p}_{MC}$ est en outre bornée inférieurement par $1/(B+1)$ (Dwass, 1957 ; Hope, 1968 ; voir la bibliographie complémentaire, section 20).

5.3 Ce que l'on peut et ne peut pas affirmer à $T = 8$

- **Résultats exacts disponibles à $T = 8$.** Loi binomiale (Cox–Stuart), loi de permutation de Spearman, loi mahonienne du S de Kendall, loi combinatoire du nombre de suites, loi exacte de Smirnov à deux échantillons, et les lois de Student et de Fisher de la régression auxiliaire *sous l'hypothèse de normalité exacte des erreurs*. Ces p-values sont valides sans réserve de taille d'échantillon.
- **Résultats asymptotiques sans justification suffisante à $T = 8$.** Les statistiques de type multiplicateur de Lagrange (Breusch–Pagan, White), portmanteau (Ljung–Box, Box–Pierce), Jarque–Bera, et les approximations normales de Mann–Kendall, Wald–Wolfowitz et D'Agostino. La littérature disponible ne fournit, pour aucune d'entre elles, de borne d'erreur exploitable à $T = 8$.
- **Deux cas où aucune p-value de Monte-Carlo n'est possible.** Les tests de Student sur la pente et de Fisher global ont pour hypothèse nulle $b = 0$. Or le bootstrap paramétrique simule sous le *modèle ajusté*, pour lequel $\hat{b} \neq 0$: le modèle de simulation appartient à H_1 et non à H_0 . Une p-value de Monte-Carlo y serait dépourvue de sens. Ces deux tests conservent donc leur loi de Fisher/Student, qui est *exacte* sous normalité des erreurs : la limitation porte sur l'hypothèse de normalité, non sur la taille d'échantillon.
- **Un troisième cas, de nature différente : la grandeur rivée par l'estimation.** Le centrage et la variance unitaire des résidus standardisés (fiches 9.5 et 9.6) sont fixés par les conditions du premier ordre du maximum de vraisemblance. La loi simulée sous le modèle ajusté existe bien, mais elle porte un *atome* en la valeur observée : la p-value de Monte-Carlo s'y décide au signe d'un bruit numérique. À la différence des deux cas précédents, il n'y a ici aucun repli possible : ni loi exacte, ni loi nominale utilisable, cette dernière produisant à $\hat{\pi}_t$ constant une p-value qui ne dépend plus

des données. Ces deux lignes sont restituées comme *diagnostics*, sans p-value retenue et avec le motif.

- **Ce qu’aucune méthode ne restitue.** Ni le bootstrap ni les lois exactes n’augmentent la *puissance*. À $T = 8$, l’ensemble du dispositif reste très peu puissant : une p-value élevée n’est pas une validation d’hypothèse. Les diagnostics de robustesse de la section 10 conservent la priorité sur les tests d’hypothèse.

5.4 Tableau 1 : disponibilité et choix des p-values

Ce tableau recense les tests *effectivement présents* dans le moteur (R/engine.R). La colonne « Asympt. utilisable à $T = 8$? » ne répond pas mécaniquement : elle distingue l'existence théorique d'une loi limite de la qualité de son approximation à $T = 8$.

La colonne « Méthode » indique le périmètre d'emploi : **LN** pour les méthodes lognormales (risque de prime, section B, et risque de réserve n° 1, section C), **MW** pour la méthode du risque de réserve n° 2 (Merz–Wüthrich, section D), et **Les deux** lorsque le test est employé dans les deux dispositifs. Dans ce dernier cas la statistique est identique, mais son support diffère : résidus normalisés z_t d'un côté, résidus standardisés de Mack $r(i, j)$ de l'autre (voir la section 13).

Test	Méthode	Stat.	Exacte ?	Asympt. ?	MC ?	Voie retenue	Asympt. utilisable à $T = 8$?	Recommandation ACPR
Student, constante	LN	t_a	Oui (sous normalité)	—	Oui	Exacte (MC en recouplement)	Sans objet : loi exacte	Distribution exacte à privilégier. <i>Mais</i> le non-rejet ne prouve rien : compléter par le TOST
Équivalence (TOST)	LN	max des 2 unilatéraux	Oui si Δ fixée a priori	—	Sans objet	Exacte (Δ a priori) ou quasi-exacte ($\Delta = \theta\bar{y}$)	Sans objet : loi exacte	Seul test fournissant une preuve positive de proportionnalité ; fixer Δ a priori. Puissance de 46 % seulement à $T = 8$
Student, pente	LN	t_b	Oui (sous normalité)	—	Non (voir texte)	Exacte (loi t)	Sans objet : loi exacte	Distribution exacte à privilégier ; vérifier la normalité
Fisher global	LN	F	Oui (sous normalité)	—	Non (voir texte)	Exacte (loi F)	Sans objet : loi exacte	Idem ; redondant avec t_b
RESET	LN	F	Non	Oui	Oui	Monte-Carlo	Déconseillée : $\hat{y}^2, \hat{y}^3$ dépendent de y , la loi F n'est pas exacte	Bootstrap recommandé
Spearman ($\times 2$)	LN	S	Oui ($T \leq 9$)	Oui	Oui	Exacte	Inutile : l'exacte est calculable	Distribution exacte à privilégier
Mann–Kendall	LN	Z / S	Oui (loi mahonienne)	Oui	Oui	Exacte	Déconseillée : approx. normale usuellement requise à $T \geq 10$	Distribution exacte à privilégier
Cox–Stuart	LN	K	Oui (binomiale)	—	Oui	Exacte	Sans objet	Exacte ; mais $p_{\min} = 0,125$ à $T = 8$: test inopérant
Breusch–Pagan studentisé (Koenker)	LN	LM	Non	Oui	Oui	Monte-Carlo	Déconseillée : convergence χ^2 lente, aucune borne à $T = 8$	Bootstrap recommandé ; version de référence pour conclure
Breusch–Pagan original (1979)	LN	LM	Non	Oui, <i>sous normalité</i>	Oui	Monte-Carlo	Déconseillée : convergence lente <i>et</i> hypothèse de normalité non acquise	À lire en regard de la version studentisée ; un écart signale H3, pas H2
White	LN	LM	Non	Oui	Oui	Monte-Carlo	Déconseillée : 3 coefficients auxiliaires pour 8 points	Bootstrap ; puissance quasi nulle
Goldfeld–Quandt	LN	F	Approx. seulement	Oui	Oui	Monte-Carlo	Sous conditions : exacte si régressions séparées, ici résidus globaux	Bootstrap recommandé
Brown–Forsythe	LN	W	Non	Oui	Oui	Monte-Carlo	Déconseillée : loi F approchée, 4 points par groupe	Bootstrap recommandé
Smirnov 2 éch.	LN	D	Oui (combinatoire)	Oui	Oui	Exacte	Inutile	Exacte ; $n_1 = n_2 = 4$: $p_{\min} = 0,029$
Shapiro–Wilk	LN	W	Oui , loi de W évaluée par simulation directe (sans Royston)	Approx. Royston	Oui	Monte-Carlo, avec p Royston <i>et</i> p de loi nulle simulée	Sous conditions pour Royston ; la loi nulle simulée s'en affranchit	Loi nulle simulée à privilégier ; les deux concordent à $T = 8$

Suite page suivante

Test	Méthode	Stat.	Exacte ?	Asympt. ?	MC ?	Voie retenue	Asympt. utilisable à $T = 8$?	Recommandation ACPR
Shapiro–Francia	LN	W'	Non	Approx. Royston	Oui	Monte-Carlo	Sous conditions : validité annoncée $5 \leq T \leq 5000$	Bootstrap recommandé
Anderson–Darling	LN	A^2	Non (param. estimés)	Oui (Stephens, cas 3)	Oui	Monte-Carlo, p de Stephens en complément	Sous conditions : ajustement empirique, calibration vérifiée à $T = 8$	Bootstrap retenu ; p de Stephens disponible
Cramér–von Mises	LN	W^2	Non	Oui (Stephens, cas 3)	Oui	Monte-Carlo, p de Stephens en complément	Idem A^2	Bootstrap retenu ; p de Stephens disponible
KS contre $\mathcal{N}(0, 1)$	LN	D	Non	Oui (Kolmogorov)	Oui	Monte-Carlo	Déconseillée : 0 rejet sur 3 000 simulations à 5 %, test vidé de sa puissance	Utiliser Lilliefors à la place
Lilliefors	LN	D_L	Non	Oui (Dallal–Wilkinson)	Oui	p de Dallal–Wilkinson	Oui : calibration vérifiée à $T = 8$ (5,2 % à 5 %)	Version correcte du KS à paramètres estimés
Jarque–Bera	LN	JB	Non	Oui	Oui	Monte-Carlo	Déconseillée : convergence χ^2_2 très lente ; b_2 borné par $\sim T$	Bootstrap ; test peu informatif à $T = 8$
D’Agostino (asym.)	LN	Z	Non	Oui (transf. S_U)	Oui	Monte-Carlo	Sous conditions : défini dès $T \geq 8$, à la limite du domaine	Bootstrap ; à interpréter avec prudence
Anscombe–Glynn	LN	Z	Non	Oui	—	Non applicable ($T < 20$)	Sans objet	Non utilisable à $T = 8$
Durbin–Watson	LN	DW	Oui : forme quadratique, méthode d’Imhof	—	Oui	Exacte (Imhof)	Sans objet : loi exacte	Distribution exacte à privilégier ; statistique calculée sur résidus centrés
Ljung–Box (1, 2)	LN	Q	Non	Oui	Oui	Monte-Carlo	Déconseillée : approx. χ^2 mal calibrée en petit échantillon	Bootstrap recommandé
Box–Pierce	LN	Q	Non	Oui	Oui	Monte-Carlo	Déconseillée : encore moins bonne que Ljung–Box	Bootstrap ; préférer Ljung–Box
Suites (W.–W.)	LN	Z / R	Oui (combinatoire)	Oui	Oui	Exacte	Déconseillée : approx. normale requiert $n_1, n_2 \geq 10$	Distribution exacte à privilégier
Centrage des résidus	LN	—	—	—	—	Diagnostic	Sans objet	Aucune p-value : $\bar{z}$ est rivé par une identité de l’estimation. La p-value nominale du t ne dépendrait pas des données ($= 1$ à $\hat{\pi}_t$ constant). Restitué sans verdict

Suite page suivante

Test	Méthode	Stat.	Exacte ?	Asympt. ?	MC ?	Voie retenue	Asympt. utilisable à $T = 8$?	Recommandation ACPR
Variance unitaire	LN	—	—	—	—	Diagnostic	Sans objet	Idem pour $\text{Var}(z)$; la loi simulée porte un atome en la valeur observée et la p-value nominale du χ^2 ne dépendrait pas des données (0,6651878 à $T = 8$)
sup-F (rupture)	LN	$\sup F$	Non	Théorique seulement (Andrews)	Oui	Monte-Carlo	Absence de justification : loi de sup. de processus, convergence fonctionnelle	Seul test sans p-value non simulée : bootstrap indispensable
OLS-CUSUM	LN	$\sup S $	Non	Oui (Kolmogorov asympt.)	Oui	Monte-Carlo	Absence de justification : 8 points ne forment pas une trajectoire brownienne	Bootstrap indispensable; p asympt. fournie pour mémoire
Grubbs	LN	G	Borne de Bonferroni	—	Oui	Monte-Carlo	Sous conditions : borne conservatrice, non exacte	Bootstrap; borne utilisable comme majorant
Rosner (ESD)	LN	R_i	Valeurs critiques tabulées	—	—	Procédure de décision	Sans objet (pas de p-value)	Indicatif seulement; fiabilité annoncée pour $T \geq 25$
Méthode Merz–Wüthrich — M1 : proportionnalité des cumulés								
Tendance avec le cumulé, à colonne donnée	MW	t pondéré (GLS, effet fixe de colonne)	Non	Oui	Oui	Monte-Carlo	Déconseillée : les cellules d'une colonne partagent $\hat{f}_j$ et $\hat{\sigma}_j$	Version agrégée puissante (100 % sous l'alternative testée); les tests par colonne localisent
Ordonnée à l'origine par colonne	MW	X de Fisher	Non	Oui, $\chi^2(2K)$	Oui	Monte-Carlo	Déconseillée : colonnes adjacentes non indépendantes	Test central de M1 ; calibration MC vérifiée (10,7 % et 4,7 %)
Homogénéité de f_j entre années de survénance	MW	X de Fisher	Non	Oui, $\chi^2(2K)$	Oui	Monte-Carlo	Idem	Seconde exigence du texte : « pour toutes les années d'accident »
Absence de courbure	MW	X de Fisher	Non	Oui, $\chi^2(2K)$	Oui	Monte-Carlo	Idem	Puissance faible : 3 paramètres pour 4 à 6 observations
Famille α (pondération)	MW	amplitude relative	Non	Non	Oui	Monte-Carlo	Sans objet : aucune loi analytique	Diagnostic de robustesse; chiffrer l'enjeu du choix de pondération
Méthode Merz–Wüthrich — M2 : variance proportionnelle au cumulé								
Breusch–Pagan sur résidus de Mack	MW	LM	Non	Oui	Oui	Monte-Carlo	Déconseillée : convergence χ^2 lente et dépendance intra-colonne	Bootstrap recommandé; teste l'exposant 1 imposé par le règlement
Exposant de variance par colonne	MW	X de Fisher	Non	Oui, $\chi^2(2K)$	Oui	Monte-Carlo	Déconseillée : colonnes non indépendantes	Localise ce que Breusch–Pagan agrège; un rejet est une limite du modèle, pas un motif de changement de méthode
Variance unitaire des résidus de Mack	MW	—	—	—	—	Diagnostic	Sans objet	Indicateur d'échelle de $\hat{\sigma}_j$

Suite page suivante

Test	Méthode	Stat.	Exacte ?	Asympt. ?	MC ?	Voie retenue	Asympt. utilisable à $T = 8$?	Recommandation ACPR
Méthode Merz–Wüthrich — M3 : indépendance								
Homogénéité des résidus entre années de surveillance	MW	H de Kruskal–Wallis	Non	Oui, $\chi^2(k-1)$	Oui	Monte-Carlo	Déconseillée : groupes très déséquilibrés (de J à 1 résidu)	Traduction testable de D(2)(h)(i); complète le test calendaire
Effets d’année calendaire	MW	Z	Non	Oui (moments <i>exacts</i> de Z)	Oui	Monte-Carlo	Sous conditions : les moments sont exacts, l’approximation normale de leur somme ne l’est pas	Bootstrap de résidus; test le plus informatif sur un triangle
Corrélation entre années de développement	MW	ρ agrégé	Non	Non	Oui	Monte-Carlo	Sans objet : aucune loi analytique	Bootstrap indispensable
Autocorrélation (Durbin–Watson) sur résidus de Mack	MW	DW	Non	Non : loi d’Imhof in-applicable	Oui	Monte-Carlo	Sans objet : aucune loi analytique	Bootstrap indispensable
Test des suites sur résidus de Mack	MW	Z	Non (échangeabilité en défaut)	Oui	Oui	Monte-Carlo	Déconseillée : dépendance intra-colonne	Bootstrap recommandé
Méthode Merz–Wüthrich — M4 : points aberrants								
Grubbs sur résidus de Mack	MW	G	Borne de Bonferroni	—	Oui	Monte-Carlo	Sous conditions : suppose la normalité, non exigée par le modèle	Bootstrap; borne utilisable comme majorant
Rosner (ESD) sur résidus de Mack	MW	R_i	Valeurs critiques tabulées	—	—	Procédure de décision	Sans objet (pas de p-value)	Indicatif; $n = 28$ à $T = 8$, sous le seuil de fiabilité
Méthode Merz–Wüthrich — M5 : normalité (diagnostic, non exigée)								
Shapiro–Wilk sur résidus de Mack	MW	W	Oui , loi nulle simulée	Approx. Royston	Non (voir texte)	Loi nulle simulée	Sans objet : loi propre	Diagnostic seulement : normalité non exigée par D(2)(h)
Lilliefors sur résidus de Mack	MW	D_L	Non	Oui (Dallal–Wilkinson)	Non	p de Dallal–Wilkinson	Sous conditions	Variante secondaire; diagnostic seulement
Méthode Merz–Wüthrich — M6 : robustesse de l’estimation								
Concentration de la réserve sur la dernière année	MW	—	—	—	—	Diagnostic	Sans objet	Équivalent du jackknife : mesure la concentration du résultat sur la ligne la moins informative
Extrapolation de $\hat{\sigma}_{j-1}^2$	MW	—	—	—	—	Diagnostic	Sans objet	Valeur imposée par le règlement, non estimée : à signaler dans le dossier

Lecture. « Sans objet : loi exacte » signifie que la question de la qualité de l'approximation asymptotique ne se pose pas, une loi exacte étant employée. « Absence de justification suffisante » signifie que la littérature consultée n'établit pas, pour $T = 8$, de borne d'erreur ni d'étude de simulation permettant de conclure : la p-value asymptotique n'est alors pas retenue.

5.5 Tableau 2 : nature et vitesse des convergences

Ce tableau sépare strictement les deux phénomènes : la convergence en T de la loi de la statistique, et la convergence en B de l'estimateur de la p-value. Lorsque les deux coexistent, ils sont documentés sur deux lignes distinctes. Les blocs (A), (B) et (D) concernent la méthode lognormale ; le bloc (C) est propre à la méthode Merz–Wüthrich, où la profondeur pertinente n'est plus T mais le nombre d'observations $n_j = I - j$ de chaque colonne du triangle, qui décroît jusqu'à 2 ou 3 sur les dernières années de développement.

Test	Objet qui converge	Limite	Nature	Vitesse	Hypothèses	Conséquence à $T = 8$
(A) Convergence en T de la loi de la statistique — non contrôlable, T est une donnée						
Student / Fisher	<i>Aucune</i> : loi exacte à T fini	—	—	—	Erreurs i.i.d. $\mathcal{N}(0, \sigma^2)$, régresseurs fixes	Valide, sous réserve de la normalité
Breusch–Pagan (Koenker), White	$LM = TR_{aux}^2$	$\chi^2(q)$	Convergence en loi	Non établie de façon exploitable; TCL sous-jacent en $\mathcal{O}(T^{-1/2})$	Moments d'ordre 4 finis, indépendance	Non exploitable; bootstrap requis
Breusch–Pagan (1979)	$LM = \frac{1}{2} \text{SCE}$	$\chi^2(q)$	Convergence en loi	Idem, <i>mais</i> la limite n'est atteinte que si $\text{Var}(u^2) = 2\sigma^4$	Normalité des erreurs , en sus des précédentes	Non exploitable; sur-rejet si queues lourdes
Ljung–Box, Box–Pierce	Q	$\chi^2(h)$	Convergence en loi	Non établie; niveau effectif connu comme dégradé en petit échantillon	Stationnarité, moments d'ordre 2	Non exploitable; bootstrap requis
Jarque–Bera	$(\sqrt{b_1}, b_2)$ puis JB	$\chi^2(2)$	Convergence en loi	Réputée <i>très</i> lente	Moments d'ordre 8 finis pour la normalité asymptotique de b_2	Non exploitable; b_2 borné par $\sim T$
Mann–Kendall	S (U -statistique)	$\mathcal{N}(0, 1)$ après normalisation	Convergence en loi	Berry–Esseen pour U -statistiques : $\mathcal{O}(T^{-1/2})$	Variance de la projection non nulle, moment d'ordre 3	Borne $\mathcal{O}(8^{-1/2}) \approx 0,35$: inexploitable. Loi exacte employée
Wald–Wolfowitz	R	$\mathcal{N}(0, 1)$	Convergence en loi	$\mathcal{O}(n^{-1/2})$ (TCL); recommandation d'usage $n_1, n_2 \geq 10$	Continuité, indépendance	Loi exacte employée
Spearman	$\hat{\rho}_s$	$\mathcal{N} / t(T - 2)$	Convergence en loi	$\mathcal{O}(T^{-1/2})$	Indépendance, absence d'ex æquo	Loi de permutation exacte employée
D'Agostino	$\sqrt{b_1}$ transformé	$\mathcal{N}(0, 1)$	Convergence en loi	Transformation S_U conçue pour corriger l'ordre T^{-1} ; validité annoncée $T \geq 8$	Moments d'ordre 6 finis	Limite du domaine; bootstrap en complément
Anderson–Darling, CvM, KS	Processus empirique $\sqrt{T}(\hat{F} - F_0)$	Pont brownien (transformé)	Convergence faible dans $D[0, 1]$	$\mathcal{O}(T^{-1/2})$ pour les fonctionnelles régulières	F_0 continue, paramètres connus	Hypothèse violée (paramètres estimés); bootstrap requis
sup-F	$\{F(k)\}_k$	Sup. d'un processus de Bessel	Convergence faible	Fonctionnelle : lente, non quantifiée à T petit	Erreurs i.i.d., écrêtement τ fixé	Non exploitable; bootstrap requis
OLS-CUSUM	$S(\lfloor uT \rfloor)$	Pont brownien B°	Convergence faible (principe d'invariance)	$\mathcal{O}(T^{-1/2})$	Erreurs i.i.d., variance finie	8 points : non exploitable
Shapiro–Wilk / Francia	W, W'	Approx. normalisée de Royston	Approximation numérique, non asymptotique	Sans objet (ajustement empirique)	Domaine de validité annoncé par l'auteur	Domaine couvert mais transformation distincte à $T \leq 11$; bootstrap en complément

Suite page suivante

Test	Objet qui converge	Limite	Nature	Vitesse	Hypothèses	Conséquence à $T = 8$
Centrage, variance unitaire (diagnostics)	<i>Aucun</i> : $\bar{z}$ et $\text{Var}(z)$ sont rivés par les conditions du premier ordre	—	—	Sans objet	Optimum intérieur en γ ; $\hat{\pi}_t$ constant pour la forme simple $\sum_t z_t = 0$, $\sum_t z_t^2 = T$	Aucune p-value : la loi simulée sous le modèle ajusté porte un atome en la valeur observée, et la loi nominale, qui ignore l'estimation, produit à $\hat{\pi}_t$ constant une p-value qui ne dépend plus des données du tout : 1 pour le t de Student et 0,6651878 pour le χ^2 , à $T = 8$. Restitués sans verdict
(B) Convergence en B de l'estimateur Monte-Carlo — entièrement contrôlable						
Toutes statistiques bootstrapées	$\hat{p}_{MC} = \frac{1 + \#\{S^{(b)} \geq S_{obs}\}}{B+1}$	p^* , p-value bootstrap exacte	Convergence presque sûre (LFGN) et en loi (TCL)	Écart-type $\sqrt{p(1-p)/B} = \mathcal{O}(B^{-1/2})$; granularité $1/(B+1)$	Réplications i.i.d. sous le modèle ajusté	$B = 999 \Rightarrow \pm 0,009$ à $p = 0,10$. Sans lien avec T
Idem	Loi bootstrap p^*	Vraie p-value sous H_0	Convergence bootstrap en T	Consistance établie asymptotiquement; raffinement d'ordre supérieur pour statistiques pivotales	Modèle correctement spécifié, estimateur consistant	Non quantifiable à $T = 8$. C'est ici, et non dans le choix de B , que réside la limite du dispositif : la correction en $1/(B+1)$ ne rend pas le test exact
(C) Convergence propre à la méthode Merz-Wüthrich						
Effets d'année calendaire	$Z = \sum_k \min(L_k, S_k)$	$\mathcal{N}(0, 1)$ après centrage-réduction	Convergence en loi	Non quantifiée; les moments de chaque Z_k sont en revanche <i>exacts</i>	Indépendance des diagonales, absence d'ex æquo dans les colonnes	Le nombre de diagonales exploitables est $I - 1$: la somme porte sur peu de termes, d'où le recours au bootstrap
Facteurs $\hat{f}_j$	Estimateur des moindres carrés pondérés	f_j	Convergence en probabilité; sans biais sous M1	$\mathcal{O}_P(n_j^{-1/2})$ avec $n_j = I - j$ observations	M1 et M3	Les colonnes de droite ne reposent que sur 2 ou 3 observations
Variances $\hat{\sigma}_j^2$	Estimateur pondéré de la variance	σ_j^2	Convergence en probabilité	$\mathcal{O}_P(n_j^{-1/2})$, avec $n_j - 1$ degrés de liberté	M2, moments d'ordre 4 finis	$\hat{\sigma}_{j-1}^2$ n'est pas estimée mais extrapolée par la règle du règlement
$\sqrt{\text{MSEP}}$	Erreur de prédiction à un an	Erreur vraie	Convergence en probabilité	Non établie à I fini	M1 à M3, modèle correctement spécifié	Non quantifiable; la MSEP hérite de l'incertitude sur $\hat{\sigma}_{j-1}^2$
Combinaisons de Fisher (ordonnée à l'origine, homogénéité, courbure, exposant de variance)	$X = -2 \sum \ln p_k$	$\chi^2(2K)$	Convergence en loi	Sans objet en toute rigueur : la loi $\chi^2(2K)$ suppose l'indépendance des K p-values, mise en défaut car les colonnes j et $j+1$ partagent $C(\cdot, j+1)$	Indépendance des colonnes	p-value du χ^2 indicative seulement; bootstrap retenu

Suite page suivante

Test	Objet qui converge	Limite	Nature	Vitesse	Hypothèses	Conséquence à $T = 8$
Corrélation entre colonnes	$\hat{\rho}$ agrégé	<i>aucune limite tabulable</i>	—	Sans objet : la géométrie du triangle interdit toute normalisation	Continuité, absence d'ex æquo	Bootstrap seul recours ; 5 à 6 paires exploitables à $T = 8$
Durbin–Watson et suites sur résidus de Mack	DW, Z	$\mathcal{N}(0, 1)$ / loi combinatoire	Convergence en loi	Non établie : les résidus d'une colonne partagent $\hat{f}_j$ et $\hat{\sigma}_j$	Échangeabilité, mise en défaut ici	Lois classiques écartées ; bootstrap retenu
Bootstrap de résidus	$\hat{p}_{MC}$	p-value semi-paramétrique	Convergence en B (Monte-Carlo) et en I (validité bootstrap)	$\mathcal{O}(B^{-1/2})$ pour la première ; non établie pour la seconde	Échangeabilité des résidus standardisés	Ne permet pas de tester la normalité : la loi nulle simulée est la loi empirique des résidus
(D) Convergence de l'estimateur du paramètre (méthode lognormale)						
$(\hat{\delta}, \hat{\gamma})$ (MV)	Estimateur du maximum de vraisemblance	(δ_0, γ_0)	Convergence en probabilité ; normalité asymptotique	$\mathcal{O}_P(T^{-1/2})$ sous conditions de régularité	Modèle correct, identifiabilité, intérieur du domaine	$\hat{\delta}$ souvent au bord : régularité en défaut, normalité asymptotique non applicable
Test du rapport de vraisemblance sur δ	LR	$\frac{1}{2}\chi^2(0) + \frac{1}{2}\chi^2(1)$	Convergence en loi	Non quantifiée à T petit	Frontière du domaine (résultat de Chernoff)	p-value $\chi^2(1)$ conservatrice d'un facteur 2

Point de méthode central. Les deux blocs (A) et (B) répondent à des questions différentes. Le bloc (B) montre que l'erreur numérique sur $\hat{p}_{MC}$ est maîtrisée et réductible à volonté en augmentant B . Le bloc (A) montre qu'à $T = 8$, aucune des lois asymptotiques mobilisées ne dispose d'une justification exploitable. Le bootstrap paramétrique déplace le problème sans le supprimer : il remplace une approximation asymptotique par une approximation *de plug-in*, dont la validité reste asymptotique en T et n'est pas quantifiable à $T = 8$. C'est la raison pour laquelle la section 11 (jackknife, largeur de l'intervalle bootstrap, position de $\hat{\delta}$) doit primer sur la lecture des p-values dans le dossier remis au superviseur.

5.6 Choix de la base de résidus

Plusieurs séries peuvent servir de support aux tests. Le choix n'est pas neutre : il détermine à la fois l'hypothèse effectivement testée et la validité des p-values classiques.

Les trois séries candidates

Série	Définition	Loi sous le modèle
Résidus normalisés	$z_t = \sqrt{\hat{\pi}_t} v_t$	i.i.d. $\mathcal{N}(0, 1)$: la seule série exactement échangeable
Résidus logarithmiques	$v_t = \ln r_t + \frac{1}{2\hat{\pi}_t} - \ln \hat{\beta}$	indépendants et normaux, mais de variance $1/\pi_t$ variable avec x_t
Ratios centrés	$u_t = r_t - \bar{r}$, avec $r_t = y_t/x_t$	indépendants, mais ni normaux ni de même variance

La différence $y_t - x_t$ n'est pas un résidu mais le *résultat technique* de l'exercice : elle mélange le niveau de marge et l'erreur de prévision. Le résidu correspondant sur l'échelle monétaire est $e_t = y_t - \hat{\beta}x_t$, égal à $x_t(r_t - \hat{\beta})$: à un facteur de volume près, il coïncide avec u_t . C'est donc u_t qui est retenu comme base « brute », le passage au ratio neutralisant l'effet de taille au premier ordre.

Amplitude effective de l'hétéroscédasticité résiduelle

Sous le modèle, $\text{Var}(r_t) = \sigma^2[\delta + (1 - \delta)\bar{x}/x_t]$. Sur un jeu de volumes allant de 50 à 200 avec $\delta = 0,35$, l'écart-type théorique des r_t varie de 0,120 à 0,076, soit un facteur 1,6 entre la première et la dernière année. Les u_t ne sont donc pas identiquement distribués : toute loi de référence supposant l'échangeabilité (permutation, combinatoire, ou normale i.i.d.) est invalide sur cette base. Cette invalidité disparaît lorsque $\hat{\pi}_t$ est constant — c'est-à-dire lorsque $\hat{\delta} = 1$, ou lorsque les volumes x_t le sont — puisque les r_t sont alors identiquement distribués. Les trois séries ne deviennent pas pour autant proportionnelles : $z_t = \sqrt{\hat{\pi}_t} v_t$ l'est bien de v_t , à facteur constant, mais u_t vit sur l'échelle linéaire quand v_t vit sur l'échelle logarithmique, et l'on ne passe de l'une à l'autre que par une transformation monotone non linéaire. Ce point est repris plus bas : à $\hat{\pi}_t$ constant, cette transformation est tout ce qui sépare encore les deux bases, ce qui prive la base u_t de son objet.

Où la bascule est légitime, et où elle ne l'est pas

Famille	Bascule	Justification
H1 — linéarité	sans objet	Les tests de tendance (Spearman, Mann–Kendall, Cox–Stuart) portent <i>déjà</i> sur r_t . Il n'existe pas de version sur z_t qui aurait un sens : la tendance recherchée est celle du ratio lui-même.
H2 — variance	non	Changer de base changerait l'hypothèse nulle. Sur z_t , on teste s'il subsiste une hétéroscédasticité <i>après</i> pondération, ce qui doit être rejeté par les données si le modèle est correct. Sur u_t , on testerait l'hétéroscédasticité <i>brute</i> , dont la présence est précisément ce que le modèle postule : le test serait attendu significatif et ne dirait rien de la qualité du calibrage.
H3 — lognormalité	non	Le modèle prédit que z_t est normal, non que r_t l'est (r_t est approximativement lognormal). Tester la normalité de u_t reviendrait à tester une hypothèse que le modèle ne formule pas. Sur v_t , la normalité est bien prédite mais la variance $1/\hat{\pi}_t$ n'est pas constante, ce qui invalide les tests de normalité usuels dès que $\hat{\pi}_t$ varie, c'est-à-dire dès que $\hat{\delta} < 1$ et que les volumes x_t ne sont pas constants.
H4 — indépendance	oui	L'indépendance est une propriété que le modèle attribue aux Y_t <i>conditionnellement</i> aux x_t : elle se transmet aux trois séries. Les deux bases testent donc la même hypothèse.
Stabilité et valeurs aberrantes	oui	Idem. Sur u_t , une valeur aberrante s'interprète directement comme un boni/mali exceptionnel et une rupture comme un changement de régime du ratio, sans dépendre de la qualité de l'ajustement.

Statut des p-values selon la base

Sur la base u_t , les p-values exactes et asymptotiques sont **indicatives seulement** : elles supposent l'échangeabilité, mise en défaut par l'hétéroscédasticité résiduelle. En revanche, **la p-value de Monte-Carlo reste exactement valide** : le bootstrap paramétrique simule Y_t sous le modèle ajusté, donc la loi de référence d'une statistique quelconque des données — y compris calculée sur u_t — est correctement reproduite, hétéroscédasticité comprise. C'est cette p-value que le moteur retient sur cette base.

Vérification par simulation à $T = 8$, sous H_0 , statistiques calculées sur u_t et p-values de Monte-Carlo (400 répliquions, $B = 199$) :

Statistique sur u_t	rejets à 10 %	rejets à 5 %
Durbin–Watson	0,107	0,050
Grubbs	0,115	0,055

Les deux valeurs sont compatibles avec les niveaux nominaux à l'intérieur de l'intervalle de confiance à 95 % ($\pm 0,029$ et $\pm 0,021$).

Ce contrôle est sans objet lorsque $\hat{\pi}_t$ est constant

Six lignes de la table auditable sont calculées sur la base u_t : Durbin–Watson, Ljung–Box au retard 1, test des suites, rupture de niveau (sup-F), stabilité cumulée (OLS-CUSUM) et Grubbs, chacune ayant son homologue sur z_t . Le contrôle qu'elles portent consiste à vérifier que les conclusions d'indépendance et de stabilité ne sont pas un artefact de la pondération $\hat{\pi}_t$. **Là où il n'y a pas de pondération, il n'y a pas d'artefact de pondération à détecter**, et ce contrôle perd son objet. C'est le cas dès que $\hat{\pi}_t$ est constant, donc à $\hat{\delta} = 1$ ou à volumes x_t constants — soit le cas courant à $T = 8$.

Conséquence algébrique exacte. Lorsque $\hat{\pi}_t \equiv \hat{\pi}$, la forme fermée de $\ln \hat{\beta}$ se réduit à $\ln \hat{\beta} = \frac{1}{2\hat{\pi}} + \overline{\ln r}$, d'où $v_t = \ln r_t - \overline{\ln r}$ et

$$z_t = \sqrt{\hat{\pi}} (\ln r_t - \overline{\ln r}).$$

Les deux bases ne diffèrent alors plus que par la transformation logarithmique $r \mapsto \ln r$, à un facteur d'échelle et un recentrage près. Cette transformation est *monotone*.

Conséquence exacte pour le test des suites. La statistique des suites ne dépend que des signes des écarts à la médiane, qu'une transformation monotone préserve : elle prend donc la **même valeur** sur les deux bases. Mesuré sur le jeu de contrôle ($T = 8, \hat{\delta} = 1$) : $Z = -0,7637626$ sur z_t comme sur u_t , et les huit signes de $r_t - \text{med}(r)$ et de $z_t - \text{med}(z)$ coïncident un à un. Les deux lignes affichent néanmoins des p-values différentes (1,000 contre 0,768), non parce que la statistique diffère, mais parce que la ligne sur z_t retient la p-value exacte combinatoire alors que celle sur u_t retient une p-value de Monte-Carlo.

Pour les cinq autres, un écart du second ordre. En écrivant $r_t = \bar{r}(1 + \varepsilon_t)$, le développement de $\ln$ donne $\ln r_t - \ln \bar{r} = \varepsilon_t + \mathcal{O}(\varepsilon_t^2)$: les deux séries centrées coïncident au premier ordre, et leur différence est d'ordre ε^2 , soit du *second* ordre en coefficient de variation des r_t (approximation numérique, développement limité). L'écart tient donc à l'opposition *logarithmique contre linéaire*, et non à $\hat{\pi}_t$. Mesuré sur le jeu de contrôle, où le coefficient de variation vaut $\text{CV}(r) = 0,151$: l'écart maximal entre $\ln r_t - \ln \bar{r}$ et $(r_t - \bar{r})/\bar{r}$ vaut 0,0143, à comparer à $\text{CV}(r)^2 = 0,0228$; $\text{cor}(z, u) = 0,998$ et $\text{cor}(z, \ln r) = 1$ à la précision machine. Les six lignes sur base u_t et leurs six homologues sur z_t y portent le même verdict OK ; pour les cinq paires autres que le test des suites, les p-values retenues diffèrent d'au plus 0,091 (sup-F, 0,840 contre 0,931), l'écart le plus faible étant celui de Durbin–Watson (0,0011). Une statistique qui repose sur une quasi-annulation garde en revanche un écart relatif important sur la valeur elle-même — Ljung–Box au retard 1 vaut $9,2 \cdot 10^{-3}$ sur z_t et $1,3 \cdot 10^{-4}$ sur u_t — sans que le verdict en dépende à ce niveau de p-value.

Ce que cela change pour le dossier, et ce que cela ne change pas. Les six lignes restent exactes : leur statistique, leur p-value de Monte-Carlo et leur verdict sont justes, et elles gardent tout leur sens *lorsque* $\hat{\pi}_t$ *varie*, cas pour lequel elles ont été prévues. Ce qui était faux est la promesse formulée sans condition : présentées comme six vérifications indépendantes, elles sont, à $\hat{\pi}_t$ constant, des **quasi-doublons** de leurs homologues sur z_t — et un doublon exact pour le test des suites. Six verdicts OK de la table auditable n'y apportent donc pas six informations. Le moteur porte lui-même cette réserve : dans ce cas, le champ détail de chacune des six lignes commence par « CONTROLE SANS OBJET ICI » et indique que la ligne est un quasi-doublon de son homologue sur résidus standardisés. La situation n'a rien d'exceptionnel : sur les 999 répliques du bootstrap paramétrique du jeu de contrôle, 493 — soit 49,3 % — ont un $\hat{\pi}_t^*$ constant (constat de simulation, graine 20260831).

Usage recommandé. La base z_t reste celle du dossier : c'est la seule sur laquelle les p-values exactes et asymptotiques sont valides, et c'est elle qui teste les hypothèses telles que l'annexe XVII les formule. La base u_t est un *contrôle de cohérence de la pondération*, **sous la condition que cette pondération existe** : elle vérifie que les conclusions d'indépendance et de stabilité ne sont pas un artefact des poids $\hat{\pi}_t$. Une divergence marquée entre les deux bases sur un même test signale que le résultat dépend du modèle plutôt que des données, et doit être documentée. **Lorsque $\hat{\pi}_t$ est constant, ce contrôle est sans objet** et les six lignes correspondantes sont des quasi-doublons de leurs homologues sur z_t : elles ne doivent pas être lues comme six vérifications supplémentaires (voir « Ce contrôle est sans objet lorsque $\hat{\pi}_t$ est constant », plus haut dans cette sous-section, et le champ détail de ces lignes, qui porte la réserve). Les deux bases sont calculées systématiquement par le moteur et figurent toutes deux dans l'export ; la bascule de l'application ne fait que filtrer l'affichage.

5.7 Variantes principales et secondaires

Quatre tests existent dans le dispositif sous deux formes concurrentes. Pour alléger la lecture, l'application n'affiche par défaut que la forme retenue comme référence, les autres restant accessibles par une

case à cocher et présentes dans l'export.

Forme de référence	Forme secondaire	Motif du choix
Breusch–Pagan studen- tisé (Koenker)	Breusch–Pagan original (1979)	La forme originale suppose la normalité des erreurs, hypothèse non acquise à $T = 8$; elle sur-rejette fortement sur queues lourdes.
Shapiro–Wilk (Royston)	Shapiro–Wilk à loi nulle simulée	Les deux concordent à $T = 8$ (4,95 % contre 5,05 %). La forme de Royston est retenue comme référence parce qu'elle est celle de <code>shapiro.test()</code> , donc la plus immédiatement vérifiable.
Lilliefors	Kolmogorov–Smirnov contre $\mathcal{N}(0, 1)$	La seconde applique une loi de référence valable à paramètres connus ; à paramètres estimés elle est vidée de sa puissance.
Ljung–Box	Box–Pierce	La pondération $(T+2)/(T-k)$ de Ljung–Box corrige le biais de petit échantillon que Box–Pierce ignore.

Le classement en forme de référence et forme secondaire est une convention d'*affichage*, consignée dans le champ variante de la table des tests. Il ne modifie ni les calculs, ni les verdicts, ni le contenu de l'export.

5.8 Tests dont l'usage reste fragile à $T = 8$

Les tests suivants figurent dans le dispositif mais leur interprétation doit être explicitement réservée à $T = 8$. Chacun est accompagné d'un complément méthodologique, indiqué en troisième colonne.

Test	Fragilité à $T = 8$	Complément méthodologique
Méthode lognormale		
Cox–Stuart	$m = 4$ paires $\Rightarrow p_{\min} = 2 \cdot 2^{-4} = 0,125$: le rejet est <i>impossible</i> à tout seuil usuel	Conservé (loi exacte), mais signalé comme inopérant ; la détection de tendance repose sur Mann–Kendall exact
Jarque–Bera	b_2 borné par $\sim T$; convergence χ^2_2 très lente	p-value de Monte-Carlo ajoutée ; test à lire comme purement indicatif
White	3 coefficients auxiliaires estimés sur 8 points	p-value de Monte-Carlo ajoutée ; Breusch–Pagan à privilégier
Anscombe–Glynn	Non défini pour $T < 20$	Marqué <i>non applicable</i> ; l’analyse de queue repose sur A^2 et le QQ-plot à enveloppe
Rosner (ESD)	Fiabilité des valeurs critiques annoncée pour $T \geq 25$	Conservé comme signal d’attention ; aucune exclusion de donnée ne doit en découler sans justification métier
sup-F, OLS-CUSUM	Convergence fonctionnelle ; 8 points ne forment pas une trajectoire limite	p-value de Monte-Carlo seule retenue ; à lire conjointement avec la distance de Cook
Student / Fisher (pente)	Loi exacte, mais <i>conditionnelle</i> à la normalité des erreurs, non testable indépendamment à $T = 8$	Aucune p-value de Monte-Carlo possible (voir texte) ; la normalité est examinée séparément en section 6
Méthode Merz–Wüthrich		
Corrélation entre années de développement	Cinq à six paires de colonnes seulement comptent au moins trois observations à $T = 8$	Aucune loi analytique n’existe ; bootstrap seul recours, puissance très faible
Rosner (ESD) sur résidus de Mack	Fiabilité annoncée pour $n \geq 25$; un triangle 8×8 fournit 28 résidus, soit la limite du domaine	Conservé comme signal d’attention ; aucune exclusion de cellule sur ce fondement
Extrapolation de $\hat{\sigma}_{T-1}^2$	La quantité n’est pas estimée mais imposée par une règle du règlement, appuyée sur deux colonnes	Diagnostic dédié ; à mentionner explicitement dans le dossier
Tests de normalité (M5)	Non exigés par le modèle, et exclus du bootstrap de résidus dont la nulle est la loi empirique observée	Loi nulle propre pour Shapiro–Wilk ; lecture comme diagnostic seulement

PARTIE III

Fiches de tests par hypothèse

Hypothèse H1 — linéarité et proportionnalité

Énoncé réglementaire (annexe XVII, B/C(2)(f)(i)). L'espérance des pertes agrégées est *linéairement proportionnelle* aux primes acquises (ou à la provision d'ouverture) : $\mathbb{E}[Y_t] = \beta x_t$, sans terme constant, avec β constant dans le temps.

6.1 Test de Student sur la constante

Référence. W. S. Gosset (« Student »), *The probable error of a mean*, *Biometrika*, 6(1), 1908, p. 1–25.

1. Cadre, notations et hypothèses de validité (non testées). Régression auxiliaire $y_t = a + bx_t + \varepsilon_t$. Hypothèses non testées : les ε_t sont indépendants, de variance constante σ_ε^2 , de loi $\mathcal{N}(0, \sigma_\varepsilon^2)$, et les x_t sont exogènes et non aléatoires. Nécessite $T \geq 3$ et $S_{xx} > 0$.

2. Hypothèse nulle. $H_0 : a = 0$, absence de composante de sinistralité indépendante du volume. C'est la traduction testable de la *proportionnalité stricte* exigée par le règlement.

3. Statistique de test.

$$t_a = \frac{\hat{a}}{\widehat{\text{se}}(\hat{a})}, \quad \widehat{\text{se}}(\hat{a}) = \hat{s} \sqrt{\frac{1}{T} + \frac{\bar{x}^2}{S_{xx}}}, \quad \hat{s}^2 = \frac{\text{SCR}}{T-2}.$$

4. Loi sous H_0 . $t_a \sim t(T-2)$, loi exacte sous normalité des erreurs.

5. p-value. $p = 2(1 - F_{t, T-2}(|t_a|))$. Cette p-value est **exacte** sous normalité des erreurs : elle est donc retenue en priorité par le moteur, la p-value de Monte-Carlo n'étant calculée qu'à titre de recoupement (les deux concordent étroitement sur le jeu de référence).

6. Usage et limites. On souhaite *ne pas* rejeter H_0 , ce qui constitue la faiblesse logique de ce test : **l'absence de preuve n'est pas une preuve d'absence**. Un non-rejet ne démontre pas la proportionnalité, alors que c'est précisément ce que le règlement demande d'établir. Limite aggravante dans le contexte USP : x_t est un volume toujours très éloigné de zéro et de faible amplitude relative. La constante est donc extrapolée loin du domaine des données et $\widehat{\text{se}}(\hat{a})$ est mécaniquement très grande (le terme $\bar{x}^2/S_{xx}$ domine), si bien que le test ne rejette pratiquement jamais. Le test d'équivalence de la fiche suivante renverse cette charge de la preuve.

6.2 Équivalence de la constante à zéro (TOST)

Référence. D.J. Schuirmann, *A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability*, *Journal of Pharmacokinetics and Biopharmaceutics*, 15(6), 1987, p. 657–680; W.J. Westlake, *Response to T.B.L. Kirkwood : bioequivalence testing — a need to rethink*, *Biometrics*, 37(3), 1981, p. 589–594.

1. Cadre, notations et hypothèses de validité (non testées). Même régression auxiliaire et mêmes hypothèses de validité que la fiche précédente. On se donne en outre une *marge d'équivalence* $\Delta > 0$, qui n'est pas une quantité statistique mais un seuil économique : en deçà de Δ , une composante fixe de sinistralité est jugée sans portée pratique. Le moteur propose deux modes : Δ fixée a priori (`delta_equiv`), ou $\Delta = \theta \bar{y}$ (`theta_equiv`, 10 % par défaut), c'est-à-dire une fraction de la perte annuelle moyenne.

2. Hypothèse nulle.

$$H_0 : |a| \geq \Delta \quad (\text{la constante n'est pas négligeable}) \quad \text{contre} \quad H_1 : |a| < \Delta.$$

Les rôles sont inversés par rapport au test précédent : c'est le *rejet* de H_0 qui établit la proportionnalité pratique. L'hypothèse à démontrer est passée en H_1 , ce qui est la construction correcte lorsque l'on veut prouver une absence d'effet.

3. Statistique de test. Décomposition en deux tests unilatéraux (procédure d'intersection-union) :

$$t_{\text{bas}} = \frac{\hat{a} + \Delta}{\widehat{\text{se}}(\hat{a})} \quad (H_0^- : a \leq -\Delta), \quad t_{\text{haut}} = \frac{\hat{a} - \Delta}{\widehat{\text{se}}(\hat{a})} \quad (H_0^+ : a \geq +\Delta).$$

On rejette H_0 au niveau α si et seulement si les deux sous-hypothèses sont rejetées, soit $t_{\text{bas}} > t_{1-\alpha, T-2}$ et $t_{\text{haut}} < -t_{1-\alpha, T-2}$.

4. Loi sous H_0 . Chaque statistique unilatérale suit *exactement* une loi de Student à $T - 2$ degrés de liberté sous normalité des erreurs. Aucun résultat asymptotique n'intervient.

5. p-value. Règle du maximum, propre aux procédures d'intersection-union :

$$p_{\text{TOST}} = \max \left(1 - F_{t, T-2}(t_{\text{bas}}), F_{t, T-2}(t_{\text{haut}}) \right).$$

Cette p-value est exacte **si Δ est fixée a priori**. Avec la marge relative $\Delta = \theta \bar{y}$, la marge dépend des données et l'exactitude n'est plus qu'approchée ; le moteur signale alors la nature de la p-value comme *quasi-exacte* et non comme exacte. Pour un dossier ACPR, il est recommandé d'arrêter Δ à l'avance et de le documenter.

6. Usage et limites. C'est le seul test du dispositif qui puisse fournir une *preuve positive* de la proportionnalité exigée par l'annexe XVII. Sa limite est celle de tous les tests à $T = 8$: la puissance est faible. Une étude de simulation sous $a = 0$ avec $\theta = 10\%$ donne une probabilité de conclure à l'équivalence de 46 % à $T = 8$, 80 % à $T = 15$ et 98 % à $T = 30$. Autrement dit, à $T = 8$, l'échec à démontrer l'équivalence est le résultat le plus probable *même lorsque la proportionnalité est parfaitement vérifiée* : ce résultat ne doit donc pas être présenté comme un indice défavorable, mais comme une limite d'information.

Formulation écartée. Poser $H_0 : a > 0$ et $H_0 : a < 0$ comme deux tests séparés sans marge ne répond pas au besoin : rejeter $H_0 : a \geq 0$ prouve $a < 0$, donc une preuve *contre* la proportionnalité. Quant à l'union $H_0 : a \neq 0$, elle n'est pas testable : la valeur $a = 0$ est adhérente à cet ensemble, la borne supérieure de la probabilité de rejet sur H_0 y vaut 1, et aucun test de niveau $\alpha < 1$ n'existe. L'introduction d'une marge $\Delta > 0$ strictement positive est ce qui rend le problème bien posé.

6.3 Test de Student sur la pente

Référence. Student (1908), *op. cit.*

1. Cadre, notations et hypothèses de validité (non testées). Identique à la fiche précédente (mêmes hypothèses de validité non testées).

2. Hypothèse nulle. $H_0 : b = 0$, absence de tout lien linéaire entre le volume et les pertes.

3. Statistique de test.

$$t_b = \frac{\hat{b}}{\widehat{\text{se}}(\hat{b})}, \quad \hat{b} = \frac{S_{xy}}{S_{xx}}, \quad \widehat{\text{se}}(\hat{b}) = \frac{\hat{s}}{\sqrt{S_{xx}}}.$$

4. Loi sous H_0 . $t_b \sim t(T - 2)$.

5. p-value. $p = 2(1 - F_{t, T-2}(|t_b|))$.

6. Usage et limites. Ce test s'interprète en sens inverse des autres tests de cette section : on souhaite ici *rejeter* H_0 . Une pente non significative signifierait que le volume n'explique pas les pertes, ce qui priverait de fondement le modèle réglementaire sur ce segment. Le script traduit cette inversion dans ses verdicts (p faible $\Rightarrow$ OK). Limites : avec $T = 10$ la puissance reste modeste ; et la significativité de la pente ne dit rien sur la *proportionnalité* (absence de constante), qui relève de la fiche précédente. Les deux tests sont complémentaires et non substituables.

6.4 Test de Fisher de significativité globale

Référence. R. A. Fisher, *On the mathematical foundations of theoretical statistics*, *Philosophical Transactions of the Royal Society A*, 222, 1922, p. 309–368 ; *Statistical Methods for Research Workers*, Oliver & Boyd, Édimbourg, 1925.

1. Cadre, notations et hypothèses de validité (non testées). Identique aux deux fiches précédentes. On note k le nombre de régresseurs hors constante (ici $k = 1$).

2. Hypothèse nulle. $H_0 : b = 0$ (plus généralement, nullité conjointe de tous les coefficients de pente).

3. Statistique de test.

$$F = \frac{(\text{SCT} - \text{SCR})/k}{\text{SCR}/(T - k - 1)} = \frac{R^2/k}{(1 - R^2)/(T - k - 1)}.$$

4. Loi sous H_0 . $F \sim \mathcal{F}(k, T - k - 1)$, soit ici $\mathcal{F}(1, T - 2)$.

5. p-value. $p = 1 - F_{\mathcal{F}, k, T-k-1}(F)$.

6. Usage et limites. On souhaite, comme pour la pente, *rejeter* H_0 . En régression simple ce test est strictement équivalent au test de Student sur la pente ($F = t_b^2$, p-values identiques) : il est conservé pour la lisibilité du rapport et redeviendrait informatif si l'on ajoutait des régresseurs (indicatrices d'année, variable d'inflation). Même limite de puissance à T faible.

6.5 Coefficient de détermination R^2

Référence. Sortie standard de `lm()`. Sur la loi sous H_0 : R. A. Fisher, *The general sampling distribution of the multiple correlation coefficient*, *Proceedings of the Royal Society A*, 121, 1928, p. 654–673.

1. Cadre, notations et hypothèses de validité (non testées). Même régression auxiliaire. **Il ne s'agit pas d'un test** mais d'un indicateur descriptif ; les rubriques sont renseignées par cohérence de présentation.

2. Hypothèse nulle. Aucune en tant qu'indicateur. Si l'on souhaite néanmoins tester R^2 , l'hypothèse pertinente est celle du test de Fisher ci-dessus, $H_0 : b = 0$.

3. Statistique de test.

$$R^2 = 1 - \frac{\text{SCR}}{\text{SCT}} = \frac{S_{xy}^2}{S_{xx}S_{yy}}, \quad R_{\text{aj}}^2 = 1 - (1 - R^2) \frac{T - 1}{T - k - 1}.$$

4. Loi sous H_0 . Sous $H_0 : b = 0$ et normalité des erreurs, $R^2 \sim \mathcal{B}\left(\frac{k}{2}, \frac{T-k-1}{2}\right)$ (loi bêta), d'espérance $k/(T - 1)$.

5. p-value. Celle du test de Fisher, $p = 1 - F_{\mathcal{F}, k, T-k-1}\left(\frac{R^2/k}{(1-R^2)/(T-k-1)}\right)$. Le script n'affiche pas de p-value sur cette ligne et la marque comme indicateur.

6. Usage et limites. La loi bêta donne la clé de lecture essentielle : sous H_0 , l'espérance de R^2 vaut $k/(T - 1)$, soit 11 % pour $T = 10$. Autrement dit, un R^2 apparemment « correct » est mécaniquement facile à atteindre sur un petit échantillon et ne doit jamais être lu comme une validation du modèle. Le script signale $R^2 < 0,5$ comme point d'attention, et il convient de privilégier R_{aj}^2 , qui pénalise le nombre de paramètres.

6.6 Test RESET de Ramsey

Référence. J.B. Ramsey, *Tests for specification errors in classical linear least-squares regression analysis*, *Journal of the Royal Statistical Society, Series B*, 31(2), 1969, p. 350–371.

1. Cadre, notations et hypothèses de validité (non testées). On part du modèle contraint réglementaire $y_t = \beta x_t + \varepsilon_t$ (sans constante), d'où $\hat{y}_t = \hat{\beta} x_t$, puis l'on estime le modèle augmenté $y_t = \beta x_t + \gamma_2 \hat{y}_t^2 + \gamma_3 \hat{y}_t^3 + \varepsilon_t$. Hypothèses non testées : erreurs indépendantes, homoscédastiques, normales. Nécessite $T > k + q = 3$.

2. Hypothèse nulle. $H_0 : \gamma_2 = \gamma_3 = 0$, soit « la forme linéaire est correctement spécifiée ».

3. Statistique de test. Avec SCR_0 et SCR_1 les sommes de carrés résiduels des modèles contraint et augmenté, $q = 2$ restrictions et $k = 1$ paramètre contraint :

$$F = \frac{(\text{SCR}_0 - \text{SCR}_1)/q}{\text{SCR}_1/(T - k - q)}.$$

4. Loi sous H_0 . $F \sim \mathcal{F}(q, T - k - q)$, soit $\mathcal{F}(2, T - 3)$.

5. p-value. $p = 1 - F_{\mathcal{F}, q, T-k-q}(F)$.

6. Usage et limites. On souhaite *ne pas* rejeter. Le test est générique : il détecte une non-linéarité sans en indiquer la forme. Limites à T faible : avec $T = 5$ il ne reste que 2 degrés de liberté au dénominateur, ce qui le rend presque inopérant ; et $\hat{y}^2$, $\hat{y}^3$ sont fortement colinéaires lorsque l'amplitude des volumes est faible, ce qui réduit encore la puissance. À utiliser en complément, non en substitution, de l'examen graphique.

6.7 Corrélation de rang de Spearman (ratio contre volume, ratio contre temps)

Référence. C. Spearman, *The proof and measurement of association between two things*, *American Journal of Psychology*, 15(1), 1904, p. 72–101.

1. Cadre, notations et hypothèses de validité (non testées). Couple de séries $(u_t, v_t) : (r_t, x_t)$ pour la variante « ratio contre volume », (r_t, t) pour la variante « ratio contre temps ». On note R_t, Q_t les rangs respectifs et $d_t = R_t - Q_t$. Hypothèses non testées : observations indépendantes, variables continues (peu ou pas d'ex æquo).

2. Hypothèse nulle. H_0 : indépendance des deux séries, donc absence de toute association monotone.

3. Statistique de test. En l'absence d'ex æquo,

$$\hat{\rho}_s = 1 - \frac{6 \sum_{t=1}^T d_t^2}{T(T^2 - 1)}, \quad \text{le script rapportant } S = \sum_t d_t^2.$$

En présence d'ex æquo, $\hat{\rho}_s$ est le coefficient de Pearson calculé sur les rangs.

4. Loi sous H_0 . Sous H_0 , la loi exacte de S est la loi de permutation : les $T!$ appariements de rangs sont équiprobables. Pour T modéré on utilise l'approximation

$$t = \hat{\rho}_s \sqrt{\frac{T-2}{1-\hat{\rho}_s^2}} \sim t(T-2).$$

5. p-value. Approximation employée par le script (appel avec `exact = FALSE`) : $p = 2(1 - F_{t,T-2}(|t|))$. La p-value exacte s'obtient par énumération des permutations.

6. Usage et limites. Test non paramétrique robuste aux valeurs extrêmes et à la non-normalité, bon complément des tests paramétriques précédents. Deux limites : (i) il ne détecte que les associations *monotones* – une relation en U passera inaperçue ; (ii) l'approximation de Student est médiocre pour $T < 10$, où la loi exacte de permutation devrait être préférée. Sur la variante « ratio contre volume », un rejet signale un effet d'échelle non capté par la proportionnalité stricte.

6.8 Test de tendance de Mann–Kendall

Référence. H. B. Mann, *Nonparametric tests against trend*, *Econometrica*, 13(3), 1945, p. 245–259 ; M. G. Kendall, *Rank Correlation Methods*, 4^e éd., Griffin, Londres, 1975.

1. Cadre, notations et hypothèses de validité (non testées). Série chronologique $r_1, \dots, r_T$. Hypothèses non testées : sous H_0 les r_t sont indépendants et identiquement distribués, la variable est continue. On note g le nombre de groupes d'ex æquo et t_g leurs effectifs.

2. Hypothèse nulle. H_0 : absence de tendance monotone, les r_t étant i.i.d. (toutes les permutations chronologiques sont équiprobables).

3. Statistique de test.

$$S = \sum_{i=1}^{T-1} \sum_{j=i+1}^T \text{sign}(r_j - r_i), \quad \text{Var}(S) = \frac{T(T-1)(2T+5) - \sum_g t_g(t_g-1)(2t_g+5)}{18},$$

puis la statistique standardisée avec correction de continuité

$$Z = \begin{cases} (S-1)/\sqrt{\text{Var}(S)} & \text{si } S > 0, \\ 0 & \text{si } S = 0, \\ (S+1)/\sqrt{\text{Var}(S)} & \text{si } S < 0. \end{cases}$$

4. Loi sous H_0 . Sous H_0 , S suit une loi exacte tabulée, symétrique autour de 0 ; asymptotiquement $Z \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$.

5. p-value. $p = 2(1 - \Phi(|Z|))$.

6. Usage et limites. Test de référence pour détecter une dérive progressive du ratio S/P (dérive tarifaire, inflation des sinistres, évolution de la politique de provisionnement), ce qui contredirait directement la constance de β . Limites : l'approximation normale n'est acceptable qu'à partir de $T \approx 10$, en-deçà la loi exacte est nécessaire. Surtout, le test suppose l'indépendance des observations : en présence d'autocorrélation positive il rejette beaucoup trop souvent, ce qui impose de le lire conjointement avec les tests de la section 7.

6.9 Test de tendance par signes de Cox–Stuart

Référence. D. R. Cox, A. Stuart, *Some quick sign tests for trend in location and dispersion*, *Biometrika*, 42(1/2), 1955, p. 80–95.

1. Cadre, notations et hypothèses de validité (non testées). On pose $c = \lceil T/2 \rceil$ et l'on forme les paires (r_t, r_{t+c}) . Soit $D_t = r_{t+c} - r_t$ et m le nombre de paires avec $D_t \neq 0$. Hypothèses non testées : indépendance des observations, continuité.

2. Hypothèse nulle. H_0 : absence de tendance, formalisée par $\mathbb{P}(D_t > 0) = 1/2$ pour toute paire.

3. Statistique de test. $K = \#\{t : D_t > 0\}$, nombre de différences positives parmi les m paires non nulles.

4. Loi sous H_0 . $K \sim \mathcal{B}(m, 1/2)$, loi binomiale *exacte* (aucune approximation asymptotique).

5. p-value. Test binomial bilatéral exact :

$$p = \sum_{j : \mathbb{P}(K=j) \leq \mathbb{P}(K=k_{\text{obs}})} \binom{m}{j} \left(\frac{1}{2}\right)^m,$$

somme des probabilités des issues au moins aussi improbables que celle observée.

6. Usage et limites. Avantage décisif : la loi est exacte, sans hypothèse de normalité ni approximation asymptotique. **Limite rédhibitoire à petit T** : le test n'utilise que le signe de $m \approx T/2$ différences. Pour $T = 10$, $m = 5$ et la p-value bilatérale minimale atteignable vaut $2 \times (1/2)^5 = 0,0625 > 0,05$: *le test ne peut structurellement jamais rejeter au seuil de 5 %*, quelle que soit la force de la tendance. Il faut $m \geq 6$ (donc $T \geq 12$) pour qu'un rejet à 5 % devienne possible. À T faible, ce test est purement indicatif et Mann–Kendall doit lui être préféré.

Hypothèse H2 — structure de variance quadratique

Énoncé réglementaire (annexe XVII, B/C(2)(f)(ii)). La variance des pertes agrégées est $\text{Var}(Y_t) = \sigma^2[(1 - \delta)\bar{x}x_t + \delta x_t^2]$, mélange convexe d’une composante linéaire en volume (risque mutualisable) et d’une composante quadratique (risque systématique). Le paramètre $\delta \in [0, 1]$ est estimé conjointement à γ .

Les tests de cette section portent sur les résidus *déjà normalisés* z_t : si la pondération $\hat{\pi}_t$ capture correctement l’hétéroscédasticité, il ne doit subsister *aucune* relation entre z_t^2 et x_t . Un rejet signale donc une structure de variance mal spécifiée, et non une hétéroscédasticité en soi (qui est attendue sur les données brutes).

7.1 Test de Breusch–Pagan, version studentisée de Koenker

Référence. T. S. Breusch, A. R. Pagan, *A simple test for heteroscedasticity and random coefficient variation*, *Econometrica*, 47(5), 1979, p. 1287–1294 ; version robuste TR^2 due à R. Koenker, *A note on studentizing a test for heteroscedasticity*, *Journal of Econometrics*, 17(1), 1981, p. 107–112.

1. Cadre, notations et hypothèses de validité (non testées). Régression auxiliaire $z_t^2 = c_0 + c_1x_t + \eta_t$, de coefficient de détermination R_{aux}^2 . Hypothèses non testées : indépendance des observations et validité de l’approximation asymptotique.

2. Hypothèse nulle. $H_0 : c_1 = 0$: la variance des résidus normalisés ne dépend pas du volume, donc la pondération réglementaire π_t est correctement spécifiée.

3. Statistique de test.

$$\text{LM} = T \cdot R_{\text{aux}}^2.$$

4. Loi sous H_0 . $\text{LM} \xrightarrow{\mathcal{L}} \chi^2(q)$, q étant le nombre de régresseurs auxiliaires hors constante, ici $q = 1$.

5. p-value. $p = 1 - F_{\chi_q^2}(\text{LM})$.

6. Usage et limites. On souhaite *ne pas* rejeter. Limites sérieuses à T faible : la convergence vers la loi du khi-deux est lente et la taille effective du test s’écarte notablement du niveau nominal pour $T < 30$. De plus, la forme testée est *linéaire* en x_t : une hétéroscédasticité résiduelle de forme différente peut échapper au test, d’où la variante de White. Enfin, la version originale de Breusch–Pagan exige la normalité des erreurs ; la forme TR^2 retenue ici (Koenker) s’en affranchit et est donc préférable dans ce contexte.

7.2 Test de Breusch–Pagan, version originale de 1979

Référence. T. S. Breusch, A. R. Pagan, *A simple test for heteroscedasticity and random coefficient variation*, *Econometrica*, 47(5), 1979, p. 1287–1294.

1. Cadre, notations et hypothèses de validité (non testées). Mêmes données et mêmes notations que la fiche précédente. **Hypothèse de validité supplémentaire, et déterminante : la normalité des erreurs.** C’est elle qui justifie $\text{Var}(u_t^2) = 2\sigma^4$, d’où le facteur $\frac{1}{2}$ de la statistique. Cette hypothèse n’est pas testée ici : elle relève de H3, examinée séparément en partie III.

2. Hypothèse nulle. $H_0 : c_1 = 0$, la variance des résidus normalisés ne dépend pas du volume.

3. Statistique de test. En posant $g_t = z_t^2 / \hat{\sigma}^2$ avec $\hat{\sigma}^2 = T^{-1} \sum_t z_t^2$, on régresse g sur x et l'on retient la moitié de la somme des carrés expliqués :

$$LM = \frac{1}{2} \sum_{t=1}^T (\hat{g}_t - \bar{g})^2.$$

4. Loi sous H_0 . $LM \xrightarrow{\mathcal{L}} \chi^2(q)$ sous H_0 et normalité des erreurs, avec $q = 1$ régresseur auxiliaire.

5. p-value. $p = 1 - F_{\chi_1^2}(LM)$, p-value non simulée. Une p-value de Monte-Carlo est calculée en parallèle et reste celle retenue pour le verdict à $T = 8$.

6. Usage et limites. Cette version est celle qui est publiée et citée dans la littérature ; elle figure dans l'outil à ce titre, et pour permettre la confrontation avec la version studentisée. **Elle n'est pas robuste à la non-normalité** : si les erreurs ont des queues plus lourdes que la normale, alors $\text{Var}(u_t^2) > 2\sigma^4$, le facteur $\frac{1}{2}$ sous-estime la variance de la statistique et le test sur-rejette massivement. L'ampleur du phénomène a été mesurée par simulation.

Loi des erreurs sous H_0	BP 1979	Koenker 1981
Normale, $T = 8$	0,021	0,043
Normale, $T = 30$	0,039	0,047
Normale, $T = 200$	0,051	0,051
Student à 3 ddl (queues lourdes), $T = 200$	0,380	0,041
Exponentielle (asymétrique), $T = 200$	0,270	0,038

Fréquence de rejet au seuil nominal de 5 % sous H_0 vraie, 4 000 réplifications. Sous erreurs normales, les deux versions convergent vers le niveau nominal, la version originale étant seulement conservatrice en petit échantillon. Sous erreurs à queues lourdes, la version originale rejette près de huit fois trop souvent, alors que la version studentisée reste calibrée.

Règle de lecture. Les deux versions doivent être lues *ensemble*. Une divergence marquée entre elles ne signale pas une hétéroscédasticité, mais un écart à la normalité : elle renvoie à H3 et non à H2. Pour conclure sur la structure de variance, c'est la version studentisée qui fait foi, la normalité n'étant jamais acquise à $T = 8$.

7.3 Test de White

Référence. H. White, *A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity*, *Econometrica*, 48(4), 1980, p. 817–838.

1. Cadre, notations et hypothèses de validité (non testées). Régression auxiliaire enrichie $z_t^2 = c_0 + c_1 x_t + c_2 x_t^2 + \eta_t$. Mêmes hypothèses de validité que Breusch–Pagan. Nécessite $T > 3$.

2. Hypothèse nulle. $H_0 : c_1 = c_2 = 0$.

3. Statistique de test. $LM = T \cdot R_{\text{aux}}^2$, avec le R^2 de la régression enrichie.

4. Loi sous H_0 . $LM \xrightarrow{\mathcal{L}} \chi^2(q)$ avec $q = 2$.

5. p-value. $p = 1 - F_{\chi_2^2}(LM)$.

6. Usage et limites. Plus général que Breusch–Pagan (il capte une hétéroscédasticité quadratique) au prix d'un degré de liberté supplémentaire, ce qui le rend peu adapté au régime USP : avec $T = 5$ à 8, estimer

trois coefficients auxiliaires laisse trop peu d'information et la puissance devient très faible. Le test est par ailleurs un test de mauvaise spécification *générale* plutôt que d'hétéroscédasticité stricto sensu : un rejet peut aussi traduire une erreur de forme fonctionnelle relevant de H1.

7.4 Test de Goldfeld–Quandt

Référence. S. M. Goldfeld, R. E. Quandt, *Some tests for homoscedasticity*, *Journal of the American Statistical Association*, 60(310), 1965, p. 539–547.

1. Cadre, notations et hypothèses de validité (non testées). Résidus triés selon x_t croissant, puis scindés en deux sous-groupes de taille $h = \lfloor T/2 \rfloor$ (observation centrale écartée si T impair). Hypothèses non testées : normalité et indépendance des résidus ; la variance, si elle varie, est monotone en x_t .

2. Hypothèse nulle. $H_0 : \sigma_1^2 = \sigma_2^2$, égalité des variances entre le sous-groupe des faibles volumes et celui des forts volumes.

3. Statistique de test.

$$F = \frac{\frac{1}{h} \sum_{t \in \text{groupe haut}} z_t^2}{\frac{1}{h} \sum_{t \in \text{groupe bas}} z_t^2}.$$

4. Loi sous H_0 . $F \sim \mathcal{F}(h, h)$ sous H_0 et normalité. *Approximation* : les z_t provenant d'un ajustement global et non de deux régressions séparées, les degrés de liberté sont légèrement surestimés.

5. p-value. Bilatérale : $p = 2 \min(F_{\mathcal{F}, h, h}(F), 1 - F_{\mathcal{F}, h, h}(F))$.

6. Usage et limites. Test simple et lisible dont le principal défaut est de *jeter la moitié de l'information* utile : il ne compare que deux blocs et ignore la structure interne à chacun. Avec $T = 10$, on compare deux blocs de 5 observations : un rapport de variances de 2 ou 3 ne sera pas détecté. Sensible à la non-normalité, contrairement à Brown–Forsythe.

7.5 Test de Brown–Forsythe

Référence. M. B. Brown, A. B. Forsythe, *Robust tests for the equality of variances*, *Journal of the American Statistical Association*, 69(346), 1974, p. 364–367 ; variante robuste de H. Levene, *Robust tests for equality of variances*, in *Contributions to Probability and Statistics*, Stanford University Press, 1960.

1. Cadre, notations et hypothèses de validité (non testées). Deux groupes $g \in \{1, 2\}$ définis par $x_t \leq \text{med}(x)$ et $x_t > \text{med}(x)$, d'effectifs n_1, n_2 , $N = n_1 + n_2$, $k = 2$. On calcule les écarts absolus à la médiane du groupe, $d_{gi} = |z_{gi} - \text{med}_g(z)|$, de moyennes $\bar{d}_g$ et $\bar{d}$. Hypothèse non testée : indépendance des observations. La normalité n'est *pas* requise, c'est l'apport de la méthode.

2. Hypothèse nulle. H_0 : égalité des dispersions entre les deux groupes.

3. Statistique de test.

$$W = \frac{(N - k) \sum_{g=1}^k n_g (\bar{d}_g - \bar{d})^2}{(k - 1) \sum_{g=1}^k \sum_{i=1}^{n_g} (d_{gi} - \bar{d}_g)^2}.$$

4. Loi sous H_0 . $W \sim \mathcal{F}(k - 1, N - k)$ approximativement, soit ici $\mathcal{F}(1, T - 2)$.

5. p-value. $p = 1 - F_{\mathcal{F}, k-1, N-k}(W)$.

6. Usage et limites. L'usage de la médiane (plutôt que de la moyenne, comme chez Levene) confère une bonne robustesse aux distributions asymétriques ou à queues lourdes, ce qui est précieux en assurance

non-vie. Limite : comme Goldfeld–Quandt, il ne compare que deux blocs et la loi de Fisher n’est qu’approximative. À $T \leq 10$, à considérer comme un simple indicateur.

7.6 Test de Smirnov à deux échantillons

Référence. N. V. Smirnov, *Sur les écarts de la courbe de distribution empirique*, *Recueil Mathématique (Matematicheskii Sbornik)*, 6(48), 1939, p. 3–26.

1. Cadre, notations et hypothèses de validité (non testées). Deux sous-échantillons de résidus normalisés : $z^{(1)}$ (années à faible volume, effectif n_1) et $z^{(2)}$ (années à fort volume, effectif n_2), de fonctions de répartition empiriques $\hat{F}_1, \hat{F}_2$. Hypothèses non testées : indépendance intra et inter échantillons, continuité des lois. Le script n’active ce test que si $T \geq 8$ et $n_1, n_2 \geq 3$.

2. Hypothèse nulle. $H_0 : F_1 = F_2$, égalité complète des lois – hypothèse plus forte que la seule égalité des variances.

3. Statistique de test.

$$D_{n_1, n_2} = \sup_{u \in \mathbb{R}} |\hat{F}_1(u) - \hat{F}_2(u)|.$$

4. Loi sous H_0 . Sous H_0 , la loi exacte de D_{n_1, n_2} est combinatoire (dénombrement de chemins), calculée exactement par `ks.test` en l’absence d’ex æquo. Asymptotiquement, avec $\lambda = \sqrt{n_1 n_2 / (n_1 + n_2)}$:

$$\mathbb{P}(\lambda D_{n_1, n_2} \leq u) \longrightarrow K(u) = 1 - 2 \sum_{j=1}^{\infty} (-1)^{j-1} e^{-2j^2 u^2}.$$

5. p-value. Exacte par énumération pour $n_1 n_2$ petit ; sinon

$$p \approx 2 \sum_{j \geq 1} (-1)^{j-1} \exp(-2j^2 \lambda^2 D_{n_1, n_2}^2).$$

6. Usage et limites. Complément utile aux tests de variance : il détecte aussi un décalage de niveau ou un changement de forme entre petits et gros volumes. Deux limites : (i) puissance faible à effectifs réduits – avec $n_1 = n_2 = 5$, la plus petite p-value atteignable est $2/\binom{10}{5} \approx 0,008$, le rejet reste donc possible mais exige un écart maximal ; (ii) les deux échantillons ne sont pas strictement indépendants puisque les z_t partagent les mêmes paramètres estimés $(\hat{\beta}, \hat{\delta}, \hat{\gamma})$, ce qui invalide légèrement la loi de référence. Le *QQ-plot à deux échantillons* associé (section 9) reste le diagnostic le plus lisible.

7.7 Position de $\hat{\delta}$ dans son domaine (diagnostic)

Référence. Annexe XVII, sections B et C, paragraphe 6 (contrainte $0 \leq \delta \leq 1$).

1. Cadre, notations et hypothèses de validité (non testées). $\hat{\delta}$ est obtenu par minimisation sous contrainte de bornes de la log-vraisemblance négative. **Il ne s’agit pas d’un test** mais d’un diagnostic d’identifiabilité.

2. Hypothèse nulle. Sans objet en tant que diagnostic. Le test formel correspondant est le test du rapport de vraisemblance $H_0 : \delta = 0$ ou $\delta = 1$, documenté en section 10.

3. Statistique de test. La valeur $\hat{\delta}$ elle-même, avec le drapeau $\mathbb{K}\{\hat{\delta} < 10^{-6} \text{ ou } \hat{\delta} > 1 - 10^{-6}\}$.

4. Loi sous H_0 . Sans objet.

5. p-value. Sans objet ; le script marque la ligne ALERTE si la solution est au bord, OK sinon.

6. Usage et limites. Une solution *au bord* signifie que les données ne permettent pas d'identifier un mélange interne des deux composantes de variance : la vraisemblance est monotone en δ sur $[0, 1]$ et l'optimum est poussé sur une borne. Ce n'est pas une erreur mais un signal fort à documenter, car (i) l'écart-type asymptotique de $\hat{\delta}$ n'est alors pas défini de manière usuelle, (ii) le paramètre final peut varier fortement selon la borne retenue, et (iii) la théorie asymptotique standard des tests sur δ ne s'applique plus (voir la correction de Chernoff en section 10). Sur des historiques de 5 à 12 points, la solution au bord est le cas de figure le plus fréquent en pratique.

Hypothèse H3 — lognormalité des pertes agrégées

Énoncé réglementaire (annexe XVII, B/C(2)(f)(iii)). Les pertes agrégées (ou le montant de liquidation) suivent une loi lognormale. Cette hypothèse se teste de façon équivalente comme la normalité des résidus normalisés z_t .

Point commun à toute cette section. Les z_t ne sont pas des observations brutes mais des résidus d'un modèle dont trois paramètres $(\hat{\beta}, \hat{\delta}, \hat{\gamma})$ ont été estimés sur les mêmes données. La loi de référence de tous les tests de normalité en est modifiée (elle devient stochastiquement plus concentrée), ce qui rend ces tests *conservateurs* si l'on utilise les p-values tabulées pour paramètres connus. D'où le recalcul systématique d'une p-value de Monte-Carlo (section 4).

8.1 Test de Shapiro–Wilk

Référence. S. S. Shapiro, M. B. Wilk, *An analysis of variance test for normality (complete samples)*, *Biometrika*, 52(3/4), 1965, p. 591–611 ; normalisation de J. P. Royston, *Approximating the Shapiro-Wilk W-test for non-normality*, *Statistics and Computing*, 2, 1992, p. 117–119.

1. Cadre, notations et hypothèses de validité (non testées). Échantillon $z_1, \dots, z_T$ supposé (hypothèse non testée) i.i.d., sans ex æquo. Valable pour $3 \leq T \leq 5000$. On note $m = (m_1, \dots, m_T)'$ le vecteur des espérances des statistiques d'ordre d'un échantillon normal centré réduit et V leur matrice de covariance.

2. Hypothèse nulle. H_0 : les z_t sont issus d'une loi normale $\mathcal{N}(\mu, \sigma^2)$, μ et σ non spécifiés.

3. Statistique de test.

$$W = \frac{\left(\sum_{i=1}^T a_i z_{(i)}\right)^2}{\sum_{t=1}^T (z_t - \bar{z})^2}, \quad a' = \frac{m'V^{-1}}{\sqrt{m'V^{-1}V^{-1}m}}.$$

$W \in]0, 1]$, une valeur proche de 1 étant favorable à la normalité.

4. Loi sous H_0 . Aucune forme analytique fermée. Royston (1992) fournit une transformation normalisante : pour $12 \leq T \leq 5000$, $\ln(1 - W)$ est approximativement $\mathcal{N}(\mu_W, \sigma_W^2)$, où μ_W et σ_W sont des polynômes en $\ln T$; pour $4 \leq T \leq 11$, la transformation utilisée est $-\ln(\varsigma - \ln(1 - W))$ avec ς dépendant de T .

5. p-value. $p = 1 - \Phi\left(\frac{\ln(1 - W) - \mu_W}{\sigma_W}\right)$ pour $T \geq 12$, avec la transformation adaptée pour $T \leq 11$.

6. Usage et limites. Test de référence pour les petits échantillons et généralement le plus puissant contre un large éventail d'alternatives. Ses limites en régime USP restent néanmoins sévères : à $T = 8$, sa puissance contre une loi à queues lourdes réaliste n'est que de quelques dizaines de pour cent, si bien qu'un p élevé n'apporte quasiment aucune information. Il est par ailleurs sensible aux ex æquo (fréquents si les montants sont arrondis) et à l'estimation préalable des paramètres. **Lire prioritairement p_mc.**

8.2 Test de Shapiro–Francia

Référence. S. S. Shapiro, R. S. Francia, *An approximate analysis of variance test for normality*, *Journal of the American Statistical Association*, 67(337), 1972, p. 215–216 ; p-values selon J. P. Royston, *A toolkit for testing for non-normality in complete and censored samples*, *The Statistician*, 42(1), 1993, p. 37–43.

1. Cadre, notations et hypothèses de validité (non testées). Mêmes hypothèses que Shapiro–Wilk. Valable pour $5 \leq T \leq 5000$. On utilise les scores normaux approchés de Blom, $\tilde{m}_i = \Phi^{-1}((i - 3/8)/(T + 1/4))$.

2. Hypothèse nulle. H_0 : les z_t sont issus d’une loi normale.

3. Statistique de test.

$$W' = \text{corr}(z_{(i)}, \tilde{m}_i)^2 = \frac{\left(\sum_i \tilde{m}_i z_{(i)}\right)^2}{\left(\sum_i \tilde{m}_i^2\right)\left(\sum_t (z_t - \bar{z})^2\right)},$$

soit exactement le carré du coefficient de corrélation du QQ-plot normal.

4. Loi sous H_0 . Pas de forme fermée. Royston (1993) : en posant $u = \ln T$ et $v = \ln u$,

$$\ln(1 - W') \approx \mathcal{N}(\mu, \sigma^2), \quad \mu = -1,2725 + 1,0521(v - u), \quad \sigma = 1,0308 - 0,26758(v + 2/u).$$

5. p-value. $p = 1 - \Phi\left(\frac{\ln(1 - W') - \mu}{\sigma}\right)$.

6. Usage et limites. Simplification de Shapiro–Wilk (remplacement de V^{-1} par l’identité), souvent plus puissante contre les alternatives à *queues lourdes* et légèrement moins contre les alternatives asymétriques. Son intérêt est d’être la traduction numérique exacte du QQ-plot, ce qui facilite la justification en dossier. Mêmes limites de puissance qu’à la fiche précédente.

8.3 Test d’Anderson–Darling

Référence. T. W. Anderson, D. A. Darling, *A test of goodness of fit*, *Journal of the American Statistical Association*, 49(268), 1954, p. 765–769 ; approximations de R. B. D’Agostino, M. A. Stephens (dir.), *Goodness-of-Fit Techniques*, Marcel Dekker, 1986.

1. Cadre, notations et hypothèses de validité (non testées). Échantillon i.i.d. (hypothèse non testée), $p_{(i)} = \Phi(z_{(i)})$. Statistique de distance à la fonction de répartition empirique (famille EDF).

2. Hypothèse nulle. H_0 : les z_t suivent la loi $\mathcal{N}(0, 1)$ de référence.

3. Statistique de test.

$$A^2 = -T - \frac{1}{T} \sum_{i=1}^T (2i - 1) \left[\ln p_{(i)} + \ln(1 - p_{(T+1-i)}) \right],$$

forme discrète de $A^2 = T \int \frac{(\hat{F}(u) - F_0(u))^2}{F_0(u)(1 - F_0(u))} dF_0(u)$: la pondération $[F_0(1 - F_0)]^{-1}$ amplifie les écarts dans les *queues*.

4. Loi sous H_0 . Sous H_0 à paramètres connus, A^2 converge vers une loi limite tabulée indépendante de F_0 . Lorsque les paramètres sont estimés, on utilise la statistique modifiée $A^{*2} = A^2(1 + 0,75/T + 2,25/T^2)$, de loi différente.

5. p-value. Deux p-values sont rapportées. La première est *non simulée* : approximations par morceaux de D’Agostino & Stephens (1986) pour le cas où moyenne et variance sont estimées, par exemple $p \approx \exp(1,2937 - 5,709 A^{*2} + 0,0186 A^{*4})$ sur la plage $0,60 < A^{*2} < 13$, avec d’autres branches ailleurs. Ce sont des ajustements empiriques et non un résultat exact ; leur calibration a été vérifiée par simulation (5,2 % de rejets au seuil de 5 % à $T = 8$). La seconde est la p-value de Monte-Carlo, qui reste celle retenue pour le verdict car elle tient compte du modèle effectivement ajusté.

6. Usage et limites. Test le plus pertinent pour un usage actuariel : la pondération en queue le rend sensible précisément là où se joue le capital réglementaire. Limite propre à ce contexte : cette sensibilité est aussi sa fragilité, car sur 8 à 12 points les deux ou trois observations extrêmes déterminent presque entièrement A^2 . À croiser impérativement avec les tests de valeurs aberrantes de la section 8.

8.4 Test de Cramér–von Mises

Référence. H. Cramér, *On the composition of elementary errors*, *Skandinavisk Aktuarietidskrift*, 11, 1928 ; R. von Mises, *Wahrscheinlichkeit, Statistik und Wahrheit*, Springer, 1928 ; forme et approximations selon M. A. Stephens, *EDF statistics for goodness of fit and some comparisons*, *JASA*, 69(347), 1974, p. 730–737.

1. Cadre, notations et hypothèses de validité (non testées). Identique à Anderson–Darling.

2. Hypothèse nulle. H_0 : les z_t suivent $\mathcal{N}(0, 1)$.

3. Statistique de test.

$$W^2 = \frac{1}{12T} + \sum_{i=1}^T \left(p_{(i)} - \frac{2i-1}{2T} \right)^2 = T \int (\hat{F} - F_0)^2 dF_0.$$

4. Loi sous H_0 . Loi limite de Cramér–von Mises sous H_0 à paramètres connus ; statistique modifiée $W^{*2} = W^2(1 + 0,5/T)$ lorsque les paramètres sont estimés.

5. p-value. Approximations par morceaux de Stephens pour le cas à paramètres estimés, rapportées comme p-value non simulée (calibration vérifiée par simulation : 4,9 % de rejets au seuil de 5 % à $T = 8$) ; la p-value de Monte-Carlo reste celle retenue pour le verdict.

6. Usage et limites. Version non pondérée d’Anderson–Darling : elle accorde le même poids à toute la distribution, et est donc *moins* sensible aux queues, ce qui la rend plus stable mais moins pertinente pour un usage prudentiel. Utile en recoupement : un rejet par A^2 non confirmé par W^2 oriente vers un problème localisé en queue plutôt que vers une non-normalité d’ensemble.

8.5 Test de Kolmogorov–Smirnov contre $\mathcal{N}(0, 1)$

Référence. A. N. Kolmogorov, *Sulla determinazione empirica di una legge di distribuzione*, *Giornale dell’Istituto Italiano degli Attuari*, 4, 1933, p. 83–91 ; H. W. Lilliefors, *On the Kolmogorov–Smirnov test for normality with mean and variance unknown*, *JASA*, 62(318), 1967, p. 399–402.

1. Cadre, notations et hypothèses de validité (non testées). Identique aux deux fiches précédentes.

2. Hypothèse nulle. H_0 : les z_t suivent $\mathcal{N}(0, 1)$.

3. Statistique de test.

$$D = \sup_u |\hat{F}(u) - \Phi(u)| = \max_{1 \leq i \leq T} \max \left(\frac{i}{T} - p_{(i)}, p_{(i)} - \frac{i-1}{T} \right).$$

4. Loi sous H_0 . À paramètres connus, $\sqrt{T} D$ converge vers la loi de Kolmogorov :

$$\mathbb{P}(\sqrt{T} D \leq u) \longrightarrow K(u) = 1 - 2 \sum_{j=1}^{\infty} (-1)^{j-1} e^{-2j^2 u^2}.$$

À paramètres *estimés*, la loi correcte est celle de Lilliefors, stochastiquement plus concentrée et sans forme analytique.

5. p-value. $p \approx 2 \sum_{j \geq 1} (-1)^{j-1} \exp(-2j^2 T D^2)$, formule de Kolmogorov, rapportée à titre de p-value non simulée. La p-value de Monte-Carlo reste celle retenue pour le verdict.

6. Usage et limites. Test historiquement dominant mais *le moins puissant* de cette section : le supremum ne retient qu'un seul point d'écart et sous-pondère les queues. Piège classique, quantifié ici : appliquer la loi de Kolmogorov alors que les paramètres ont été estimés rend le test extrêmement conservateur. Une simulation à $T = 8$ donne **zéro rejet sur 3 000 répliques** au seuil de 5 %, ce qui produirait une fausse impression de validation. Le test de Lilliefors (fiche suivante) est la réponse correcte à cette situation.

8.6 Test de Lilliefors

Référence. H. W. Lilliefors, *On the Kolmogorov-Smirnov test for normality with mean and variance unknown*, *Journal of the American Statistical Association*, 62(318), 1967, p. 399–402 ; p-value : G. E. Dallal, L. Wilkinson, *An analytic approximation to the distribution of Lilliefors' test statistic for normality*, *The American Statistician*, 40(4), 1986, p. 294–296, prolongée au-delà de 0,10 par les polynômes de Stephens (1974).

1. Cadre, notations et hypothèses de validité (non testées). Échantillon i.i.d. (hypothèse non testée). **Différence essentielle avec la fiche précédente :** la moyenne et l'écart-type ne sont pas ceux du modèle mais sont *estimés sur l'échantillon lui-même*, ce qui correspond à la situation réelle lorsque l'on teste la normalité sans connaître les paramètres.

2. Hypothèse nulle. H_0 : les z_t sont issus d'une loi normale de moyenne et de variance quelconques.

3. Statistique de test.

$$D_L = \sup_u \left| \hat{F}(u) - \Phi\left(\frac{u - \bar{z}}{s_z}\right) \right|,$$

soit la statistique de Kolmogorov–Smirnov calculée après standardisation empirique.

4. Loi sous H_0 . Loi de Lilliefors, *stochastiquement plus concentrée* que celle de Kolmogorov puisque l'ajustement des paramètres rapproche mécaniquement $\hat{F}$ de la loi de référence. Elle n'a pas de forme analytique fermée.

5. p-value. Approximation analytique de Dallal & Wilkinson (1986), valable pour $p < 0,10$:

$$p \approx \exp\left(-7,01256 K^2(T + 2,78019) + 2,99587 K \sqrt{T + 2,78019} - 0,122119 + \frac{0,974598}{\sqrt{T}} + \frac{1,67997}{T}\right),$$

prolongée au-delà par les polynômes de Stephens. Il s'agit d'une p-value **non simulée**, disponible dès $T \geq 5$. Une p-value de Monte-Carlo est calculée en parallèle.

6. Usage et limites. C'est la version correcte du test de Kolmogorov–Smirnov lorsque les paramètres sont estimés. La calibration a été vérifiée par simulation à $T = 8$: 10,6 % de rejets au seuil nominal de 10 % et 5,2 % au seuil de 5 %, à comparer aux 0 % du test de Kolmogorov mal appliqué. Sa puissance reste néanmoins celle de la famille Kolmogorov–Smirnov, c'est-à-dire faible devant Shapiro–Wilk et Anderson–Darling.

8.7 Shapiro–Wilk sans la normalisation de Royston

Référence. Shapiro & Wilk (1965), *op. cit.*; loi nulle évaluée par simulation directe. Sur la légitimité de l’invariance : la statistique W est invariante par translation et par changement d’échelle, propriété établie dans l’article original.

1. Cadre, notations et hypothèses de validité (non testées). Même statistique W que la fiche « Shapiro–Wilk »; seule la *loi de référence* change.

2. Hypothèse nulle. H_0 : les z_t sont issus d’une loi normale.

3. Statistique de test. W , identique à la fiche précédente.

4. Loi sous H_0 . W étant invariante par translation et par changement d’échelle, sa loi sous H_0 ne dépend d’aucun paramètre : elle ne dépend que de T . Elle peut donc être évaluée numériquement en simulant des échantillons $\mathcal{N}(0, 1)$ de taille T . L’outil emploie 20 000 tirages, mis en cache par valeur de T et pilotés par une graine dédiée.

5. p-value. $\hat{p} = (1 + \#\{W^{(b)} \leq W_{\text{obs}}\}) / (B_{\text{null}} + 1)$, rejet en queue basse.

6. Usage et limites. Cette variante répond à une objection de principe : la p-value de `shapiro.test()` repose sur la transformation normalisante de Royston (1992), qui est un *ajustement empirique*, non un résultat exact. La version proposée ici évalue directement la loi exacte de W , à l’erreur de Monte-Carlo près, en $\mathcal{O}(B_{\text{null}}^{-1/2})$.

Point important à ne pas confondre. Cette simulation n’est *pas* un bootstrap paramétrique : elle ne dépend pas du modèle USP ajusté, mais seulement de T . Elle relève donc de la catégorie « exacte, évaluée numériquement » et non de la catégorie « Monte-Carlo » du tableau 5.4. En pratique, les deux versions concordent étroitement : sur 2 000 répliques à $T = 8$, la fréquence de rejet au seuil de 5 % vaut 4,95 % pour la loi simulée contre 5,05 % pour la normalisation de Royston, ce qui valide a posteriori l’approximation de Royston à cette taille d’échantillon.

8.8 Test de Jarque–Bera

Référence. C. M. Jarque, A. K. Bera, *Efficient tests for normality, homoscedasticity and serial independence of regression residuals*, *Economics Letters*, 6(3), 1980, p. 255–259.

1. Cadre, notations et hypothèses de validité (non testées). Échantillon i.i.d., moments d’ordre 4 finis (hypothèses non testées). Test du multiplicateur de Lagrange contre la famille de Pearson.

2. Hypothèse nulle. H_0 : asymétrie et aplatissement conformes à la loi normale, soit $\mathbb{E}[\sqrt{b_1}] = 0$ et $\mathbb{E}[b_2] = 3$ conjointement.

3. Statistique de test.

$$JB = \frac{T}{6} \left(b_1 + \frac{(b_2 - 3)^2}{4} \right), \quad \sqrt{b_1} = \frac{m_3}{m_2^{3/2}}, \quad b_2 = \frac{m_4}{m_2^2}.$$

4. Loi sous H_0 . $JB \xrightarrow{\mathcal{L}} \chi^2(2)$, comme somme des carrés de deux statistiques asymptotiquement normales et indépendantes.

5. p-value. $p = 1 - F_{\chi^2_2}(JB)$.

6. Usage et limites. **À manier avec une grande prudence en régime USP.** La convergence vers $\chi^2(2)$ est notoirement lente : pour $T < 50$, la taille effective s’écarte fortement du niveau nominal. Surtout,

l'aplatissement empirique est *mécaniquement borné*, b_2 ne pouvant dépasser une quantité de l'ordre de T : avec $T = 8$, l'échantillon est structurellement incapable de manifester une queue lourde et le test ne peut pratiquement pas rejeter pour excès d'aplatissement. La p-value p_{mc} est ici indispensable ; en son absence, ce test n'apporte à peu près rien sur un historique réglementaire minimal.

8.9 Test d'asymétrie de D'Agostino

Référence. R. B. D'Agostino, *Transformation to normality of the null distribution of g_1* , *Biometrika*, 57(3), 1970, p. 679–681.

1. Cadre, notations et hypothèses de validité (non testées). Échantillon i.i.d. ; nécessite $T \geq 8$ pour que la transformation normalisante soit définie, le script marquant le test non applicable en-deçà.

2. Hypothèse nulle. H_0 : coefficient d'asymétrie de la population nul.

3. Statistique de test. En posant $\sqrt{b_1} = m_3/m_2^{3/2}$:

$$Y = \sqrt{b_1} \sqrt{\frac{(T+1)(T+3)}{6(T-2)}}, \quad \beta_2 = \frac{3(T^2 + 27T - 70)(T+1)(T+3)}{(T-2)(T+5)(T+7)(T+9)},$$

$$W^2 = -1 + \sqrt{2(\beta_2 - 1)}, \quad \alpha = \sqrt{\frac{2}{W^2 - 1}}, \quad \varsigma = \frac{1}{\sqrt{\ln W}},$$

$$Z = \varsigma \ln \left(\frac{Y}{\alpha} + \sqrt{\left(\frac{Y}{\alpha} \right)^2 + 1} \right) = \varsigma \operatorname{arcsinh} \left(\frac{Y}{\alpha} \right).$$

4. Loi sous H_0 . $Z \sim \mathcal{N}(0, 1)$ approximativement sous H_0 , la transformation de Johnson S_U ci-dessus corrigeant l'asymétrie de la loi exacte de $\sqrt{b_1}$ à T fini.

5. p-value. $p = 2(1 - \Phi(|Z|))$.

6. Usage et limites. Utile pour *localiser* la cause d'un rejet global de normalité : une asymétrie significative oriente vers un mélange de sinistres graves et attritionnels mal séparés, diagnostic actionnable au regard de l'exigence de l'annexe XVII sur le retraitement des événements déjà couverts par les sous-modules catastrophe. Limite : la correction de petit échantillon vaut dès $T \geq 8$, mais la puissance ne devient réellement exploitable que vers $T \geq 20$.

8.10 Test d'aplatissement d'Anscombe–Glynn

Référence. F. J. Anscombe, W. J. Glynn, *Distribution of the kurtosis statistic b_2 for normal samples*, *Biometrika*, 70(1), 1983, p. 227–234.

1. Cadre, notations et hypothèses de validité (non testées). Échantillon i.i.d. ; nécessite $T \geq 20$. Sur un historique réglementaire de 5 à 15 années, ce test est donc presque toujours *non applicable* et le script l'indique explicitement.

2. Hypothèse nulle. H_0 : aplatissement de la population égal à 3 (valeur normale).

3. Statistique de test. Avec $b_2 = m_4/m_2^2$,

$$\mathbb{E}[b_2] = \frac{3(T-1)}{T+1}, \quad \operatorname{Var}(b_2) = \frac{24T(T-2)(T-3)}{(T+1)^2(T+3)(T+5)}, \quad x = \frac{b_2 - \mathbb{E}[b_2]}{\sqrt{\operatorname{Var}(b_2)}},$$

$$\sqrt{\beta_1} = \frac{6(T^2 - 5T + 2)}{(T + 7)(T + 9)} \sqrt{\frac{6(T + 3)(T + 5)}{T(T - 2)(T - 3)}}, \quad A = 6 + \frac{8}{\sqrt{\beta_1}} \left(\frac{2}{\sqrt{\beta_1}} + \sqrt{1 + \frac{4}{\beta_1}} \right),$$

$$Z = \frac{\left(1 - \frac{2}{9A}\right) - \left(\frac{1 - 2/A}{1 + x\sqrt{2/(A-4)}}\right)^{1/3}}{\sqrt{2/(9A)}}.$$

4. Loi sous H_0 . $Z \sim \mathcal{N}(0, 1)$ approximativement (transformation de Wilson–Hilferty).

5. p-value. $p = 2(1 - \Phi(|Z|))$.

6. Usage et limites. C’est le test le plus directement pertinent pour un actuair (l’épaisseur de queue conditionne le quantile à 99,5 %), mais aussi le moins souvent disponible : il exige $T \geq 20$, davantage que ce qu’exige la crédibilité pleine de l’annexe XVII. Lorsqu’il n’est pas applicable, l’analyse de queue doit reposer sur le QQ-plot, sur Anderson–Darling et sur les tests de valeurs aberrantes.

Hypothèse H4 — indépendance et validité du maximum de vraisemblance

Énoncé réglementaire (annexe XVII, B/C(2)(f)(iv)). L'estimation par maximum de vraisemblance est appropriée, ce qui suppose notamment l'indépendance des Y_t conditionnellement aux x_t , sans autocorrélation résiduelle.

9.1 Test de Durbin–Watson

Référence. J. Durbin, G. S. Watson, *Testing for serial correlation in least squares regression, I, Biometrika*, 37(3/4), 1950, p. 409–428 ; *II, Biometrika*, 38(1/2), 1951, p. 159–178.

1. Cadre, notations et hypothèses de validité (non testées). Série de résidus $z_1, \dots, z_T$ ordonnée chronologiquement. Hypothèses non testées : résidus issus d'un modèle correctement spécifié, homoscedastiques et gaussiens ; régresseurs exogènes et non aléatoires.

2. Hypothèse nulle. $H_0 : \rho = 0$ dans le schéma $z_t = \rho z_{t-1} + \nu_t$, soit l'absence d'autocorrélation d'ordre 1.

3. Statistique de test.

$$DW = \frac{\sum_{t=2}^T (z_t - z_{t-1})^2}{\sum_{t=1}^T z_t^2} \approx 2(1 - \hat{\rho}_1).$$

$DW \in [0, 4]$: proche de 2 sous H_0 , proche de 0 en autocorrélation positive forte, proche de 4 en autocorrélation négative forte.

4. Loi sous H_0 . Sous H_0 , les résidus normalisés sont $\mathcal{N}(0, I_T)$: DW est alors le *rapport de deux formes quadratiques* en variables normales, $DW = z'Az/z'z$ où A est la matrice des différences secondes. Ses valeurs propres sont connues analytiquement, $\lambda_j = 2(1 - \cos(\pi j/T))$, $j = 0, \dots, T-1$ (vérification numérique faite). La loi de DW est donc **exactement calculable**, sans tabulation ni approximation.

5. p-value. On écrit $\mathbb{P}(DW \leq c) = \mathbb{P}(z'(A - cI)z \leq 0)$, queue d'une forme quadratique évaluée par la méthode d'Imhof (1961) :

$$\mathbb{P}(Q > 0) = \frac{1}{2} - \frac{1}{\pi} \int_0^\infty \frac{\sin \theta(u)}{u \rho(u)} du, \quad \theta(u) = \frac{1}{2} \sum_j \arctan(h_j u), \quad \rho(u) = \prod_j (1 + h_j^2 u^2)^{1/4},$$

avec $h_j = \lambda_j - c$. La p-value bilatérale est $2 \min(\mathbb{P}(DW \leq d), \mathbb{P}(DW \geq d))$. Le centrage retirant une dimension, l'intégration porte sur les $T-1$ valeurs propres non nulles de A projetée sur l'orthogonal du vecteur constant.

6. Usage et limites. Deux points d'implémentation méritent d'être signalés. *Le centrage* : la statistique est calculée sur des résidus centrés, car la définition classique porte sur des résidus de moindres carrés, de moyenne nulle par construction. Les z_t satisfont la contrainte $\sum_t \sqrt{\hat{\pi}_t} z_t = 0$ mais pas $\bar{z} = 0$; sans centrage, le dénominateur serait majoré de $T\bar{z}^2$ et DW biaisée vers le bas. Le centrage rend en outre la statistique cohérente avec l'autocorrélation employée par les tests portmanteau. *La p-value* : elle est exacte, et non asymptotique ; la validation par simulation donne 10,1 % de rejets au seuil nominal de

10 % et 5,2 % au seuil de 5 % (1 500 répliques à $T = 8$). Les bornes d_L/d_U , établies pour des résidus de moindres carrés, ne sont pas utilisées. Le test ne détecte par ailleurs qu'une dépendance d'ordre 1.

9.2 Tests portemanteau de Ljung–Box et de Box–Pierce

Référence. G. E. P. Box, D. A. Pierce, *Distribution of residual autocorrelations in autoregressive-integrated moving average time series models*, *JASA*, 65(332), 1970, p. 1509–1526 ; G. M. Ljung, G. E. P. Box, *On a measure of lack of fit in time series models*, *Biometrika*, 65(2), 1978, p. 297–303.

1. Cadre, notations et hypothèses de validité (non testées). Série $z_1, \dots, z_T$, autocorrélations empiriques $\hat{\rho}_k = \sum_{t=k+1}^T (z_t - \bar{z})(z_{t-k} - \bar{z}) / \sum_{t=1}^T (z_t - \bar{z})^2$. Le script teste $h = 1$ et, si $T \geq 8$, $h = 2$. Hypothèses non testées : stationnarité et existence des moments d'ordre 2.

2. Hypothèse nulle. $H_0 : \rho_1 = \dots = \rho_h = 0$, absence d'autocorrélation jusqu'au retard h .

3. Statistique de test.

$$Q_{BP} = T \sum_{k=1}^h \hat{\rho}_k^2, \quad Q_{LB} = T(T+2) \sum_{k=1}^h \frac{\hat{\rho}_k^2}{T-k}.$$

La pondération $(T+2)/(T-k)$ de Ljung–Box corrige le biais de Q_{BP} à T fini.

4. Loi sous H_0 . $Q \xrightarrow{\mathcal{L}} \chi^2(h)$ sous H_0 (et $\chi^2(h-p-q)$ si les résidus proviennent d'un ARMA(p, q) ajusté, ce qui n'est pas le cas ici).

5. p-value. $p = 1 - F_{\chi_h^2}(Q)$.

6. Usage et limites. Ljung–Box est à préférer systématiquement à Box–Pierce, dont l'approximation est plus grossière à T faible ; le script affiche les deux en recoupement. Limites : l'approximation χ^2 n'est fiable qu'à partir de $T \approx 30$, et la règle d'usage $h \leq T/5$ impose de se restreindre à $h \leq 2$ ou 3 sur un historique réglementaire. Un rejet au retard 2 non confirmé au retard 1 doit être interprété avec prudence : sur 12 points, il s'agit souvent d'un artefact.

9.3 Test des suites de Wald–Wolfowitz

Référence. A. Wald, J. Wolfowitz, *On a test whether two samples are from the same population*, *Annals of Mathematical Statistics*, 11(2), 1940, p. 147–162.

1. Cadre, notations et hypothèses de validité (non testées). On transforme la série en une suite binaire de signes $s_t = \text{sign}(z_t - \text{med}(z))$, en écartant les valeurs nulles. Soit n_1 le nombre de signes positifs, n_2 le nombre de négatifs, $n = n_1 + n_2$, et R le nombre de « suites » (séquences maximales de signes identiques). Hypothèse non testée : continuité de la variable.

2. Hypothèse nulle. H_0 : la suite des signes est un arrangement aléatoire, les $\binom{n}{n_1}$ arrangements étant équiprobables.

3. Statistique de test.

$$\mathbb{E}[R] = \frac{2n_1n_2}{n} + 1, \quad \text{Var}(R) = \frac{2n_1n_2(2n_1n_2 - n)}{n^2(n-1)}, \quad Z = \frac{R - \mathbb{E}[R]}{\sqrt{\text{Var}(R)}}.$$

4. Loi sous H_0 . Loi exacte combinatoire pour R (dénombrement des compositions) ; asymptotiquement $Z \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$.

5. p-value. Approximation normale utilisée par le script : $p = 2(1 - \Phi(|Z|))$.

6. Usage et limites. Test non paramétrique très général : il détecte aussi bien une autocorrélation (trop peu de suites) qu’une alternance systématique (trop de suites), sans hypothèse de forme. Limite importante : l’approximation normale n’est recommandée que pour $n_1, n_2 \geq 10$, soit $T \geq 20$. En-deçà, la loi exacte devrait être utilisée, et la granularité de R (entier compris entre 2 et n) limite fortement le nombre de p-values atteignables.

9.4 Condition du premier ordre (diagnostic numérique)

Référence. Diagnostic numérique ; conditions d’optimalité du maximum de vraisemblance.

1. Cadre, notations et hypothèses de validité (non testées). En annulant la dérivée de l’objectif par rapport à $\ln \beta$, on obtient la contrainte que l’estimation impose mécaniquement aux résidus *quel que soit* le couple (δ, γ) :

$$\sum_{t=1}^T \hat{\pi}_t v_t = 0 \quad \Longleftrightarrow \quad \sum_{t=1}^T \sqrt{\hat{\pi}_t} z_t = 0.$$

Diagnostic, non test.

2. Hypothèse nulle. Sans objet.

3. Statistique de test. Écart relatif à la condition d’optimalité : $\text{FOC} = \left| \sum_t \hat{\pi}_t v_t \right| / \sum_t \hat{\pi}_t$.

4. Loi sous H_0 . Sans objet.

5. p-value. Aucune. Le moteur pose ECHEC si $\text{FOC} > 10^{-6}$.

6. Usage et limites. Point de vigilance essentiel. C’est la moyenne *pondérée* $\sum_t \hat{\pi}_t v_t$ qui est contrainte à zéro, et non la moyenne simple $\bar{z}$ des résidus normalisés. Les deux ne coïncident que si $\hat{\pi}_t$ est constant, c’est-à-dire si $\hat{\delta} = 1$ ou si les volumes x_t sont constants. Sur un jeu de données où $\hat{\delta}$ est intérieur au domaine, on observe typiquement $\text{FOC} \approx 10^{-17}$ (précision machine) alors que $\bar{z} \approx 10^{-2}$: la moyenne simple des résidus n’est donc *pas* un contrôle de convergence. Elle n’est pas pour autant une quantité libre : l’écart entre les deux moyennes est de l’ordre de la dispersion des poids $\hat{\pi}_t$, ce qui interdit d’en faire un test et conduit à la restituer comme diagnostic (fiche 9.5).

Portée exacte de ce diagnostic. FOC ne mesure pas non plus la convergence. `usp_noyau()` calcule $\ln \hat{\beta}$ en forme fermée, $\ln \hat{\beta} = (T/2 + \sum_t \hat{\pi}_t \ln r_t) / \sum_t \hat{\pi}_t$; en reportant dans $v_t = \ln r_t + 1/(2\hat{\pi}_t) - \ln \hat{\beta}$, on obtient $\sum_t \hat{\pi}_t v_t = 0$ *identiquement*, pour tout couple (δ, γ) et non seulement à l’optimum. Vérifié numériquement sur des couples arbitraires — $(0,5; -1)$, $(0; -3)$, $(1; 0)$, $(0,3; -2,5)$, $(1; 3)$ — où FOC reste inférieur à 10^{-15} . Le ECHEC de la rubrique 5 ne peut donc se déclencher qu’en cas d’anomalie arithmétique (débordement, valeur non finie), jamais parce que l’optimisation se serait arrêtée trop tôt. La convergence en γ , elle, est signalée par l’écart de $\sum_t z_t^2$ à T (fiche 9.6), seul indicateur de cette nature dans la restitution.

9.5 Centrage des résidus standardisés (diagnostic)

Référence. Diagnostic ; conditions du premier ordre du maximum de vraisemblance (fiche 9.4).

1. Cadre, notations et hypothèses de validité (non testées). Résidus standardisés $z_t = \sqrt{\hat{\pi}_t} v_t$ et leur moyenne simple $\bar{z}$. **Diagnostic, non test.** La relation $\sum_t \sqrt{\hat{\pi}_t} z_t = 0$ vaut *toujours*, et pas seulement à l’optimum : $\ln \hat{\beta}$ étant obtenu en forme fermée, $\ln \hat{\beta} = (T/2 + \sum_t \hat{\pi}_t \ln r_t) / \sum_t \hat{\pi}_t$, elle est une **identité algébrique** vérifiée pour tout couple (δ, γ) , convergé ou non (fiche 9.4). $\bar{z}$ est donc rivé par l’estimation

en toute circonstance. Cette contrainte pondérée ne se réduit à $\sum_t z_t = 0$ que lorsque $\hat{\pi}_t$ est *constant*, c'est-à-dire lorsque $\hat{\delta} = 1$ ou lorsque les volumes x_t le sont. Le seul fait que $\hat{\delta}$ soit au bord de $[0, 1]$ ne suffit pas : à $\hat{\delta} = 0$ avec des volumes variables, $\hat{\pi}_t$ varie et l'égalité $\sum_t z_t = 0$ ne tient pas. Le moteur distingue ces trois situations dans le commentaire attaché à la ligne.

2. Hypothèse nulle. Sans objet. L'hypothèse $\mathbb{E}[z_t] = 0$, sous laquelle cette grandeur était auparavant restituée comme un test, ne peut pas être mise en défaut par les données : $\bar{z}$ est déterminé par l'estimation, non librement observé.

3. Statistique de test. Aucune statistique de test. La grandeur restituée est l'estimation $\bar{z}$, portée par le champ estim de la table des tests ; les champs stat et loi sont vides.

4. Loi sous H_0 . Sans objet, pour deux raisons distinctes. *Loi nominale.* La loi $t(T - 1)$ de $\bar{z}\sqrt{T}/s_z$ est optimiste : les z_t dépendent de trois paramètres estimés $(\hat{\beta}, \hat{\delta}, \hat{\gamma})$ et satisfont la contrainte linéaire ci-dessus, de sorte que le nombre effectif de degrés de liberté est inférieur à $T - 1$. Cet argument, exact, reste faible : il suggère une p-value seulement trop optimiste, donc utilisable avec prudence. **Le fait qui tranche est plus radical.** Lorsque $\hat{\pi}_t$ est constant, $\bar{z} = 0$ est une identité algébrique ; la valeur affichée est un zéro machine, le rapport $\bar{z}\sqrt{T}/s_z$ l'est aussi, et la p-value bilatérale vaut 1 *quelles que soient les données*. Ce n'est pas une p-value élevée : c'est une **constante de T** , qui ne contient aucune information sur l'échantillon. Conséquence algébrique exacte, vérifiée numériquement sur deux jeux sans rapport l'un avec l'autre, à $T = 8$:

Jeu de données	$\hat{\delta}$	t observé	p nominale bilatérale
Jeu de contrôle du dossier	1	$-5,3 \cdot 10^{-16}$	1,0000000000
Jeu étranger, volumes x_t constants ^(a)	0	$-8,7 \cdot 10^{-17}$	1,0000000000

^(a) $x_t \equiv 100$ et $y_t = 55, 70, 61, 84, 48, 92, 66, 73$, jeu construit pour cette vérification et sans rapport avec le dossier.

Le second jeu n'a aucun point commun avec le premier et conduit même à $\hat{\delta} = 0$; il donne pourtant la même p-value, parce que la constance de $\hat{\pi}_t$ y résulte non de $\hat{\delta}$ mais de celle des volumes. Sur les 493 réplifications à $\delta^* = 1$ de la simulation décrite ci-dessous, la p-value nominale vaut 1 sur toutes, sans exception. Un verdict fondé sur cette p-value serait un OK qu'**aucune donnée ne peut faire perdre** — l'assurance d'un contrôle qui n'en est pas un, que la rubrique 6 écarte. La même vérification, conduite sur la variance unitaire dont la loi nominale est un χ^2 et non un t , donne le même constat (fiche 9.6) : ce n'est donc pas une particularité de la loi de Student.

Loi simulée. La loi de $\bar{z}$ sous le modèle ajusté n'est pas davantage exploitable, non parce qu'elle serait constante, mais parce qu'elle est un *mélange*. Constat de simulation sur le jeu de contrôle ($T = 8$, $\hat{\delta} = 1$, $B = 999$ réplifications, graine 20260831) : 493 réplifications donnent $\delta^* = 1$ et une moyenne $\bar{z}^*$ d'écart-type $2,2 \cdot 10^{-16}$, soit un zéro machine ; 460 donnent $\delta^* = 0$ et un écart-type de $1,7 \cdot 10^{-2}$, composante diffuse ; 46 un δ^* intérieur.

Ce n'est pas le mélange en lui-même qui prive la p-value de sens, mais le fait que la loi simulée porte un **atome en la valeur observée**. La valeur observée est elle-même un zéro machine ($\bar{z} = -2,0 \cdot 10^{-16}$) et les 493 réplifications de la première composante le sont aussi ($|\bar{z}^*| \leq 7,8 \cdot 10^{-16}$) : une p-value bilatérale $2 \min(\mathbb{P}(\bar{z}^* \geq \bar{z}), \mathbb{P}(\bar{z}^* \leq \bar{z}))$ se décide alors par le classement d'ex æquo numériques. Mesuré : sur ces 493 réplifications, 420 vérifient $\bar{z}^* \geq \bar{z}$ et 74 vérifient $\bar{z}^* \leq \bar{z}$, uniquement d'après le signe d'un bruit de l'ordre de 10^{-16} — d'où la dépendance du résultat à la plateforme de calcul. La somme $420 + 74 = 494$ excède 493 d'une unité : une réplification tombe exactement sur la valeur observée et est comptée dans les deux queues, les deux inégalités de la p-value bilatérale étant larges.

Se restreindre à la composante diffuse ne sauverait pas la vérification : la p-value recalculée sur les seules 506 réplifications à $\hat{\pi}_t^*$ non constant vaut 0,966. La valeur observée est par construction au centre de cette

composante, de sorte qu'un test conditionnel serait *inopérant* et non simplement mal calibré. Ces deux chiffres sont des constats de simulation sur ce jeu de données, non des propriétés démontrées du modèle.

5. p-value. Aucune. La grandeur a été retirée des statistiques simulées par `.stats_bootstrapables()` : ni p-value exacte, ni p-value de Monte-Carlo, ni p-value asymptotique n'est calculée ni affichée pour cette ligne, et aucune p-value n'est retenue.

6. Usage et limites. Pourquoi aucun verdict. Une grandeur que l'estimation rive ne peut pas contredire le modèle ; lui attacher un verdict OK donnerait au lecteur du dossier l'assurance d'un contrôle qui n'en est pas un. La ligne est donc restituée comme diagnostic, avec le verdict INFO, et accompagnée du motif. Ce qu'elle apporte à $T = 8$ est très limité, et il faut le dire sans détour. Lorsque $\hat{\pi}_t$ est constant, $\bar{z}$ n'est que du bruit d'arrondi et ne renseigne sur rien — en particulier **pas** sur la qualité de l'arrêt de l'optimiseur, puisque l'identité rappelée en rubrique 1 ne dépend pas de la convergence : mesuré, $\bar{z}$ vaut $-1,7 \cdot 10^{-17}$ à $(\hat{\delta}, \gamma) = (1, 0)$ et $1,6 \cdot 10^{-16}$ à $(1, 3)$, deux points très éloignés de l'optimum. Lorsque $\hat{\pi}_t$ varie, $\bar{z}$ est l'écart entre centrage pondéré et centrage non pondéré : l'identité $\sum_t \sqrt{\hat{\pi}_t} z_t = 0$ donne la borne exacte

$$|\bar{z}| \leq \frac{\max_t |\sqrt{\hat{\pi}_t} - \bar{c}|}{\bar{c}} \cdot \frac{1}{T} \sum_t |z_t|, \quad \bar{c} = \frac{1}{T} \sum_t \sqrt{\hat{\pi}_t}.$$

$\bar{z}$ est donc *de l'ordre de* la dispersion des poids, sans en être une fonction : le coefficient qui les relie est aléatoire. Mesuré sur les 506 répliques à $\hat{\pi}_t^*$ non constant, la corrélation entre $|\bar{z}^*|$ et l'amplitude relative de $\hat{\pi}_t^*$ n'est que de 0,26, et le rapport des deux s'étend de 0,006 à 0,12 entre les quantiles 5 % et 95 %. Dans les deux cas, $\bar{z}$ n'est pas une propriété libre des résidus. Un biais systématique de niveau non capté par $\hat{\beta}$ reste recherché ailleurs, par des vérifications qui portent, elles, un verdict : les tests de tendance de l'hypothèse H1 (section 6) pour une dérive du ratio S/P, les fiches 10.1 et 10.2 pour une rupture de régime.

9.6 Variance unitaire des résidus standardisés (diagnostic)

Référence. Diagnostic ; conditions du premier ordre du maximum de vraisemblance (fiche 9.4).

1. Cadre, notations et hypothèses de validité (non testées). Résidus standardisés $z_t = \sqrt{\hat{\pi}_t} v_t$ et leur variance empirique $\text{Var}(z)$. **Diagnostic, non test.** La condition du premier ordre en γ rive l'échelle des z_t comme celle en $\ln \beta$ en rive le niveau : lorsque $\hat{\pi}_t$ est constant ($\hat{\delta} = 1$, ou volumes x_t constants), les deux conditions donnent ensemble $\sum_t z_t^2 = T$, soit $\text{Var}(z) = T/(T - 1)$ — c'est-à-dire 1,143 à $T = 8$, et non 1. À la différence de celle en $\ln \beta$ (fiche 9.4), cette seconde relation n'est *pas* une identité algébrique : elle suppose la dérivée en γ effectivement annulée, donc l'optimisation aboutie. Hors du cas $\hat{\pi}_t$ constant, seule la contrainte pondérée subsiste et $\text{Var}(z)$ est de l'ordre de l'écart entre échelle pondérée et échelle non pondérée. L'argument suppose en outre l'optimum *intérieur* en γ : si $\hat{\gamma}$ butait sur une borne de son domaine $[-12, 3]$, la dérivée ne serait pas annulée et l'égalité tomberait. Cette réserve est théorique : $\sigma = \hat{\beta} e^\gamma$, de sorte que $\gamma = 3$ signifierait $\sigma \approx 20 \hat{\beta}$ et $\gamma = -12$, $\sigma \approx 6 \cdot 10^{-6} \hat{\beta}$, deux situations sans réalité pour un ratio S/P ; sur le jeu de contrôle, aucune des 999 répliques n'atteint une borne ($\hat{\gamma}^*$ reste entre $-3,34$ et $-1,37$).

2. Hypothèse nulle. Sans objet. L'hypothèse $\text{Var}(z_t) = 1$, sous laquelle cette grandeur était auparavant restituée comme un test, n'est pas celle que l'estimation laisse libre : la valeur de référence imposée par les conditions du premier ordre est $T/(T - 1)$, et non 1.

3. Statistique de test. Aucune statistique de test ; la quantité $C = (T - 1) s_z^2$ n'est plus calculée. La grandeur restituée est l'estimation $\text{Var}(z)$, portée par le champ `estim` de la table des tests.

4. Loi sous H_0 . Sans objet. La loi $\chi^2(T - 1)$ de C est nominale : elle ignore l'estimation préalable

de $(\hat{\beta}, \hat{\delta}, \hat{\gamma})$ et la contrainte d'échelle qui en résulte. Comme au centrage (fiche 9.5), l'argument décisif n'est pas que cette loi serait optimiste, mais qu'à $\hat{\pi}_t$ constant elle produit une p-value **indépendante des données**. Les conditions du premier ordre donnent alors $\sum_t z_t^2 = T$ et $\bar{z} = 0$, d'où $C = (T - 1)s_z^2 = \sum_t z_t^2 - T\bar{z}^2 = T$ à la tolérance d'arrêt près, et la p-value bilatérale $2 \min(F_{\chi^2(T-1)}(T), 1 - F_{\chi^2(T-1)}(T))$ ne dépend plus que de T : elle vaut 0,6651878 à $T = 8$. Cette conséquence est algébrique, mais — à la différence de celle du centrage — elle n'est exacte qu'à la tolérance d'arrêt de l'optimiseur près, puisqu'elle repose sur la condition en γ et non sur la forme fermée de $\ln \hat{\beta}$ (rubrique 1). Vérifiée numériquement : sur le jeu de contrôle comme sur un jeu étranger à volumes constants (fiche 9.5), la p-value nominale vaut 0,6651888, les deux valeurs coïncidant jusqu'à la huitième décimale ; sur les 493 réplifications à $\delta^* = 1$, elle reste comprise entre 0,665100 et 0,665224, l'amplitude résiduelle n'étant due qu'à cette même tolérance d'arrêt, discutée plus bas. Le verdict qui en découlerait serait donc, lui aussi, un OK qu'aucune donnée ne peut faire perdre.

La loi simulée sous le modèle ajusté porte, comme celle du centrage (fiche 9.5), un atome en la valeur observée. Constat de simulation sur les mêmes $B = 999$ réplifications (graine 20260831) : les 493 à $\hat{\pi}_t^*$ constant donnent une valeur rivée à $T/(T - 1)$, d'écart-type $3,5 \cdot 10^{-6}$; les 506 autres une valeur diffuse, d'écart-type $4,9 \cdot 10^{-3}$.

Une différence avec le centrage mérite d'être relevée, car elle change la nature du bruit comparé : ici, ce n'est pas l'arrondi machine mais la **tolérance d'arrêt de l'optimiseur**. Sur les 493 réplifications concernées, $\text{Var}(z^*) - T/(T - 1)$ s'étend de $-3,0 \cdot 10^{-5}$ à $+7,1 \cdot 10^{-5}$, de médiane $-7,7 \cdot 10^{-7}$, quand la valeur observée vaut $-7,8 \cdot 10^{-7}$. Or les deux ne sont pas produites au même réglage : l'ajustement observé emploie `factr = 1e5` et le réajustement des réplifications `factr = 1e7`. La p-value de Monte-Carlo autrefois retenue (0,864) comparait donc deux tolérances d'optimiseur différentes. Se restreindre à la composante diffuse ne sauverait pas davantage la vérification qu'au centrage : la p-value recalculée sur les seules 506 réplifications à $\hat{\pi}_t^*$ non constant vaut 0,998.

5. p-value. Aucune. La grandeur a été retirée des statistiques simulées par `.stats_bootstrapables()` ; aucune p-value n'est calculée ni retenue pour cette ligne.

6. Usage et limites. Pourquoi aucun verdict. Comme pour le centrage, la grandeur est rivée par l'estimation : elle est restituée comme diagnostic, avec le verdict INFO et le motif. Sur le jeu de contrôle ($T = 8$, $\hat{\delta} = 1$), $\text{Var}(z) = 1,142856$ contre $T/(T - 1) = 1,142857$: l'écart, $-6,8 \cdot 10^{-7}$ en relatif, provient de la tolérance d'arrêt de l'optimiseur et non des données.

Ce que ce diagnostic apporte, et qu'aucun autre n'apporte. L'écart de $\sum_t z_t^2$ à T est, à ce jour, le *seul* indicateur de la convergence en γ de toute la restitution : la condition en $\ln \beta$ étant une identité (fiche 9.4), elle ne peut rien signaler, tandis que celle en γ n'est satisfaite qu'à l'optimum. Les ordres de grandeur mesurés situent ce que « notable » veut dire : à l'optimum, 10^{-6} en relatif avec `factr = 1e5`, et jusqu'à $6 \cdot 10^{-5}$ sur les réplifications réajustées avec `factr = 1e7` ; à $\hat{\delta} = 1$ mais γ forcé hors de l'optimum, $\sum_t z_t^2 - T$ vaut $-7,8$ pour $\gamma = 0$ et $-7,97$ pour $\gamma = 3$. Un écart de cet ordre est donc un défaut de convergence, non une propriété des données. Lorsque $\hat{\pi}_t$ varie, l'écart est en revanche de l'ordre de la dispersion des poids, sans en être une fonction, et ne se lit plus comme un contrôle numérique. Le contrôle de l'échelle de σ proprement dit relève de l'intervalle bootstrap et du jackknife (section 11), qui portent, eux, sur σ_{USP} .

Diagnostics de stabilité, ruptures et points aberrants

Ces diagnostics ne correspondent pas directement à l'une des quatre hypothèses réglementaires, mais conditionnent la validité pratique des tests précédents : un point aberrant ou une rupture de régime peut à lui seul provoquer ou masquer un rejet ailleurs.

10.1 Test de rupture sup-F (Quandt / Chow / Andrews)

Référence. R. E. Quandt, *Tests of the hypothesis that a linear regression system obeys two separate regimes*, *JASA*, 55(290), 1960, p. 324–330 ; G. C. Chow, *Tests of equality between sets of coefficients in two linear regressions*, *Econometrica*, 28(3), 1960, p. 591–605 ; loi limite : D. W. K. Andrews, *Tests for parameter instability and structural change with unknown change point*, *Econometrica*, 61(4), 1993, p. 821–856.

1. Cadre, notations et hypothèses de validité (non testées). Série $z_1, \dots, z_T$ et ensemble des points de rupture candidats $\mathcal{K} = \{k : \max(2, \lfloor \tau T \rfloor) \leq k \leq \min(T - 2, T - \lfloor \tau T \rfloor)\}$ avec un écrêtement $\tau = 0,15$ (indispensable : sans lui la statistique diverge aux extrémités). Les bornes 2 et $T - 2$ garantissent au moins deux observations de chaque côté, sans quoi la variance intra-segment n'est pas définie. Hypothèses non testées : erreurs indépendantes, homoscédastiques, gaussiennes.

2. Hypothèse nulle. H_0 : absence de rupture de niveau, soit $\mathbb{E}[z_t]$ constant sur toute la période.

3. Statistique de test. Pour un point de rupture k fixé, en notant $\bar{z}_1^{(k)}$ et $\bar{z}_2^{(k)}$ les moyennes avant et après :

$$\text{SCR}(k) = \sum_{t \leq k} (z_t - \bar{z}_1^{(k)})^2 + \sum_{t > k} (z_t - \bar{z}_2^{(k)})^2, \quad F(k) = \frac{\text{SCT} - \text{SCR}(k)}{\text{SCR}(k)/(T - 2)},$$

puis $\sup F = \max_{k \in \mathcal{K}} F(k)$.

4. Loi sous H_0 . Pas $\mathcal{F}(1, T - 2)$: le point de rupture étant *estimé* et non fixé a priori, la loi de $\sup F$ est celle d'un supremum de processus, tabulée par Andrews (1993) et dépendant de τ . Ses quantiles sont sensiblement supérieurs à ceux de la loi de Fisher.

5. p-value. Approximation analytique de B. E. Hansen (*Approximate asymptotic p values for structural-change tests*, *Journal of Business & Economic Statistics*, 15(1), 1997, p. 60–67). Le script utilise la p-value de Monte-Carlo.

6. Usage et limites. Erreur classique à éviter : comparer $\sup F$ aux quantiles de $\mathcal{F}(1, T - 2)$, ce qui surestime massivement le nombre de ruptures détectées, le maximum sur une dizaine de candidats étant mécaniquement grand sous H_0 . La simulation règle ce problème. Un rejet est très informatif : il signale un changement de politique de souscription, de provisionnement ou de périmètre, et peut justifier de restreindre la profondeur T retenue.

10.2 Test de stabilité OLS-CUSUM

Référence. R. L. Brown, J. Durbin, J. M. Evans, *Techniques for testing the constancy of regression relationships over time*, *Journal of the Royal Statistical Society, Series B*, 37(2), 1975, p. 149–192 ; version fondée sur les résidus MCO : W. Ploberger, W. Krämer, *The CUSUM test with OLS residuals*, *Econometrica*, 60(2), 1992, p. 271–285.

1. Cadre, notations et hypothèses de validité (non testées). Série de résidus z_t , $\hat{\sigma}$ leur écart-type empirique. Hypothèses non testées : indépendance et homoscedasticité sous H_0 .

2. Hypothèse nulle. H_0 : constance des paramètres du modèle sur toute la période.

3. Statistique de test.

$$S(j) = \frac{1}{\hat{\sigma}\sqrt{T}} \sum_{t=1}^j (z_t - \bar{z}), \quad \text{CUSUM} = \max_{1 \leq j \leq T} |S(j)|.$$

4. Loi sous H_0 . Sous H_0 , $S(\lfloor uT \rfloor) \Rightarrow B^\circ(u)$, pont brownien standard sur $[0, 1]$. La statistique converge donc vers $\sup_{u \in [0,1]} |B^\circ(u)|$, de loi de Kolmogorov.

5. p-value. Asymptotiquement $p = 2 \sum_{j=1}^{\infty} (-1)^{j-1} \exp(-2j^2 \text{CUSUM}^2)$. Le script retient la p-value de Monte-Carlo, l'approximation brownienne étant inutilisable à $T \leq 15$.

6. Usage et limites. Complémentaire du sup-F : le CUSUM détecte plutôt des dérives *graduelles*, là où le sup-F détecte des ruptures *brutales*. Sa limite majeure ici est que la convergence vers le pont brownien suppose T grand : sur 10 points, le processus cumulé n'a aucune chance de ressembler à une trajectoire brownienne et seule la simulation donne un niveau correct.

10.3 Test de Grubbs

Référence. F. E. Grubbs, *Sample criteria for testing outlying observations*, *Annals of Mathematical Statistics*, 21(1), 1950, p. 27–58 ; *Procedures for detecting outlying observations in samples*, *Technometrics*, 11(1), 1969, p. 1–21.

1. Cadre, notations et hypothèses de validité (non testées). Échantillon $z_1, \dots, z_T$, $T \geq 3$. Hypothèse non testée *et* déterminante : sous H_0 , les observations sont i.i.d. *normales*.

2. Hypothèse nulle. H_0 : toutes les observations proviennent de la même loi normale (aucune valeur aberrante). L'alternative est la présence d'*exactement une* valeur aberrante.

3. Statistique de test.

$$G = \frac{\max_t |z_t - \bar{z}|}{s_z}.$$

4. Loi sous H_0 . Sous H_0 , la loi exacte de G se déduit de celle de Student : en posant

$$t^* = \sqrt{\frac{T(T-2)G^2}{(T-1)^2 - TG^2}},$$

on a $t^* \sim t(T-2)$ pour une observation fixée ; G étant un maximum sur T observations, la loi de référence intègre une correction de multiplicité.

5. p-value. Borne de Bonferroni utilisée par le script, tronquée à 1 :

$$p = \min \left(1, 2T(1 - F_{t,T-2}(t^*)) \right).$$

6. Usage et limites. Deux limites structurelles. (i) *Masquage* : en présence de deux valeurs aberrantes ou plus, celles-ci gonflent s_z et le test ne détecte plus rien, d'où la nécessité du test de Rosner. (ii) La statistique est bornée : $G \leq (T-1)/\sqrt{T}$, soit 2,85 pour $T = 10$; sur de très petits échantillons, aucune observation ne peut être « suffisamment » extrême. Enfin, la sensibilité à l'hypothèse de normalité est totale : sur une vraie loi à queue lourde, le test signale des aberrations qui n'en sont pas.

10.4 Procédure ESD généralisée de Rosner

Référence. B. Rosner, *Percentage points for a generalized ESD many-outlier procedure*, *Technometrics*, 25(2), 1983, p. 165–172.

1. Cadre, notations et hypothèses de validité (non testées). Généralisation itérative de Grubbs. On fixe a priori un nombre maximal k de valeurs aberrantes recherchées (le script prend $k = \max(1, \lfloor T/4 \rfloor)$) et un niveau α , qui est celui passé à `usp_run()` (0,10 par défaut) et non une valeur figée. Hypothèse non testée : normalité de la population sous-jacente.

2. Hypothèse nulle. H_0 : aucune valeur aberrante. On teste séquentiellement les alternatives « il y a exactement i valeurs aberrantes », $i = 1, \dots, k$.

3. Statistique de test. Pour $i = 1, \dots, k$, sur l'échantillon S_i obtenu en retirant les $i - 1$ observations déjà écartées :

$$R_i = \frac{\max_{z \in S_i} |z - \bar{z}_{S_i}|}{s_{S_i}}.$$

4. Loi sous H_0 . Valeurs critiques exactes, avec $n_i = T - i + 1$ et $t_{\text{crit}} = F_{t, n_i-2}^{-1}(1 - \frac{\alpha}{2n_i})$:

$$\lambda_i = \frac{(n_i - 1) t_{\text{crit}}}{\sqrt{(n_i - 2 + t_{\text{crit}}^2) n_i}}.$$

5. p-value. Aucune p-value : il s'agit d'une procédure de décision à niveau α fixé. Le nombre retenu de valeurs aberrantes est $\hat{k} = \max\{i : R_i > \lambda_i\}$, et 0 si aucun dépassement.

6. Usage et limites. Résout le problème de masquage de Grubbs et constitue la référence pour la détection multiple. Limites : la littérature recommande $T \geq 25$ pour une fiabilité correcte des valeurs critiques, ce qui n'est jamais atteint en régime USP ; le choix de k est arbitraire et influence le résultat ; l'hypothèse de normalité reste critique. À $T \leq 15$, la procédure est un simple signal d'attention, non une justification d'exclusion de données – laquelle doit toujours reposer sur une analyse métier (sinistre exceptionnel identifié, erreur de saisie avérée).

10.5 Distance de Cook (diagnostic)

Référence. R. D. Cook, *Detection of influential observation in linear regression*, *Technometrics*, 19(1), 1977, p. 15–18.

1. Cadre, notations et hypothèses de validité (non testées). Régression contrainte $y_t = \beta x_t + \varepsilon_t$ à k paramètres ($k = 1$), de résidus e_t , de variance résiduelle estimée $\hat{s}^2$ et de leviers h_t (fiche suivante). **Diagnostic d'influence, non test.**

2. Hypothèse nulle. Sans objet.

3. Statistique de test.

$$D_t = \frac{e_t^2}{k \hat{s}^2} \cdot \frac{h_t}{(1 - h_t)^2} = \frac{\sum_i (\hat{y}_i - \hat{y}_{i(-t)})^2}{k \hat{s}^2},$$

où $\hat{y}_{i(-t)}$ est la prévision obtenue en retirant l'observation t .

4. Loi sous H_0 . Aucune loi exacte. On rapproche parfois D_t des quantiles de $\mathcal{F}(k, T - k)$, mais il s'agit d'une heuristique sans fondement rigoureux.

5. p-value. Aucune. Le script applique le seuil conventionnel $D_t > 4/T$.

6. Usage et limites. Mesure combinée du levier et de l'ampleur du résidu : elle répond à la question « de combien le modèle changerait-il si je retirais cette année ? ». C'est le diagnostic le plus directement utile en régime USP, où une seule année peut déterminer le paramètre. Limites : le seuil $4/T$ est purement conventionnel (d'autres auteurs retiennent 1), et la distance porte sur la régression auxiliaire, non sur le modèle de vraisemblance complet – le jackknife de la section 10 fournit la mesure exacte pour ce dernier.

10.6 Leviers (*hat values*, diagnostic)

Référence. D. C. Hoaglin, R. E. Welsch, *The hat matrix in regression and ANOVA*, *The American Statistician*, 32(1), 1978, p. 17–22.

1. Cadre, notations et hypothèses de validité (non testées). Matrice de projection $H = X(X'X)^{-1}X'$ de la régression contrainte. **Diagnostic, non test.**

2. Hypothèse nulle. Sans objet.

3. Statistique de test. $h_t = H_{tt}$, soit ici, en régression simple sans constante, $h_t = \frac{x_t^2}{\sum_{i=1}^T x_i^2}$, avec $\sum_t h_t = k$ et $0 \leq h_t \leq 1$.

4. Loi sous H_0 . Aucune.

5. p-value. Aucune. Seuil conventionnel : $h_t > 2k/T$.

6. Usage et limites. Le levier ne dépend que des x_t : il identifie les années dont le *volume* est atypique, indépendamment de la sinistralité observée. Une année à fort levier n'est pas problématique en soi, mais elle le devient si son résidu est également grand – c'est exactement ce que combine la distance de Cook. En contexte USP, un levier élevé signale généralement une année de forte croissance ou une intégration de portefeuille, à rapprocher du contrôle d'amplitude du volume de la section 3.

Diagnostics de robustesse de l'estimation

11.1 Test du rapport de vraisemblance sur les cas limites de δ

Référence. S. S. Wilks, *The large-sample distribution of the likelihood ratio for testing composite hypotheses*, *Annals of Mathematical Statistics*, 9(1), 1938, p. 60–62 ; correction de frontière : H. Chernoff, *On the distribution of the likelihood ratio*, *Annals of Mathematical Statistics*, 25(3), 1954, p. 573–578 ; D. O. Stram, J. W. Lee, *Variance components testing in the longitudinal mixed effects model*, *Biometrics*, 50(4), 1994, p. 1171–1177.

1. Cadre, notations et hypothèses de validité (non testées). On note $\ell(\delta, \gamma)$ la log-vraisemblance et $\mathcal{O}(\delta, \gamma) = -2\ell$ à une constante près, soit la fonction objectif minimisée par le script. Hypothèses non testées : régularité du modèle, identifiabilité, échantillon suffisant pour la théorie asymptotique.

2. Hypothèse nulle. $H_0 : \delta = \delta_0$ avec $\delta_0 \in \{0, 1\}$, c'est-à-dire structure de variance purement linéaire en volume ($\delta_0 = 0$) ou purement quadratique ($\delta_0 = 1$).

3. Statistique de test. Statistique du rapport de vraisemblance, obtenue par profilage sur γ :

$$\text{LR}(\delta_0) = \min_{\gamma} \mathcal{O}(\delta_0, \gamma) - \min_{\delta \in [0,1], \gamma} \mathcal{O}(\delta, \gamma).$$

4. Loi sous H_0 . Sous les conditions de régularité de Wilks, $\text{LR} \xrightarrow{\mathcal{L}} \chi^2(1)$. **Mais $\delta_0 = 0$ et $\delta_0 = 1$ sont sur la frontière du domaine $[0, 1]$:** la condition de régularité est violée et le résultat de Chernoff (1954) s'applique, la loi limite devenant le mélange

$$\frac{1}{2} \chi^2(0) + \frac{1}{2} \chi^2(1),$$

où $\chi^2(0)$ désigne la masse de Dirac en 0.

5. p-value. p-value naïve rapportée par le script : $p = 1 - F_{\chi^2_1}(\text{LR})$. p-value corrigée pour la frontière : $p_{\text{Chernoff}} = \frac{1}{2}(1 - F_{\chi^2_1}(\text{LR})) = p/2$.

6. Usage et limites. Point d'attention majeur. La p-value affichée est *conservatrice d'un facteur 2* lorsque $\hat{\delta}$ est au bord : la vraie p-value est la moitié de celle rapportée. Le script affiche volontairement la version naïve, plus prudente, mais la note de justification doit mentionner la correction. Sur le fond, ce test répond à la question pratique décisive : la structure de mélange imposée par le règlement est-elle réellement identifiée par les données, ou un cas limite serait-il statistiquement aussi défendable ? Une LR faible pour les deux bornes signifie que δ n'est pas identifié et que le paramètre final repose sur une convention plutôt que sur l'information contenue dans l'historique.

11.2 Jackknife (sensibilité au retrait d'une année)

Référence. M. H. Quenouille, *Approximate tests of correlation in time series*, *Journal of the Royal Statistical Society, Series B*, 11(1), 1949, p. 68–84 ; J. W. Tukey, *Bias and confidence in not quite large samples*, *Annals of Mathematical Statistics*, 29(2), 1958, p. 614.

1. Cadre, notations et hypothèses de validité (non testées). Pour chaque t , on réestime intégralement le modèle sur l'échantillon privé de l'observation t , d'où $\hat{\sigma}^{(-t)}$ et $\sigma_{\text{USP}}^{(-t)}$. Le facteur de crédibilité c et la

correction $\sqrt{(T+1)/(T-1)}$ sont maintenus à ceux de l'échantillon complet, l'objectif étant d'isoler l'effet de l'observation retirée et non de rejouer les règles de l'annexe XVII sur $T-1$ années. **Diagnostic, non test.**

2. Hypothèse nulle. Sans objet.

3. Statistique de test.

$$\Delta_{\max} = \max_{1 \leq t \leq T} \frac{|\sigma_{\text{USP}}^{(-t)} - \sigma_{\text{USP}}|}{\sigma_{\text{USP}}}.$$

L'estimateur jackknife du biais, $\widehat{\text{biais}} = (T-1)(\overline{\sigma^{(-\cdot)}} - \hat{\sigma})$, est également calculable à partir de la table produite.

4. Loi sous H_0 . Aucune loi de référence n'est utilisée pour $\Delta_{\max}$.

5. p-value. Aucune. Seuils conventionnels du script : ALERTE au-delà de 10 %, ECHEC au-delà de 20 %.

6. Usage et limites. C'est, à T faible, le diagnostic le plus informatif de tout le dispositif. Il répond directement à la question que posera le superviseur : le paramètre proposé résiste-t-il au retrait d'une seule année ? Un $\Delta_{\max}$ de 25 % signifie que le calibrage est déterminé par une observation unique, ce qui fragilise le dossier bien davantage qu'un test de normalité en échec. Limite : le jackknife suppose une influence approximativement linéaire de chaque observation, hypothèse discutable en présence d'une solution au bord sur δ , où le retrait d'un point peut faire basculer l'optimum d'une borne à l'autre de façon discontinue.

11.3 Intervalle de confiance par bootstrap paramétrique

Référence. Efron (1979), *op. cit.* ; B. Efron, R. J. Tibshirani, *An Introduction to the Bootstrap*, Chapman & Hall, 1993.

1. Cadre, notations et hypothèses de validité (non testées). On réutilise les B répliques décrites en section 4, dont on extrait $\sigma_{\text{USP}}^{(b)} = c \hat{\sigma}^{(b)} \sqrt{(T+1)/(T-1)} + (1-c) \sigma_{\text{std}}$. **Diagnostic, non test.**

2. Hypothèse nulle. Sans objet (procédure d'estimation d'incertitude, non de décision).

3. Statistique de test. Quantiles empiriques de la distribution bootstrap : $[\hat{q}_{\alpha/2}, \hat{q}_{1-\alpha/2}]$ (intervalle de percentile), et largeur relative $L = (\hat{q}_{0,95} - \hat{q}_{0,05})/\sigma_{\text{USP}}$.

4. Loi sous H_0 . La distribution bootstrap approxime la loi d'échantillonnage de $\hat{\sigma}_{\text{USP}}$ conditionnellement au modèle ajusté.

5. p-value. Aucune. Seuils conventionnels du script sur L : ALERTE au-delà de 50 %, ECHEC au-delà de 80 %.

6. Usage et limites. Quantifie l'incertitude d'échantillonnage du paramètre final, ce que ne fait aucun test d'hypothèse. Il est fréquent d'obtenir, sur un historique de 10 ans, un intervalle à 90 % dont la largeur dépasse 50 % de la valeur centrale : cela ne disqualifie pas le calibrage (le mélange par crédibilité en amortit une partie) mais doit être présenté explicitement. Limites : l'intervalle de percentile n'est corrigé ni du biais ni de l'asymétrie – les variantes BCa seraient plus exactes – et il reste conditionnel à la validité du modèle paramétrique, donc optimiste si le modèle est mal spécifié.

11.4 Convergence multi-démarrages

Référence. Diagnostic numérique ; sur l'optimisation sous contraintes de bornes : R. H. Byrd, P. Lu, J. Nocedal, C. Zhu, *A limited memory algorithm for bound constrained optimization*, *SIAM Journal on Scientific Computing*,

16(5), 1995, p. 1190–1208 (algorithme L-BFGS-B).

1. Cadre, notations et hypothèses de validité (non testées). L'optimisation de $\mathcal{O}(\delta, \gamma)$ est relancée depuis une grille de points de départ ($9 \times 6 = 54$ démarrages dans la configuration par défaut). **Diagnostic, non test.**

2. Hypothèse nulle. Sans objet.

3. Statistique de test. Proportion de démarrages atteignant le minimum global à 10^{-6} près :

$$\hat{\kappa} = \frac{1}{S} \sum_{s=1}^S \mathbb{1}_{\left\{ \left| \mathcal{O}_s^* - \min_{s'} \mathcal{O}_{s'}^* \right| < 10^{-6} \right\}},$$

complétée par le code de retour de l'optimiseur.

4. Loi sous H_0 . Sans objet.

5. p-value. Aucune. ALERTE si $\hat{\kappa} < 0,5$ ou si le code de retour est non nul.

6. Usage et limites. Garantit que le minimum rapporté est global et non local, ce qui n'a rien d'automatique : la fonction objectif de l'annexe XVII peut présenter un plateau très plat en δ lorsque l'amplitude des volumes x_t est faible (car π_t dépend alors peu de δ), situation dans laquelle l'optimiseur s'arrête en des points différents selon son initialisation. Un $\hat{\kappa}$ faible est un signal d'alerte à traiter *avant* toute interprétation des tests, au même titre que l'écart de $\sum_t z_t^2$ à T (fiche 9.6) ; la nullité de la moyenne pondérée des résidus, elle, est une identité et ne signale rien (fiche 9.4).

Diagnostics graphiques complémentaires

Les graphiques ne comportent ni hypothèse nulle ni p-value. Toutes les quantités qu'ils représentent sont calculées dans R/engine.R (`engine_plots_data()` et `mw_plots_data()`) et exposées dans `res$plots_data`; la couche d'affichage ne fait que les tracer. Ils sont documentés ici car, aux profondeurs réglementaires, leur pouvoir informatif dépasse souvent celui des tests formels.

12.1 Couverture exhaustive

Les vingt-six représentations produites par l'outil sont recensées ci-dessous. Celles qui appellent un commentaire méthodologique font l'objet d'une fiche; les autres sont d'interprétation directe et sont décrites dans le tableau.

Fonction	Méthode	Rattachement	Objet
<i>Données et ajustement</i>			
plot_ajustement()	LN	—	Nuage (x_t, y_t) et droite $\hat{\beta}x$: contrôle visuel direct de la proportionnalité (H1).
plot_ratio()	LN	H1	Ratio r_t dans le temps, avec le niveau $\hat{\beta}$: une dérive contredit la constance de β .
plot_residus()	LN	H2	Résidus z_t contre le volume : structure résiduelle après pondération.
plot_mw_facteurs()	MW	—	Facteurs $\hat{f}_j$ par année de développement, avec la référence $f = 1$: visualise la cadence de liquidation.
plot_mw_reserve()	MW	M6	Réserve par année de survenance : montre la concentration sur les années récentes.
<i>Structure de variance</i>			
plot_spread()	LN	H2	Fiche dédiée.
plot_qq2ech()	LN	H2	Fiche dédiée.
plot_mw_regressions()	MW	M1	Fiche dédiée. Petits multiples $C(i, j + 1)$ contre $C(i, j)$, une vignette par année de développement.
plot_mw_origine()	MW	M1	Fiche dédiée. Ordonnée à l'origine estimée par colonne, avec son intervalle à 95 %.
plot_mw_alpha()	MW	M1	Fiche dédiée. Facteur estimé selon $\alpha = 0, 1$ et 2.
plot_mw_residus_C()	MW	M1, M2	Résidus de Mack contre $C(i, j)$: teste conjointement la proportionnalité de la moyenne et celle de la variance.
plot_mw_residus_dev()	MW	M2	Résidus par année de développement : localise la colonne dont la variance est mal spécifiée.
<i>Normalité</i>			
plot_qqnorm()	LN	H3	Fiche dédiée.
plot_mw_qq()	MW	M5	QQ-plot des résidus de Mack. Diagnostic seulement : la normalité n'est pas une hypothèse du modèle.
<i>Indépendance</i>			
plot_mw_residus_acc()	MW	M3	Résidus par année de survenance : détecte une ligne atypique du triangle.
plot_mw_residus_cal()	MW	M3	Résidus par année calendaire : contrepartie graphique du test des effets calendaires, la plus directement lisible des trois vues de résidus.

Suite du recensement : diagnostics d'influence, estimation et calibration.

Fonction	Méthode	Rattachement	Objet
<i>Influence et leviers</i>			
plot_influence_levier()	LN	—	Fiche dédiée.
plot_influence_cook()	LN	—	Fiche dédiée.
plot_influence_sigma()	LN	—	Fiche dédiée.
plot_mw_levier()	MW	—	Fiche dédiée.
plot_mw_dfbeta()	MW	—	Fiche dédiée.
plot_mw_contributions()	MW	M6	Fiche dédiée.
<i>Estimation et calibration</i>			
plot_profil_delta()	LN	—	Profil de vraisemblance en δ : un plateau signale une structure de variance non identifiée.
plot_surface_objectif()	LN	—	Surface $-2 \ln L$ sur la grille (δ, γ) : montre si l'optimum au bord est un vrai minimum.
plot_coupe_delta()	LN	—	Coupe de la surface à $\hat{\gamma}$: lecture bidimensionnelle de la même platitude, avec son amplitude chiffrée.
plot_boot_sigma()	LN MW	+ —	Distribution bootstrap de $\hat{\sigma}$: matérialise l'incertitude d'échantillonnage du paramètre.
plot_calibration()	LN MW	+ —	Valeurs candidates et paramètre retenu : situe σ_{USP} entre le standard et l'estimé seul.

12.2 Fiches détaillées

12.3 QQ-plot normal

Référence. M. B. Wilk, R. Gnanadesikan, *Probability plotting methods for the analysis of data*, *Biometrika*, 55(1), 1968, p. 1–17.

1. Cadre, notations et hypothèses de validité (non testées). Nuage des couples $(\Phi^{-1}((i - \frac{3}{8})/(T + \frac{1}{4})), z_{(i)})$, $i = 1, \dots, T$, avec droite de référence passant par les premier et troisième quartiles. Rattaché à l'hypothèse H3.

2. Hypothèse nulle. Sans objet. Le test numérique correspondant est Shapiro–Francia, dont la statistique W' est exactement le carré du coefficient de corrélation de ce nuage.

3. Statistique de test. Sans objet (représentation graphique).

4. Loi sous H_0 . Sans objet.

5. p-value. Sans objet.

6. Usage et limites. Lecture : un alignement sur la droite conforte la normalité ; une courbure en S traduit des queues plus lourdes (points extrêmes au-dessus à droite et en dessous à gauche) ou plus légères ; une courbure convexe ou concave traduit une asymétrie. Limite : sur 8 à 12 points, l'œil surestime facilement les écarts – il est utile de superposer une enveloppe de simulation obtenue par bootstrap paramétrique pour calibrer la lecture.

12.4 QQ-plot à deux échantillons (faible volume contre fort volume)

Référence. Wilk & Gnanadesikan (1968), *op. cit.*

1. Cadre, notations et hypothèses de validité (non testées). Les résidus sont scindés en deux groupes selon x_t inférieur ou supérieur à $\text{med}(x)$. On porte en abscisse les quantiles empiriques du groupe « faible volume » et en ordonnée ceux du groupe « fort volume », évalués aux mêmes probabilités avec $n = \min(n_1, n_2)$. Droite de référence : la première bissectrice. Rattaché à l'hypothèse H2.

2. Hypothèse nulle. Sans objet. Le test numérique correspondant est le test de Smirnov à deux échantillons (section 5).

3. Statistique de test. Sans objet.

4. Loi sous H_0 . Sans objet.

5. p-value. Sans objet.

6. Usage et limites. Diagnostic visuel direct de l'hypothèse de structure de variance : si la pondération π_t est correcte, les résidus normalisés des petits et des gros volumes suivent la même loi et les points s'alignent sur la bissectrice. Une *pente* supérieure à 1 signale une dispersion résiduelle plus forte sur les gros volumes (donc un δ sous-estimé), une pente inférieure à 1 l'inverse ; un décalage vertical d'ensemble signale une différence de niveau relevant plutôt de H1. Limite : avec 5 points par groupe, la pente apparente est très instable.

12.5 Graphiques d'influence et de levier

Référence. R. D. Cook (1977), *op. cit.* ; D. C. Hoaglin, R. E. Welsch (1978), *op. cit.* ; pour la représentation conjointe, J. M. Chambers, W. S. Cleveland, B. Kleiner, P. A. Tukey, *Graphical Methods for Data Analysis*, Wadsworth, 1983.

1. Cadre, notations et hypothèses de validité (non testées). Trois représentations, rattachées aux diagnostics d'influence de la section 11. Pour la méthode lognormale, la régression de référence est le modèle réglementaire contraint $y_t = \beta x_t$, à $k = 1$ paramètre, de leviers $h_t = x_t^2 / \sum_i x_i^2$ (de somme k) et de résidus standardisés $e_t / (s\sqrt{1 - h_t})$.

2. Hypothèse nulle. Sans objet. Les tests numériques correspondants sont la distance de Cook et les leviers, documentés en section 11.

3. Statistique de test. Sans objet (représentations graphiques). Les iso-distances de Cook tracées dans le plan (h, r) sont les courbes

$$r = \pm \sqrt{\frac{D k (1 - h)}{h}}, \quad D \in \{0,5; 1\},$$

qui découlent directement de l'identité $D_t = r_t^2 h_t / (k(1 - h_t))$, vérifiée numériquement à 10^{-10} près par le moteur.

4. Loi sous H_0 . Sans objet.

5. p-value. Sans objet.

6. Usage et limites. Le premier graphique croise levier et résidu standardisé : il sépare visuellement les observations *atypiques en volume* (levier élevé, résidu faible) de celles qui sont *réellement influentes* (au-delà d'une iso-courbe de Cook). Un levier élevé seul n'est pas problématique ; c'est sa combinaison avec un résidu important qui l'est. Le deuxième donne la distance de Cook par année avec son seuil $4/T$. Le troisième, propre au projet, est le plus directement exploitable en dossier : il représente l'écart relatif sur σ_{USP} induit par le retrait de chaque année, issu du jackknife. À $T = 8$, il n'est pas rare qu'une seule année déplace le paramètre de plus de 10 %, ce que la seule lecture des distances de Cook ne montre pas.

Transposition à la méthode Merz-Wüthrich. Le facteur $\hat{f}_j$ étant une moyenne pondérée des facteurs individuels de poids $C(i, j)$, le levier exact de la cellule (i, j) vaut $h(i, j) = C(i, j) / S_j$, de somme 1 par

colonne (vérifié numériquement). L'influence exacte se mesure par le DFBETA

$$\hat{f}_j^{(-i)} = \frac{\sum_{i'} C(i', j+1) - C(i, j+1)}{\sum_{i'} C(i', j) - C(i, j)},$$

obtenu sans réajustement itératif. S'y ajoute la décomposition de la réserve et de la variance de processus de la MSEP par année de survenance. Cette dernière est une *décomposition* et non un leave-one-out : le terme d'erreur d'estimation de la MSEP comporte des termes croisés, partagés entre paires d'années, qui ne sont pas attribuables à une année isolée, ce que le graphique ne prétend pas faire.

12.6 Graphique dispersion-niveau (*spread-location*)

Référence. J. W. Tukey, *Exploratory Data Analysis*, Addison-Wesley, 1977 ; lissage local de W. S. Cleveland, *Robust locally weighted regression and smoothing scatterplots*, *JASA*, 74(368), 1979, p. 829–836.

1. Cadre, notations et hypothèses de validité (non testées). Nuage $(x_t, \sqrt{|z_t|})$ avec courbe de lissage local (*lowess*). Rattaché à l'hypothèse H2.

2. Hypothèse nulle. Sans objet.

3. Statistique de test. Sans objet. La transformation $\sqrt{|\cdot|}$ stabilise la variance de la mesure de dispersion et rend la courbe plus lisible que $|z_t|$ ou z_t^2 .

4. Loi sous H_0 . Sans objet.

5. p-value. Sans objet.

6. Usage et limites. Une courbe lissée horizontale confirme que la pondération capture l'hétéroscédasticité ; une pente marquée signale une structure de variance résiduelle non modélisée, en cohérence avec un rejet de Breusch–Pagan ou de White. Limite : le lissage local n'a aucune stabilité en-dessous d'une dizaine de points et sa forme dépend fortement du paramètre de fenêtre ; à T faible, seule une pente très prononcée doit être retenue.

12.7 Visualisation de la régression chain-ladder (Merz–Wüthrich)

Référence. T. Mack (1993), *op. cit.*, section 3, qui recommande explicitement l'examen graphique des nuages $C(i, j+1)$ contre $C(i, j)$ avant tout test formel.

1. Cadre, notations et hypothèses de validité (non testées). Trois représentations, rattachées à l'hypothèse M1. La première est un ensemble de petits multiples : pour chaque année de développement j , le nuage des couples $(C(i, j), C(i, j+1))$, la droite $y = \hat{f}_j x$ — celle qu'impose le règlement, passant par l'origine — et la droite ajustée avec constante. La deuxième porte les ordonnées à l'origine estimées $\hat{a}_j$ avec leur intervalle à 95 %. La troisième compare les estimateurs $\hat{f}_j^{(\alpha)}$ pour $\alpha = 0, 1$ et 2 .

2. Hypothèse nulle. Sans objet. Les tests numériques correspondants sont les fiches 14.2 et 14.5.

3. Statistique de test. Sans objet (représentations graphiques).

4. Loi sous H_0 . Sans objet.

5. p-value. Sans objet.

6. Usage et limites. Les petits multiples sont la contrepartie visuelle directe du test de nullité de l'ordonnée à l'origine : **l'écart entre les deux droites est le test**. Ils permettent en outre trois lectures qu'aucun test ne fournit : identifier la colonne responsable d'un rejet, repérer le point qui l'entraîne, et constater le

rétrécissement du nuage à mesure que n_j décroît — rappel visuel que les dernières colonnes ne reposent que sur deux ou trois points.

Le graphique des ordonnées à l'origine résume les mêmes informations sous forme compacte, les colonnes significatives étant mises en évidence. Celui de la famille α chiffre l'enjeu du choix de pondération : des courbes confondues signifient que la question est sans portée pratique sur le triangle considéré ; des courbes qui divergent sur une colonne désignent celle où l'hypothèse de proportionnalité ou de variance est la plus fragile.

Limite : seules les neuf premières années de développement sont représentées en petits multiples, au-delà la lisibilité s'effondre. Les colonnes suivantes comptent de toute façon moins de trois observations et ne sont pas testées.

12.8 Influence et leviers du triangle (Merz–Wüthrich)

Référence. T. Mack (1993), *op. cit.*, pour la structure de pondération ; R. D. Cook (1977) et D. C. Hoaglin, R. E. Welsch (1978), *op. cit.*, pour les notions de levier et d'influence transposées ici.

1. Cadre, notations et hypothèses de validité (non testées). Trois représentations. Le facteur $\hat{f}_j$ étant une moyenne pondérée des facteurs individuels de poids $C(i, j)$, le levier *exact* de la cellule (i, j) dans son estimation vaut $h(i, j) = C(i, j)/S_j$, de somme 1 par colonne (vérifié numériquement). L'influence exacte se mesure par le DFBETA

$$\hat{f}_j^{(-i)} = \frac{\sum_{i'} C(i', j+1) - C(i, j+1)}{\sum_{i'} C(i', j) - C(i, j)},$$

obtenu sans réajustement itératif. **Diagnostics, non tests.**

2. Hypothèse nulle. Sans objet.

3. Statistique de test. Sans objet (représentations graphiques). Les quantités tracées sont $h(i, j)$, la variation relative $(\hat{f}_j^{(-i)} - \hat{f}_j)/\hat{f}_j$, et la décomposition de la réserve et de la variance de processus par année de survénance (champ `$terme_variance` de `mw_msep()`).

4. Loi sous H_0 . Sans objet.

5. p-value. Sans objet.

6. Usage et limites. Le premier graphique croise levier et résidu de Mack : il sépare les cellules atypiques par leur *poids* de celles qui sont réellement influentes. Le deuxième donne le DFBETA cellule par cellule, directement interprétable : de combien le facteur de développement bougerait si cette cellule était retirée. Le troisième compare, année de survénance par année de survénance, la part de la réserve et la part de la variance de processus de la MSEP.

Réserve de lecture importante. Ce troisième graphique est une *décomposition* et non un *leave-one-out*. Le terme d'erreur d'estimation de la MSEP (champ `$terme_covariance` de `mw_msep()`) comporte des termes croisés, partagés entre paires d'années de survénance, qui ne sont pas attribuables à une année isolée : seule la variance de processus, attribuable année par année, y figure. Il n'existe donc pas, pour la méthode Merz–Wüthrich, d'équivalent exact du jackknife sur σ_{USP} disponible pour la méthode lognormale ; c'est le diagnostic de concentration (fiche 18.2) qui en tient lieu.

Méthode Merz–Wüthrich — cadre et spécification

13.1 Positionnement par rapport à la méthode lognormale

L'annexe XVII ouvre deux voies pour l'écart-type propre du risque de réserve. La section C (méthode n° 1) repose sur un modèle lognormal appliqué à deux vecteurs annuels ; la section D (méthode n° 2) repose sur un modèle de chaîne d'échelle appliqué à un *triangle* de paiements cumulés, et sur l'erreur de prédiction à un an de Merz–Wüthrich. Les deux méthodes visent le même paramètre mais reposent sur des hypothèses de nature différente, ce qui commande des batteries de tests distinctes.

	Méthode lognormale (B et C)	Merz–Wüthrich (D)
Donnée d'entrée	deux vecteurs x_t, y_t de longueur T	triangle $C(i, j), (I + 1) \times (J + 1)$
Modèle	$\mathbb{E}[Y_t] = \beta x_t$, variance quadratique, loi lognormale	chaîne d'échelle : $\mathbb{E}[C(i, j + 1) C(i, j)] = f_j C(i, j)$, variance proportionnelle à $C(i, j)$
Loi spécifiée	oui, entièrement	non : seuls les deux premiers moments
Paramètres estimés	β, δ, γ (maximum de vraisemblance)	f_j, σ_j^2 (moindres carrés pondérés)
Estimation de l'écart-type	fonction $\sigma(\delta, \gamma)$	$\sqrt{\text{MSEP}}$ rapportée à la réserve
Correction de taille finie	$\sqrt{(T + 1)/(T - 1)}$	aucune
Durée de crédibilité	années de survénance (B) ou exercices (C)	années de survénance, section G(3)(c)
Nature du bootstrap	paramétrique (loi entièrement spécifiée)	semi-paramétrique, par rééchantillonnage des résidus

13.2 Spécification réglementaire

Les formules ci-dessous sont la transcription littérale de l'annexe XVII, section D, paragraphes 3 à 5, sous leur *forme imprimée* et non sous une forme algébriquement équivalente plus compacte : un lecteur doit pouvoir les comparer au texte terme à terme. Les années de survénance sont indexées $i = 0, \dots, I$, les années de développement $j = 0, \dots, J$, et $C(i, j)$ désigne les sinistres cumulés.

Version du texte et pagination. Les formules ont été relevées sur la version consolidée en vigueur de l'annexe XVII. Pour le paragraphe 5, le libellé publié en 2015 diffère de celui en vigueur : c'est ce dernier qui est reproduit ci-dessous et qu'implémente `mw_msep()`. L'acte qui a opéré cette correction n'est pas identifié à ce jour ; l'hypothèse d'un rectificatif refondu sans marqueur de modification, la seule que suggèrent les pièces consultées, est signalée comme une hypothèse et non comme un fait établi. La pagination « L 12/277-278 », qui circule dans les documents de travail du projet, n'a pas été vérifiée sur le *Journal officiel* ; elle n'est donc pas reprise ici.

Facteurs de développement.

$$\hat{f}_j = \frac{\sum_{i=0}^{I-j-1} C(i, j+1)}{\sum_{i=0}^{I-j-1} C(i, j)}, \quad \hat{C}(i, j) = C(i, I-i) \hat{f}_{I-i} \cdots \hat{f}_{j-2} \hat{f}_{j-1}.$$

Variances de développement. Pour $j = 0, \dots, J - 2$,

$$\hat{\sigma}_j^2 = \frac{1}{I - j - 1} \sum_{i=0}^{I-j-1} C(i, j) \left(\frac{C(i, j+1)}{C(i, j)} - \hat{f}_j \right)^2,$$

et, pour la dernière année de développement, le règlement impose l'extrapolation

$$\hat{\sigma}_{J-1}^2 = \min \left(\hat{\sigma}_{J-2}^2, \hat{\sigma}_{J-3}^2, \frac{\hat{\sigma}_{J-2}^4}{\hat{\sigma}_{J-3}^2} \right).$$

Erreur quadratique moyenne de prédiction. En posant $\hat{Q}_j = \hat{\sigma}_j^2 / \hat{f}_j^2$, $S_j = \sum_{i=0}^{I-j-1} C(i, j)$ et $S'_j = \sum_{i=0}^{I-j} C(i, j)$:

$$\begin{aligned} \text{MSEP} = & \sum_{i=1}^I \hat{C}(i, J)^2 \left(\frac{\hat{Q}_{I-i}}{C(i, I-i)} + \frac{\hat{Q}_{I-i}}{S_{I-i}} + \sum_{j=I-i+1}^{J-1} \frac{C(I-j, j)}{S'_j} \cdot \frac{\hat{Q}_j}{S_j} \right) \\ & + 2 \sum_{i=1}^I \sum_{k=i+1}^I \hat{C}(i, J) \hat{C}(k, J) \left(\frac{\hat{Q}_{I-i}}{S_{I-i}} + \sum_{j=I-i+1}^{J-1} \frac{C(I-j, j)}{S'_j} \cdot \frac{\hat{Q}_j}{S_j} \right). \end{aligned}$$

Le crochet, noté Δ_i comme dans `mw_msep()`, figure **deux fois** : une première fois à l'intérieur de la première somme, à côté du terme de variance de processus $\hat{Q}_{I-i}/C(i, I-i)$, et une seconde fois dans la double somme, affectée du **facteur 2**. La première somme contient donc les termes diagonaux $\hat{C}(i, J)^2 \Delta_i$. Les bornes $k = i + 1, \dots, I$, l'indice $I - i$ porté par le crochet, le facteur 2 et l'exposant 1 sur $C(I - j, j)/S'_j$ sont ceux du texte. Cette notation Δ_i , propre à la méthode Merz-Wüthrich, est sans rapport avec la marge d'équivalence Δ du test TOST de la méthode lognormale.

Forme imprimée et forme de Merz-Wüthrich. Pour $k > i$, le crochet indexé par i est celui indexé par $\min(i, k)$, et $2 \sum_{i < k}$ reproduit exactement la double somme complète hors diagonale ; les termes diagonaux étant portés par la première somme, la formule imprimée ci-dessus est identiquement l'erreur de prédiction à un an de Merz-Wüthrich (2008). Le moteur transcrit la *forme imprimée* ; cette identité est *vérifiée* numériquement (section 19) et non présumée.

Restitution du résultat. `mw_msep()` renvoie la MSEP et deux composantes : `$terme_variance` = $\sum_{i=1}^I \hat{C}(i, J)^2 \hat{Q}_{I-i}/C(i, I-i)$, la variance de processus seule, et `$terme_covariance` = $\sum_{i=1}^I \hat{C}(i, J)^2 \Delta_i + 2 \sum_{i < k} \hat{C}(i, J) \hat{C}(k, J) \Delta_i$, l'erreur d'estimation, ses termes diagonaux compris. Leur somme est exactement la MSEP du texte. Ce découpage est un choix de présentation : le règlement ne prescrit aucune décomposition.

Paramètre propre.

$$\sigma_{(\text{res}, s, \text{USP})} = c \cdot \frac{\sqrt{\text{MSEP}}}{\sum_{i=0}^I (\hat{C}(i, J) - C(i, I-i))} + (1 - c) \sigma_{(\text{res}, s)}.$$

Domaine de définition. Le dénominateur $\hat{R} = \sum_{i=0}^I (\hat{C}(i, J) - C(i, I-i))$ est l'estimation chain-ladder de la réserve totale. Le rapport $\sqrt{\text{MSEP}}/\hat{R}$ que le paragraphe 4 met en facteur de c est un *coefficient de variation à horizon un an* de cette réserve : la MSEP du paragraphe 5 mesure l'erreur de prédiction à un an de l'engagement réévalué, dont $\hat{R}$ est l'espérance conditionnelle estimée. **Le paragraphe ne le nomme pas ainsi** : c 'est une caractérisation de la grandeur, pas une citation du texte.

Le moteur refuse le calcul lorsque $\hat{R} \leq 0$, et lorsque la MSEP n'est pas finie ou est négative ; il retourne alors `ok = FALSE` et le champ `validation` (`mw_valider_ajustement()`, section 3). **Ces refus n'ont pas tous le même statut**, et le document les distingue.

(i) $\hat{R} = 0$: *fait mathématique*. La division n'est pas définie et l'expression du paragraphe 4 ne produit aucune valeur. Il n'y a rien à interpréter.

(ii) $\hat{R} < 0$: *interprétation, déclarée comme telle*. L'expression arithmétique du paragraphe 4 est ici **parfaitement définie et rend un nombre** : sur un triangle à cumulés décroissants de réserve totale $\hat{R} = -372,397$, elle rend 0,034877. Le refus n'est donc **pas** imposé par l'arithmétique : c'est une interprétation du texte, retenue par l'outil, et fondée sur trois appuis.

- **La grandeur que le paragraphe 4 annonce est « l'écart type »** propre à l'entreprise. Un écart type est non négatif par définition de ce que le paragraphe prétend produire : un nombre négatif n'est pas un écart type mal calibré, ce n'est pas un écart type. Or, pour $\hat{R} < 0$, le rapport $\sqrt{\text{MSEP}}/\hat{R}$ est négatif, et le mélange de crédibilité rend un $\sigma_{(\text{res},s,\text{USP})}$ *inférieur* à l'écart-type standard $\sigma_{(\text{res},s)}$ — un allègement d'exigence obtenu par une division par un nombre négatif. C'est l'appui principal.
- **Le refus ne prive l'entreprise d'aucun droit**. L'article 220, paragraphe 1, point b) présente les méthodes du risque de réserve n° 1 (section C) et n° 2 (section D) comme *alternatives* : l'entreprise à qui l'outil refuse la seconde conserve la première. Le refus ne crée donc aucune impasse réglementaire, ce qui est la condition de son admissibilité.
- **Le règlement envisage lui-même le cas**. L'article 220, paragraphe 2, prévoit qu'une entreprise puisse ne pas être « en mesure d'utiliser » une méthode standardisée, et impose alors de retenir « le résultat le plus prudent ». Un paramètre propre *inférieur* au paramètre standard, obtenu par une division par un nombre négatif, en est l'exact contraire.

Un quatrième appui, hors annexe XVII, va dans le même sens : le règlement refuse explicitement qu'un risque de réserve soit porté par un volume négatif.

Article 116, paragraphe 6, du règlement délégué (UE) 2015/35

Pour tous les segments visés à l'annexe II, la mesure de volume pour le risque de réserve pour un segment donné est égale à la meilleure estimation des provisions pour sinistres à payer [...]. La mesure de volume n'est pas un montant négatif.

Les deux grandeurs ne se confondent pas : la mesure de volume de l'article 116 est la meilleure estimation des provisions pour sinistres à payer, tandis que $\hat{R}$ est l'estimation que la chaîne d'échelle produit sur le triangle fourni. Mais l'écart-type que la section D calibre est précisément celui que la formule standard applique à cette mesure de volume, dont le règlement exige qu'elle ne soit pas négative. Refuser de calibrer $\sigma_{(\text{res},s,\text{USP})}$ sur une réserve négative prolonge donc une exigence du texte plutôt que d'y ajouter une règle propre à l'outil.

(iii) *MSEP non finie ou négative : convention d'implémentation*. Tous les termes du paragraphe 5 sont positifs ou nuls sur un triangle recevable ; ce cas est inatteignable depuis `run_engine()`. Le contrôle est une garde défensive, qui préserve le domaine de $\sqrt{\text{MSEP}}$ si `mw_valider_ajustement()` est appelée hors de la chaîne. Ce n'est pas une lecture du texte.

Le refus porte sur le **total** $\hat{R}$, et sur lui seul. **Le texte ne se prononce ni sur l'un ni sur l'autre** : aucun paragraphe de la section D ne traite le cas d'une réserve négative, au total comme par année de survenance. La distinction est donc une **décision de l'outil**, et non une lecture du règlement : seule la somme $\sum_{i=0}^I (\hat{C}(i, J) - C(i, I - i))$ figure au dénominateur du paragraphe 4, et l'outil ne refuse que ce que cette formule rend inexploitable, à savoir le total. Des réserves négatives sur certaines années de survenance — bonis de liquidation, recours sur années anciennes —, ou un facteur $\hat{f}_j < 1$ isolé, restent donc licites : dès lors que $\hat{R} > 0$, le calcul est mené normalement et ces situations ne donnent lieu qu'à l'avertissement sur les cumulés décroissants (section 3).

Restriction d’implémentation. Le paragraphe 2(e) autorise $I \geq J$, mais la formule du paragraphe 4 fait intervenir $C(i, I - i)$, qui n’est définie que si $I - i \leq J$. Le cas $I > J$ produirait un trapèze dont le texte ne précise pas le traitement. Le moteur impose donc $I = J$ (triangle carré) et refuse explicitement les autres géométries, plutôt que de les traiter par une convention implicite non prévue par le règlement.

13.3 Hypothèses testables et résidus

Le paragraphe 2(h) énonce quatre hypothèses, qui structurent la batterie de tests au même titre que H1 à H4 pour la méthode lognormale :

Code	Énoncé (annexe XVII, D(2)(h))	Correspondance lognormale
M1	(iii) $\mathbb{E}[C(i, j + 1) \mid C(i, j)] = f_j C(i, j)$	H1 — même forme de proportionnalité sans constante
M2	(iv) $\text{Var}[C(i, j + 1) \mid C(i, j)] = \sigma_j^2 C(i, j)$	H2 — mais puissance 1 imposée, sans mélange δ à estimer
M3	(i) et (ii) indépendance entre années de surveillance et entre montants incrémentaux	H4 — indépendance
M5	<i>aucune</i>	H3 — sans équivalent : la lognormalité n’est pas requise

Le support des tests est le résidu standardisé de Mack

$$r(i, j) = \frac{\sqrt{C(i, j)}}{\hat{\sigma}_j} \left(\frac{C(i, j + 1)}{C(i, j)} - \hat{f}_j \right),$$

centré, d’échelle approximativement unitaire et non corrélé sous M1 à M3.

La normalité n’est pas une hypothèse de la méthode. Le paragraphe 2(h) ne spécifie que les deux premiers moments conditionnels. Les tests de normalité figurent donc dans la famille M5 comme *diagnostics*, et non comme vérifications d’une hypothèse réglementaire. Ils ne deviennent pertinents que si l’on souhaite exploiter la MSEP pour construire un quantile, usage qui excède la méthode elle-même.

13.4 Réemploi et adaptation des tests

Test	Statut	Commentaire
Durbin–Watson, test des suites, Grubbs, Rosner, Shapiro–Wilk, Lilliefors	réemployés	Appliqués aux résidus de Mack au lieu des résidus normalisés ; la statistique est inchangée, seule la loi de référence est réévaluée.
Breusch–Pagan studentisé	adapté	Régression des carrés des résidus sur $C(i, j)$ et non sur le volume x_t : teste la puissance 1 de M2.
Test de proportionnalité	adapté	Régression pondérée des facteurs $F(i, j)$ sur $C(i, j)$: une pente non nulle contredit M1.
Test des effets d’année calendaire	nouveau	Propre aux triangles : les diagonales représentent les exercices comptables. Sans équivalent dans la méthode lognormale.
Corrélation entre années de développement	nouveau	Teste M3(ii) entre colonnes adjacentes.
Mann–Kendall, Cox–Stuart, Spearman, RESET, TOST, sup-F, CU-SUM	sans objet	Ces tests portent sur une série chronologique de ratios, objet qui n’existe pas dans la géométrie du triangle.

Synthèse de couverture

Famille	Entrées	Type	p-value retenue
M1	Tendance avec le cumulé, à colonne donnée	test	Monte-Carlo
M1	Ordonnée à l'origine, colonne par colonne	test	Monte-Carlo
M1	Homogénéité de f_j entre années de survenance	test	Monte-Carlo
M1	Absence de courbure	test	Monte-Carlo
M1	Famille α (pondération)	test	Monte-Carlo
M2	Hétéroscédasticité résiduelle contre le cumulé	test	Monte-Carlo
M2	Exposant de variance, colonne par colonne	test	Monte-Carlo
M2	Variance unitaire des résidus	diagnostic	—
M3	Homogénéité des résidus entre années de survenance	test	Monte-Carlo
M3	Effets d'année calendaire	test	Monte-Carlo
M3	Corrélation entre années de développement	test	Monte-Carlo
M3	Autocorrélation (Durbin–Watson)	test	Monte-Carlo
M3	Test des suites	test	Monte-Carlo
M4	Cellule aberrante (Grubbs)	test	Monte-Carlo
M4	Cellules aberrantes multiples (Rosner)	procédure de décision	—
M5	Shapiro–Wilk	test (diagnostic)	exacte simulée
M5	Lilliefors	test (diagnostic), secondaire	asymptotique
M6	Extrapolation de $\hat{\sigma}_{j-1}^2$	diagnostic	—
M6	Concentration de la réserve	diagnostic	—

Dix-neuf entrées, dont quatorze tests d'hypothèse, une procédure de décision et quatre diagnostics. Treize des quatorze tests reposent sur le bootstrap de résidus ; seul Shapiro–Wilk dispose d'une loi nulle propre, pour la raison exposée dans sa fiche. Les six entrées en gras ci-dessus sont celles qui vérifient les hypothèses de chaîne d'échelle *colonne par colonne*, comme l'exige la formulation « pour toutes les années d'accident » du texte ; la régression agrégée initiale, conservée en tête, ne le permettait pas.

Hypothèse M1 — proportionnalité des cumulés

Énoncé. annexe XVII, D(2)(h)(iii) : $\mathbb{E}[C(i, j+1) \mid C(i, j)] = f_j C(i, j)$.

Les fiches ci-dessous suivent la structure en six rubriques employée pour les hypothèses H1 à H4 de la méthode lognormale. Les notations sont celles de la section 2.

14.1 M1 — Absence de tendance des facteurs avec le cumulé, à colonne donnée

Référence. T. Mack, *Distribution-free calculation of the standard error of chain ladder reserve estimates*, *ASTIN Bulletin*, 23(2), 1993, section 3.

1. Cadre, notations et hypothèses de validité (non testées). Régression auxiliaire menée sur l'ensemble des cellules du triangle :

$$F(i, j) = \mu_j + b C(i, j) + \varepsilon_{ij}, \quad \text{poids } w_{ij} = C(i, j) / \hat{\sigma}_j^2,$$

où μ_j est un **effet fixe d'année de développement**. Deux points de construction sont déterminants et ont été établis par simulation.

L'effet fixe de colonne est indispensable. Le facteur f_j décroît fortement avec j (de 3,49 à 1,02 sur le triangle de contrôle) alors que le cumulé $C(i, j)$ croît : une régression agrégée *sans* terme de colonne capte cette relation mécanique et non une dépendance au volume. Sur des triangles simulés *exactement* sous H_0 , une telle régression rejette dans **100 % des cas**. Avec l'effet fixe, la fréquence de rejet revient à 0,068 au seuil nominal de 0,10.

La pondération doit être celle des moindres carrés généralisés. Puisque $\text{Var}(F(i, j)) = \sigma_j^2 / C(i, j)$, le poids exact est $C(i, j) / \sigma_j^2$ et non $C(i, j)$ seul : σ_j^2 varie de plusieurs ordres de grandeur entre la première et la dernière colonne, et pondérer par $C(i, j)$ seul rend l'échelle résiduelle dominée par les premières colonnes — au point que le test ne rejette *jamaïs* sous l'alternative comme sous l'hypothèse nulle.

2. Hypothèse nulle. $H_0 : b = 0$ — à année de développement donnée, le facteur de développement ne dépend pas du niveau du cumulé.

3. Statistique de test. $t = \hat{b} / \widehat{\text{se}}(\hat{b})$ dans la régression pondérée à effet fixe de colonne.

4. Loi sous H_0 . Loi de Student approchée : les cellules d'une même colonne partagent $\hat{f}_j$ et $\hat{\sigma}_j$, ce qui invalide les degrés de liberté nominaux. Loi de référence : bootstrap de résidus.

5. p-value. p-value de Monte-Carlo retenue ; la p-value de Student est fournie comme complément non simulé.

6. Usage et limites. Ce test est le pendant *agrégé* du test d'ordonnée à l'origine par colonne qui suit : il gagne en puissance ce que l'autre gagne en localisation. Puissance mesurée sous une alternative où le facteur dépend linéairement du volume : 100 % de rejets au seuil de 10 %. Il ne dit pas, en revanche, quelle colonne est en cause : c'est le rôle du test par colonne et du graphique en petits multiples.

14.2 M1 — Nullité de l'ordonnée à l'origine, colonne par colonne

Référence. T. Mack, *Distribution-free calculation of the standard error of chain ladder reserve estimates*, *ASTIN Bulletin*, 23(2), 1993, section 3 ; combinaison des p-values : R. A. Fisher, *Statistical Methods for Research Workers*, 4^e éd., Oliver & Boyd, 1932, §21.1.

1. Cadre, notations et hypothèses de validité (non testées). Pour chaque année de développement j comptant au moins trois observations, on ajuste la régression pondérée

$$C(i, j + 1) = a_j + b_j C(i, j) + \varepsilon_{ij}, \quad \text{poids } w_{ij} = 1/C(i, j),$$

sur les $n_j = I - j$ couples disponibles. Le choix du poids n'est pas arbitraire : il découle de l'hypothèse de variance M2, et il possède une propriété remarquable établie par Mack — **la régression pondérée sans constante et de poids $1/C(i, j)$ a pour estimateur des moindres carrés exactement le facteur chain-ladder** :

$$\hat{b}_j^{(\text{sans constante})} = \frac{\sum_i w_{ij} C(i, j) C(i, j + 1)}{\sum_i w_{ij} C(i, j)^2} = \frac{\sum_i C(i, j + 1)}{\sum_i C(i, j)} = \hat{f}_j.$$

Cette identité a été vérifiée numériquement colonne par colonne, à 10^{-16} près. Elle est ce qui fait de l'ajout d'une constante le test *naturel* de l'hypothèse réglementaire. Hypothèses de validité non testées : indépendance des lignes, variance correctement pondérée, erreurs approximativement normales.

2. Hypothèse nulle. $H_0 : a_j = 0$ pour toute année de développement j , c'est-à-dire la proportionnalité stricte exigée par D(2)(h)(iii).

3. Statistique de test. Statistique de Student $t_j = \hat{a}_j / \widehat{\text{se}}(\hat{a}_j)$ dans chaque colonne, puis combinaison des K p-values par la méthode de Fisher : $X = -2 \sum_k \ln p_k$.

4. Loi sous H_0 . $X \sim \chi^2(2K)$ si les colonnes étaient indépendantes. Elles ne le sont pas tout à fait : les colonnes j et $j + 1$ partagent le vecteur $C(\cdot, j + 1)$. La p-value du khi-deux est donc rapportée comme non simulée et *indicative* ; la loi de référence retenue est celle du bootstrap de résidus.

5. p-value. p-value de Monte-Carlo retenue. Calibration vérifiée par simulation sous H_0 (1 500 triangles 10×10) : 10,7 % de rejets au seuil nominal de 10 % et 4,7 % au seuil de 5 %.

6. Usage et limites. C'est le test central de M1, et celui que la régression agrégée ne pouvait pas fournir. Il répond à la première des deux exigences du texte réglementaire : une proportionnalité *sans constante*, vérifiée *pour chaque* année de développement. Le graphique des petits multiples (section 12.7) en donne la contrepartie visuelle : la droite pleine est la proportionnalité imposée par le règlement, la droite pointillée l'ajustement libre ; l'écart entre les deux *est* le test.

Limite : le nombre d'observations décroît de I à 3 le long du triangle, si bien que les dernières colonnes ne contribuent presque rien. Le tableau détaillé restitué par le moteur donne la colonne responsable, ce qui est la seule lecture actionnable.

14.3 M1 — Homogénéité de f_j entre années de survenance

Référence. Annexe XVII, D(2)(h)(iii), dont la formulation « pour toutes les années d'accident » constitue la seconde exigence ; C. Spearman (1904), *op. cit.* pour la corrélation de rang.

1. Cadre, notations et hypothèses de validité (non testées). Dans chaque colonne j comptant au moins quatre observations, on mesure la corrélation de rang entre les facteurs individuels $F(i, j)$ et l'indice i de l'année de survenance. Hypothèses non testées : continuité, absence d'ex æquo.

2. Hypothèse nulle. H_0 : le facteur f_j est commun à toutes les années de survenance ; les facteurs individuels ne présentent aucune tendance en i .

3. Statistique de test. $\hat{p}_{s,j}$ par colonne, p-values combinées par la méthode de Fisher.

4. Loi sous H_0 . $\chi^2(2K)$ approchée, avec la même réserve d'indépendance que la fiche précédente. Loi de référence : bootstrap de résidus.

5. p-value. p-value de Monte-Carlo retenue.

6. Usage et limites. Ce test répond à la *seconde* exigence du texte, distincte de la première : même si la proportionnalité vaut dans chaque colonne, un facteur qui dériverait d'une année de survenance à l'autre invaliderait le modèle. En pratique, une telle dérive traduit un changement de politique de règlement ou de mix de portefeuille. Elle n'est pas détectable par le test d'ordonnée à l'origine, qui porte sur le niveau et non sur la pente.

14.4 M1 — Absence de courbure de la régression

Référence. Test du terme quadratique, dans l'esprit de J. B. Ramsey (1969), *op. cit.* ; appliqué ici colonne par colonne.

1. Cadre, notations et hypothèses de validité (non testées). Régression pondérée augmentée d'un terme quadratique, $C(i, j + 1) = a_j + b_j C(i, j) + c_j C(i, j)^2 + \varepsilon_{ij}$, poids $1/C(i, j)$, sur les colonnes comptant au moins quatre observations.

2. Hypothèse nulle. H_0 : $c_j = 0$ dans chaque colonne.

3. Statistique de test. Statistique de Student sur $\hat{c}_j$, p-values combinées par Fisher.

4. Loi sous H_0 . $\chi^2(2K)$ approchée. Loi de référence : bootstrap de résidus.

5. p-value. p-value de Monte-Carlo retenue.

6. Usage et limites. La linéarité et la nullité de la constante sont deux propriétés distinctes : une relation courbe peut passer par l'origine et satisfaire le test précédent tout en contredisant $\mathbb{E}[C(i, j + 1) \mid C(i, j)] = f_j C(i, j)$. Ce test ferme cette possibilité. Limite sévère à faible profondeur : estimer trois paramètres sur quatre à six observations laisse très peu de degrés de liberté, et la puissance est faible.

14.5 M1 — Stabilité du facteur selon la pondération (famille α)

Référence. T. Mack, *Which stochastic model is underlying the chain ladder method?*, *Insurance : Mathematics and Economics*, 15(2–3), 1994.

1. Cadre, notations et hypothèses de validité (non testées). On considère la famille d'estimateurs

$$\hat{f}_j^{(\alpha)} = \frac{\sum_i C(i, j)^\alpha F(i, j)}{\sum_i C(i, j)^\alpha}, \quad \alpha \in \{0, 1, 2\},$$

où $\alpha = 0$ donne la moyenne simple des facteurs individuels, $\alpha = 1$ le facteur chain-ladder du règlement, et $\alpha = 2$ une pondération par le carré du volume. **Sous l'hypothèse M1, les trois estiment la même quantité** : l'espérance conditionnelle étant proportionnelle à $C(i, j)$, tout jeu de poids positifs fournit un estimateur sans biais de f_j .

2. Hypothèse nulle. H_0 : les trois estimateurs visent le même f_j dans chaque colonne.

3. Statistique de test. Amplitude relative moyenne, pondérée par les effectifs :

$$A = \frac{\sum_j n_j (\max_{\alpha} \hat{f}_j^{(\alpha)} - \min_{\alpha} \hat{f}_j^{(\alpha)}) / \hat{f}_j^{(1)}}{\sum_j n_j}.$$

4. Loi sous H_0 . **Aucune loi analytique** : la statistique agrège trois estimateurs fortement corrélés sur des colonnes de tailles décroissantes.

5. p-value. p-value de Monte-Carlo exclusivement.

6. Usage et limites. Diagnostic de robustesse plus que test d'hypothèse. Une divergence marquée signale soit que l'espérance n'est pas proportionnelle à $C(i, j)$ (violation de M1), soit que la pondération en $C(i, j)$ est inadaptée (violation de M2) : le test ne sépare pas les deux causes, et doit donc être lu conjointement avec la fiche 14.7. Son intérêt propre est de chiffrer l'enjeu : si A est faible, le choix de pondération imposé par le règlement est sans conséquence matérielle sur le paramètre final.

14.6 M2 — Hétéroscédasticité résiduelle contre le cumulé

Référence. T. S. Breusch, A. R. Pagan (1979), *op. cit.* ; version studentisée de R. Koenker (1981), *op. cit.*, appliquée ici aux résidus de Mack.

1. Cadre, notations et hypothèses de validité (non testées). Régression auxiliaire $r(i, j)^2 = c_0 + c_1 C(i, j) + \eta$, de coefficient de détermination R_{aux}^2 , sur les $\sum_j n_j$ cellules du triangle. Hypothèses non testées : indépendance des cellules, validité de l'approximation asymptotique.

2. Hypothèse nulle. $H_0 : c_1 = 0$ — les résidus standardisés ne dépendent plus de $C(i, j)$, donc la pondération en $C(i, j)$ imposée par M2 capture correctement la variance.

3. Statistique de test. $LM = n R_{\text{aux}}^2$, où n est le nombre de résidus.

4. Loi sous H_0 . $\chi^2(1)$ asymptotique. L'approximation est doublement fragile ici : le nombre de cellules est modeste et les résidus d'une même colonne sont liés par $\hat{f}_j$ et $\hat{\sigma}_j$.

5. p-value. p-value de Monte-Carlo retenue ; la p-value du khi-deux est fournie comme complément non simulé. **Celle-ci sous-rejette massivement** : 0,5 % de rejets mesurés au seuil nominal de 10 % (section 19.2), car $\hat{\sigma}_j^2$ est estimé sur la colonne même, ce qui réduit la dispersion des résidus standardisés et donc le R^2 de la régression auxiliaire.

6. Usage et limites. Ce test porte spécifiquement sur l'exposant 1 de la structure de variance $\text{Var}[C(i, j+1) \mid C(i, j)] = \sigma_j^2 C(i, j)$. Un rejet suggère un exposant différent — variance constante ($\alpha = 0$) ou proportionnelle au carré ($\alpha = 2$) — alternatives discutées par Barnett & Zehnirith mais *non prévues par l'annexe XVII*, qui impose $\alpha = 1$. Le rejet doit donc être documenté comme une limite du modèle réglementaire, non comme un motif de changement de méthode.

14.7 M2 — Adéquation de l'exposant de variance, colonne par colonne

Référence. Annexe XVII, D(2)(h)(iv) ; complément par colonne du test de Breusch–Pagan de la fiche précédente.

1. Cadre, notations et hypothèses de validité (non testées). Dans chaque colonne j comptant au moins quatre résidus, on mesure la corrélation de rang entre $|r(i, j)|$ et $C(i, j)$.

2. Hypothèse nulle. H_0 : l'amplitude des résidus standardisés ne dépend pas de $C(i, j)$ à l'intérieur d'une colonne, ce qui est la traduction directe de $\text{Var}[C(i, j+1) \mid C(i, j)] = \sigma_j^2 C(i, j)$.

3. Statistique de test. $\hat{\rho}_{s,j}$ par colonne, p-values combinées par Fisher.

4. Loi sous H_0 . $\chi^2(2K)$ approchée. Loi de référence : bootstrap de résidus.

5. p-value. p-value de Monte-Carlo retenue.

6. Usage et limites. Le test de Breusch–Pagan de la fiche précédente agrège toutes les colonnes ; ce test-ci localise. Un rejet signale que l'exposant 1 imposé par le règlement est inadapté — l'alternative étant un exposant 0 (variance constante) ou 2 (proportionnelle au carré). **Le règlement ne laissant pas ce choix ouvert**, un rejet doit être documenté comme une limite du modèle réglementaire et non comme un motif de changement de méthode.

14.8 M2 — Variance unitaire des résidus de Mack (diagnostic)

Référence. Diagnostic d'échelle ; Mack (1993), *op. cit.*, définition de $\hat{\sigma}_j^2$.

1. Cadre, notations et hypothèses de validité (non testées). Résidus standardisés $r(i, j)$. **Diagnostic, non test** : la rubrique est renseignée par cohérence de présentation.

2. Hypothèse nulle. Sans objet. Par construction, $\hat{\sigma}_j^2$ est calibré colonne par colonne, de sorte que la variance des résidus vaut approximativement 1 à l'intérieur de chaque colonne, sans que la variance globale soit contrainte.

3. Statistique de test. $\text{Var}(r(i, j))$ sur l'ensemble du triangle.

4. Loi sous H_0 . Sans objet.

5. p-value. Aucune. Le moteur signale un écart supérieur à 0,5 en valeur absolue.

6. Usage et limites. Une variance globale nettement différente de 1 signale une mauvaise spécification de $\hat{\sigma}_j$, le plus souvent concentrée sur les dernières colonnes, où n_j tombe à deux ou trois observations. À lire conjointement avec la fiche sur l'extrapolation de $\hat{\sigma}_{j-1}^2$.

Hypothèse M3 — indépendance

Énoncé. annexe XVII, D(2)(h)(i) et (ii) : indépendance des années de survenance et des montants incrémentaux.

Les fiches ci-dessous suivent la structure en six rubriques employée pour les hypothèses H1 à H4 de la méthode lognormale. Les notations sont celles de la section 2.

15.1 M3 — Effets d'année calendaire (test de Mack)

Référence. T. Mack, *Which stochastic model is underlying the chain ladder method?*, *Insurance : Mathematics and Economics*, 15(2–3), 1994, p. 133–138 ; T. Mack (1993), *op. cit.*, section 5.

1. Cadre, notations et hypothèses de validité (non testées). Dans chaque colonne j , les facteurs observés $F(i, j)$ sont classés en « grands » (L) et « petits » (S) par rapport à leur médiane, les valeurs égales à la médiane étant écartées. Les diagonales $k = i + j$ correspondent aux exercices comptables. Hypothèses non testées : continuité des facteurs, indépendance des colonnes.

2. Hypothèse nulle. H_0 : absence d'effet d'année calendaire — la répartition des L et des S le long de chaque diagonale est purement aléatoire, tous les arrangements étant équiprobables.

3. Statistique de test. Sur la diagonale k comportant n_k étiquettes dont L_k « grandes » : $Z_k = \min(L_k, n_k - L_k)$, puis $Z = \sum_k Z_k$ et

$$\frac{Z - \mathbb{E}[Z]}{\sqrt{\text{Var}[Z]}}.$$

4. Loi sous H_0 . Sous H_0 , $L_k \sim \mathcal{B}(n_k, 1/2)$, d'où les moments **exacts**, avec $m_k = \lfloor (n_k - 1)/2 \rfloor$:

$$\mathbb{E}[Z_k] = \frac{n_k}{2} - \binom{n_k - 1}{m_k} \frac{n_k}{2^{n_k}}, \quad \text{Var}[Z_k] = \frac{n_k(n_k - 1)}{4} - \binom{n_k - 1}{m_k} \frac{n_k(n_k - 1)}{2^{n_k}} + \mathbb{E}[Z_k] - \mathbb{E}[Z_k]^2.$$

Ces deux expressions ont été vérifiées par énumération exhaustive de la loi de $\min(L, n - L)$ pour $n = 2, \dots, 12$: concordance à 10^{-10} près. En revanche, la normalité de la *somme* Z n'est qu'approchée.

5. p-value. $p = 2(1 - \Phi(|Z^*|))$ pour la version asymptotique ; la p-value de Monte-Carlo est celle retenue.

6. Usage et limites. C'est le test le plus informatif du dispositif Merz–Wüthrich, car il détecte ce que ni M1 ni M2 ne voient : un choc affectant un exercice comptable entier (inflation, changement de cadence de règlement, modification de la politique de provisionnement). Un tel choc viole l'indépendance des années de survenance posée par D(2)(h)(i). Limite à $T = 8$: la somme ne porte que sur $I - 1$ diagonales exploitables, dont plusieurs ne comptent que deux ou trois étiquettes, d'où le recours au bootstrap plutôt qu'à l'approximation normale.

15.2 M3 — Homogénéité des résidus entre années de survenance

Référence. W. H. Kruskal, W. A. Wallis, *Use of ranks in one-criterion variance analysis*, *Journal of the American Statistical Association*, 47(260), 1952, p. 583–621.

1. Cadre, notations et hypothèses de validité (non testées). Les résidus de Mack sont groupés par année de survenance i . Le test compare les rangs entre groupes, sans hypothèse de loi. Hypothèses non testées : indépendance des résidus, continuité.

2. Hypothèse nulle. H_0 : les résidus ont la même distribution dans toutes les années de survenance, ce qui est la traduction testable de l'indépendance stochastique des années de survenance posée par D(2)(h)(i).

3. Statistique de test. H de Kruskal–Wallis, sur $k - 1$ degrés de liberté où k est le nombre d'années de survenance comportant au moins un résidu.

4. Loi sous H_0 . $\chi^2(k - 1)$ asymptotique, approximation médiocre lorsque les groupes comptent une ou deux observations — ce qui est le cas des dernières lignes du triangle. Loi de référence : bootstrap de résidus.

5. p-value. p-value de Monte-Carlo retenue ; le khi-deux est fourni comme complément non simulé.

6. Usage et limites. Complète le test des effets d'année calendaire, qui porte sur les diagonales : celui-ci porte sur les *lignes*. Un rejet signale qu'une année de survenance se comporte différemment des autres, ce qui viole l'hypothèse d'indépendance et d'identité de distribution. Limite structurelle : les groupes sont très déséquilibrés, la première ligne comptant J résidus et la dernière un seul.

15.3 M3 — Corrélation entre années de développement adjacentes

Référence. T. Mack (1993), *op. cit.*, section 4 ; C. Spearman (1904), *op. cit.* pour la corrélation de rang.

1. Cadre, notations et hypothèses de validité (non testées). Pour chaque paire de colonnes adjacentes $(k - 1 \rightarrow k)$ et $(k \rightarrow k + 1)$, on calcule la corrélation de rang de Spearman entre les facteurs individuels observés sur les mêmes années de survenance. L'agrégation est pondérée par $n_k - 1$. Hypothèses non testées : continuité, absence d'ex æquo.

2. Hypothèse nulle. H_0 : les facteurs de développement successifs ne sont pas corrélés, ce qui est la traduction testable de D(2)(h)(ii), l'indépendance des montants incrémentaux à l'intérieur d'une année de survenance.

3. Statistique de test. $\hat{\rho} = \frac{\sum_k (n_k - 1) \hat{\rho}_{s,k}}{\sum_k (n_k - 1)}$, moyenne pondérée des corrélations de rang par paire de colonnes.

4. Loi sous H_0 . **Aucune loi analytique** : la géométrie du triangle fait que les paires de colonnes se recouvrent partiellement et reposent sur des effectifs décroissants. Aucune approximation asymptotique n'est mobilisable.

5. p-value. p-value de Monte-Carlo exclusivement. C'est, avec la corrélation, le seul test du dispositif pour lequel aucune p-value non simulée n'existe.

6. Usage et limites. Un rejet signale que la cadence de liquidation d'une année de survenance est persistante : une année qui se développe vite sur une colonne continue de le faire sur la suivante. Cela contredit l'indépendance des incréments et biaise la MSEP, qui suppose que les erreurs de projection ne se cumulent pas. Limite : sur un triangle 8×8 , seules cinq ou six paires de colonnes comptent au moins trois observations, ce qui rend le test très peu puissant.

15.4 M3 — Autocorrélation des résidus de Mack (Durbin–Watson)

Référence. J. Durbin, G. S. Watson (1950, 1951), *op. cit.*

1. Cadre, notations et hypothèses de validité (non testées). Résidus de Mack ordonnés selon leur parcours du triangle (colonne par colonne, années de survenance croissantes). Hypothèses non testées : résidus homoscédastiques et de moyenne nulle sous le modèle.

2. Hypothèse nulle. H_0 : absence d'autocorrélation d'ordre 1 des résidus de Mack.

3. Statistique de test. $DW = \sum_{t=2}^n (z_t - z_{t-1})^2 / \sum_{t=1}^n z_t^2$, calculée sur les résidus centrés.

4. Loi sous H_0 . Contrairement à la méthode lognormale, la loi exacte d'Imhof n'est pas applicable ici : les résidus de Mack ne forment pas un vecteur gaussien de matrice de covariance connue, la structure de dépendance dépendant de la géométrie du triangle. La loi de référence est celle du bootstrap de résidus.

5. p-value. p-value de Monte-Carlo exclusivement.

6. Usage et limites. Complément aux deux tests précédents : l'ordre de parcours étant conventionnel, un rejet est plus difficile à interpréter que pour une série chronologique. Il faut alors se reporter aux graphiques des résidus par année de survenance, de développement et calendrier, qui localisent la structure.

15.5 M3 — Test des suites sur les résidus de Mack

Référence. A. Wald, J. Wolfowitz (1940), *op. cit.*

1. Cadre, notations et hypothèses de validité (non testées). Suite des signes des résidus de Mack par rapport à leur médiane, dans le même ordre de parcours que ci-dessus. On note n_1 le nombre de signes positifs, n_2 le nombre de négatifs et R le nombre de suites.

2. Hypothèse nulle. H_0 : la suite des signes est un arrangement aléatoire.

3. Statistique de test. $Z = (R - \mathbb{E}[R]) / \sqrt{\text{Var}[R]}$, avec $\mathbb{E}[R] = 2n_1n_2/n + 1$ et $\text{Var}[R] = 2n_1n_2(2n_1n_2 - n) / (n^2(n - 1))$.

4. Loi sous H_0 . La loi combinatoire exacte du nombre de suites suppose l'échangeabilité des signes, mise en défaut ici par la dépendance intra-colonne : elle n'est donc pas retenue, contrairement à ce qui est fait pour la méthode lognormale. Loi de référence : bootstrap de résidus.

5. p-value. p-value de Monte-Carlo retenue ; l'approximation normale est fournie comme complément non simulé. **Celle-ci sur-rejette nettement** : 15,3 % de rejets mesurés au seuil nominal de 10 % (section 19.2). La cause est identifiée : la contrainte $\sum_i \sqrt{C(i, j)} r(i, j) = 0$ rend les résidus d'une même colonne négativement corrélés, donc leurs signes plus alternés que sous l'échangeabilité supposée.

6. Usage et limites. Test non paramétrique robuste, sensible aussi bien au regroupement qu'à l'alternance excessive des signes. Sa lecture souffre, comme celle de Durbin–Watson, du caractère conventionnel de l'ordre de parcours.

Diagnostics M4 — points aberrants du triangle

Énoncé. hors énoncé réglementaire : conditionne la lecture de M1 à M3.

Les fiches ci-dessous suivent la structure en six rubriques employée pour les hypothèses H1 à H4 de la méthode lognormale. Les notations sont celles de la section 2.

16.1 M4 — Cellule aberrante du triangle (Grubbs)

Référence. F. E. Grubbs (1950, 1969), *op. cit.*

1. Cadre, notations et hypothèses de validité (non testées). Résidus de Mack, considérés comme un échantillon unique. Hypothèse non testée et déterminante : normalité des résidus sous H_0 , laquelle n'est pas une hypothèse du modèle de Mack (voir M5).

2. Hypothèse nulle. H_0 : aucun résidu aberrant — toutes les cellules proviennent du même modèle. L'alternative est la présence d'exactly une cellule aberrante.

3. Statistique de test. $G = \max_{i,j} |r(i,j) - \bar{r}| / s_r$.

4. Loi sous H_0 . Borne de Bonferroni fondée sur la loi de Student, conservatrice ; elle suppose la normalité et l'indépendance, toutes deux approximatives ici. Loi de référence : bootstrap de résidus.

5. p-value. p-value de Monte-Carlo retenue ; la borne de Bonferroni est fournie comme majorant non simulé. **Ce majorant est extrêmement conservateur** sur des résidus de Mack : aucun rejet en 600 simulations sous H_0 au seuil de 10 % (section 19.2). Il ne doit donc jamais servir de critère de décision.

6. Usage et limites. Le moteur indique les coordonnées (i, j) de la cellule la plus extrême, ce qui rend le résultat directement actionnable : il s'agit typiquement d'un sinistre exceptionnel ou d'une erreur de saisie sur une année de développement donnée. **Aucune exclusion de cellule ne doit être opérée sur ce seul fondement** : la justification doit être métier.

16.2 M4 — Cellules aberrantes multiples (ESD généralisé de Rosner)

Référence. B. Rosner (1983), *op. cit.*

1. Cadre, notations et hypothèses de validité (non testées). Généralisation itérative de Grubbs, appliquée aux résidus de Mack, avec $k = \lfloor n/4 \rfloor$ candidats au plus. Hypothèse non testée : normalité.

2. Hypothèse nulle. H_0 : aucune cellule aberrante. On teste séquentiellement les alternatives « il y a exactement i cellules aberrantes », $i = 1, \dots, k$.

3. Statistique de test. $R_i = \max |r - \bar{r}_{S_i}| / s_{S_i}$ sur l'échantillon privé des $i - 1$ cellules déjà écartées.

4. Loi sous H_0 . Valeurs critiques λ_i tabulées, fondées sur la loi de Student.

5. p-value. **Aucune** : il s'agit d'une procédure de décision à niveau α fixé, non d'un test produisant une p-value.

6. Usage et limites. Résout le problème de masquage de Grubbs lorsque plusieurs cellules sont atypiques. La littérature recommande $n \geq 25$ pour la fiabilité des valeurs critiques ; un triangle 8×8 fournit 28 résidus, ce qui place la procédure à la limite de son domaine. À traiter comme un signal d'attention.

Diagnostics M5 — normalité des résidus de Mack

Énoncé. hors annexe XVII : la normalité n'est pas une hypothèse du modèle, qui ne spécifie que les deux premiers moments conditionnels.

Les fiches ci-dessous suivent la structure en six rubriques employée pour les hypothèses H1 à H4 de la méthode lognormale. Les notations sont celles de la section 2.

17.1 M5 — Shapiro–Wilk sur les résidus de Mack

Référence. S. S. Shapiro, M. B. Wilk (1965), *op. cit.* ; loi nulle évaluée par simulation directe.

1. Cadre, notations et hypothèses de validité (non testées). Résidus de Mack. **La normalité n'est pas une hypothèse du modèle :** le paragraphe D(2)(h) ne spécifie que les deux premiers moments conditionnels. Ce test est donc un *diagnostic* et non la vérification d'une exigence réglementaire.

2. Hypothèse nulle. H_0 : les résidus de Mack sont issus d'une loi normale.

3. Statistique de test. W , statistique de Shapiro–Wilk.

4. Loi sous H_0 . W étant invariante par translation et changement d'échelle, sa loi sous H_0 ne dépend que de l'effectif : elle est évaluée numériquement par simulation directe de 20 000 échantillons normaux.

5. p-value. p-value exacte à l'erreur de Monte-Carlo près, en $\mathcal{O}(B_{\text{null}}^{-1/2})$.

6. Usage et limites. Point de méthode déterminant. Ce test ne peut pas passer par le bootstrap de résidus employé pour tous les autres tests de la méthode, car celui-ci tire dans la loi *empirique* des résidus observés : son hypothèse nulle serait « les résidus suivent leur propre loi empirique », ce qui rendrait le test vide de sens (la simulation confirme une fréquence de rejet nulle au lieu de 5 %). D'où le recours à une loi nulle propre, indépendante du triangle ajusté. Le résultat n'est pertinent que si l'on souhaite exploiter la MSEP pour construire un quantile, usage qui excède la méthode réglementaire.

17.2 M5 — Lilliefors sur les résidus de Mack

Référence. H. W. Lilliefors (1967), *op. cit.* ; p-value : G. E. Dallal, L. Wilkinson (1986), *op. cit.*

1. Cadre, notations et hypothèses de validité (non testées). Identique à la fiche précédente. Variante *secondaire* : masquée par défaut dans l'application, conservée dans l'export.

2. Hypothèse nulle. H_0 : les résidus de Mack sont issus d'une loi normale, de moyenne et de variance quelconques.

3. Statistique de test. $D_L = \sup_u |\hat{F}(u) - \Phi((u - \bar{r})/s_r)|$.

4. Loi sous H_0 . Loi de Lilliefors, tenant compte de l'estimation de la moyenne et de l'écart-type sur l'échantillon.

5. p-value. Approximation analytique de Dallal & Wilkinson, prolongée par les polynômes de Stephens. p-value non simulée, disponible dès $n \geq 5$.

6. Usage et limites. Complément de recoupement à Shapiro–Wilk, moins puissant. Même réserve de fond : la normalité n’est pas exigée par la méthode.

Diagnostics M6 — robustesse de l'estimation

Énoncé. hors énoncé réglementaire : mesure la concentration du résultat et la part de convention dans le calcul.

Les fiches ci-dessous suivent la structure en six rubriques employée pour les hypothèses H1 à H4 de la méthode lognormale. Les notations sont celles de la section 2.

18.1 M6 — Extrapolation de $\hat{\sigma}_{J-1}^2$ (diagnostic)

Référence. Annexe XVII, section D, paragraphe 5(d)(ii), seconde ligne.

1. Cadre, notations et hypothèses de validité (non testées). La variance de la dernière année de développement ne peut être estimée, faute d'observations. **Diagnostic, non test.**

2. Hypothèse nulle. Sans objet.

3. Statistique de test. La valeur retenue, $\hat{\sigma}_{J-1}^2 = \min(\hat{\sigma}_{J-2}^2, \hat{\sigma}_{J-3}^2, \hat{\sigma}_{J-2}^4/\hat{\sigma}_{J-3}^2)$.

4. Loi sous H_0 . Sans objet : la quantité n'est pas estimée mais *imposée* par une règle d'extrapolation.

5. p-value. Aucune.

6. Usage et limites. Ce diagnostic existe pour rendre visible dans le dossier un point que le calcul masque : une des entrées de la MSEP ne provient pas des données mais d'une convention réglementaire, reposant sur deux colonnes seulement. Comme la dernière année de développement contribue à la MSEP de toutes les années de survénance récentes — celles qui portent l'essentiel de la réserve — cette convention a un effet non négligeable sur le paramètre final. Elle doit être mentionnée explicitement.

18.2 M6 — Concentration de la réserve sur la dernière année

Référence. Diagnostic de concentration ; décomposition du paragraphe 4.

1. Cadre, notations et hypothèses de validité (non testées). Part de la réserve totale portée par la dernière année de survénance, $(\hat{C}(I, J) - C(I, 0)) / \sum_i (\hat{C}(i, J) - C(i, I - i))$. Le dénominateur est la réserve chain-ladder totale $\hat{R}$, strictement positive partout où ce diagnostic est restitué, le calcul étant refusé sinon (section 3) : la part est donc toujours définie. Elle n'est en revanche encadrée par rien (rubrique 6). **Diagnostic, non test.**

2. Hypothèse nulle. Sans objet.

3. Statistique de test. La part elle-même. Le moteur signale un dépassement de 40 %.

4. Loi sous H_0 . Sans objet.

5. p-value. Aucune.

6. Usage et limites. La dernière année de survénance n'est observée que sur une seule cellule : son ultime résulte du produit de *tous* les facteurs de développement, et son erreur de prédiction domine la MSEP. Une part élevée signifie que le paramètre propre repose principalement sur la ligne la moins informative

du triangle. Ce diagnostic joue, pour la méthode Merz–Wüthrich, le rôle que joue le jackknife pour la méthode lognormale : il mesure la concentration du résultat sur une observation unique.

Limite connue. La part n'est *ni majorée par 1 ni minorée par 0*. Le refus d'une réserve totale non positive (section 3) garantit le signe du dénominateur, pas celui du numérateur : dès qu'une année de survenance porte une réserve négative — situation licite tant que $\hat{R}$ reste strictement positive —, la part peut dépasser 1 ou devenir négative. Or le moteur la compare au seul seuil de 40 % : une part négative ne déclenche aucun signalement, alors qu'elle traduit une répartition au moins aussi atypique que celle que le seuil vise. Le signalement n'a donc de portée que si toutes les réserves par année de survenance sont positives ou nulles, condition que le moteur ne vérifie pas. Cette limite est antérieure à la règle de refus et n'est pas corrigée par elle ; elle doit être lue avec le diagnostic, et la répartition de la réserve par année de survenance examinée directement.

PARTIE IV**Validation, références et synthèse**

Vérification empirique de l'implémentation

L'implémentation a été validée par trois voies indépendantes.

Recalcul indépendant des statistiques

Chaque statistique a été confrontée à un recalcul direct ou à une identité connue : égalité $F = t_b^2$ et égalité des p-values de Fisher et de Student en régression simple ; égalité de W' (Shapiro–Francia) et du carré du coefficient de corrélation du QQ-plot ; recalcul par boucle explicite de A^2 , W^2 , D et du S de Mann–Kendall ; cohérence de D avec ks.test ; vérification de la borne $G \leq (T - 1)/\sqrt{T}$ pour Grubbs ; et vérification numérique que la p-value bilatérale minimale de Cox–Stuart vaut exactement 0,0625 pour $T = 10$, ce qui confirme l'affirmation de la section 4.

Taille effective et puissance

Sur 3 000 échantillons normaux de taille 200, la fréquence de rejet au seuil nominal de 5 % ressort à 4,9 % (D'Agostino), 4,5 % (Anscombe–Glynn), 4,1 % (Jarque–Bera) et 5,6 % (Wald–Wolfowitz) ; la borne de Bonferroni de Grubbs donne 4,6 % pour $T = 20$, conformément à son caractère conservateur. Côté puissance, D'Agostino détecte l'asymétrie d'une loi exponentielle dans 100 % des cas et Anscombe–Glynn les queues d'une loi de Student à 4 degrés de liberté dans 92,5 % des cas.

Calibration des p-values de Monte-Carlo

C'est le point le plus important, puisque ces p-values sont celles retenues pour la majorité des tests — mesuré sur le jeu de contrôle (méthode prime, $T = 8$, $B = 999$), 26 des 50 lignes de la table auditable retiennent une p-value de Monte-Carlo, contre 9 une p-value exacte, 1 une p-value quasi-exacte et 2 une p-value asymptotique, les 12 dernières étant des diagnostics ou indicateurs sans p-value retenue. Sur 400 jeux de données simulés *depuis le modèle* de l'annexe XVII, la fréquence de rejet au seuil nominal de 10 % a été mesurée pour chacune des statistiques bootstrapées.

Statistique	$T = 10$	$T = 20$
Anderson–Darling	0,092	0,113
Cramér–von Mises	0,075	0,102
Kolmogorov–Smirnov	0,092	0,115
Shapiro–Wilk	0,090	0,110
Shapiro–Francia	0,083	0,107
Jarque–Bera	0,087	0,095
Durbin–Watson	0,092	0,105
Ljung–Box (retard 1)	0,095	0,090
sup-F	0,083	0,083
OLS-CUSUM	0,075	0,087
Grubbs	0,090	0,085

Toutes les valeurs sont compatibles avec le niveau nominal de 10 % à l'intérieur de l'intervalle de confiance à 95 % ($\pm 0,029$ pour 400 réplifications). La procédure de bootstrap paramétrique est donc correctement calibrée, y compris à $T = 10$ où aucune des lois asymptotiques utilisées par les tests classiques ne l'est.

Réserve. Cette validation est conditionnelle au modèle : elle établit que, *si* les données sont engendrées par le modèle de l'annexe XVII, les p-values de Monte-Carlo ont le bon niveau. Elle ne dit rien de la puissance du dispositif contre des écarts réalistes au modèle, laquelle reste faible à ces tailles d'échantillon.

19.1 Vérification de l'implémentation Merz–Wüthrich

Le triangle de Taylor & Ashe (1983), référence classique de la littérature, sert de jeu de contrôle.

Contrôle	Résultat	Statut
Facteurs de développement $\hat{f}_j$	3,4906; 1,7473; 1,4574; ...	conformes aux valeurs publiées
Réserve chain-ladder totale	18 680 856	conforme
Erreur type <i>ultime</i> de Mack	2 447 095	conforme à la valeur publiée
MSEP à un an = transcription littérale du paragraphe D(5)	écart relatif nul (précision machine)	conforme au texte
$\sqrt{\text{MSEP}}$ à un an = ChainLadder::CDR (Merz–Wüthrich 2008)	1 778 967,66336 contre 1 778 967,66335758	écart relatif $-2,6 \times 10^{-15}$
Erreur à un an < erreur ultime	1 778 968 < 2 447 095	conforme à la théorie
Homogénéité : $\lambda \cdot C \Rightarrow CV$ invariant	vérifié à 10^{-10}	
Triangle déterministe $\Rightarrow \text{MSEP} = 0$	$2,7 \times 10^{-18}$	
Moments de Z (test calendaire) par énumération exhaustive	$n = 2, \dots, 12$	exacts

La conformité de l'erreur type ultime de Mack à sa valeur publiée valide simultanément $\hat{f}_j$, $\hat{\sigma}_j^2$ et la règle d'extrapolation de $\hat{\sigma}_{j-1}^2$, qui sont les entrées de la MSEP à un an.

Sur quoi repose la validation de la MSEP à un an. Elle repose sur deux voies distinctes : d'une part la confrontation du moteur à une transcription littérale du paragraphe D(5), réécrite depuis le texte et implémentée séparément dans la batterie de tests unitaires; d'autre part une comparaison *externe* avec ChainLadder::CDR (paquet R ChainLadder 0.2.18), implémentation publique de Merz–Wüthrich (2008), reproduite à $-2,6 \times 10^{-15}$ en écart relatif. Nous n'avons pas identifié de valeur *publiée* de la MSEP à un an sur ce triangle : la comparaison externe porte sur une implémentation de référence, non sur un nombre publié.

Ce que les versions antérieures de ce document affirmaient à tort. Jusqu'à la correction de la transcription du paragraphe D(5) (section 13), la validation de cette grandeur était présentée comme reposant sur une « double implémentation indépendante ». Elle ne l'était pas : les deux implémentations reprenaient la même transcription fautive du paragraphe D(5) — termes diagonaux $\hat{C}(i, J)^2 \Delta_i$ et facteur 2 omis — et ne pouvaient donc rien détecter. La MSEP en était sous-estimée (1 519 876 au lieu de 1 778 968 sur ce triangle), dans le sens favorable à l'entreprise. C'est ce défaut que la transcription de la section 13 et les deux voies ci-dessus corrigent.

19.2 Calibration des p-values asymptotiques (Merz–Wüthrich)

Les p-values non simulées de la méthode Merz–Wüthrich sont rapportées à titre de complément, la p-value retenue étant celle du bootstrap. Il importe néanmoins de savoir *de combien* elles s'en écartent, et pourquoi. Fréquences de rejet mesurées sur 600 triangles 10×10 simulés exactement sous H_0 , au seuil nominal de 10 % (intervalle de confiance à 95 % : $\pm 0,024$) :

Test	Rejets à 10 %	Interprétation
Ordonnée à l'origine (Fisher)	0,092	Conforme
Homogénéité de f_j (Fisher)	0,125	Léger sur-rejet, dans l'incertitude
Courbure (Fisher)	0,112	Conforme
Exposant de variance (Fisher)	0,097	Conforme
Kruskal–Wallis	0,135	Sur-rejet : groupes très déséquilibrés
Effets d'année calendaire	0,123	Sur-rejet : approximation normale d'une somme portant sur peu de diagonales
Test des suites	0,153	Sur-rejet marqué. La contrainte $\sum_i \sqrt{C(i, j)} r(i, j) = 0$ rend les résidus d'une colonne négativement corrélés, d'où une alternance des signes plus fréquente que sous l'échangeabilité supposée par l'approximation normale
Grubbs (borne de Bonferroni)	0,000	Extrêmement conservatrice. La borne est un majorant, et les résidus étant déjà standardisés par colonne, l'écart au maximum est faible
Breusch–Pagan (χ^2)	0,005	Très conservatrice. $\hat{\sigma}_j^2$ est estimé sur la colonne même ; les résidus standardisés ont une dispersion réduite, donc un R^2 auxiliaire trop faible

Conséquence pratique. Les écarts observés entre p-value asymptotique et p-value de Monte-Carlo ne traduisent pas une erreur de calcul mais la *non-validité* des lois de référence classiques sur des résidus de triangle, qui ne sont ni indépendants ni échangeables. Trois tests s'en écartent fortement et dans des sens opposés : le test des suites sur-rejette, Grubbs et Breusch–Pagan sous-rejettent massivement. Dans les trois cas, c'est la p-value de Monte-Carlo qui est retenue par le moteur, et elle seule doit être utilisée en dossier. La p-value non simulée n'est conservée que pour documenter l'écart.

19.3 Calibration des p-values de Monte-Carlo (Merz–Wüthrich)

Sur 160 triangles 10×10 simulés sous le modèle de Mack, fréquence de rejet au seuil nominal de 10 % (intervalle de confiance à 95 % : $\pm 0,046$) :

Statistique	rejets à 10 %	rejets à 5 %
Effets d'année calendaire	0,062	0,019
Corrélation entre années de développement	0,119	0,037
Breusch–Pagan sur résidus de Mack	0,100	0,062
Grubbs	0,113	0,044
Durbin–Watson	0,100	0,050
Test des suites	0,056	0,025
Proportionnalité (pente)	0,069	0,044

Toutes les valeurs sont compatibles avec les niveaux nominaux à l'intérieur de l'intervalle de confiance.

Compléments bibliographiques

Les fiches de la partie III citent les articles *fondateurs* de chaque test : ils établissent la statistique et sa loi. Les affirmations relatives à la *qualité de l'approximation* à $T = 8$ et à la *validité du bootstrap* relèvent en revanche d'une littérature distincte, rassemblée ici. Chaque entrée précise la portée exacte de la référence, c'est-à-dire l'affirmation qu'elle soutient dans le présent document.

Vitesse de convergence et bornes d'erreur

- A. C. Berry, *The accuracy of the Gaussian approximation to the sum of independent variates*, *Transactions of the American Mathematical Society*, 49(1), 1941, p. 122–136 ; C.-G. Esseen, *On the Liapounoff limit of error in the theory of probability*, *Arkiv för Matematik, Astronomi och Fysik*, 28A(9), 1942, p. 1–19. *Portée*. Les fiches citaient jusqu'ici uniquement les auteurs des tests. Le théorème de Berry–Esseen est la référence qui permet d'énoncer une vitesse $\mathcal{O}(T^{-1/2})$ pour les approximations normales, et donc de montrer qu'à $T = 8$ la borne est de l'ordre de 0,35, c'est-à-dire sans valeur pratique. Aucune référence antérieure du document ne supportait cette affirmation.
- H. Callaert, P. Janssen, *The Berry-Esseen theorem for U-statistics*, *The Annals of Statistics*, 6(2), 1978, p. 417–421. *Portée*. Le S de Mann–Kendall est une U -statistique et non une somme de variables indépendantes : le Berry–Esseen classique ne s'applique pas directement. Cette référence est celle qui couvre exactement le cas rencontré. La référence existante (Mann, 1945) établit la statistique, pas sa vitesse de convergence.

Lois exactes employées à la place des approximations normales

- M. G. Kendall, J. D. Gibbons, *Rank Correlation Methods*, 5^e éd., Edward Arnold / Oxford University Press, 1990. *Portée*. Le document citait Kendall (1975, 4^e éd.). L'édition de 1990 est celle qui est aujourd'hui la référence courante pour la distribution exacte de S et ses tables. Les deux éditions sont conservées : la 4^e pour l'antériorité de la méthode, la 5^e pour le résultat exact effectivement implémenté.
- F. Swed, C. Eisenhart, *Tables for testing randomness of grouping in a sequence of alternatives*, *The Annals of Mathematical Statistics*, 14(1), 1943, p. 66–87. *Portée*. Wald & Wolfowitz (1940), déjà cité, établit le test ; Swed & Eisenhart fournit la distribution combinatoire exacte du nombre de suites, qui est celle implémentée dans le moteur, l'approximation normale n'étant conservée qu'à titre indicatif.
- D. J. Best, D. E. Roberts, *Algorithm AS 89 : The upper tail probabilities of Spearman's ρ* , *Journal of the Royal Statistical Society, Series C (Applied Statistics)*, 24(3), 1975, p. 377–379. *Portée*. La référence Spearman (1904) établit le coefficient. Best & Roberts documente le calcul des probabilités exactes en petit échantillon, qui est ce que `cor.test(..., exact = TRUE)` met en œuvre et que le moteur retient à $T = 8$.

Théorie du bootstrap et des tests de Monte-Carlo

- M. Dwass, *Modified randomization tests for nonparametric hypotheses*, *The Annals of Mathematical Statistics*, 28(1), 1957, p. 181–187 ; A. C. A. Hope, *A simplified Monte Carlo significance test procedure*, *Journal of the Royal Statistical Society, Series B*, 30(3), 1968, p. 582–598. *Portée.* Ce sont les références qui établissent que le test de Monte-Carlo fondé sur $\hat{p} = (1 + \#\{S^{(b)} \geq S_{\text{obs}}\})/(B + 1)$ est de niveau *exact* pour B fini lorsque $\alpha(B + 1)$ est entier. Le document invoquait cette propriété en citant Efron (1979), qui ne la démontre pas. C’est une correction de référence, non un simple ajout.
- P. H. Jöckel, *Finite sample properties and asymptotic efficiency of Monte Carlo tests*, *The Annals of Statistics*, 14(1), 1986, p. 336–347 ; R. A. Marriott, *Barnard’s Monte Carlo tests : how many simulations ?*, *Journal of the Royal Statistical Society, Series C*, 28(1), 1979, p. 75–77. *Portée.* Ces travaux quantifient la perte de puissance induite par un B fini, et fondent le choix d’un B de l’ordre du millier. Ils justifient la ligne (B) du tableau 5.5.
- P. J. Bickel, D. A. Freedman, *Some asymptotic theory for the bootstrap*, *The Annals of Statistics*, 9(6), 1981, p. 1196–1217 ; K. Singh, *On the asymptotic accuracy of Efron’s bootstrap*, *The Annals of Statistics*, 9(6), 1981, p. 1187–1195. *Portée.* Efron (1979), seule référence bootstrap du document, introduit la méthode mais n’en établit pas la consistance. Ces deux articles sont ceux qui démontrent la validité asymptotique, et donc ce qui fonde — et ce qui limite — l’emploi du bootstrap ici : la garantie est *asymptotique en T* , ce qui est précisément le point à signaler à $T = 8$.
- P. Hall, *The Bootstrap and Edgeworth Expansion*, Springer, 1992 ; A. C. Davison, D. V. Hinkley, *Bootstrap Methods and their Application*, Cambridge University Press, 1997. *Portée.* Hall (1992) est l’ouvrage de référence sur les raffinements d’ordre supérieur obtenus pour les statistiques pivotales, qui explique pourquoi le bootstrap améliore l’approximation sans la rendre exacte. Davison & Hinkley (1997) traite spécifiquement du bootstrap paramétrique et des tests de Monte-Carlo tels qu’employés ici.

Comportement en petit échantillon des tests employés

- N. Davies, C. M. Triggs, P. Newbold, *Significance levels of the Box-Pierce portmanteau statistic in finite samples*, *Biometrika*, 64(3), 1977, p. 517–522. *Portée.* Le document affirmait que l’approximation χ^2 des tests portmanteau est mal calibrée en petit échantillon en citant Ljung & Box (1978). Davies, Triggs & Newbold est l’étude dédiée à cette question et constitue la référence appropriée. Ljung & Box reste cité pour la statistique elle-même.
- K. O. Bowman, L. R. Shenton, *Omnibus test contours for departures from normality based on $\sqrt{b_1}$ and b_2* , *Biometrika*, 62(2), 1975, p. 243–250 ; C. M. Jarque, A. K. Bera, *A test for normality of observations and regression residuals*, *International Statistical Review*, 55(2), 1987, p. 163–172. *Portée.* Bowman & Shenton documente la lenteur de convergence des statistiques fondées sur $\sqrt{b_1}$ et b_2 vers leur loi limite, ce qui est le fondement de la mise en garde du tableau 5.4 sur Jarque–Bera. L’article de 1987 est la version complète du test, la note de 1980 dans *Economics Letters* en étant la forme abrégée : les deux sont conservées.
- S. S. Shapiro, M. B. Wilk, H. J. Chen, *A comparative study of various tests for normality*, *Journal of the American Statistical Association*, 63(324), 1968, p. 1343–1372. *Portée.* Étude de puissance de référence pour les tests de normalité, qui documente leur faiblesse en très petit échantillon. Elle soutient l’affirmation, présente dans les fiches, selon laquelle une p-value élevée n’apporte quasiment aucune information à T faible.

- G. S. Maddala, *Introduction to Econometrics*, 3^e éd., Wiley, 2001, pour la discussion du caractère non exact du test RESET. *Portée*. Ramsey (1969), seule référence citée jusqu'ici, développe le test à partir de résidus BLUS. Dans la forme usuellement implémentée — et retenue ici — les régresseurs auxiliaires sont des puissances des valeurs ajustées, qui dépendent de y : la statistique n'est alors plus exactement de loi de Fisher. Cette nuance, absente de la version précédente de la documentation, motive le recours au bootstrap.
- J. P. Imhof, *Computing the distribution of quadratic forms in normal variables*, *Biometrika*, 48(3/4), 1961, p. 419–426. *Portée*. Référence exacte de la méthode évoquée dans la fiche Durbin–Watson pour le calcul de la loi exacte de la statistique, dont le document mentionnait le nom sans la référencer.

20.1 Traçabilité entre la documentation et le code

L'architecture complète du moteur est décrite en section 1. Le tableau ci-dessous relie chaque développement du présent document à son implémentation.

Chaque affirmation quantitative de ce document correspond à une fonction identifiable du moteur R/engine.R, seul fichier contenant de la logique statistique ou actuarielle.

Élément documenté	Implémentation dans R/engine.R
Noyau du modèle ($\pi_t, \hat{\beta}, z_t$)	usp_pi(), usp_noyau()
Optimisation sous contrainte $\delta \in [0, 1]$	usp_objectif(), usp_ajuster()
Lois exactes (Kendall, suites)	mk_p_exacte(), runs_p_exacte()
Statistiques de test	stat_*, test_*
Bootstrap paramétrique et p-values MC	.stats_bootstrapables(), usp_bootstrap()
Hierarchie exacte $\succ$ MC $\succ$ asymptotique	fonction add() interne à usp_tests()
Sortie de la hiérarchie (grandeur rivée par l'estimation)	branche finale de add() : p_retenue et nature_p à NA, verdict INFO
Réserve sur la base « ratios bruts » à $\hat{\pi}_t$ constant	champ detail des six lignes de base r dans usp_tests()
Erreur de Monte-Carlo	champ err_mc de usp_bootstrap()
Jackknife, profils, rapport de vraisemblance	usp_jackknife(), usp_profil()
Calibration et paramètre final	usp_parametre(), usp_credibilite()
Contrôles de validité	engine_valider_donnees(), usp_controle_donnees(), mw_valider_triangle(), mw_valider_ajustement()
Quantités des graphiques	engine_plots_data()
Orchestration complète	run_engine()
Table auditable des tests	engine_table_tests()

L'application Shiny (app.R, R/display_helpers.R) ne contient aucun de ces calculs : elle collecte les entrées, appelle run_engine() et affiche l'objet retourné. Le moteur s'exécute indépendamment de toute interface, ce qui permet une revue et une reproduction externes : source("R/engine.R") puis run_engine(xt = ..., yt = ...).

Méthode Merz–Wüthrich

Les références ci-dessous fondent la section 13 et les fiches M1 à M6. Elles n'ont pas d'équivalent dans le corpus lognormal, la méthode reposant sur un modèle et un mode d'inférence différents.

- T. Mack, *Distribution-free calculation of the standard error of chain ladder reserve estimates*, *ASTIN Bulletin*, 23(2), 1993, p. 213–225. *Portée*. Article fondateur du modèle de chaîne d'échelle

stochastique : il établit les estimateurs $\hat{f}_j$ et $\hat{\sigma}_j^2$, l'erreur type *ultime*, et surtout l'énoncé des trois hypothèses reprises au paragraphe D(2)(h) du règlement. C'est la valeur publiée de l'erreur ultime sur le triangle de Taylor & Ashe qui a servi à valider notre implémentation de $\hat{f}_j$, $\hat{\sigma}_j^2$ et de la règle d'extrapolation.

- T. Mack, *Which stochastic model is underlying the chain ladder method ?*, *Insurance : Mathematics and Economics*, 15(2–3), 1994, p. 133–138. *Portée*. Source du test des effets d'année calendaire et de la discussion des hypothèses testables. C'est de cet article que proviennent les moments de $Z_k = \min(L_k, S_k)$, que nous avons vérifiés par énumération exhaustive.
- M. Merz, M. V. Wüthrich, *Modelling the claims development result for solvency purposes*, *Casualty Actuarial Society E-Forum*, automne 2008, p. 542–568. *Portée*. Article dont dérive la formule d'erreur de prédiction à un an du paragraphe D(5). La distinction entre erreur à un an et erreur ultime est le fondement même de la méthode n° 2, et l'ordre $\sqrt{\text{MSEP}_{1 \text{ an}}} < \sqrt{\text{MSEP}_{\text{ultime}}}$ que nous avons vérifié numériquement en découle. C'est également l'implémentation publique de cet article (ChainLadder::CDR) qui fournit la valeur de comparaison externe de notre MSEP à un an (section 19).
- M. V. Wüthrich, M. Merz, *Stochastic Claims Reserving Methods in Insurance*, Wiley, 2008. *Portée*. Ouvrage de référence rassemblant le cadre théorique complet (modèle de Mack, résultat de développement des sinistres, erreurs de prédiction). Il est cité pour le cadre général, l'article de 2008 l'étant pour la formule précise.
- P. D. England, R. J. Verrall, *Stochastic claims reserving in general insurance*, *British Actuarial Journal*, 8(3), 2002, p. 443–518. *Portée*. Référence du bootstrap par rééchantillonnage des résidus, seul possible ici puisque le modèle de Mack ne spécifie aucune loi. Elle fonde la nature *semi-paramétrique* des p-values de Monte-Carlo de cette méthode, et donc la réserve exposée en section 4.2.
- G. C. Taylor, F. R. Ashe, *Second moments of estimates of outstanding claims*, *Journal of Econometrics*, 23(1), 1983, p. 37–61. *Portée*. Source du triangle de dix années de survenance utilisé comme jeu de contrôle. Son statut de référence partagée par la littérature est ce qui rend la validation reproductible par un tiers.
- G. Barnett, B. Zehnwrith, *Best estimates for reserves*, *Proceedings of the Casualty Actuarial Society*, 87, 2000, p. 245–321. *Portée*. Discussion des exposants alternatifs de la structure de variance ($\alpha = 0, 1$ ou 2). Citée dans la fiche M2 pour situer l'exposant 1 imposé par le règlement parmi les choix possibles, et non pour recommander une alternative — l'annexe XVII ne laissant pas ce choix ouvert.

Points sur lesquels la littérature ne permet pas de conclure

Conformément à l'exigence de ne pas produire de conclusion artificiellement précise, les points suivants sont signalés comme *non tranchés* par la littérature consultée.

1. **Aucune borne d'erreur exploitable à $T = 8$** n'a pu être identifiée pour les statistiques de type multiplicateur de Lagrange (Breusch–Pagan, White) ni pour les statistiques portmanteau. Les résultats disponibles sont soit purement asymptotiques, soit des études de simulation portant sur des tailles supérieures. L'affirmation « la loi χ^2 est inadéquate à $T = 8$ » est donc fondée sur l'absence de justification, non sur une borne quantifiée.
2. **La vitesse de convergence du bootstrap paramétrique dans ce modèle** n'est pas établie. Les résultats de Bickel & Freedman (1981), Singh (1981) et Hall (1992) portent sur des cadres où l'es-

timeur est asymptotiquement normal et le paramètre intérieur au domaine. Ici, $\hat{\delta}$ est fréquemment sur la frontière $\{0, 1\}$, situation qui sort de ce cadre. Aucun taux ne peut donc être annoncé.

3. **La loi exacte de la statistique agrégée Z** du test des effets d'année calendaire n'est pas établie. Les moments de chaque Z_k sont exacts, mais la normalité de leur somme sur un nombre réduit de diagonales n'est justifiée par aucun résultat que nous ayons identifié ; d'où le recours au bootstrap.
4. **Aucune valeur publiée de la MSEP à un an** n'a pu être identifiée pour le triangle de Taylor & Ashe. La validation de cette grandeur repose donc sur la transcription littérale du paragraphe D(5), sur des propriétés structurelles et sur la comparaison avec une implémentation externe (ChainLadder : : CDR), non sur un nombre publié dans la littérature.
5. **Le domaine de validité exact de la transformation de Royston** pour $4 \leq T \leq 11$ est documenté par son auteur, mais nous n'avons pas identifié d'étude indépendante en évaluant la précision spécifiquement à $T = 8$.

Articulation des deux corpus. Les références des fiches établissent *ce que calcule* chaque test ; celles de la présente section établissent *ce que vaut* le résultat à la profondeur d'intérêt. Les secondes portent sur les vitesses de convergence, les lois exactes effectivement implémentées et les fondements théoriques du bootstrap et des tests de Monte-Carlo.

Synthèse et lecture des verdicts

Verdict	Signification
OK	p-value <i>retenue</i> — celle que désigne <code>nature_p</code> , choisie dans l'ordre exacte $\succ$ Monte-Carlo $\succ$ asymptotique — au-dessus du seuil d'alerte, ou diagnostic sans anomalie. Pour les tests de Student sur la pente et de Fisher, la logique est inversée : OK correspond à un <i>p faible</i> .
ALERTE	p-value retenue dans la zone intermédiaire $[\alpha/2; \alpha]$ (par défaut [5 % ; 10 %]), ou diagnostic structurel à documenter : solution au bord sur δ , point influent isolé, jackknife entre 10 % et 20 %, intervalle bootstrap large.
ECHEC	p-value retenue sous le seuil strict, ou anomalie structurelle marquée. N'invalide pas mécaniquement l'USP, mais impose une justification explicite : nature de l'écart, retraitement envisagé, sensibilité du paramètre final.
INFO	Diagnostic sans seuil statistique associé : test non applicable faute d'effectif ($T < 8$ pour D'Agostino, $T < 20$ pour Anscombe–Glynn), grandeur rivée par l'estimation (fiches 9.5 et 9.6), indicateur descriptif, ou lecture graphique.

Hiérarchie de lecture recommandée

1. **Contrôles de données** (section 3) – bloquants. Aucun résultat n'a de sens si un contrôle est en échec.
2. **Convergence numérique** – préalable technique : part des démarrages convergents (fiche 11.4) et écart de $\sum_t z_t^2$ à T (fiche 9.6). La nullité de la moyenne *pondérée* des résidus n'en fait pas partie : c'est une identité algébrique, vraie même sans convergence (fiche 9.4). La moyenne simple $\bar{z}$ est, elle, un diagnostic (fiche 9.5).
3. **Jackknife et intervalle bootstrap** (section 11) – la mesure la plus directe de la solidité du calibrage à T faible.
4. **Position de $\hat{\delta}$ et test du rapport de vraisemblance** (fiches 7.7 et 11.1) – identifiabilité de la structure de variance.
5. **Ruptures et points influents** (section 10) – susceptibles d'expliquer tout rejet observé par ailleurs.
6. **Tests des hypothèses H1 à H4** (sections 6 à 9), en lisant pour chacun la p-value *retenue* par le moteur, celle que désigne le champ `nature_p`. La hiérarchie appliquée est *exacte* $\succ$ *Monte-Carlo* $\succ$ *asymptotique* (section 5) : la p-value de Monte-Carlo n'est pas la première servie, elle vient *après* la p-value exacte lorsque celle-ci existe. Mesuré sur le jeu de contrôle (méthode prime, $T = 8$, $B = 999$) : des 50 lignes de la table auditable, 9 retiennent une p-value exacte, et 8 d'entre elles disposent pourtant d'une `p_mc` qui n'est pas retenue : lire systématiquement `p_mc` reviendrait à écarter huit p-values exactes au profit d'estimations entachées d'une erreur de Monte-Carlo (section 5.2). Les trois colonnes restent affichées : leur comparaison est un contrôle utile, mais elle ne modifie pas le verdict.

Tests structurellement inopérants à faible T

Test	Seuil de validité	Nature du problème
Cox–Stuart	$T \geq 12$	Rejet à 5 % <i>impossible</i> pour $m \leq 5$ paires.
Anscombe–Glynn	$T \geq 20$	Non défini en-deçà ; marqué INFO.
D’Agostino (asymétrie)	$T \geq 8$	Non défini en-deçà ; puissance faible jusqu’à $T \approx 20$.
Jarque–Bera	$T \geq 50$	b_2 borné par $\approx T$; convergence χ^2 très lente.
Ljung–Box / Box–Pierce	$T \geq 30$	Approximation χ^2 mal calibrée.
Wald–Wolfowitz	$n_1, n_2 \geq 10$	Approximation normale ; granularité de R .
Breusch–Pagan / White	$T \geq 30$	Convergence asymptotique lente.
Rosner ESD	$T \geq 25$	Valeurs critiques peu fiables en-deçà.
Durbin–Watson	—	Bornes invalides sur résidus de maximum de vraisemblance.
sup-F de Quandt	—	Loi de Fisher inapplicable (point de rupture estimé).

Rappel final. Le décompte des tests en échec ne se substitue pas à l’analyse qualitative exigée par le règlement d’exécution (UE) 2015/498 : la note de justification du dossier de candidature doit expliquer, segment par segment, en quoi la méthode retenue est adaptée au profil de risque de l’organisme, y compris pour les segments non retenus. Aucun test isolé, ni aucun comptage de tests, ne peut établir cette démonstration.

ANNEXE

Flux détaillés entre fonctions

Annexe — flux détaillés entre fonctions

La figure 1 donne la vue d'ensemble de la chaîne de calcul. La présente annexe descend au niveau de la fonction individuelle. Elle poursuit un objectif précis : rendre visible, pour chaque test, *combien* de fonctions concourent à son résultat et *lesquelles* sont partagées avec d'autres tests. Cette information conditionne la portée d'une revue de code : une anomalie dans une fonction mutualisée se propage à plusieurs tests, alors qu'une anomalie dans une fonction dédiée reste circonscrite.

22.1 Convention graphique

Forme ou couleur	Signification
Bloc bleu clair	Entrée ou donnée intermédiaire
Bloc blanc, contour bleu	Fonction dédiée à un seul test
Bloc orangé, contour épais	Fonction mutualisée entre plusieurs tests ou entre les deux méthodes
Bloc gris	Fonction interne de support, préfixée d'un point, jamais appelée directement par <code>usp_tests()</code> ou <code>mw_tests()</code>
Bloc vert	Sortie : p-value ou grandeur restituée
Flèche pleine	Transmission d'un objet, dont le nom figure sur la flèche
Flèche pointillée	Dépendance de second rang (mise en cache, loi de référence)

Les fonctions mutualisées appellent une vigilance particulière. Le tableau suivant les recense.

Fonction	Portée	Tests concernés
<code>usp_credibilite()</code>	LN + MW	Calibration des deux méthodes : seule fonction de calcul commune aux deux branches
<code>test_grubbs()</code>	LN + MW	Grubbs sur z_t , sur ratios bruts, et sur résidus de Mack
<code>test_rosner()</code>	LN + MW	ESD généralisé, dans les deux méthodes
<code>test_runs()</code>	LN + MW	Test des suites, dans les deux méthodes
<code>stat_dw()</code>	LN + MW	Durbin–Watson, dans les deux méthodes
<code>.shapiro_sur()</code>	LN + MW	Shapiro–Wilk (Royston et loi nulle simulée), dans les deux méthodes
<code>stat_lilliefors()</code> , <code>lillie_p()</code>	LN + MW	Lilliefors, dans les deux méthodes
<code>test_lm_complet()</code>	LN	Student sur la constante, Student sur la pente, Fisher global, R^2 : quatre entrées issues d'un seul appel
<code>usp_noyau()</code> , <code>usp_pi()</code>	LN	Tout le noyau lognormal : résidus z_t , donc l'intégralité de H2, H3, H4
<code>.stats_bootstrapables()</code>	LN	Les 34 statistiques bootstrapées de la méthode lognormale, en un seul appel
<code>mw_ajuster()</code>	MW	$\hat{f}_j$, $\hat{\sigma}_j^2$, $\hat{C}(i, j)$: entrée de la MSEP, des résidus, de tous les tests M1 à M6
<code>mw_residus()</code>	MW	Support de M1, M2, M3, M4 et M5
<code>.mw_stats()</code>	MW	Les 7 statistiques bootstrapées de la méthode

22.2 Graphe chapeau : les deux branches et leurs points de partage




FIGURE 2 : Vue chapeau. Les deux branches sont disjointes jusqu’aux fonctions de statistique, dont sept sont mutualisées (en orangé), puis se rejoignent sur `usp_credibilite()`. Une anomalie dans un bloc orangé affecterait *les deux* méthodes.

22.3 Méthode lognormale : hypothèse H1




FIGURE 3 : Hypothèse H1. `test_lm_complet()` alimente **quatre** entrées de la table des tests à partir d'un unique ajustement : une anomalie s'y propagerait aux quatre. Mann-Kendall illustre la configuration inverse : un seul test, mais quatre fonctions dont deux internes.

22.4 Méthode lognormale : hypothèse H2




FIGURE 4 : Hypothèse H2. Chacun des six tests dispose de sa propre fonction : la portée d'une anomalie y est circonscrite à un test, contrairement à H1.

22.5 Méthode lognormale : hypothèses H3 et H4, stabilité




FIGURE 5 : Hypothèses H3 et H4 et diagnostics de stabilité. Tous les tests partent du même objet, les résidus z_t : une erreur dans `usp_noyau()` affecterait l'intégralité de ce graphe. Trois fonctions internes (en gris) fournissent des lois de référence : `sw_loi_nulle()`, `.imhof_p_sup0()` et `.runs_dens()`. `.shapiro_sur()` alimente deux entrées distinctes de la table des tests.

22.6 Méthode Merz–Wüthrich : de l’ajustement aux tests M1 à M6




FIGURE 6 : Méthode Merz–Wüthrich. `mw_ajuster()` et `mw_residus()` sont les deux points de passage obligés : la première alimente à la fois la MSEP et les résidus, la seconde l’intégralité des tests M1 à M5. Quatre blocs de tests reposent sur des fonctions déjà employées par la méthode lognormale (en orange), ce qui mutualise la revue de code mais étend la portée d’une anomalie éventuelle.

22.7 Lecture en termes de revue de code

Configuration	Exemples	Conséquence pour la revue
Un test, une fonction dédiée	White, Goldfeld– Quandt, Brown– Forsythe, Jarque– Bera, corrélation entre colonnes	Revue circonscrite : une anomalie n’affecte que ce test.
Un test, plusieurs fonctions	Mann–Kendall (test_mann_kendall + mk_p_exacte() + deux internes), Durbin–Watson (stat_dw() + dw_p_exacte() + .imhof_p_sup0())	La statistique et la loi de référence sont séparées : il faut vérifier les deux, et leur cohérence d’appariement.
Une fonction, plusieurs tests	test_lm_complet() (4 entrées), .shapiro_sur() (2 entrées)	Une anomalie se propage à toutes les entrées issues de l’appel.
Fonction commune aux deux méthodes	test_grubbs(), test_rosner(), test_runs(), stat_dw(), .shapiro_sur(), stat_lilliefors(), usp_credibilite()	Portée maximale : une anomalie affecterait les deux dispositifs, donc les deux dossiers. Priorité de revue.

Cette hiérarchie explique l’ordre de vérification retenu lors du développement : les fonctions communes et les noyaux (usp_noyau(), mw_ajuster()) ont fait l’objet de contrôles indépendants — recalcul manuel, identités analytiques, comparaison à des valeurs publiées — avant les fonctions dédiées, dont la portée d’erreur est limitée à un seul test.